



**FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO
PAULISTA: ENGENHARIA DE DADOS**

Stream Processing Pipelines

SÃO PAULO

2025



Bruno Gomes Nogueira – 364457

Evaldo Loiola Mota Junior – 364056

Gabriel Pinheiro Ximenes - 365776

Herivelto Raimundo Lemos de Macedo Junior – 364212

João Paulo Martins Rodrigues – 364668



Cenário de Negócio

Empresa: *ShopTrend*, varejista digital (e-commerce de moda).

Problema de Negócio

A ShopTrend precisa monitorar em **tempo real** o comportamento do usuário no site, mas atualmente tudo é processado em batch no dia seguinte. Isso causa:

- Demora para identificar queda de conversão
- Falta de insight sobre abandono de carrinho
- Nenhuma reação rápida a campanhas com pico de tráfego
- Perda de oportunidades de remarketing imediato

Objetivo

Criar uma arquitetura de streaming que permita:

- Capturar eventos do site (pageview, add_to_cart, checkout, order_confirmed)
- Processá-los em tempo real 30s – 5m
- Armazenar em camadas estruturadas Bronze, Silver e Gold
- Executar análises imediatas

Requisitos de Latência

- **Latência ponta a ponta:** entre 30 segundos e 5 minutos
Suficiente para remarketing imediato e detecção proativa de falhas.


Volume Estimado

- 50–200 eventos por segundo (picos)
- 4–6 milhões de eventos/dia
- Cada evento ~0,5–3 kB

Decisões de Negócio com Base nos Dados

- Permitir alertas time de TI em caso de erro no checkout
- Ajustar campanhas de marketing em tempo real
- Reforçar estoque de itens com aumento súbito de demanda
- Enviar push/email para carrinhos abandonados em até 10 segundos
- Ajustar recomendações durante navegação do usuário
- Ajustar preços (pricing dinâmico) baseado na demanda recente.

Diagrama de Arquitetura



Justificativa das Escolhas Tecnológicas

Ingestão → Kinesis Data Streams + Kinesis Firehose

Por que usar Kinesis Data Streams?

- Baixíssima latência
- Capaz de lidar com picos instantâneos
- Permite múltiplos consumidores (Databricks, Lambda, Firehose etc.)
- Escalabilidade horizontal via shards

Por que incluir também o Firehose?

Usado como **rota opcional** para gravar dados no S3 com:

- Buffer automático (intervalo configurável de 1–300 s)
- Compressão automática
- Transformações leves via Lambda
- Garantia de entrega
- Custos baixos

Armazenamento → Amazon S3 + Delta Lake

Por que S3?

- Barato
- Altamente durável
- Integrado com Databricks, Glue, Athena, Firehose
- Ideal para Data Lake arquiteturas Bronze/Silver/Gold

Por que Delta Lake?

- ACID transactions
- Time Travel
- Merge, schema evolution
- Alta performance para consultas
- Suporte nativo no Databricks Structured Streaming

Camadas:

- **Bronze:** eventos crus em Delta
- **Silver:** tabelas normalizadas por tipo de evento
- **Gold:** métricas agregadas (funil, orders, vendas)



Por que Terraform ?

- Rastreamento via Git
- Revisão por PR
- Versionamento
- Auditoria completa do que foi criado/modificado

Processamento → Databricks Structured Streaming (Apache Spark Streaming)

- Motor unificado para batch e streaming
- Checkpoints e exactly-once delivery
- Permite lógica complexa (joins, windows, deduplicação)
- Integração nativa com Apache Spark

Orquestração → Databricks Workflows

- Scripts em Python, jobs e DLT
- Alertas e monitoração automática
- Evita uso de Airflow, Step Functions ou Glue Jobs

Analytic Engine

- **Power BI** - Para relatórios gerenciais em tempo real via DirectQuery



Estimativa de Custos (simplificada — mensal)

Valores aproximados usando AWS + Databricks.

Kinesis Data Streams

- 2 shards (capaz de até 2 MB/s ingressos + 2 MB/s egressos)
- US\$ 35–60/mês

Kinesis Firehose

- Preço por GB ingerido
- Considerando ~200 GB/mês
- US\$ 15–25/mês

S3 Storage

- 500 GB (Bronze + Silver + Gold)
- US\$ 10–15/mês


Databricks (streaming cluster)

- 1 cluster com 1 driver m5.xlarge + 2 workers m5.xlarge
- (aprox. 50 DBUs/dia × US\$ 0,27/DBU)
- **US\$ 350–550/mês**

Evidências de Funcionamento

Producer

Script:



Repositório: [link](#)



AWS

AWS Kineses Stream:

The screenshot shows the Amazon Kinesis console interface. The left sidebar contains navigation links for 'Amazon Kinesis', 'Fluxos de dados', and 'Recursos'. The main area displays the 'shoptrend-events-stream' stream. The 'Visualizador de dados' tab is selected, showing a table of records. The table has four columns: 'Chave de parti...', 'Dados', 'Carimbo de data/hora aproxim.', and 'Número de sequência'. The records show event data for 'pageview', 'order_confirmed', and 'add_to_cart'.

Amazon Data Firehose:

The screenshot shows the Amazon Data Firehose console interface. The left sidebar contains navigation links for 'Amazon Data Firehose' and 'Recursos'. The main area displays the 'shoptrend-events-stream-firehose' delivery stream. The 'Monitoramento' tab is selected, showing the 'Detalhes do fluxo do Firehose' section. The status is 'Ativo', and the destination is 'Amazon S3'. The 'Teste com dados de demonstração' section is also visible.


AWS S3:

The screenshot shows the Amazon S3 console interface. The left sidebar contains navigation links for 'Amazon S3' and 'Recursos'. The main area displays the 'shoptrend-events-stream-firehose' bucket. The 'Objetos' tab is selected, showing a list of objects. The objects are listed with columns: 'Nome', 'Tipo', 'Última modificação', 'Tamanho', and 'Classe de armazenamento'. The objects are 'raw/' and 'raw/'.




DataBricks

Estrutura de pastas:



Estrutura de armazenamento:





Script:

Exemplo camada Silver

```
# =====
# CONFIGURAÇÃO DE PATHS E TABELAS
# =====
BRONZE_TABLE = "streaming_catalog.bronze.events"
CHECKPOINT_BASE = "dbfs:/Volumes/streaming_catalog/silver/_checkpoints"
SILVER_BASE_PATH = "dbfs:/Volumes/streaming_catalog/silver/events"

# Lista de tipos de evento (event_type)
event_types = ["add_to_cart", "pageview", "order_confirmed", "checkout"]

# =====
# LEITURA DO STREAMING DA TABELA BRONZE
# =====
df_bronze = spark.readStream.format("delta").table(BRONZE_TABLE)

# =====
# LOOP PARA CRIAR TABELAS SILVER POR EVENT TYPE
# =====
for event in event_types:
    silver_table_name = f"streaming_catalog.silver.{event}"
    silver_path = f"{SILVER_BASE_PATH}/{event}"
    checkpoint_path = f"{CHECKPOINT_BASE}/{event}"


    # Filtra apenas o evento desejado
    df_event = df_bronze.filter(df_bronze.event_type == event)

    # Grava o streaming na tabela Silver específica
    stream = (
        df_event.writeStream
            .format("delta")
            .outputMode("append")
            .option("mergeSchema", "true")
            .option("checkpointLocation", checkpoint_path)
            .trigger(availableNow=True)
            .toTable(silver_table_name)
    )

    print(f"[INFO] Streaming iniciado para {event} -> Tabela: {silver_table_name}")
```

[illegible]

PowerBI:





Evidências

Producer:

```
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS
(View) ps -u users | more | wc -l
~/Stream Processing Pipelines - src/producer.py | Projetos/Stream Processing Pipelines - stream_processing_pipelines->
ducer.py:480d3c2-8c91-4e48-a89e-9a591e9d04ffenviando eventos para o Kinesis Stream: shoptrend-events-stream
Enviado: {'event_type': 'checkout', 'event_id': '529ab4dc-4868-4b24-8c52-1885aa39fa8e', 'user_id': 'f8e16905-60e7-4e72-866c-988cd9463713', 'session_id': '38f1a132-544a-41e2-b21f-fa37d9789781', 'cart_items': [{'product_id': 'p654', 'product_name': 'Mochila Escolar', 'price': 89.9, 'quantity': 2}, {'product_id': 'p123', 'product_name': 'Camiseta Básica', 'price': 49.9, 'quantity': 2}], 'cart_value': 359.4, 'timestamp': '2025-12-02T13:18:08.48023-03:00'}
Enviado: {'event_type': 'add_to_cart', 'event_id': '866a7e46-603a-48fb-a4af-4afe57fd8fe5', 'user_id': '02070236-885c-4172-9f2a-668deb05bd03', 'session_id': 'bfa3facf-08db-4096-a89b-97eebc21c7c2', 'product': {'product_id': 'p789', 'product_name': 'Tênis Esportivo', 'price': 299.0, 'quantity': 3, 'timestamp': '2025-12-02T13:18:10.313035-03:00'}}
Enviado: {'event_type': 'checkout', 'event_id': '4307b0a8-207a-4f11-a045-26c920b311ac', 'user_id': 'a2080a41-f0b5-4db6-a055-06456fc2252a', 'session_id': '1277d046-7354-4e42-9086-c4fb40807013', 'cart_items': [{'product_id': 'p789', 'product_name': 'Tênis Esportivo', 'price': 299.0, 'quantity': 2}, {'product_id': 'p121', 'product_name': 'Boné Preto', 'price': 39.9, 'quantity': 1}], 'cart_value': 637.0, 'timestamp': '2025-12-02T13:18:11.460946-03:00'}}
Enviado: {'event_type': 'checkout', 'event_id': 'ba3fd8fb-22a1-48c3-8214-c8b3faae7338', 'user_id': '05668f12-1e95-4e59-9d2c-479688a1faec', 'session_id': '27c5b5c8-4b03-4ff3-9766-9911a6b1d939', 'cart_items': [{'product_id': 'p123', 'product_name': 'Camiseta Básica', 'price': 49.9, 'quantity': 2}, {'product_id': 'p654', 'product_name': 'Mochila Escolar', 'price': 89.9, 'quantity': 3}], 'cart_value': 669.2, 'timestamp': '2025-12-02T13:18:12.013446-03:00'}}
Enviado: {'event_type': 'checkout', 'event_id': '64fe320f-fd6b-4b06-b506-535b51bd721', 'user_id': 'babe5385-c389-406d-8c77-0e03f9611c27', 'session_id': '6f7bb55f-f72e-48d7-aa7a-e85389e159cb', 'cart_items': [{'product_id': 'p456', 'product_name': 'Calça Jeans', 'price': 129.9, 'quantity': 3}, {'product_id': 'p654', 'product_name': 'Mochila Escolar', 'price': 89.9, 'quantity': 3}], 'cart_value': 759.2, 'timestamp': '2025-12-02T13:18:13.769484-03:00'}}
Enviado: {'event_type': 'order_confirmed', 'event_id': 'e20530fe-656d-4c20-8e2f-c2de30cfff540', 'user_id': 'cccc3152-5e06-4570-9209-09120f94056f', 'session_id': 'e1bd4e64-4508-4a0b-bf09-70de6f1e2d67', 'order_id': '01e98919-1b5b-41a7-9fc7-99a4d54330bc', 'product': {'product_id': 'p321', 'product_name': 'Boné Preto', 'price': 39.9, 'quantity': 3, 'total_value': 119.7, 'timestamp': '2025-12-02T13:18:14.919458-03:00'}}
Enviado: {'event_type': 'checkout', 'event_id': '9f2edaf6-aaef-4d8e-839c-678575697fff', 'user_id': '768923cd-b3a1-43fd-a0d-db7a5a0323a7', 'session_id': '05704eal-8785-48d7-8a4c-e7ad27057ebc', 'cart_items': [{'product_id': 'p789', 'product_name': 'Tênis Esportivo', 'price': 299.0, 'quantity': 1}, {'product_id': 'p789', 'product_name': 'Tênis Esportivo', 'price': 299.0, 'quantity': 3}, {'product_id': 'p456', 'product_name': 'Calça Jeans', 'price': 129.9, 'quantity': 1}], 'cart_value': 1325.9, 'timestamp': '2025-12-02T13:18:16.076572-03:00'}}
Enviado: {'event_type': 'pageview', 'event_id': 'e7205c8a-c314-40be-b0ac-840b2a0d9fc8', 'user_id': 'a20d1d24-d3db-447f-87c1-d07aca086ec3', 'session_id': '37793aa5-7b09-4e03-abab-8a609450782c', 'page': 'product', 'product': {'product_id': 'p321', 'product_name': 'Boné Preto', 'price': 39.9, 'timestamp': '2025-12-02T13:18:17.216798-03:00'}}
Enviado: {'event_type': 'add_to_cart', 'event_id': '4b09405c-65fa-4cc8-b991-3595e830a4c4', 'user_id': 'd95f0f3-773a-43f4-852b-125b04c5b56a', 'session_id': 'f78052e0-dead-4172-8091-15af3d308eaf', 'product': {'product_id': 'p321', 'product_name': 'Boné Preto', 'price': 39.9, 'quantity': 1, 'timestamp': '2025-12-02T13:18:18.304809-03:00'}}
Enviado: {'event_type': 'add_to_cart', 'event_id': 'f18e9764-0904-dec3-b10d-20002d726082', 'user_id': 'dc5360b7-b73b-4e52-b355-c18c845c586f', 'session_id': 'ca0304e-400a-4f65-aa0b-2b0ff59aa093', 'product': {'product_id': 'p654', 'product_name': 'Mochila Escolar', 'price': 89.9, 'quantity': 1, 'timestamp': '2025-12-02T13:18:19.519189-03:00'}}
```

Captura e escrita de dados:

```
consumer_kinesis_write_landing x +
Run Help Python Tabs: ON Last edit was 1 minute ago
Interrupt 01:33

f"year={year}/month={month}/day={day}"

# Grava como JSON particionado
(
    df.write.mode("append")
    .json(target_path)
)

print(f"[OK] {len(events)} registros gravados em {target_path}")

time.sleep(1)

> See performance Statements 28/29 1 | Tasks 20/20 (0 running)
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 1 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 1 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 3 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 4 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 4 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 4 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 3 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 3 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 2 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
[OK] 3 registros gravados em dbfs:/Volumes/streaming_catalog/raw/landing/shoptrend-events-stream/year=2025/month=12/day=02
```

Dados no PowerBI:

stream_data

Página Inicial

Transformar

Adicionar Coluna

Exibição

Ferramentas

Ajuda

Fechar e Aplicar

Nova Fonte

Fontes Recentes

Inserir Dados

Configurações da fonte de dados

Gerenciar Parâmetros

Exportar resultados da consulta

Atualizar Visualização

Propriedades

Editor Avançado

Escolher Colunas

Remover Colunas

Manter Linhas

Remover Linhas

Classificar

Dividir Coluna

Agregar por

Usar a Primeira Linha como Cabeçalho

Substituir Valores

Transformar

Config. Consulta

PROPRIEDADES

Nome

fact_checkout_item

Todas as Propriedades

ETAPAS APLICADAS

Fonte

Navegação

Consultas [12]

fact_checkout_id

event_ts

date_key

user_id

session_id

product

100% Válidos

100% Válidos

100% Válidos

100% Válidos

100% Válidos

100% Válidos

0% Erro

0% Erro

0% Erro

0% Erro

0% Erro

0% Erro

0% Vazio

0% Vazio

0% Vazio

0% Vazio

0% Vazio

0% Vazio

1

78f8b2cd-e19e-4d8c-a3d1-a7c6b943653

01/12/2025 17:20:49

20251201 76999b32-e7c9-49ad-ba7a-ed7b6b0e4af

858b0091-9705-4527-b33b-2a9ad82f2e80

p789

2

78f8b2cd-e19e-4d8c-a3d1-a7c6b943653

01/12/2025 17:20:49

20251201 76999b32-e7c9-49ad-ba7a-ed7b6b0e4af

858b0091-9705-4527-b33b-2a9ad82f2e80

p654

3

ce0d059c-742c-448d-a17f-02c772084c83

01/12/2025 17:20:49

20251201 d5dc8e86-5f7b-495c-b23b-d5b6c6120c

6014d7be-87ee-4cf1-b896-ca3ca-486083

p123

4

ce0d059c-742c-448d-a17f-02c772084c83

01/12/2025 17:20:49

20251201 d5dc8e86-5f7b-495c-b23b-d5b6c6120c

6014d7be-87ee-4cf1-b896-ca3ca-486083

p456

5

ce0d059c-742c-448d-a17f-02c772084c83

01/12/2025 17:20:49

20251201 d5dc8e86-5f7b-495c-b23b-d5b6c6120c

6014d7be-87ee-4cf1-b896-ca3ca-486083

p456

6

ce0d059c-742c-448d-a17f-02c772084c83

01/12/2025 17:20:49

20251201 d5dc8e86-5f7b-495c-b23b-d5b6c6120c

6014d7be-87ee-4cf1-b896-ca3ca-486083

p456

7

4147792b-b099-4768-bc98-6f21181bfe20

01/12/2025 17:20:43

20251201 b10186b9-4c36-4fa0-9480-92a559a6609e

13026bd4-c338-4ae1-ab5b-1c77caeda24f

p789

8

4147792b-b099-4768-bc98-6f21181bfe20

01/12/2025 17:20:43

20251201 b10186b9-4c36-4fa0-9480-92a559a6609e

13026bd4-c338-4ae1-ab5b-1c77caeda24f

p654

9

4147792b-b099-4768-bc98-6f21181bfe20

01/12/2025 17:20:43

20251201 b10186b9-4c36-4fa0-9480-92a559a6609e

13026bd4-c338-4ae1-ab5b-1c77caeda24f

p321

10

4147792b-b099-4768-bc98-6f21181bfe20

01/12/2025 17:20:43

20251201 b10186b9-4c36-4fa0-9480-92a559a6609e

13026bd4-c338-4ae1-ab5b-1c77caeda24f

p654

11

73fee389-8d8b-4f51-bd8c-3b90e120a230

01/12/2025 17:20:43

20251201 3b180016-a80d-49fb-bf57-3600db334ee7

3b61a997-b595-4c74-82d4-47bcc278bdec

p321

12

73fee389-8d8b-4f51-bd8c-3b90e120a230

01/12/2025 17:20:43

20251201 3b180016-a80d-49fb-bf57-3600db334ee7

3b61a997-b595-4c74-82d4-47bcc278bdec

p789

13

453c4d65-fdec-4337-b928-44366b159293

01/12/2025 17:21:00

20251201 28eb64b0-1f3d-45c1-951a-943659174a05

63d415e6-4c39-4574-bd3e-3f2cb073d3cb

p456

14

453c4d65-fdec-4337-b928-44366b159293

01/12/2025 17:21:00

20251201 28eb64b0-1f3d-45c1-951a-943659174a05

63d415e6-4c39-4574-bd3e-3f2cb073d3cb

p321

15

453c4d65-fdec-4337-b928-44366b159293

01/12/2025 17:21:00

20251201 28eb64b0-1f3d-45c1-951a-943659174a05

63d415e6-4c39-4574-bd3e-3f2cb073d3cb

p654

16

453c4d65-fdec-4337-b928-44366b159293

01/12/2025 17:21:00

20251201 28eb64b0-1f3d-45c1-951a-943659174a05

63d415e6-4c39-4574-bd3e-3f2cb073d3cb

p789

17

dcbb76d6-394f-4782-b5e9-fc88a13318c9

01/12/2025 17:21:00

20251201 2029c460-e89f-44be-a6ac-c8921ec345f3

48f54100-2828-4c0d-97a4-4990046e2230

p654

18

dcbb76d6-394f-4782-b5e9-fc88a13318c9

01/12/2025 17:21:00

20251201 2029c460-e89f-44be-a6ac-c8921ec345f3

48f54100-2828-4c0d-97a4-4990046e2230

p654

19

625da9fc-64d3-4116-a09c-d3f49e073cfs

01/12/2025 17:20:51

20251201 fe352b05-9375-494c-bda1-0e9b9e8d825c

3613d51f-1f65-45c0-aa75-bcc36f09f260

p789

20

625da9fc-64d3-4116-a09c-d3f49e073cfs

01/12/2025 17:20:51

20251201 fe352b05-9375-494c-bda1-0e9b9e8d825c

3613d51f-1f65-45c0-aa75-bcc36f09f260

p456

21

625da9fc-64d3-4116-a09c-d3f49e073cfs

01/12/2025 17:20:51

20251201 fe352b05-9375-494c-bda1-0e9b9e8d825c

3613d51f-1f65-45c0-aa75-bcc36f09f260

p321

22

625da9fc-64d3-4116-a09c-d3f49e073cfs

01/12/2025 17:20:51

20251201 fe352b05-9375-494c-bda1-0e9b9e8d825c

3613d51f-1f65-45c0-aa75-bcc36f09f260

p123

23

c5872119-a0fe-4f7b-849f-b6721b64405c

01/12/2025 17:21:03

20251201 276c0988-d8a5-4658-ba53-72c87adeed37

130d86c4-d473-4f3e-a274-c0637dbf1d4d

p456

24

78f8b2cd-e19e-4d8c-a3d1-a7c6b943653

01/12/2025 17:20:49

20251201 76999b32-e7c9-49ad-ba7a-ed7b6b0e4af

858b0091-9705-4527-b33b-2a9ad82f2e80

p789

Considerações finais

O desenvolvimento deste projeto proporcionou uma visão completa e prática sobre a construção de uma arquitetura moderna de processamento de dados em streaming, desde a ingestão dos eventos até sua organização em camadas estruturadas e prontas para consumo analítico. Ao longo do processo, diversos desafios foram identificados, exigindo decisões técnicas fundamentadas e ajustes contínuos para garantir um fluxo robusto e confiável.

Um dos principais aprendizados foi compreender na prática a diferença entre um fluxo de dados tradicional em batch e um pipeline orientado a eventos. O uso integrado de serviços como Kinesis Firehose, S3, Databricks e Delta Lake evidenciou a importância de manter pipelines resilientes a variações de schema e capazes de operar com baixa latência. A adoção do Delta Lake com Autoloader simplificou o gerenciamento de evolução de schema e checkpoints, permitindo maior controle sobre o ciclo de vida dos dados e garantindo idempotência no processamento.

Durante a implementação, surgiram dificuldades específicas relacionadas ao Databricks, especialmente por se tratar da versão gratuita. Algumas funcionalidades essenciais para arquiteturas maduras, como notebook workflows, execução de pipelines de forma orquestrada e limites de paralelismo, não estavam disponíveis. Isso exigiu adaptações e abordagens alternativas, como a execução manual dos notebooks ou substituição de mecanismos de orquestração por scripts externos. Além disso, algumas limitações de acesso ao Unity Catalog e políticas mais rígidas de armazenamento gerenciado geraram erros complexos, principalmente relacionados ao uso de caminhos dentro de áreas protegidas do workspace. Esses problemas contribuíram para uma compreensão mais profunda do funcionamento interno da plataforma, incluindo suas políticas de segurança, organização de storage e requisitos para definição de tabelas gerenciadas.

O uso do Terraform também reforçou a importância da infraestrutura como código. A necessidade de configurar serviços interdependentes – IAM Roles, políticas de acesso, Firehose, buckets S3 e integrações com o Databricks – deixou claro que ambientes configurados manualmente tendem a ser frágeis, inconsistentes e difíceis de reproduzir. A automação da infraestrutura garante padronização, rastreabilidade e maior eficiência na criação de ambientes de desenvolvimento e produção.

Por fim, este projeto consolidou conhecimentos não apenas técnicos, mas também conceituais. A experiência prática com serviços de nuvem, pipelines em streaming, arquitetura orientada a eventos e governança de dados permitiu compreender como decisões de design se conectam a requisitos de negócio, custos operacionais, tempo de resposta e confiabilidade. As dificuldades enfrentadas acrescentaram profundidade ao aprendizado, demonstrando que a construção de um pipeline de streaming envolve



entender tanto ferramentas quanto as restrições inerentes a cada serviço ou modelo de entrega.