


FIAP

NBA



.

ENGENHARIA DE DADOS



DATA SCIENCE



Dra. Regina Tomie Ivata Bernal

Cientista de Dados na área da Saúde

Formação Acadêmica:

Estatístico - UFSCar

Mestre em Saúde Pública - FSP/USP

Doutor em Ciências - Epidemiologia - FSP/USP

Pós-doutorado - Escola de Enfermagem-UFMG/I

profregina.bernal@fiap.com.br
reginabernal@terra.com.br

Atividades Profissionais:

Professora de pós-graduação na FIAP

Consultora externa da SVS/MS

Cientista de Dados em Saúde

CALENDÁRIO

Presencial

02/02/2026

Aplicação de Data
Science

Introdução a
Estatística

Exercício prático

09/03/2026

16/03/2026

23/03/2026

30/03/2026

TÓPICO 3

TO

AVALIAÇÃO

40%

**Lista de
exercícios**

40%

**Exercício
prático em
grupo**

20%

**Avaliação
diagnóstica
(Primeira aula)**

**Avaliação final
(Última aula)**

JORNADA

MÓDULO 1. DATA ENGINEER PEOPLE SKILLS

64H/A



MÓDULO 2. DATA PLATFORMS & ENGINEERING FOUNDATIONS

108H/A



MÓDULO 3. INTELLIGENCE DATA PLATFORMS

96H/A



Data Warehouse, Lakehouse e Data Mesh

- Modern Data Stack
- Cloud Data Warehouses - Snowflake e/ou Databricks
- Uso de APIs de GenAI em plataformas analíticas - Google BigQuery ML, AWS Bedrock

Data Science for Data Engineer

- Fundamentos das técnicas aplicadas em Data Science
- Pré-processamento de dados
- Conexão entre pipelines de dados e modelos ML

Agents & Agentic AI

- Arquitetura no Stack de Dados
- Frameworks e Tecnologias para construção
- Padrões para Desenvolvimento

Knowledge Graph

- Graph Databases
- Graph Data Science
- Ontologias e Inferências semânticas
- LLMs e geração de grafos enriquecidos

Generative AI


- Conceitos básicos: LLMs, diffusion models
- Principais frameworks e APIs: OpenAI, Hugging Face, Google Vertex AI
- Visão geral das plataformas: Azure OpenAI, Anthropic, Databricks com Dolly
- GPUs e otimizações para treinamento

GenAI & Databases

- Vector Databases e Vector Index
- Prompt Engineering e Few Shot Learning
- Text Embedding e Vector Search
- Vetorização para recuperação de informações (RAG)


Data Product Management

- Design de Data Products
- Observabilidade
- Linhagem e Testes de dados
- Data Product Lifecycle



Fonte: Prof. Anderson Vieira Dourado - Aula 1 - Generative AI - Introdução.pdf

Definições



Representação dos dados e suas relações


Modelo de Dados:

Um modelo entidade relacionamento (**MER**) é um modelo de dados para descrever os dados de um **domínio de negócio** ou seus requisitos de **processo**, de uma maneira abstrata.

Sua representação é feita em um diagrama conhecido por **DER**.

Fonte: Prof. Eduardo Galego - [29ABD-AdvDataModeling-2025JUN-Modulo1\(1\).pdf](#)

Plataforma de Dados




Fonte: <https://www.infoq.com/br/presentations/data-science-na-olx>




DATA ANALYTICS

DATA ANALYTICS

Métodos



Forecasts from ARIMA(1,1,2)(0,1,0)[4]




UNIVERSO DE FORNECEDORES

MicroStrategyIBMSAPsasMicrosoftalteryxtableauQlikTIBCO
The Power of Now[®]Information
BuildersORACLEOPEN TEXT
The Content Experts[™]RR Studioorangepythonjulia



ESTATÍSTICA



Estatística

É a ciência que trata dados numéricos provenientes de mensuração em grupos de indivíduos.

Trata da organização, descrição, apresentação análise e interpretação de dados resultantes da observação de fenômenos coletivos. Produz métodos para inferência estatística.

✓ Propriedades

Estuda as variações:

- entre indivíduos;
- em um mesmo indivíduo.



COMO TIRAR INFORMAÇÕES DELES

O QUE
ACONTECEU?

DESCRITIVO



QUANTOS CANCELAMENTOS?
QUANTOS CLIENTES NOVOS, QUANTOS ANTIGOS?
QUAL REGIÃO?
QUE TIPO DE CLIENTE?

POR QUE ISTO
ACONTECEU?

DIAGNÓSTICO



QUAL A RELAÇÃO ENTRE CANCELAMENTO
VOLUNTÁRIO POR TEMPO DE CONTA E TIPO DE
CLIENTE?

O QUE
ACONTECERÁ?

PREDITIVO



QUAL A PROBABILIDADE DE UM CLIENTE
CANCELAR O SERVIÇO EM UMA CERTA
REGIÃO NOS PRÓXIMOS 3 MESES?

O QUE
POSSO FAZER?

PRESCRITIVO



LISTA DE AÇÕES PARA RETER OS CLIENTES,
SEGUNDO SEU VALOR?

EXEMPLO

DATA DRIVEN

Flamengo x PSG: o que Safonov nos ensina sobre Análise de Dados

A final da Copa Intercontinental da FIFA 2025 entre Flamengo x PSG, decidida nos pênaltis, foi mais do que emoção.

Foi uma aula prática de decisão orientada por dados.

O goleiro do PSG, Matvey Safonov, defendeu quatro pênaltis consecutivos. E não foi sorte.

Em suas mãos, um relatório dos jogadores (scouting report) com dados dos batedores do Flamengo:

- ✓ Pé preferencial
- ✓ Tendência de lado
- ✓ Percentual de chutes
- ✓ Altura mais comum

Safonov não adivinhou.

Ele calculou probabilidades.

No futebol ou nos negócios, a lógica é a mesma:

- 📊 Dados reduzem riscos
- 🎯 Melhoram decisões sob pressão
- 🔧 Transformam preparo em resultado

- 👉 Dados não substituem talento.
- 👉 Dados potencializam o talento.

No fim, vence quem chega mais preparado para o momento decisivo.




Fonte:

[Winder Rosa](#)


Data Analyst | Business Intelligence | Power BI | Excel | SQL |
PcD

LARGE LANGUAGE MODEL



https://www.linkedin.com/posts/regina-t-i-bernal-36a85241_one-of-the-best-and-clearest-explanations-activity-7350855225206870020-BfPR?utm_source=share&utm_medium=member_android&rcm=ACoA-AAjYlIIBmqLMH9ZDnFCW92ZPRgDiyCuE9wY

DATA ANALYTICS



Levantamento de Dados

Data Cleaning:

- Padronização
- Transformação de Dados
- Adoção de De-Para de Atributos

Atributo Descrição

Sexo:	Masculino	De 2	Para 0
	Feminino	4	1
Idade:Criação de Faixa Etária	0-10		1
	11-18		2
	19-25		3
	26-30		4
	31-35		5
	36-40		6
	41-45		7
	46	8	
	sem informação		0

Levantamento de Dados

Atributo Descrição

Internet: Acesso últimos 3 meses

De	Para
1	1
3	0

Anos

de Estudo: Criação da Faixa Grau de Instrução

0-4	1
5-8	2
9-11	3
12	4

Renda: Criação de Faixa Salarial baseando em salários mínimos (Valor atual R\$380,00)

0-380	1
381-760	2
761-1900	3
1901-3800	4
3801	5
sem informação	0

Área: Agrupamento da área de residência em 1-Urbana e 2-Rural

1-3	1
4-8	2


+ + .




Levantamento de Dados



Levantamento de Dados




Exemplo de Cluster Não Hierárquico






Técnicas de Discriminação

Exemplo de Árvore de Decisão





LETRAMENTO ESTATÍSTICOS




MOTIVAÇÃO

Em ambientes corporativos, as decisões estratégicas são cada vez mais orientadas por dados.

O letramento estatístico permite que o profissional:

- Interprete **médias, variabilidade, correlações e tendências corretamente.**
- Avalie **incertezas, riscos e probabilidades.**
- Escolha os **algoritmos** e as **métricas** de avaliação dos modelos para cada tipo de problema.

Machine Learning Algorithms Mindmap



Data Mining



aplicações práticas de Data Mining se podem ser categorizadas de acordo com a tarefa que se pretende resolver

Técnicas Supervisionadas

Técnicas Não Supervisionadas

Tarefas de Mining

Atividade Preditiva

Predição

Classificação

.Regressão

.Séries Temporais

.Regressão logística

.Árvore de decisão

Support Vector Machine

K-nearest neighbour

Atividade Descritiva

Regras de Associação

Agrupamento

Sumarização

.Apriori

.Cluster
DBSCAN


+ Componentes principais.

Data Mining: Mineração - Construção de Modelos




aplicações práticas de Data Mining se podem ser categorizadas de acordo com a tarefa que se pretende resolver

- **Regressão:** Compreende a busca por uma função que mapeie os registros de um banco de dados em um intervalo de valores numéricos reais. Esta tarefa é similar à tarefa de Classificação, com a diferença de que o atributo alvo assume valores numéricos.




- **Classificação.** A tarefa de Classificação consiste em descobrir uma função que mapeie um conjunto de registros em um conjunto de classes. Uma vez descoberta, tal função pode ser aplicada a novos registros de forma a prever a classe em que tais registros se enquadram.



Técnica de Regressão: Regressão Linear Simples

Exemplo: Faturamento anual (em milhões de Reais) por número de ckeckouts

Exemplo



Técnica de Classificação: Árvore de Decisão

Exemplo

sinistra



Node 0			
Category	%	n	
0.000	50.0	10280	
1.000	50.0	10280	
Total	100.0	20560	

Upmora
Adj. P-value=0.000, Chi-square=1380.
754, d=0

1.0

Node 1			
Category	%	n	
0.000	72.8	3310	
1.000	27.2	1234	
Total	22.1	4544	

Upmora
Adj. P-value=0.000, Chi-square=251.
879, d=1

5.0:8.0

Node 2			
Category	%	n	
0.000	41.2	4610	
1.000	58.8	6599	
Total	54.4	11179	

Upmora
Adj. P-value=0.000, Chi-square=249.
102, d=1

4.0

Node 3			
Category	%	n	
0.000	44.8	1014	
1.000	55.2	1821	
Total	14.3	2905	

Upmora
Adj. P-value=0.000, Chi-square=48.879.
d=1

2.0

Node 4			
Category	%	n	
0.000	35.0	1049	
1.000	45.0	899	
Total	9.3	1908	

Upmora
Adj. P-value=0.000, Chi-square=78.522.
d=1

≤ 3292.0

> 3292.0

Node 5			
Category	%	n	
0.000	64.2	1897	
1.000	35.8	947	
Total	12.9	2844	

Node 6			
Category	%	n	
0.000	84.9	1613	
1.000	15.1	287	
Total	9.2	1900	

≤ 3292.0

> 3292.0

Node 7			
Category	%	n	
0.000	39.3	4101	
1.000	60.7	6341	
Total	50.8	10442	

Node 8			
Category	%	n	
0.000	89.1	509	
1.000	30.9	229	
Total	3.6	737	

≤ 3292.0

> 3292.0

Node 9			
Category	%	n	
0.000	42.8	1143	
1.000	57.2	1530	
Total	13.0	2673	

Node 10			
Category	%	n	
0.000	65.3	171	
1.000	34.7	91	
Total	1.3	262	

≤ 3292.0

> 3292.0

Node 11			
Category	%	n	
0.000	49.7	739	
1.000	50.3	747	
Total	7.2	1485	

Node 12			
Category	%	n	
0.000	73.5	311	
1.000	26.5	112	
Total	2.1	423	

Modelo de Churn

Pesos definidos na modelagem

-0,24	Grupo 7	Origem	Grupo 1	0,29
-1,84	Grupo 1	Grupo de CEP	Grupo 6	1,34
-0,63	46 ou mais	Tempo de Base em meses	Menos de 12	0,73
	0	Atendimento Call Center	6 ou mais	
-0,59	0	Média de dias de Atraso	Mais de 24	0,88
	Mais de R\$1000	Valor do Plano/Pacote	Menos de 160	
-0,11	Acima de 59 anos	Faixa Etária	18 a 23 anos	0,18
	2 ou mais	Dependentes	0	
0,23		Constante		0,23
4%	Propensão			98%

Técnica de Classificação: Regressão Logística

• • • + • □


• Clientes +



Clientes com o evento(*)

(*) Evento (exemplos)

- Aquisição
- Cancelamento
- Pagamento




Pontuação dos Clientes
com Probabilidade



Regra de Decisão

Corte



0% Probabilidade do evento ocorrer

□ 100%


Ranking
dos
Clientes

• • •

Técnica de Classificação: Redes Neurais

Exemplo

Exemplo: risco de crédito



As redes neurais usam dados de entrada.

Atribui pesos nas conexões entre os atributos (neurônios).

E obtém um resultado (risco de ter ou não crédito) - nível de saída.


Modelos de Séries Temporais

Previsão


Exemplo

Quantidade de transações mensais com cartões de crédito

Transações Crédito - Comércio Varejista



Transações Crédito - Turismo & Entretenimento



TÉCNICAS NÃO SUPERVISIONADAS

Data Mining



aplicações práticas de Data Mining se podem ser categorizadas de acordo com a tarefa que se pretende resolver

- **Descoberta de Associações:** Nessa tarefa, cada registro do conjunto de dados é normalmente chamado de transação. Cada transação é composta por um conjunto de itens. A tarefa de descoberta de associações compreende a busca por itens que frequentemente ocorrem de forma simultânea em uma quantidade mínima de transações do conjunto de dados.

- **Descoberta de Sequências:** É uma extensão da tarefa de Descoberta de Associações cujo propósito é identificar itens frequentes considerando um determinado período de tempo. Consideremos o exemplo das compras no supermercado. Se o banco de dados possui a identificação do cliente responsável por cada compra, a descoberta de associações pode ser ampliada de forma a considerar a ordem em que os produtos são comprados ao longo do tempo.



Técnica Descoberta de Sequências

• • • + • □

Quais associações são significativas ?

• Item comprado anteriormente +




Itens a serem sugeridos de acordo com a força


1.o produto



2.o produto



3.o produto




Item comprado anteriormente



Itens a serem sugeridos de acordo com a força


1.o produto



2.o produto



3.o produto





Data Mining



aplicações práticas de Data Mining se podem ser categorizadas de acordo com a tarefa que se pretende resolver


- **Agrupamento (Clusterização):** Consiste em segmentar os registros do conjunto de dados em subconjuntos ou clusters, de tal forma que os elementos de um cluster compartilhem propriedades comuns que os distingam de elementos nos demais clusters. O objetivo nesta tarefa é maximizar a similaridade intracluster e minimizar a similaridade intercluster.



Técnica de Agrupamento: Análise de Clusters

Segmentação Comportamental do Cliente

Exemplo



Data Mining



aplicações práticas de Data Mining se podem ser categorizadas de acordo com a tarefa que se pretende resolver

- **Sumarização:** Consiste em identificar e indicar similaridades entre registros do conjunto de dados.

Construção do
indicador de satisfação

Exemplo


- Velocidade de acesso à internet
- Utilidade / Adequação da internet
- Estabilidade da conexão
- Disponibilidade de acesso à Internet
- Valores pelo acesso da internet
- Interesse dos(as) atendentes
- Solução dada pela empresa
- Conhecimento dos(as) atendentes
- Rapidez com que é dada a resposta
- Tempo para ser atendido
- Conhecimento dos tipos de serviços
- Informações apresentadas nos manuais
- Utilidade das informações na mídia
- Informações sobre os serviços e planos
- Informações sobre as áreas de cobertura
- Diversidade e facilidade de aquisição
- Utilidade / adequação dos serviços
- Tempo de espera para ser atendido
- Tempo do atendimento
- Conhecimento e preparo atendentes
- Solução dos problemas
- Valor dos descontos de horários
- Preço da ligação
- Modernidade da empresa
- Quantidade de vezes que não funciona
- Frequência que ocorre queda da ligação
- Cobertura no Estado
- Fazer e receber ligações na sua cidade
- Qualidade das ligações em áreas internas
- Qualidade das ligações entre celulares

Técnica de Sumarização : Análise Fatorial

Exemplo

- Entendimento das variáveis latentes

- Criação de Indicadores



➤ Acesso ao conhecimento: educação

- Taxa de alfabetização da população acima de 15 anos

- Proporção de pessoas com acesso aos níveis de ensino primário

➤ Direito a uma vida longa e saudável: longevidade

- Expectativa de vida ao nascer

➤ Direito a um padrão de vida digno:



- Renda PIB *per capita*

Data Mining




aplicações práticas de Data Mining se podem ser categorizadas de acordo com a tarefa que se pretende resolver

- **Deteção de Desvios:** Tal tarefa consiste em identificar registros do conjunto de dados cujas características destoem dos que se considera a norma no contexto em análise. Tais registros são denominados valores atípicos (outliers).



(a) Multi-class Anomaly Detection



(b) One-class Anomaly Detection

EXTRAÇÃO DE CONHECIMENTOS

Data Mining

“**Data mining** é uma expressão inglesa ligada à **informática** cuja tradução é **mineração de dados**. Consiste em uma funcionalidade que **agrega e organiza dados**, encontrando neles **padrões, associações, mudanças e anomalias** relevantes. “


Fonte: <https://www.significados.com.br/data-mining/>

“**Prospecção de dados** ou **mineração de dados** (também conhecida pelo termo [inglês data mining](#)) é o processo de explorar grandes quantidades de [dados](#) à procura de padrões consistentes, como regras de associação ou sequências temporais, para detectar relacionamentos sistemáticos entre [variáveis](#), detectando assim novos subconjuntos de dados.”

Fonte: https://pt.wikipedia.org/wiki/Minera%C3%A7%C3%A3o_de_dados

Extração de Conhecimento

Extração de conhecimento em bases de dados
- A metodologia de data mining -



Fonte: Berry & Linoff, 2004.

Algumas aplicações de Análises Estatísticas para tomada de decisão

1

Problemas reais

- Financeiro
- Cartões de Crédito
- Seguros
- Indústria
- Varejo
- E-commerce
- Saúde
- Medicina
- Assistência Médica
- Telecom
- Aviação
- Ação Social
- Educação
- Utilies: Energia, Água
- Processos Cíveis
- Fraudes
-



+ + .

. . . .

□ . . ● ●


Algumas aplicações de Análises Estatísticas para tomada de decisão

Mercado	Área	Aplicações
Financeiro	Marketing	Modelos de churn, ativação, cross-selling, Segmentação Comportamental
	Crédito	Behaviour score, Collection score
Cartão de crédito		Fraude, Modelo de Ativação, Retenção, Recuperação, Segmentação Comportamental
Seguros		Modelos de Prospects, Detecção de Fraudes
Varejo		Projeção de demanda, Elasticidade de preço
Indústria		Controle de qualidade Conjoint Analysis
Saúde		Detecção de abusos, Modelos preditivos de doenças crônicas, Segmentação comportamental, Detecção digital de doença


Extração de Conhecimento

Extração de conhecimento em bases de dados

- A metodologia de data mining -



PROCESSO KDD




Fonte: Berry & Linoff, 2004.

KNOWLEDGE DISCOVERY IN
DATABASES (KDD)

LEVANTAMENTO DE DADOS

- “É A OPERAÇÃO DE COLETA PARA DESCRIÇÃO E/OU ANÁLISE DAS CARACTERÍSTICAS DE UMA POPULAÇÃO”



LEVANTAMENTO DE DADOS

Exemplos de dados secundários do IBGE :

- Pesquisa Mensal de Emprego.
- Pesquisa Industrial Mensal de Empregos e Salários.
- Pesquisa Mensal de Comércio.
- Pesquisa Nacional de Saúde.
- Censo Demográfico
- Pesquisa de Orçamentos Familiares (POF).
- Pesquisa Nacional por Amostra de Domicílios (PNAD).

LEVANTAMENTO DE DADOS

- Exemplos de dados secundários da Agência Nacional de Saúde suplementar (ANS)

<http://www.ans.gov.br/anstabnet/>

- Pesquisa Mensal de Comércio
- Susep

<http://www2.susep.gov.br/menuestatistica/Autoseg/menu1.aspx>

Transformação dos dados


2

Seleção de dados
apropriados ao
problema


Segmento	Dados	Fonte
Seguradora de veículos	Susep Frota de veículos	http://www2.susep.gov.br/menuestatistica/Autoseg/menu1.aspx https://www.gov.br/transportes/pt-br/assuntos/transito/conteudo-Senatran/frota-de-veiculos-2023
Operadora de Saúde	Agência Nacional de Saúde suplementar (ANS)	http://www.ans.gov.br/anstabnet/
População		https://www.ibge.gov.br

Extração de Conhecimento

Extração de conhecimento em bases de dados
- A metodologia de data mining -



PROCESSO KDD



Fonte: Berry & Linoff, 2004.

KNOWLEDGE DISCOVERY IN
DATABASES (KDD)

ESTATÍSTICA **DESCRITIVA**





ESTATÍSTICA

ESTATÍSTICA
DESCRITIVA

ORGANIZAR
DESCREVER
APRESENTAR

DISTRIBUIÇÕES
TABELAS
GRÁFICOS
MEDIDAS

Estatística Descritiva

Tem por objetivo organizar, descrever e apresentar os dados, de uma determinada população, em tabelas, gráficos e medidas de resumo.

População



População

Elementos (N=8)

Variáveis (atividade física, sexo, idade, filhos ...)



Quais as ocorrências possíveis para atividade física?

Como você representaria essas ocorrências?

Apresentação dos dados

Arquivo

estrutura matricial : linhas e colunas

ordem	Sexo	Atividade física	Estado civil	Grupo
1	F	Sim	Solteira	1
2	M	Sim	solteiro	1
3	F	Não	Casada	2
4	M	Não	Casado	2
5	F	Não	Casada	3
6	M	Não	Casado	3
7	F	Não	Solteira	3
8	M	Não	Solteiro	3


Apresentação dos dados

Arquivo

estrutura matricial : linhas e colunas

Grupo	Masculino	Feminino	Atividade física_Sim	Atividade física_Nao	Solteira	Casada
1	1	1	2	0	2	0
2	1	1	0	2	0	2
3	2	2	0	4	2	2

Escala de Mensuração




Escala de Mensuração


Variável qualitativa nominal: não existe nenhuma ordenação nos possíveis resultados. CATEGORIAS

Variável qualitativa ordinal: os possíveis resultados são ordenados. POSTOS

Variável quantitativa discreta: resultam de operação de contagem



Variável quantitativa contínua: possíveis resultados (valores) formam um intervalo de números reais



Aplicando conhecimento

Classifique cada variável de acordo com seu tipo:

Variável	Ocorrência	Tipo (escala de mensuração)
Estado civil	Solteiro	Qualitativa Nominal
	Casado	
	Viúvo	
	Divorciado	
Faz atividade física	0=Não ; 1=Sim	Qualitativa Nominal
Idade (anos)	[0 – 110]	Quantitativa contínua
Anos de estudo	[0 – 99]	Quantitativa contínua

Escala de Mensuração

Exemplo: Escala de questionário:

➡ péssimo regular bom ótimo excelente
 () () () ()

Variável
Qualitativa
ordinal

➡ —————
 | | | | |
 1 2 3 4 5
 Certamente Certamente
 Não compraria Compraria
 Discredo Concorde
 Totalmente Totalmente


Variável
discreta

APRESENTAÇÃO DOS DADOS

Tipos de Variáveis: Escala de questionário:


Exemplo: Como medir satisfação do cliente?

Escala de Satisfação




Grau de Satisfação

- classificação: “satisfeito”, “não satisfeito”
- grau de satisfação: escala de 1 a 5 associada a adjetivos
- grau de satisfação: escala de 0 a 10
- grau de satisfação: escala construída com vários itens de um questionário



MEDIDAS DE TENDÊNCIA CENTRAL




Medidas Resumo

São estatísticas que resumem, em um único valor, a tendência central (média, mediana, moda), a variabilidade (variância, desvio padrão) e a forma da distribuição (simétrica ou assimétrica) da variável.

Medidas Resumo

Distribuição simétrica



Distribuição do tempo de uso de internet (horas)

Medidas de tendência central:

- Média
- Mediana
- Moda

Indicam o centro da distribuição de frequências ou a região de maior concentração de frequência na distribuição.


Medidas de dispersão:

- Variância
- Desvio padrão

Indicam o grau de homogeneidade dos valores, até que ponto eles se encontram concentrados ou dispersos da média.

Medidas Resumo

Decisão pela média



Qual ativo você escolheria para investir? Justifique sua escolha.

Medidas Resumo

Exemplo 2

Durante uma verificação de qualidade no conteúdo de seis recipientes de café instantâneo, foram obtidas as seguintes notas:

6,03 5,59 6,40 6,00 5,99 6,02

Qual a média e a mediana encontrada?

Média aritmética: $\bar{x} = \frac{\sum_{i=1}^n x_i}{n} \Rightarrow \bar{x} = \frac{6,03 + 5,59 + 6,40 + 6,00 + 5,99 + 6,02}{6} \Rightarrow \bar{x} = 6,00$

Mediana: 5,59 5,99 6,00 6,02 6,03 6,40

$$mediana = \frac{6,00 + 6,02}{2} = 6,01$$

Medidas Resumo

Exemplo 2

Durante uma verificação de qualidade no conteúdo de seis recipientes de café instantâneo, foram obtidas as seguintes notas:

6,03 5,59 6,40 6,00 5,99 6,02

Qual a média e a mediana encontrada?

$$\bar{x} = 6,00 \quad \text{mediana} = 6,01$$

Suponha que o terceiro valor tenha sido incorretamente medido e que na verdade seja de 6,04. Determine novamente a nota média e mediana.

Média aritmética:

$$\bar{x} = \frac{6,03 + 5,59 + 6,04 + 6,00 + 5,99 + 6,02}{6} = 5,95$$


Mediana: 5,59 5,99 6,00 6,02 6,03 6,04

$$\text{mediana} = \frac{6,00 + 6,02}{2} = 6,01$$

Medidas Resumo


Decisão pela média ?????

Assimétrico à direita



Média > Mediana

Assimétrico à esquerda




Média < Mediana


Medidas Resumo

• Outras Medidas de Posição


Decis: dividem um conjunto de dados em dez partes iguais.



Percentis (P): dividem a série em cem partes, de modo que p% ficam abaixo dele (P).



Quartis: dividem a série em quatro partes iguais.



Medidas Resumo

Economia nacional

São Paulo, Rio e Brasília respondem por 21% do PIB brasileiro

Andrea Bruxellas


Direto do Rio de Janeiro

Especial para o Terra

Os municípios de São Paulo, Rio de Janeiro e Brasília respondiam por 21% do Produto Interno Bruto brasileiro em 2007. Segundo dados divulgados pelo Instituto Brasileiro de Geografia e Estatística (IBGE) nesta quarta-feira, a capital paulista responde pela maior fatia do PIB brasileiro, gerando 12% de toda riqueza produzida no País, seguida do Rio de Janeiro (5,2%), Brasília (3,8%), Belo Horizonte (1,4%) e Curitiba (1,4%).

"Com os dados de 2007 a gente pode notar uma estabilidade na série. Ou seja, na série inteira a gente vê que a renda ainda está muito concentrada em alguns municípios e isso é bastante estável. Nas cinco principais cidade a gente tem um quarto do PIB. Tirando essas cidades, a economia esta concentrada em 50 cidades que geram 50% da riqueza do País", disse a coordenadora do IBGE Sheila Cristina Zani.

Já os menores PIB do Brasil foram verificados em Santo Antônio dos Milagres (PI), São Miguel da Baixa Grande (PI), Areia de Barúnas (PB), São Luís do Piauí (PI) e Olho D'Água do Piauí (PI). Segundo o IBGE, a soma dos PIB destes cinco municípios representava 0,001% da riqueza produzida em todo País em 2007.



MEDIDAS DE DISPERSÃO



Medidas Resumo

- Medidas de Dispersão


Exemplo 8:

A: 4, 4, 4, 4, 4, 4, 4, 4

B: 3, 3, 3, 3, 5, 5, 5, 5

C: 1, 1, 3, 3, 5, 5, 7, 7

Qual o desvio padrão?



Medidas de Dispersão

- Medidas de Dispersão: variância e desvio padrão

Exemplo C

X	Média	(X-Média)	(X-Média) ²
1	4	-3	9
1	4	-3	9
3	4	-1	1
3	4	-1	1
5	4	1	1
5	4	1	1
7	4	3	9
7	4	3	9
Soma	-	0	40

Variância:

$$\sigma^2 = \frac{40}{8} = 5$$

Desvio padrão:

$$\sigma = \sqrt{\sigma^2} = \sqrt{5} = 2.24$$

MEDIDAS DISPERSÃO DESVIO PADRÃO

Desvio Padrão

É a raiz quadrada da variância.

$$s = \sqrt{s^2}$$

Qual a vantagem do Desvio Padrão em relação a Variância?

→ O desvio padrão se expressa **na mesma unidade da variável**, sendo, por isso, de maior interesse que a variância nas aplicações práticas: Quanto está distante do ponto central.

Medidas de Dispersão

O quanto os pontos (dados) estão distantes da média (ponto central)

➤ **variância da população**


$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \bar{x})^2}{N}$$

➤ **variância da amostra**


$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

MEDIDAS DISPERSÃO DESVIO PADRÃO


Média = 100
Desvio padrão = 5




Média = 100
Desvio padrão = 10



Média = 100
Desvio padrão = 15



Média = 100
Desvio padrão = 40



Medidas Resumo

Controle estatístico do processo

O Controle Estatístico de Processos (CEP) é uma ferramenta da qualidade utilizada nos processos produtivos (e de serviços) com objetivo de fornecer informações para um diagnóstico mais eficaz na prevenção e detecção de defeitos/problemas nos processos avaliados e, conseqüentemente, auxilia no aumento da produtividade/resultados da empresa, evitando desperdícios de matéria-prima, insumos, produtos etc.


(Fonte: https://pt.wikipedia.org/wiki/Controle_estat%C3%ADstico_de_processos)

Exemplo: Fábrica de Café em Pó

Medidas Resumo

Controle estatístico do processo

Gráfico de controle



O gráfico é construído a partir das medidas estatística como:

[Média aritmética.](#)

[Desvio padrão.](#)

[Média das médias.](#)

[Somatórios](#) etc.


“Mostrar evidências de que um processo esteja operando em estado de controle estatístico e dar sinais de presença de causas especiais de variação para que medidas corretivas apropriadas sejam aplicadas”.

“Manter o estado de controle estatístico estendendo a função dos limites de controle como base de decisões”.

“Apresentar informações para que sejam tomadas ações gerenciais de melhoria dos processos”.

Fonte: <http://www.portalection.com.br/controle-estatistico/processo/graficos-ou-cartas-de-controle>

MEDIDAS DISPERSÃO



Medidas **Resumo**

- Outras Medidas de Dispersão
 - **Coeficiente de Variação**
 - **Amplitude**
 - **Amplitude Inter-Quartílica**

Medidas Resumo

• Outras Medidas de Dispersão

Coeficiente de variação

É o quociente entre o desvio padrão e a média.

$$CV = \frac{\sigma}{\bar{X}}$$

Vantagem: caracterizar a dispersão dos dados em termos relativos a seu valor médio.

Medidas Resumo

Qual o coeficiente de variação?


• Outras Medidas de Dispers

Exemplo 8:

A: 4, 4, 4, 4, 4, 4, 4, 4

B: 3, 3, 3, 3, 5, 5, 5, 5

C: 1, 1, 3, 3, 5, 5, 7, 7



● Média

Medidas Resumo

- Outras Medidas de Dispersão

Amplitude

É definida como a diferença entre o maior e o menor valor de um conjunto de dados.

Fortemente relacionado com a dispersão dos dados.

A amplitude pode levar a erros de avaliação, pois não representa o conjunto dos dados. Muitas vezes reflete muito mal a dispersão dos mesmos.

OUTRAS MEDIDAS AMPLITUDE

- É definida como a diferença entre o maior e o menor valor de um conjunto de dados. Fortemente relacionado com a dispersão dos dados.


Exemplo

idade	Minimum	20,00
	Percentile 25	30,00
	Median	34,00
	Percentile 75	40,00
	Maximum	48,00

A = 28 anos

Aplicações:

- amplitude de temperatura em um dia
- controle de qualidade



A amplitude pode levar a erros de avaliação, pois não representa o conjunto dos dados.

Muitas vezes reflete muito mal a dispersão dos mesmos.

Medidas Resumo

- Outras Medidas de Dispersão

Amplitude Inter-quartílica

É a diferença entre o terceiro e o primeiro quartil ($Q3 - Q1$).

Usada em análise exploratória de dados – gráficos Box Plot.

Medidas Resumo

- Outras Medidas de Dispersão

Amplitude Inter-quartílica

É a diferença entre o terceiro e o primeiro quartil ($Q3 - Q1$).

Usada em análise exploratória de dados – gráficos Box Plot.



OUTRAS MEDIDAS AMPLITUDE INTER-QUARTÍLICA


É a diferença entre o terceiro e o primeiro quartil ($Q3 - Q1$).

Usada em análise exploratória de dados – gráficos específicos.

idade	Minimum	20,00
	Percentile 25	30,00
	Median	34,00
	Percentile 75	40,00
	Maximum	48,00

IQ = 10 anos

- medida de dispersão em torno da mediana



DETECÇÃO DE OUTLIERS



Detecção de dados suspeitos - “Outlier”

- Dado incorreto
- População diferente
- Dado correto - Evento raro

- • • + Detecção de dados suspeitos - “Outlier”



• Representação Gráfica na Análise dos Dados


O Box Plot (desenho esquemático) informa medidas de posição, dispersão, assimetria, caudas e dados atípicos (outliers). A posição central é dada pela mediana e a dispersão pela amplitude inter-quartílica. As medidas de posição q_1 , q_2 e q_3 informam a assimetria da distribuição. Os comprimentos das caudas são dados pelas linhas que vão do retângulo aos valores distantes e pelos valores atípicos.



- • • + Detecção de dados suspeitos - “Outlier”


- • • +

- Representação Gráfica na Análise dos Dados



Legenda:



Q_1 = quartil 1
 Q_2 = quartil 2 = mediana
 Q_3 = quartil 3
 IQ = interquartil



Detecção de dados suspeitos - “Outlier”

Exemplo

Exemplo



Exemplo

BOX-PLOT: DETECÇÃO DE OUTLIERS


Outliers

Observações que apresentam um grande afastamento das restantes ou são inconsistentes com elas.

Gráfico Box-Plot

Exemplo: Preço médio do produto A

N	90
Range	1,2
Mean	2,99
Median	2,98
Percentil 25	2,94
Percentil 75	3,05
Interquartile Range	0,11
Variance	0,02
Skewness	-2,92
Kurtosis	19,64



Aplicação


Detecção de dados suspeitos - “Outlier”

Exemplo

Gráfico Box-Plot

Exemplo: “Total de
unidades vendidas por
produto - Campanha 1 a

12 de 2016



Exercitando!!!!




Base
Cadastro


O que você achou da aula de hoje?

Pelo aplicativo da FIAP

(Entrar no FIAPP, e no menu clicar em Experience Survey)



Experience Survey



A grande finalidade do
conhecimento não é conhecer,
mas agir.

T. Huxley

OBRIGADO

 / Regina T. I. Bernal

FIAP

Copyright © 2025 | Professora Dra. Regina Tomie Ivata Bernal
Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente proibido sem consentimento formal, por escrito, do professor/autor.

FIAP