

FIAP

NABA

ENGENHARIA DE DADOS

DATAOPS & MLOPS

Prof . André Pontes Sampaio
profandre.sampaio@fiap.com.br

Prof. André Pontes Sampaio

<https://www.linkedin.com/in/andre-pontes-sampaio/>



Objetivos da Disciplina


O que é o Manifesto *DataOps* e seus Desafios?


Quais ferramentas podem ser utilizadas?

Arquiteturas para *Data Pipeline Orchestration*



Objetivos da Disciplina





DATAOPS E SEUS DESAFIOS




Desafios em DATAOPS



Relembrando


Ciclo de vida de um produto



**QUANDO SÃO
GERADOS
DADOS PARA
TOMADA DE
DECISÃO?**

Relembrando

Ciclo de vida de um produto



Desafios em DATAOPS



**COMO USAR ANALYTICS PARA
APOIAR ESTRATÉGIAS DE
CRESCIMENTO DOS
NEGÓCIOS?**

Desafios em DATAOPS

Notícias

06/12/2023

CIRA-SP deflagra operação de combate à sonegação fiscal superior a R\$ 3 bilhões com o poder público



R\$ 3 Bilhões

Operação Vênus em cidades de SP e em Colatina/ES cujo alvo é dono de marcas famosas milionárias (Polo Wear, Planet Girls, Hot Point), e que tem mais de 200 lojas em todo o país.

Há fortes indícios de implementação de um esquema de blindagem e ocultação patrimonial com uso de interpostas pessoas ("laranjas"), offshores e cessões de bens e recebíveis em fraudes.

Desafios em DATAOPS

Notícias

28/09/2023

Força-tarefa de SP e AL cumpre mandados de busca, apreensão e prisão em alvos do setor de plásticos



R\$ 220 milhões

Desarticular suposta organização criminosa ligadas ao ramo químico e plásticos que atua na constituição de empresas, falsidade documental e lavagem de bens.

**1.642 notas fiscais falsas;
10 PJs (pessoas jurídicas): clientes e fornecedores;
18 pessoas físicas (gestores, contadores, “laranjas”);
12 municípios paulistas.**

Desafios em DATAOPS



Minimizando o tempo e esforço para validar uma ideia

Transformando uma necessidade em algo (protótipo) que gere valor

Definindo um processo que possa ser repetido e reutilizado

Desafios em DATAOPS

Notícias

16/06/2023

Secretaria da Fazenda e Planejamento lança oficialmente o Smart Sefaz



SMART Sefaz

Fisco paulista pretende automatizar processos por meio da Ciência de Dados e uso de Inteligência Artificial.

Serão feitas análises preditivas dos riscos e comportamentos de contribuintes com base em indicadores.

Desafios em DATAOPS

Notícias

16/06/2023

Secretaria da Fazenda e Planejamento lança oficialmente o Smart Sefaz

SMART Sefaz

Trabalhos em andamento com base em MBAs

Deteccção de
**Fraude na
Abertura de
Inscrição
Estadual**

Precisão de 91% de
endereços irregulares a
partir de 202 *features*

Modelos de
Classificação
para Deteccção
de
Irregularidades
Tributárias

Classificador XGBoost:
93% acerto em operações
(usando dados reais)

Identificando
emitentes de
**nota fiscal
irregular**

Fraude estimada de
R\$ 321 milhões
(Regressão Logística)


Desafios em DATAOPS

Notícias

16/06/2023


Secretaria da Fazenda e Planejamento lança oficialmente o Smart Sefaz

Painel Power BI em Produção




Desafios em DATAOPS

Demandas e perguntas das áreas de negócios




Desafios em DATAOPS : ETL x ELT



Desafios em DATAOPS : ETL x **ELT**

BIG DATA ARCHITECTURE



**AGILIDADE NAS
DECISÕES**

Desafios em DATAOPS


BIG DATA




ANALYTICS




DECISIONS



DADOS



INFORMAÇÕES



VALOR

Desafios em DATAOPS

Mais de 85% das empresas tem projetos de AI / ML

58% das empresas já fazem ingestão de dados em tempo real


85% das empresas possuem ingestão de dados a partir de fontes externas

76% das empresas demoram pelo menos 2 meses para inserir novos dados nos pipelines de dados


79% das empresas tem pelo menos 1 erro em seus relatórios mensais



O que é DATAOPS ?



O que é DATAOPS?




Combinação de *práticas e ferramentas* que *geram valor e agilizam* novas análises com a garantia de *qualidade dos dados*



Objetivos de DATAOPS

Six stages of data pipeline maturity

- Stage 0: None
- Stage 1: Batch
- Stage 2: Realtime
- Stage 3: Integration
- Stage 4: Automation
- Stage 5: Decentralization




The Future of Data
Engineering

Beyond the Database,
and beyond the Stream
Processor: What's the Next
Step for Data Management?


Combining DataOps and
DevOps: Scale at Speed

Objetivos de DATAOPS


Stage 0: None




Stage 1: Batch



Stage 2: Realtime




Stage 3: Integration



Objetivos de DATAOPS

Realtime Data Integration

Stage 4: Automation



Automated Data Management

Data Catalog

RBAC/IAM/ACL

DLP

...

Automated Operations

Orchestration

Monitoring


Configuration

...

Objetivos de DATAOPS

Realtime Data Integration

Stage 5: Decentralization



Automated Data Management

Data Catalog

RBAC/IAM/ACL

DLP

...

Automated Operations


Orchestration

Monitoring

Configuration

...


O que é DATAOPS?



O que é DATAOPS?

AGILE

Pesquisa: Qual prática/processo/metodologia mais utilizada em projetos de Data Science?



O que é DATAOPS?

AGILE

Cross Industry Standard Process for Data Mining (CRISP-DM)

BRAINSTORM
(explorar perguntas que gerem valor)

1. Compreensão
do Negócio

2. Compreensão
dos Dados

3. Preparação
dos Dados

4. Modelagem

5. Avaliação

6. Desenvolvimento



Dados



Prototype

VALOR

CRISP-DM
consiste
em 6
passos


6 passos
são feitos
várias
vezes
(dentro de
cada
sprint)

O que é DATAOPS?


AGILE

CRISP-DM Waterfall

CRISP-DM Agile




O que é DATAOPS?




O que é DATAOPS?

AGILE

DATA DRIVEN
SCRUM




O que é DATAOPS?




O que é DATAOPS?

DEVOPS

Cultura DEVOPS vai além da tecnologia



O que é DATAOPS?



O que é DATAOPS?

DEVOPS

Pilares DEVOPS fazem sentido em DATAOPS?



Colaborar

Pipeline

Enxuto

Falhas

Conhecimento

O que é DATAOPS?

DEVOPS

Fluxo DATAOPS

Carregar e
Transformar

Deploy

Modelar e
Visualizar

Creation


Production
Process

Production

Usar e
Consumir

Avaliar e Otimizar

Monitorar e Atualizar



O que é DATAOPS?

DEVOPS

Fluxo DATAOPS

**Carregar e
Transformar**

Deploy

**Modelar e
Visualizar**

Creation


**Production
Process**

Production


**Usar e
Consumir**

Avaliar e Otimizar

Monitorar e Atualizar




O que é DATAOPS?




O que é DATAOPS?

PROCESS CONTROLS



O que é DATAOPS?



O que é DATAOPS?

PROCESS
CONTROLS

Microsoft Azure Machine Learning

automl-test > Home

Azure Machine Learning studio

Qualidade


Create new ▾


Notebooks
Code with Python SDK and run sample experiments.
[Start now](#)


Automated ML
Automatically train and tune a model using a target metric.
[Start now](#)


Designer
Drag-and-drop interface from prepping data to deploying models.
[Start now](#)

My recent resources

Runs

Run	Run ID	Experiment	Status	Submitted time	Submitted by	Run type
Run 1	AutoML_6a5762d5-d3b6-...	automl_test	Completed	Oct 6, 2020 11:34 AM	Nina Baccam	Automated...

Fonte <https://docs.microsoft.com/en-us/azure/machine-learning/how-to-understand-automated-ml>

O que é DATAOPS?

PROCESS
CONTROLS

Microsoft Azure Machine Learning

automl-test > Home

Azure Machine Learning studio



Create new ▾



Notebooks
Code with Python SDK and run sample experiments.

Start now



Automated ML
Automatically train and tune a model using a target metric.

Start now



Designer
Drag-and-drop interface from prepping data to deploying models.

Start now

My recent resources

Runs

Run	Run ID	Experiment	Status	Submitted time	Submitted by	Run type
Run 1	AutoML_6a5762d5-d3b6-...	automl_test	Completed	Oct 6, 2020 11:34 AM	Nina Baccam	Automated...

Resumindo: DATAOPS



***DataOps ajuda a **reduzir**
o tempo no ciclo
de produzir **valor** analítico
e **inovação** para a
organização***

Vamos nos Divertir!



1. Kahoot.it ou instalar o APP !
2. clicar em: ENTER PIN
3. Colocar Nome (Sobrenome)




O que vimos até aqui:

- Desafios em DataOps
- Nível de Maturidade de *Data Pipeline*
- Pilares de DataOps
 - Agile
 - DevOps
 - Controle de Processos

ORQUESTRAÇÃO EM DATAOPS

Gerenciamento Ágil

Gerenciamento ágil de microserviços



Manifesto DATAOPS


Através do trabalho com dados em organizações, com ferramentas, e em indústrias, nós pudemos desvendar a melhor maneira de desenvolver e entregar análises, que nós chamamos de DataOps.

The DataOpsManifesto


<https://dataopsmanifesto.org/pt-pt/>

Ponto de atrito

Outsourcing clássico da TI




Outsourcing ágil baseado em nuvem



Ambientes para DataOps


Onde criar os ambientes na era da nuvem:

Ferramentas X Dados



Ambientes para DataOps

Controles híbridos necessários (onde estão os dados?)



AMIs do AWS Deep Learning

Amazon SageMaker

Amazon Kinesis

Amazon Elasticsearch

Amazon QuickSight

Amazon Athena

Amazon EMR

Amazon Redshift

Amazon S3 AWS Lake Formation

Amazon S3 Glacier AWS Backup

AWS Glue AWS Lake Formation

AWS Data Exchange


Ambientes para DataOps

Controles híbridos necessários na era da nuvem:

Categoria	Casos de uso	Serviço da AWS
Análises	Consultas interativas	 Amazon Athena
	Processamento de big data	 Amazon EMR
	Data warehousing	 Amazon Redshift
	Análises em tempo real	 Amazon Kinesis
	Análises operacionais	 Amazon Elasticsearch Service
	Painéis e visualizações	 Amazon QuickSight
Ingestão de dados	Ingestão de dados em tempo real	 Amazon Kinesis Data Analytics
		 Amazon Kinesis Data Firehose
		 Amazon Kinesis Data Streams
		 Amazon Kinesis Video Streams
Data lake	Armazenamento de objetos	 Amazon S3  AWS Lake Formation
	Backup e arquivamento	 Amazon S3 Glacier  AWS Backup
	Catálogo de dados	 AWS Glue  AWS Lake Formation
	Marketplace de Dados	 AWS Data Exchange
Análises preditivas e machine learning	Frameworks e interfaces	 AMIs do AWS Deep Learning
	Plataforma para desenvolvimento de modelos	 Amazon SageMaker

Ambientes para DataOps

Empresas precisam capacitar seus times para a inovação




DataOps com Contêineres

Componentes do nosso COMÉRCIO DIGITAL

eShopOnContainers reference application



(Development environment architecture)

Cluster Docker Swarm ou K8S



DataOps com Contêineres


Componentes do nosso COMÉRCIO DIGITAL



**AGILIDADE NAS
DECISÕES**

LABORATÓRIO : ETL x ELT

ORQUESTRAÇÃO



DataOps com Contêineres

FIAP

“Containerização”

Registro de uma
imagem no Hub

Alta disponibilidade
em diversos nodes

Implantação e
distribuição da
imagem

Execução
padronizada dos
aplicativos

Desenvolvimento
em máquina local

Carateristicas:


Facilita as
práticas DataOps

Aplicações não
possuem dependências
do sistema

Facilita o
provisionamento
dos pipelines
DataOps

DataOps com Contêineres



Contêineres gerenciados



DataOps com Contêineres

Docker: plataforma Runtime de contêineres

Contêineres gerenciados



DataOps com Contêineres

Uso de contêiner está cada vez mais popular

Flexibilidade

Maioria das aplicações suportam **execução em contêiner**

Agilidade

Suportam updates com as aplicações em execução (**on the fly**)

Execução

Compartilham trechos do host para uma execução mais leve

Portabilidade

Possibilitam desenvolvimento local e **distribuição com automação**

Escalabilidade

Suportam o aumento horizontal para **distribuir carga** para novas réplicas

Orquestração

Agrupamento de **serviços relacionados interdependentes** (stacks)

Orquestração em DataOps

“

We often hear “data is the new oil” but data may be important, the key is what you use to make it valuable. What you need is a refinery, because people don’t want oil, they want gas.

ADRIEN BLIND - VP PRODUCT & TECHNOLOGY AT SAAGIE

Vamos nos Divertir!

FIAP



O que vimos até aqui:

- Utilização do Containers em DataOps
- Orquestração em DataOps
- Gerenciamento Ágil
- Arquitetura Escalável

ALTA DISPONIBILIDADE E AUTOMAÇÃO

Métricas e Indicadores

A adoção de nuvem pública define novas perspectivas para a TI interna

No cenário econômico globalizado,
mesmas tecnologias estão disponíveis para empresas de diferentes portes



Inevitáveis são as Comparações
Nuvem X On-Prem:

Custos, Prazo para Go-Live,
SLA Disponibilidade



O que deve ser medido?

Fatores Críticos de Sucesso (e suas métricas):

Menores ciclos
com entrega de
valor mais
rápido




Garantir
qualidade e
disponibilidade



Otimizar
recursos e
eliminar
desperdícios



Entregar valor
contínuamente



tempo médio
de atualização
com o pipeline
de dados

% nível de
disponibilidade

tempo de
resposta


R\$ Lucro

(Receitas
menos
Despesas)

tempo médio
entre falhas
(ex:
informações
erradas)


Arquitetura escalável

Desafios que devem ser atendidos



Arquitetura escalável

Desafios que devem ser atendidos



**Stateful vs
Stateless**

Automação

Arquitetura escalável:

- Adição de recursos:




Verticalmente (scale up/down)




Horizontalmente (scale out/in)

- Elasticidade



Aumento automático para manter a qualidade de serviço




Remoção da capacidade excessiva quando a demanda diminuir, **evitando gastos**

DataOps

BANCOS DE DADOS em Alta Disponibilidade



DataOps com Contêineres

Contêineres gerenciados



DataOps com Contêineres

Componentes do nosso COMÉRCIO DIGITAL



**AGILIDADE NAS
DECISÕES**

Padrões de Arquitetura

ACID (atomicidade)


x BASE (consistência eventual)

(Atomicidade, Consistência, Isolamento e Durabilidade)

(Basically Available, Soft State e Eventually Consistent)


BD Monolítico ou BD Separados

Contêineres gerenciados



Arquitetura Monolítica

ACID



Arquitetura de Microsserviços

BASE

Padrões de Arquitetura

ACID (atomicidade)

x BASE (consistência eventual)

(Atomicidade, Consistência, Isolamento e Durabilidade)

(Basically Available, Soft State e Eventually Consistent)

Devem ser escolhidos somente 2 (Teorema CAP):

Contêineres gerenciados




Persistence



MOM



Volumes



Padrões de Arquitetura


Consistência + Disponibilidade



Contêineres gerenciados



Volumes




Padrões de Arquitetura

Consistência + Disponibilidade - Particionamento



Contêineres gerenciados




Padrões de Arquitetura

Particionamento + Disponibilidade



Contêineres gerenciados



Padrões de Arquitetura

Particionamento + Consistência


mongoDB redis



Contêineres gerenciados



Volumes




DataOps

EVENT STREAMING **em Alta Disponibilidade**

DataOps com Contêineres

Componentes do nosso COMÉRCIO DIGITAL



**AGILIDADE NAS
DECISÕES**


Padrões de Arquitetura

Comunicação



Kafka: Arquitetura Publish/Subscribe (projeto criado pelo LinkedIn)

Cluster composto por 4 Nodes visando resiliência




Padrões de Arquitetura

Comunicação



Kafka: Producer, Consumer, Topics




Padrões de Arquitetura

Comunicação



Kafka Topics: LEADERS e FOLLOWERS

PRODUTOR



1 Broker é eleito LÍDER para cada tópico


Cada Tópico mantém **réplicas das mensagens** nos Líderes e Followers

Padrões de Arquitetura

Comunicação



Kafka Topics: REPLICATION FACTOR



A quantidade de réplicas de cada mensagem é definida pelo **REPLICATION FACTOR** ao criar cada tópico

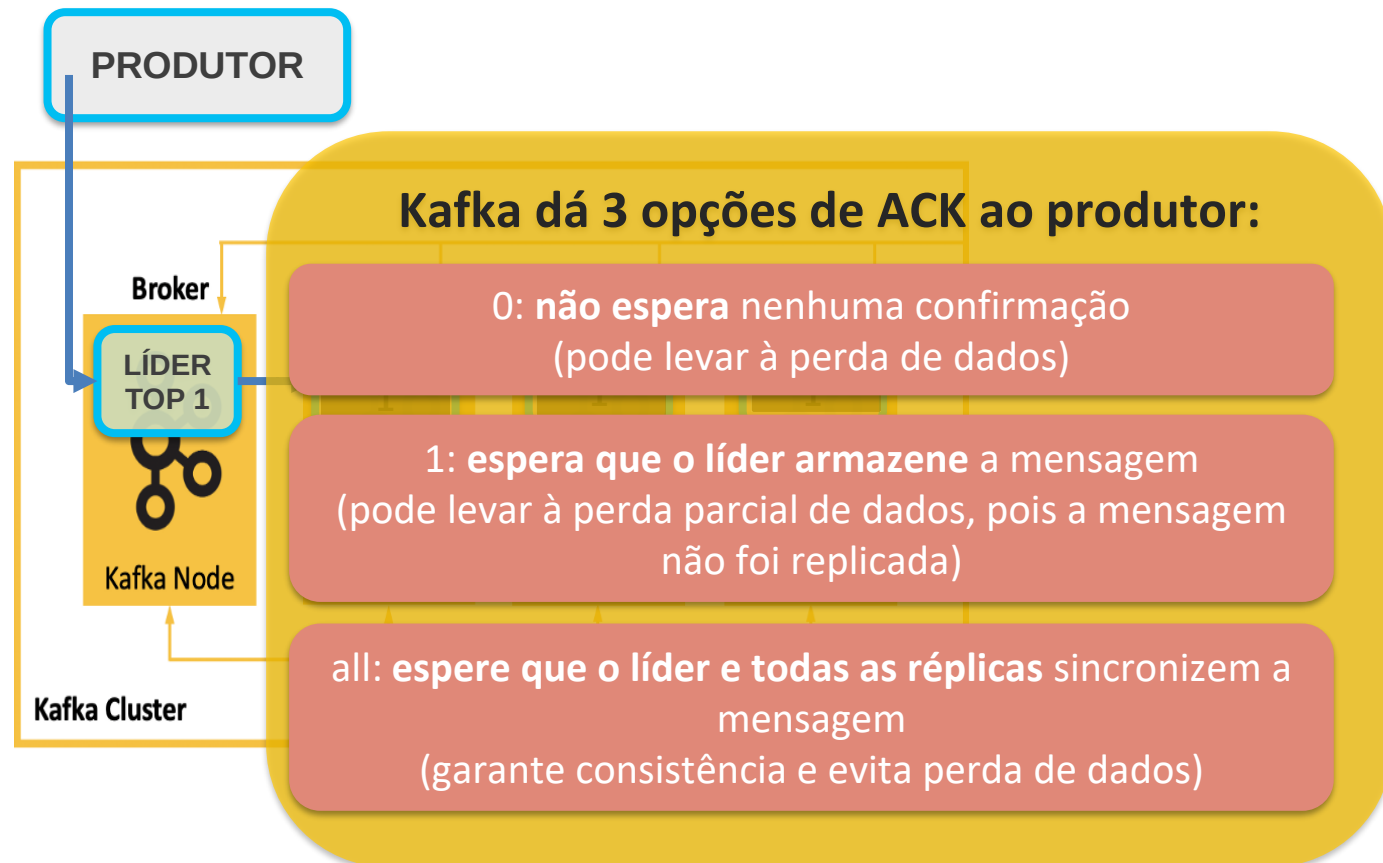
REPLICATION FACTOR: TÓPICO 1 tem 3 réplicas
TÓPICO 2 tem 1 réplica

Padrões de Arquitetura

Comunicação



Kafka Topics: REPLICATION FACTOR




Padrões de Arquitetura

Comunicação




Kafka : PARTITIONS e CONSUMER GROUPS
(leitura em paralelo por réplicas da mesma aplicação)



As operações de **leitura e gravação** em cada partição **ocorrem em paralelo**


Padrões de Arquitetura

Comunicação



Kafka : PARTITIONS e CONSUMER GROUPS


Cada réplica consome mensagens de uma ou mais partições.



Os consumidores podem receber as mensagens de partições diferentes fora da ordem


Padrões de Arquitetura

Comunicação



Kafka : PARTITIONS e CONSUMER GROUPS
(leitura em paralelo por **réplicas da mesma aplicação**)

PRODUTOR




Mensagens podem ser distribuídas nas partições de 3 maneiras:

1. **Round-robin** (usado no caso de mensagens que possam ser consumidas **fora de ordem**)
2. **Definir explicitamente** para qual **partição** o Kafka deve enviar uma mensagem
3. **Atribuir uma chave à mensagem** e o Kafka usa a mesma participação de acordo com essa chave


Padrões de Arquitetura

Comunicação




Kafka : PARTITIONS e CONSUMER GROUPS
(leitura em paralelo por réplicas da mesma aplicação)

Caso de uso onde a ordem das Mensagens é importante:




Padrões de Arquitetura

Comunicação



Kafka : PARTITIONS e CONSUMER GROUPS (usar a mesma partição)

Caso de uso onde a ordem das Mensagens é importante:




Padrões de Arquitetura

Comunicação



Consumer : OFFSETs (*auto-commmit* : *True* or *False*)
(Kafka **NÃO** aguarda ACK,
JÁ considera as mensagens como entregues)


Como tratar falhas e mensagens duplicadas?



Fonte: <https://betterprogramming.pub/how-to-handle-duplicate-messages-and-message-ordering-in-kafka-82e2fef82025>

Padrões de Arquitetura


Comunicação



Consumer : OFFSETs (*auto-commmit* : *True* or *False*)
(Kafka **AGUARDA** o **ACK**
para considerar as mensagens como entregues)

Como tratar falhas e mensagens duplicadas?

1 Kafka sends a batch of messages to consumer



auto-commmit = False

Consumer



processed messages

Padrões de Arquitetura

Comunicação



Consumer : OFFSETs (*auto-commmit* : *True or False*)


Existem 2 situações para lidar com mensagens duplicadas:

1. Consumo da mesma mensagem **não gera problemas** (ex: consumir 2 vezes o **evento ORDER_CANCEL**)

2. Quando não é possível consumir mensagens duplicadas (ex: **evento ORDER_PAYMENT** geraria 2 cobranças), a APP deve-se **guardar as mensagens recebidas e descartar duplicatas**


Padrões de Arquitetura

Comunicação



Kafka : Transações (requerem operações atômicas)

Evitando o consumo de Mensagens duplicadas:



Pattern: Transactional outbox

Padrões de Arquitetura


Comunicação



Kafka: Tolerância a falha



Desafios em DATAOPS : ELT x **ELT**



Manifesto DATAOPS



Princípios do DataOps

1**Satisfaça continuamente o seu cliente:**

Nossa maior prioridade é satisfazer o cliente através da entrega antecipada e contínua de informações analíticas valiosas que podem ser de 2 minutos até duas semanas.

2**Valor do trabalho analítico:**

Acreditamos que a principal medida do desempenho da análise de dados é o grau em que as análises são entregues, incorporando dados precisos, a bases de dados e sistemas robustos.

3**Abrace a mudança:**

Acolhemos as necessidades dos clientes em evolução e, de fato, as adotamos para gerar vantagem competitiva. Acreditamos que o método de comunicação mais eficiente, eficaz e ágil com os clientes é a conversa face a face.

4**É um esporte em equipe:**

As equipes analíticas sempre terão uma variedade de funções, habilidades, ferramentas favoritas e títulos. Uma diversidade de origens e opiniões aumenta a inovação e a produtividade.

The DataOpsManifesto

<https://dataopsmanifesto.org/pt-pt/>

Manifesto DATAOPS



Princípios do DataOps

5

Interações diárias:

Clientes, equipes de análise de dados e operações devem trabalhar juntas durante todo o projeto.

6

Auto-organização:

Acreditamos que a melhor visão analítica, algoritmos, arquiteturas, requisitos e projetos emergem de equipes auto-organizadas.

7

Reduza o heroísmo:

À medida que o ritmo e a amplitude da necessidade de insights analíticos aumentam, acreditamos que as equipes devem se esforçar para reduzir o heroísmo e criar equipes e processos sustentáveis e escaláveis.

8

Refleta:

Equipes de análise de dados devem aperfeiçoar seu desempenho nas operações através de uma auto-reflexão, em intervalos regulares, sobre os feedbacks fornecidos por seus clientes, por eles próprios e pelas estatísticas operacionais.

The DataOpsManifesto

<https://dataopsmanifesto.org/pt-pt/>

Manifesto DATAOPS



Princípios do DataOps

9

Os códigos:

As equipes usam uma variedade de ferramentas para acessar, integrar, modelar e visualizar dados. Fundamentalmente, cada uma dessas ferramentas gera códigos e configurações que descrevem as ações tomadas sobre dados para fornecer informações.

10

Orquestração:

Orquestração de dados, ferramentas, códigos, ambientes e equipes de trabalho são fatores-chave para o sucesso dos projetos de análise de dados.

11

Faça tudo ser reproduzível:

São necessários resultados reproduzíveis e, portanto, nós versionamos tudo: dados, configurações de hardware e software, código e configurações específicas de cada ferramenta utilizada.

12

Ambientes descartáveis:

Acreditamos que é importante minimizar o custo para os membros das equipes de análise de dados fazerem experimentações, proporcionando-lhes facilidade de criar ambientes técnicos descartáveis, isolados e seguros que reflitam o ambiente de produção.

The DataOpsManifesto

<https://dataopsmanifesto.org/pt-pt/>

Manifesto DATAOPS



Princípios do DataOps

13

Simplicidade:

Acreditamos que a atenção contínua à excelência técnica e ao bom design aumenta a agilidade; bem como a simplicidade – a arte de maximizar a quantidade de trabalho não feito – é essencial.

14

Análise de dados é manufatura:

Os pipelines de análise de dados são análogos às linhas de fabricação enxuta. Acreditamos que um conceito fundamental de DataOps é o foco no pensamento processual destinado a alcançar eficiência contínua na construção de insights analíticos.

15

A qualidade é primordial:

Os pipelines de análise de dados devem ser construídos com uma fundação capaz de detectar automaticamente erros no código, configuração e dados, e devem fornecer feedback contínuo aos operadores para evitar erros.

The DataOpsManifesto

<https://dataopsmanifesto.org/pt-pt/>

Manifesto DATAOPS



Princípios do DataOps

16**Monitorar a qualidade e o desempenho:**

Nosso objetivo é ter medidas de desempenho e qualidade que sejam monitoradas continuamente para detectar variações inesperadas e gerar estatísticas operacionais.

17**Reutilizar:**

Acreditamos que um aspecto fundamental da eficiência na fabricação de insights analíticos é evitar a repetição do trabalho anterior pelo indivíduo ou pelo time.

18**Melhorar os tempos dos ciclos:**



Devemos nos esforçar para minimizar o tempo e o esforço para transformar a necessidade de um cliente em uma ideia analítica, criá-la em desenvolvimento, liberá-la como um processo de produção repetível e, finalmente, refatorar e reutilizar esse produto.

The DataOpsManifesto

<https://dataopsmanifesto.org/pt-pt/>

DataOps com Contêineres

Componentes do nosso COMÉRCIO DIGITAL




**AGILIDADE NAS
DECISÕES**

Desafios em DATAOPS : LAMBDA x KAPPA

ARQUITETURA LAMBDA

Option 1: Unified serving layer




Nessa arquitetura, mantém-se 2 camadas:
processamento baseado em eventos + processamento batch

Desafios em DATAOPS : LAMBDA x KAPPA

ARQUITETURA LAMBDA


Option 2: Separate serving layers



LOAD dos dados pode ocorrer em armazenamento único (opção 1), ou em áreas distintas (opção 2)

Camada Batch:


usada na arquitetura LAMBDA



Desafios em DATAOPS : LAMBDA x KAPPA


ARQUITETURA KAPPA

One pipeline for real-time and batch consumers



Nessa arquitetura, mantém-se somente o processamento baseado em eventos

Camada Real Time: usada nas arquiteturas LAMBDA e KAPPA



Desafios em DATAOPS : LAMBDA x KAPPA

ARQUITETURA LAMBDA

Código duplicados

2 código diferentes: mudanças em um lugar precisam ser propagadas para o outro

Qualidade dos dados

Algoritmos
Batch X Stream
são equivalentes?
Como validar?

Complexidade

Como atrasos no processamento Batch podem impactar a camada de Stream?

Maior esforço

Duplicidade de recursos de infraestrutura, monitoramento e suporte

ARQUITETURA KAPPA

Reprocessamento de dados

O que acontece quando é preciso adicionar um campo?

Dados fora de ordem

O que fazer com os registros que chegam atrasados?

Custos


Quanto tempo manter os registros armazenados na ferramenta de Eventos?

Joins de dados

Como unir dados separados em 25 tabelas armazenadas separadamente?

DATA PIPELINE

Data lake reference architecture




ELT x ETL

menor tempo de carga, transformação
quando necessária

Vamos nos Divertir!


FIAP





O que vimos até aqui:

- Princípios de DataOps
- Arquitetura Lambda x Arquitetura Kappa
- Arquitetura DataOps
- Data pipeline e ML



CASOS DE USO



AIOPS : IA para Operações de TI

Software tradicional


Rotinas de programação com um conjunto específico de instruções para completar uma tarefa

Inteligência artificial

Treinamento do software usando uma enorme quantidade de dados com algoritmos que aprendem a executar uma tarefa




AIOPS : ML versus Deep Learning




AIOPS : ML versus Deep Learning

APRENDIZADO DE MÁQUINA



SUPERVISIONADO

É necessário um **dataset de treino** para ensinar o algoritmo a **predizer resultados**



NÃO SUPERVISIONADO

Não há *dataset* para treino, ou seja, não há **informação prévia sobre os dados**



POR REFORÇO

Assemelha-se com o primeiro ao aprender com as experiências anteriores e com o segundo ao aprender de uma forma não supervisionada

AIOPS : ML versus Deep Learning

Como funciona Deep Learning na identificação de imagens?



Calista Flockhart – Wikipédia,...
pt.wikipedia.org



Calista Flockhart - Wikipedia
en.wikipedia.org



Calista Flockhart - Television Actress, ...
biography.com



Calista Flockhart - IMDb
imdb.com



Calista Flockhart emerges mak...
dailymail.co.uk



Calista Flockhart Joins 'Super...
time.com



Calista Flockhart Celebrates...
instyle.com



Calista Flockhart: Biography
hellomagazine.com



Calista Flockhart | Bio - son,husba...
articlebio.com



Calista Flockhart — Fotogr...
pt.depositphotos.com




Calista Flockhart, 52, feels older than Harris...
pagesix.com



Harrison Ford e Calista Floc...
colunas.revistaepoca.globo.com


AIOPS : ML versus Deep Learning



- 1) Encontrar um rosto
- 2) Identificar características únicas
- 3) Comparar com uma base existente




Calista Flockhart – Wikipédia, ...
pt.wikipedia.org



Calista Flockhart: Biography ...
hellomagazine.com



Calista Flockhart Joins 'Super...
time.com



Calista Flockhart Celebrates...
instyle.com



Calista Flockhart: Biography ...
hellomagazine.com



Calista Flockhart | Bio - son,husba...
articlebio.com



Calista Flockhart — Fotogr...
pt.depositphotos.com



Calista Flockhart, 52, feels older than Harris...
pagesix.com





Harrison Ford e Calista Floc...
colunas.revistaepoca.globo.com


AIOPS : ML versus Deep Learning

TÉCNICAS DE MACHINE LEARNING


depende do tipo de resposta que estamos procurando



É um tumor?
Sim/Não



Quanto custa uma casa?



Separar elementos

AIOPS : ML versus Deep Learning

TÉCNICAS DE MACHINE LEARNING

SUPERVISED LEARNING



Develop predictive model based on both input and output data

CLASSIFICATION

É um tumor?
Sim/Não

REGRESSION

Quanto custa
uma casa?



AIOPS : ML versus Deep Learning


TÉCNICAS DE MACHINE LEARNING

SUPERVISED LEARNING

Develop predictive model based on both input and output data

REGRESSION

Quanto custa uma casa de 60 m²?



AIOPS : ML versus Deep Learning

TÉCNICAS DE MACHINE LEARNING

SUPERVISED LEARNING




Develop predictive model based on both input and output data

Outras variáveis influenciam o preço

REGRESSION

Distância do centro
X
Número de quartos

Quanto custa uma casa de 25 m2 com 1 quarto?



AIOPS : ML versus Deep Learning

TÉCNICAS DE MACHINE LEARNING




ML é a prática de usar algoritmos em dados para fazer uma predição com base nesses dados

SUPERVISED LEARNING

Develop predictive model based on both input and output data

$$w_0 * \text{dist_to_city_center} + w_1 * \text{rooms} + w_2 * \text{size} + b = \text{price}$$

As close as possible




AIOPS : ML versus Deep Learning

TÉCNICAS DE MACHINE LEARNING

MACHINE LEARNING

Som ambiente captado por 2 microfones

Cocktail party problem



AIOPS : ML versus Deep Learning

TÉCNICAS DE MACHINE LEARNING

Qual técnica utilizar para o exemplo anterior?


MACHINE LEARNING

CLASSIFICATION


REGRESSION

CLUSTERING


Training Dataset



Feeding All
Samples



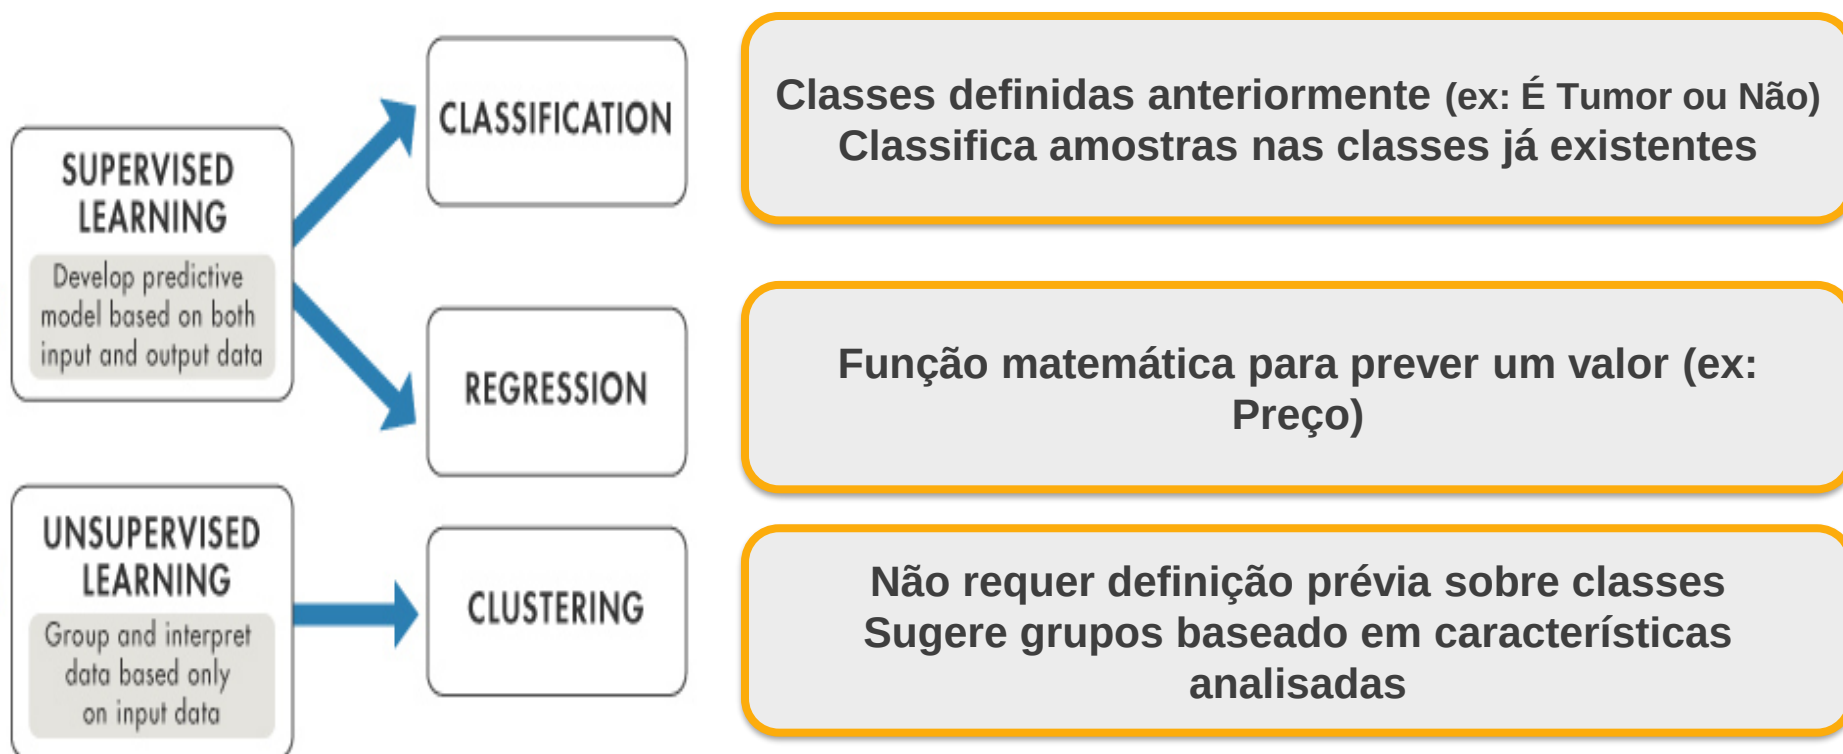
Finding
Patterns



AIOPS : ML versus Deep Learning

TÉCNICAS DE MACHINE LEARNING

Principais diferenças



AIOPS : ML versus Deep Learning

TÉCNICAS DE MACHINE LEARNING


UNSUPERVISED LEARNING

Group and interpret data based only on input data

Separação de elementos com características diferentes

The cocktail-party problem

How to amplify one voice among many



Source: Nima Mesgarani, Columbia University

AIOPS : ML versus Deep Learning

TÉCNICAS DE MACHINE LEARNING

UNSUPERVISED LEARNING

Group and interpret
data based only
on input data


Features: quais **características das amostras** podem ser analisadas para separar em diferentes grupos?

Tom de voz
(ex: suave)

**Volume da
VOZ**
(ex: baixo)

Timbre
(ex: agudo)

Convolutional DBN for audio




AIOPS : ML versus Deep Learning

TÉCNICAS DE MACHINE LEARNING

Exemplo 2 : Qual é o som da chuva e qual é o som das ondas do mar?

UNSUPERVISED LEARNING



Group and interpret data based only on input data



AIOPS : ML versus Deep Learning

Machine Learning x Deep Learning:



No Deep Learning a identificação de **FEATURES**
é feita pelo próprio modelo



AIOPS : ML versus Deep Learning

Outra técnica de Machine Learning:

Reinforcement Learning: treina um Agente para atingir um Objetivo por meio de Recompensas ou Punições



AIOPS : ML versus Deep Learning

Notícias sobre IA na Amazon

Tecnologia

Você está demitido! Amazon abandona robô recrutador que virou machista

REUTERS

Jeffrey Dastin

11/10/2018 11h32

Os especialistas em tecnologia de aprendizado de máquinas da Amazon descobriram um grande problema: **seu novo mecanismo de recrutamento de pessoal não gosta de mulheres.**

A equipe vinha criando programas de computador desde 2014 para revisar os currículos dos candidatos a emprego, com o **objetivo de automatizar a busca por talentos**, disseram à Reuters cinco pessoas familiarizadas com o esforço.

A ferramenta experimental de contratação da empresa utilizou inteligência artificial para dar aos candidatos a emprego na companhia **pontuações que variam de uma a cinco estrelas** - da mesma forma que os compradores avaliam produtos na Amazon, disseram algumas pessoas.

Fonte:

<https://noticias.uol.com.br/tecnologia/noticias/reuters/2018/10/11/voce-esta-demitido-amazon-abandona-robo-recrutador-que-virou-machista.htm>



Amazon Echo, alto-falante que grava vozes dos seus usuários

Imagem: Divulgação

Testemunha incomum: alto-falante da Amazon poderá resolver assassinato

Márcio Padrão

Do UOL, em São Paulo

13/11/2018 10h54


Um juiz dos EUA instruiu a **Amazon** a entregar gravações de áudio de um Echo, alto-falante inteligente da empresa, como prova em um caso de duplo homicídio, segundo a rede de TV norte-americana ABC.

Fonte:

<https://noticias.uol.com.br/tecnologia/noticias/redacao/2018/11/13/testemunha-incomum-alto-falante-da-amazon-podera-resolver-assassinato.htm>

AIOPS : ML versus Deep Learning

RESUMO: principais Casos de Usos



Definição de AIOps

AIOps é a aplicação de APRENDIZADO DE MÁQUINA e CIÊNCIA DE DADOS para domínios e **PROBLEMAS DE OPERAÇÕES DE TI.**

disponibilidade e monitoramento de desempenho


correlação e análise de eventos para identificar causa de falhas

AIOPS : Profissionais de DevOps

FIAP

Profissionais de TI devem estar preparados para a adoção de AIOPS


Identificar oportunidades e cenários para aplicação de ML



Estabelecer procedimentos para operações com base em algoritmos preditivos

AIOPS : Visão Geral da Arquitetura

Visualização: Insights correlacionados / analisados



Vamos nos Divertir!

FIAP



O que vimos até aqui:

- Aprendizagem por Machine Learning (ML)
 - Supervisionada
 - Não Supervisionada
 - por Reforço
- Machine Learning versus Deep Learning
- AIOPS e os Profissionais de TI
- Funcionalidades de AIOPS

OBRIGADO



FIAP

Copyright © | Professor André Pontes Sampaio
 Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente
 proibido sem consentimento formal, por escrito, do professor/autor.

