


FIAP

NABA



Armazenamento de Dados

Prof. Fábio Jardim

Banco de Dados


Bancos de dados específicos para problemas específicos.
Difícilmente um banco de dados vai ser ótimo para todos os cenários.

SQL

Relational



Analytical




NoSQL


Key - Value




Graph



Document



Wide Column




Evolução dos bancos de dados

1960, quando o uso de computadores torna-se mais acessível para as empresas. Paper de Edgar Frank Codd mudou a forma de pensar sobre os bancos de dados, criando o modelo relacional entre 1960 e 1970.

Na década de 1980 a linguagem SQL foi padronizada.


A partir de 1990 aplicações como Oracle, começaram a ser criadas.

History of Databases (1960-2020)



OLTP

On Line Transaction Process.
Banco de dados transacional, utilizado para aplicações diversas.
Muitas transações rápidas e pequenas ocorrem simultaneamente.




OLAP

On Line Analytical Process

Banco de dados otimizado para consultas e relatórios, em vez de processar transações.

Modelagem de dados diferente do OLTP.

Cargas podem ser realizadas por ETL.



OLAP vs OLTP

	OLAP	OLTP
Objetivo	Analisar grandes volumes de dados para tomada de decisão	Gerenciar e processar transações em tempo real
Fonte de Dados	Dados históricos de várias fontes	Dados de sistemas atualizados em tempo real
Estrutura de Dados	Multidimensional (cubos) ou relacional	Relacional
Modelagem	Star Schema, Snow Flake e outros	Normalização
Volume	Grande quantidade de dados	Banco de dados mais enxuto, otimizado para transação
Tempo de Resposta	Segundos ou minutos	milisegundos
Exemplo	Relatórios, exploração de dados, análise de dados	Sistema ERP, sistemas diversos, ecommerce

NoSQL

Bancos de dados de próxima geração

Not Only SQL

Open Source

Horizontalmente escaláveis

Atualmente mais de 225


Início em 2009 e está crescendo rapidamente



Not Only SQL

NoSQL

Bancos de dados modernos na web
Suporte a replicação fácil
Livre de esquema / Flexíveis
Eventualmente consistente / não ACID
Não-relacionais
Distribuídos



Tipos de Nosql

Column Store / Column Families

Document Store

Key Value / Tuple Store

Graph Databases

Multimodel Databases

Object Databases

XML Databases


Multidimensional Databases

Multivalue Databases


Event Sourcing

Time Series / Streaming Databases


Document




Graph



Key-Value



Wide-column



Document

Conhecidas como dados
semiestruturados


Principais categorias de bancos
de dados NoSQL

JSON

Inerentemente uma subclasse do
armazenamento de chave-valor
MongoDb, Elastic, DocumentDb,
Couchbase, etc...

Document Model

Collection ("Things")




Key Value

Altamente particionáveis

Escalabilidade horizontal
avançada

Muito utilizado em IoT, cache e
web

DynamoDb, Redis, MemcacheDB,
Riak, entre outros




Graph

Conjuntos de dados altamente conectados

Estruturas gráficas para consultas semânticas com nós e arestas

Utilizado em redes sociais, mecanismos de recomendação, detecção de fraudes e gráficos de conhecimento

Neo4J, TITAN, etc...




Teorema de CAP

Eric Brewer escreveu que existem 3 requisitos que possuem relação de dependência quanto a dados distribuídos.

Consistência: Ao inserir um dados, ele estará imediatamente disponível para consulta?

Disponibilidade: O banco de dados estará sempre disponível para leitura e gravação?

Tolerância à partição: Ele pode ser dividido em vários servidores e em caso de falha de alguns servidores, continuará funcionando?



Ranking

<https://db-engines.com/en/ranking>

Rank			DBMS	Database Model	Score		
Mar 2024	Feb 2024	Mar 2023			Mar 2024	Feb 2024	Mar 2023
1.	1.	1.	Oracle +	Relational, Multi-model ⓘ	1221.06	-20.39	-40.23
2.	2.	2.	MySQL +	Relational, Multi-model ⓘ	1101.50	-5.17	-81.29
3.	3.	3.	Microsoft SQL Server +	Relational, Multi-model ⓘ	845.81	-7.76	-76.20
4.	4.	4.	PostgreSQL +	Relational, Multi-model ⓘ	634.91	+5.50	+21.08
5.	5.	5.	MongoDB +	Document, Multi-model ⓘ	424.53	+4.18	-34.25
6.	6.	6.	Redis +	Key-value, Multi-model ⓘ	157.00	-3.71	-15.45
7.	7.	↑ 8.	Elasticsearch	Search engine, Multi-model ⓘ	134.79	-0.95	-4.28
8.	8.	↓ 7.	IBM Db2	Relational, Multi-model ⓘ	127.75	-4.47	-15.17
9.	9.	↑ 11.	Snowflake +	Relational	125.38	-2.07	+10.98
10.	10.	↓ 9.	SQLite +	Relational	118.16	+0.88	-15.66
11.	11.	↓ 10.	Microsoft Access	Relational	107.93	-5.24	-24.13
12.	12.	12.	Cassandra +	Wide column, Multi-model ⓘ	104.59	-4.69	-9.20
13.	13.	13.	MariaDB +	Relational, Multi-model ⓘ	95.03	-2.20	-1.81
14.	14.	14.	Splunk	Search engine	89.68	-1.97	+1.71
15.	↑ 16.	↑ 16.	Microsoft Azure SQL Database	Relational, Multi-model ⓘ	78.51	-1.06	+1.06
16.	↓ 15.	↓ 15.	Amazon DynamoDB +	Multi-model ⓘ	77.72	-5.18	-3.05
17.	17.	↑ 19.	Databricks +	Multi-model ⓘ	74.34	-2.57	+13.48
18.	18.	↓ 17.	Hive	Relational	64.82	-0.99	-6.09
19.	19.	↑ 21.	Google BigQuery +	Relational	62.67	-0.96	+9.23
20.	20.	↓ 18.	Teradata	Relational, Multi-model ⓘ	48.95	-2.29	-14.79
21.	21.	↑ 22.	FileMaker	Relational	48.81	-1.67	-2.33
22.	↑ 23.	↑ 23.	SAP HANA +	Relational, Multi-model ⓘ	45.49	+0.27	-5.36
23.	↓ 22.	↓ 20.	Neo4j +	Graph	44.36	-2.25	-9.15
24.	24.	24.	Solr	Search engine, Multi-model ⓘ	43.91	-0.69	-3.36
25.	25.	25.	SAP Adaptive Server	Relational, Multi-model ⓘ	37.49	-1.85	-5.46

Exemplo

Pesquisa textual com Document Index

Cache da sessão com Key Value

Catálogo e descrição do produto com Document

Sistema de recomendação com Grafos

Finalização da transação com Banco Relacional

Auditoria com Column Store

amazon.com.br

Enviar para 04523000

Todos Pesquisa Amazon.com.br

Olá, faça seu login Contas e Listas Devoluções e Pedidos Carrinho

Todos Venda na Amazon Mals Vendidos Prime Ofertas do Dia Livros Música Idéias de Presente Eletrônicos Computadores Novidades na Amazon Casa Games Cuidados Pessoais

Dispositivos Amazon Echo e Alexa Kindle Fire TV Acessórios Casa Inteligente Conheça Alexa Dispositivos e conteúdo Ajuda

Ouçã audiolivros na Audible

Echo Pop | Smart speaker compacto com som envolvente e Alexa | Cor Preta

Marca: Amazon

4,8 ★★★★★ 39.949 avaliações de clientes | Pesquisar nesta página

Escolha da Amazon

Mais de 3 mil compras no mês passado

R\$314¹⁰

à vista no Pix e boleto (10% off)

ou R\$ 349,00 em até 12x de R\$ 29,12 sem juros Ver parcelas disponíveis

Pagamentos e Segurança Entrega gratuita Enviado pela Amazon Política de devolução

Configuração: Echo Pop

Cor: Preto

Para desligar os microfones, basta pressionar o botão de desligar

Para desligar os microfones, basta pressionar o botão de desligar

Passe o mouse para ampliar a imagem

Veja o que Alexa pode fazer

APRESENTAMOS O ECHO POP - Este smart speaker compacto com Alexa conta com som de qualidade e é perfeito para quartos e espaços pequenos. Pequeno o suficiente para combinar com o ambiente, mas poderoso o bastante para se destacar.

CONTROLE A MÚSICA POR VOZ - Peça para Alexa tocar músicas e podcasts nas suas plataformas preferidas, como Amazon Music, Apple Music, Spotify, Deezer e outras. Conecte-o também por Bluetooth e ouça músicas do seu celular em todo o ambiente.

TORNE SUA CASA INTELIGENTE - Controle dispositivos de casa inteligente compatíveis, como plugues ou lâmpadas inteligentes, com sua voz ou pelo aplicativo Alexa. Crie rotinas para ligar as luzes ao pôr do sol ou para apagá-las automaticamente na hora de dormir.

R\$314¹⁰

à vista no Pix e boleto

Ou em até 12x de R\$ 29,12/mês

Entrega GRÁTIS: 7 - 8 de Março

Ou entrega mais rápida: Amanhã, 4 de Março. Se pedir dentro de 7 hrs 48 mins

Enviar para 04523000

Em estoque

Quantidade: 1

Adicionar ao carrinho

Comprar agora

Enviado por: Amazon.com.br

Vendido por: Amazon.com.br

Devolução: Elegível para Devolução, Reembolso ou Troca em até 30 dias após o recebimento

Pagamento: Transação segura

☐ Sim, eu quero frete GRÁTIS para este pedido com o Amazon Prime

☐ Este pedido é para presente

☒ Vincular o dispositivo à sua conta Amazon para simplificar a configuração. Por que isso é importante?


Adicionar mais produtos

☐ Capa para Echo Pop: Lilás R\$ 79,00


☐ Lâmpada Inteligente RGB Elgin: Lâmpada 10W R\$ 44,66

Escolhendo a tecnologia


Atualmente, cada problemas pode ter a solução em um mecanismo de dados diferente.




Armazenamento distribuído




Evolução modelo analítico



Ecossistema de Dados Atual





Data Lake Zones

Raw Zone: Zona de chegada do dado, sem transformação ou manipulação. Empilhamento de dados.

Process Zone: Dados vindos da Raw Zone ou Streaming. São dados já tratados, ou seja, sofreram transformações e estão prontos para serem consumidos e extraídos de forma confiável. Dados generalizados.

Access Zone: Dados tratados e aplicados regra de negócio. Geralmente atendem uma aplicação ou problema de negócio.

Outras nomenclaturas encontradas

Raw Zone	Raw Zone	Camada Bronze	Raw Data
Process Zone	Refined Zone	Camada Prata	Cleaned
Access Zone	Trusted Zone	Camada Ouro	Application

Apache Parquet

Open Source

Armazenamento colunar

Eficiência na leitura

Compactação

Schema

Mais utilizado em ambientes diversos

<https://parquet.apache.org/>



Apache ORC

Open Source

Armazenamento colunar

Suporte a ACID

Melhor performance com Hive

Formato para o ambiente Hadoop

<https://orc.apache.org/>



Apache Avro

Open Source

Serialização de dados

Streaming

Melhor utilização em real time/eventos

<https://avro.apache.org/>



Apache Arrow

Open Source


Formato Colunar

In Memory

Rápido

Integrações entre sistemas Big Data

<https://arrow.apache.org/>



Delta Lake

Criado pela Databricks

Open Source

Formato Lakehouse mais utilizados atualmente.

Permite ingerir e consumir dados de streaming e em lote de maneira integrada com uma arquitetura de solução.

Recursos transacionais



Apache Iceberg

Criado pela Netflix

Open Source

Suporta Parquet, ORC e Avro

Popular devido a integração com outros Frameworks



Apache Hudi

Criado pela Uber
Open Source
Recursos de Data Warehouse
Streaming
Processamento incremental
Suporta Parquet e ORC




O poder da compressão

Compression Technique	Compression Ratio	Compression Speed	Decompression Speed	Storage Space	Parallel Processing
<u>Gzip</u>	High	Moderate	Moderate	Moderate	No
Snappy (default)	Moderate	High	High	Moderate	No
LZO	Low	Very High	Very High	Low	No
<u>Brotli</u> (new)	Very High	Low	Low	Very Low	Yes

Exemplo

Dataset	Columns	Size on Amazon S3	Data Scanned	Cost
Data stored as CSV file	4	4TB	4TB	\$20 (4TB x \$5/TB)
Data stored as GZIP CSV file	4	1TB	1TB	\$5 (1TB x \$5/TB)
Data stored as Parquet file	4	1TB	.25TB	\$1.25 (.25TB x \$5/TB)

Apache Hadoop



O que é Hadoop


- Plataforma que fornece infraestrutura de dados, econômica e escalável
- Processamento em lote para grandes quantidade de dados
- Armazenamento e processamento distribuído
- Precursor do ecossistema Big Data
- Servidores commodities
- 4 módulos na versão 2.2, atualmente na versão 3
- HDFS, MapReduce, Hadoop Common e Yarn

História

- Criado por Doug Cutting e Mike Cafarella
- Hadoop era o nome do elefante amarelo de pelúcia do filho de Doug
- Caminho para vários outros projetos, compondo o ecossistema Big Data



História



Características do Hadoop

- Baixo custo
- Flexibilidade de armazenamento
- OpenSource
- Tolerante a falha
- Análise complexa de dados
- Escalabilidade

Onde usar Hadoop

- Análise de vídeo, imagem e texto
- Análise de sentimentos
- Data Lake
- Reconhecimento de padrões
- data warehousing
- Armazenamento
- Processamento de logs

Mode de execução

- Standalone
- Pseudo distribuído
- Distribuído
- Docker


Standalone

Todos serviços Hadoop são executados em uma única JVM

Hadoop usa o sistema de arquivos local e não o HDFS para armazenar seus dados

MapReduce são executados com um único map e um único reduce

Utilizado para que os desenvolvedores executem seu código



Pseudo-Distribuído

Simulação de um verdadeiro cluster multinode

Todos os daemons (como os processos DataNode, NameNode e Resource Manager) são executados em um único servidor

Não há como configurar replicação de dados ou alta disponibilidade





Distribuído

Cluster Hadoop utilizando múltiplos servidores



Daemons para cada processo e os daemons são executados em vários servidores



Docker



Componentes



Hadoop Common

- É a coleção de utilitários comuns e bibliotecas que oferecem suporte a outros módulos Hadoop.
- Também conhecido como Hadoop Core
- Java Archive (JAR)
- Arquivos necessários para iniciar o Hadoop



MapReduce



O que é MapReduce

- Estrutura de processamento distribuído de dados que pode ser utilizada para processar enormes quantidades de dados armazenados em HDFS.
- Abstração de processamento distribuído, fornecendo paralelização automática dos programas e suporte gerenciado de tolerância a falhas.

Onde não usar MapReduce

- Consultas com baixa latência
- Real Time
- Poucos dados

Características

- Processamento paralelo
- Ambiente distribuído
- Escalável
- Tolerantes a falhas
- Processar um grande volume de dados
- Programas desenvolvidos em Java, Python, Ruby e C++

Map

- Ponto de partida
- Recebe cada registro dos dados de entrada como pares de chave/valor
- Cada Mapper é independente um do outro, permitindo paralelismo e re-execuções de tarefas
- Hadoop cria tarefas de Mapper para cada bloco de dados HDFS dos dados de entrada.
- Produz uma lista de chave/valor

Reduce


- Responsável por agregações, filtros e combinações diversas nos dados de entrada
- Executa uma função de reduce por vez
- Shuffle: Distribui as saídas dos mappers para a execução do reducer
- Sort: Ordena os registros chave/valor, agrupando pela chave
- Reduce: Envia os conjuntos chave/valor agrupados, filtrados ou combinados o formato de saída

Shuffle e Sort

- Shuffling: Processo responsável pela transferência do dado do Map para o Reduce.
- Sorting: Ordena os pares de valores-chave gerados pelo map. A ordenação economiza tempo para o reduce, ajudando a distinguir facilmente quando uma nova tarefa de redução deve ser iniciada.

Exemplo

The overall MapReduce word count process



YARN



O que é YARN

- Yet Another Resource Negotiator
- Plataforma genérica para gerenciar recursos em um cluster
- Foi introduzido com o Hadoop 2.0
- Fez Hadoop ser um sistema de processamento de dados muito mais poderoso
- Propósito de resolver as limitações do Hadoop 1.x como limite de escalabilidade e gerenciamento de recursos


O que é YARN

- Permite que vários aplicativos sejam executados simultaneamente no mesmo cluster compartilhado
- Permite que os aplicativos negociem recursos com base na necessidade
- Implantado no Yahoo! desde setembro de 2012
- Em 2012 tornou-se um dos subprojetos do Apache Hadoop
- Ganhou o Prêmio Melhor Papel no Symposium ACM em Cloud Computing (SoCC) em 2013!

Arquitetura

- Duas principais funcionalidades: gerenciamento de recursos e agendamento/monitoramento de tarefas
- Arquitetura Master-Worker
- ResourceManager é o Master e NodeManager é o Worker

Execução YARN



HDFS



O que é HDFS

- HADOOP DISTRIBUTED FILE SYSTEM
- Tolerante a falhas
- Escalável
- Portabilidade
- Processo vai aos dados
- Projetado para arquivos muito grandes
- Desenvolvido em Java

O que é HDFS

- Coerência de dados (Escreva uma vez, leia muitos)
- Pode usar hardware commodity
- Não projetado para baixa latência
- Bloco de 128MB por padrão
- NameNode e DataNode
- Fator de replicação padrão igual 3

Componentes HDFS

- NameNode
- DataNode

NameNode

- Gerencia o sistemas de arquivos e regula acesso
- Armazena metadados
- Usa cache em RAM para acesso mais rápido ao metadado
- Não armazena dados
- Apenas 1 ativo por cluster
- Ponto único de falha sem HA (Alta Disponibilidade)
- HA no Haddop 2 com o NameNode em active-standby *


Secondary NameNode

- Também chamado de CheckPointNode
- Não é exigido, mas é recomendado
- Executado em um servidor separado do NameNode
- Executa pontos de verificação de status no NameNode
- Não é alta disponibilidade
- Armazena uma cópia do namespace do NameNode

DataNode

- Armazena os dados no HDFS
- Atende solicitações de leitura e gravação dos clientes ou NameNode
- Responsável por criar, excluir e replicar blocos de dados
- Reporta status para o NameNode (heartbeat)
- Em caso de falta de report o nó é desativado pelo NameNode
- Totalmente dependente do NameNode

Arquitetura



Servidores Hadoop



Calculando espaço no HDFS

Identificação do Consumo	Descrição	Total Disponível (TBs)
1	Espaço Bruto (10 DNs x 12 Discos x 4 TBs)	480
2	Saldo = (ID 1) - (Espaço consumido por formatação do disco e file systems ext4 = 10%)	432
3	Saldo = (ID 2) - (Espaço reservado para Tarefas MapReduce - Arquivos intermediários - área de work. Parâmetro: dfs.datanode.du.reserved = 25% de cada disco = 0,9 TB))	324
4	Saldo = (ID 3) / (Quantidade de replicas = 3)	108
5	Saldo = (ID 4) - (ID 4)*(% de espaço reservado backup)	54
6	Saldo final disponível para uso	54

Hadoop na prática

Verificar se os containers estão em execução:

```
docker ps | grep node
```

Acessando o container datanode:

```
docker exec -it namenode bash
```


hadoop

```
root@namenode:/# hadoop
Usage: hadoop [--config confdir] [COMMAND | CLASSNAME]
  CLASSNAME                run the class named CLASSNAME
or
  where COMMAND is one of:
  fs                        run a generic filesystem user client
  version                  print the version
  jar <jar>                run a jar file
                           note: please use "yarn jar" to launch
                           YARN applications, not this command.
  checknative [-a|-h]      check native hadoop and compression libraries availability
  distcp <srcurl> <desturl> copy file or directories recursively
  archive -archiveName NAME -p <parent path> <src>* <dest> create a hadoop archive
  classpath                prints the class path needed to get the
  credential               interact with credential providers
                           Hadoop jar and the required libraries
  daemonlog                get/set the log level for each daemon
  trace                    view and modify Hadoop tracing settings

Most commands print help when invoked w/o parameters.
```

hadoop fs

O shell do Sistema de arquivos (FS) inclui vários comandos tipo shell que interagem diretamente com o Hadoop Distributed File System (HDFS).
Fornece vários comandos de shell para executar operações, como copiar arquivo, visualizar o conteúdo do arquivo, alterar a propriedade de arquivos, alterar permissões, criar diretórios, etc...O shell FS é invocado por:

```
hadoop fs {args}
```

```
hdfs dfs {args}
```

```
hadoop dfs {args} (DEPRECATED)
```


Comandos HDFS

appendToFile	deleteSnapshot	ls	setfacl
cat	df	lsr	setfattr
checksum	du	mkdir	setrep
chgrp	dus	moveFromLocal	stat
chmod	expunge	moveToLocal	tail
chown	find	mv	test
copyFromLocal	get	put	text
copyToLocal	getfacl	renameSnapshot	touchz
count	getfattr	rm	truncate
cp	getmerge	rmdir	usage
createSnapshot	help	rmr	

Comandos HDFS

Criar um diretório no HDFS:

```
hadoop fs -mkdir /aula
```

Listar o conteúdo do diretório do HDFS

```
hadoop fs -ls /aula
```

Inserir arquivo no HDFS a partir do FileSystem

```
hadoop fs -put hadoop.txt /aula
```

Visualizar conteúdo do arquivo no HDFS

```
hadoop fs -cat /aula/hadoop.txt
```

```
hadoop fs -tail /aula/hadoop.txt
```

Comandos HDFS

Mover arquivo dentro do HDFS

```
hadoop fs -mv /user/cloudera/aula/hadoop.txt /user/cloudera/
```

Copiar arquivo dentro do HDFS

```
hadoop fs -cp /user/cloudera/hadoop.txt /user/cloudera/aula
```

Remover arquivo do HDFS

```
hadoop fs -rm /user/cloudera/aula/hadoop.txt
```

Copiar arquivo do HDFS para o FileSystem

```
hadoop fs -get /user/cloudera/hadoop.txt /tmp/
```

Comandos HDFS

Visualização das configurações

```
hdfs dfsadmin -report
```

Verificar se o HDFS está em modo seguro

```
hdfs dfsadmin -safemode get
```

Tirar HDFS do modo seguro

```
hdfs dfsadmin -safemode leave
```

Verificar integridade do sistema de arquivo

```
hdfs fsck /
```

Comandos HDFS

Chegar arquivos

```
hdfs fsck /user/admin/teste.txt -files -blocks -locations
```

Interface Web

http://localhost:50070



Overview 'namenode:8020' (active)

Started:	Sun Jun 07 17:40:25 UTC 2020
Version:	2.7.4, rcd915e1e8d9d0131462a0b7301586c175728a282
Compiled:	2017-08-01T00:29Z by kshvachk from branch-2.7.4
Cluster ID:	CID-b0d69e90-953a-4203-9b36-0eabe988c462
Block Pool ID:	BP-1105607905-172.21.0.5-1591209566142

Summary

Security is off.

Safemode is off.

37 files and directories, 5 blocks = 42 total filesystem object(s).

Heap Memory used 36.88 MB of 331.5 MB Heap Memory. Max Heap Memory is 889 MB.

Non Heap Memory used 41.64 MB of 42.19 MB Committed Non Heap Memory. Max Non Heap Memory is -1 B.

Web

http://localhost:8888/

The screenshot displays the Apache Hue web interface. On the left is a dark blue sidebar with navigation links: Editor, Dashboard, Scheduler, Documents, Files (highlighted), Tables, Jobs, and Importer. The main content area is titled 'File Browser' and shows the current path as 'Home / user / admin'. It includes a search bar for file names, buttons for 'Actions' and 'Delete forever', and buttons for 'Upload' and 'New'. Below this is a table listing files and directories. The table has columns for Name, Size, User, Group, Permissions, and Date. Two items are listed: a directory named 'f' owned by 'root' and a directory named '.' owned by 'admin'. At the bottom, there is a pagination bar showing 'Show 45 of 0 items' and 'Page 1 of 1' with navigation controls.

Query

Search data and saved documents...

Jobs

Editor

Dashboard

Scheduler

Documents

Files

Tables

Jobs

Importer

File Browser

Search for file name

Actions

Delete forever

Upload

New

Home / user / admin


	Name	Size	User	Group	Permissions	Date
☐	f		root	supergroup	drwxr-xr-x	June 03, 2020 08:10 PM
☐	.		admin	admin	drwxr-xr-x	June 03, 2020 08:10 PM

Show 45 of 0 items

Page 1 of 1

S3 com Minio

- Sistema de armazenamento de objetos distribuídos de alto desempenho.
- É definido por software
- Open source
- Projetado desde o início para ser o padrão em armazenamento de objetos em nuvem privada/híbrida.
- Eficiente, escalável e leve.



S3 com Minio

http://localhost:9051

MINIO

OBJECT STORE

LICENSE

User

Object Browser

Access Keys

Documentation

Administrator

Buckets

Policies

Identity

Monitoring

Notifications

Tiers

Site Replication

Settings

Subscription

License

Support


Sign Out

Object Browser


Filter Buckets

Name	Objects	Size	Access
delta-lake	17	4.5 MiB	R/W
tmp	11	13.6 MiB	R/W

Arquitetura



Utilização










Referências

Documentação Oficial Hadoop (HDFS, MapReduce e Yarn):

<http://hadoop.apache.org/docs/current/>

Livros:



OBRIGADO



proffabio.jardim@fiap.com.br



Copyright © 2018 | Professor (a) Fábio Jardim
Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente proibido
sem consentimento formal, por escrito, do professor/autor.

FIAP