



Stream Processing Pipelines

Apache Flink

Prof. Rafael Pereira

Apache Flink

- O que é? / Por que usar?
- Arquitetura
- JobManager / TaskManager
- DataStream API / DataSet API
- Operações Comuns
- Tolerância a Falhas
- Exactly Once Guarantees
- Tópicos Avançados
- Lab Time

Apache Flink - O que é?

- Framework open-source para processamento de dados distribuído.
- Processa dados em lote e em tempo real (stream).
- Características principais: escalabilidade, alta performance e tolerância a falhas.




Apache Flink - Por que usar?

- Análise de dados em movimento: Detecção de fraudes, monitoramento de redes sociais, rastreamento de localização em tempo real.
- Reação instantânea a eventos: Processamento de pedidos online, sistemas de alerta, jogos online com interação em tempo real.
- Construção de pipelines de dados escaláveis: Ingestão de dados (IoT), ETL em tempo real, dashboards com dados atualizados continuamente.



Apache Flink - Arquitetura



Fonte: Flink Docs



Apache Flink vs Spark

FIAP



Spark is not a true real time processing. It is Near to real time processing framework.

At heart Spark is a Batch processing framework.

Spark's streaming computation model is based on Microbatching.

Spark is implemented in Scala.

Spark does not have an efficient memory manager.

Frequently gets Out of Memory.



Flink is True processing framework.

At heart Flink is a Stream processing framework.

Flink's Streaming model is based on Windowing and Checkpointing.

Flink is implemented in Java.

Flink has it's own efficient automatic memory manager.

Learn Real Time, Hands-On & Practical Implementation of Flink
Click on the link given in post description

All lectures and resources/codes) © copyright © reserved 2018

Fonte: [AWS](#)



Apache Flink – JobManager (O Maestro)



- Recebe as aplicações Flink.
- Coordena a execução das tarefas nos TaskManagers.
- Gerencia os recursos do cluster.
- Monitora o progresso da execução.
- Coordena a recuperação em caso de falhas.



| Apache Flink – TaskManager (Os Músicos) FIAP

- Recebem as tarefas do JobManager.
- Processam os dados de acordo com a aplicação.
- Trocam dados entre si para completar as tarefas.



Apache Flink - APIs

- O Apache Flink consegue operar tanto modo Batch, como em modo Streaming.
- Como? Fazendo o uso de APIs específicas para cada caso.
- Streaming Mode: DataStream API.
- Batch Mode: DataSet API.



Apache Flink – DataStream API

- Processa fluxos de dados ilimitados.
- Dados como um fluxo contínuo de eventos.
- Funcionalidades:
 - Janelas de Tempo: Processamento em intervalos específicos.
 - Marcas d'água: Lidando com a desordem de eventos (atrasos).



Apache Flink – DataSet API

- Processa conjuntos de dados finitos.
- Dados como um conjunto fixo.




Apache Flink – Operações Comuns



- map: Transformando dados (Ex: de JSON para Objetos).
- filter: Filtrando o que importa (Ex: temperatura > 30°C).
- reduce: Agregando para insights (Ex: soma, média, contagem).
- keyBy: Agrupando por características (Ex: por sensor, por usuário).
- windowing: Analisando janelas de tempo (Ex: últimos 5 minutos).

Apache Flink – Tolerância a Falhas

- Checkpointing:




Fonte: [Flink Docs](#)

- Criação de snapshots periódicos do estado da aplicação.
- Armazenados em sistemas de arquivos distribuídos (ex: HDFS).
- Recuperação: Retoma a partir do último checkpoint em caso de falha.

Apache Flink – Tolerância a Falhas

- Checkpointing:



Fonte: Medium



Apache Flink – Exactly Once Guarantees



- At-most-once: Entregue no máximo uma vez.
- At-least-once: Entregue pelo menos uma vez.
- Exactly-once: Entregue exatamente uma vez.



Apache Flink – Tópicos Avançados

- Tipos de Estado (Stateful / Stateless).
- Formas de Storage (In Memory, Disk, RocksDB).
- Keyed Event Partitioning (veremos isso no Lab Time).
- Tipos de Data Sources.
- Tipos de Data Sinks.
- Tipos de Motores (Standalone, YARN, Mesos, K8s).



- Vou mostrar um exemplo interessante de processamento em tempo-real de eventos de crédito.
- O código-fonte está em:
<https://nightlies.apache.org/flink/flink-docs-release-1.20/docs/try-flink/datastream/>
- Ou em uma versão mais simplificada em:
<https://github.com/blurred-machine/Flink-Fraud-Detection-with-DataStream-API/tree/main>

Dúvidas?

FIAP



MBA⁺

Copyright © **2023-2025** - Prof. Rafael Tsuji Matsuyama
e Prof. Rafael S Novo Pereira

Todos direitos reservados. Reprodução ou divulgação
total ou parcial deste documento é expressamente
proibido sem o consentimento formal, por escrito, do
Professor (autor).