

Stream Processing Pipelines

MBA⁺

**AWS Kinesis Data Analytics
e Data Pipelines**

Prof. Rafael S Novo Pereira

AWS Kinesis Data Analytics e Data Pipelines e S

- Comparações
- Integrações
- Características
- Escolhas das Nuvens
- Cases Arquiteturais
- Precificação
- Data Pipelines

O **Amazon Kinesis** é um serviço AWS gerenciado para capturar, armazenar e analisar grandes volumes de dados em tempo real. Ele lida com eventos contínuos como cliques, logs, IoT e transações financeiras. Ideal para aplicações que exigem respostas imediatas, como detecção de fraude e análises em tempo real.

Dados Fluem o Tempo Todo

Como rios de informações, os dados modernos não param: usuários clicam, sensores enviam, vídeos transmitem.

Kinesis é o Canal que os Transporta

Ele não armazena apenas — ele mantém os dados em movimento para processamento imediato.



AWS Kinesis Data Analytics

- O AWS Kinesis Data Analytics é o serviço de processamento de dados em real-time, ideal para analisar fluxos de dados enquanto são processados.
- Apesar de ter a capacidade de processamento no próprio serviço, ele trabalha melhor em conjunto com o Data Streams e/ou Firehose.
- Recentemente o serviço sofreu mudanças, com o motor de processamento e análise utilizando o Flink e o nome foi para Managed Service for Apache Flink.



Integrações

- O Data Analytics se integra com diversos serviços de streaming para input de dados e consegue gerar outputs para serviços que recebem informações analíticas.
- Integrações com o Kinesis Data Streams e/ou AWS Lambda são comuns.



Fonte: Amazon

Snowflake

O **Snowflake** é um **Data Cloud** — uma plataforma completa de dados em nuvem que combina:

- ✓ **Data Warehouse**
- ✓ **Data Lake**
- ✓ **Data Engineering**
- ✓ **Data Sharing / Data Marketplace**
- ✓ **Secure Data Collaboration**



Ele não é apenas um banco: é uma **plataforma de dados** com arquitetura própria, totalmente separada entre:

Camada de armazenamento

Camada de processamento (compute)

Camada de serviços (orquestração, segurança, metadados)

Fonte: [Amazon](#)

O Que São Databricks e Snowflake?

Plataformas de Dados em Nuvem

Soluções modernas para armazenar, processar e analisar grandes volumes de dados na nuvem.


Diferenças Fundamentais

- **Snowflake:** Simplicidade, SQL, BI.
- **Databricks:** Processamento distribuído, Spark, ciência de dados.

Origem e Visão

Snowflake: data warehouse moderno.

Databricks: do Apache Spark, inova no lakehouse.



Arquiteturas Comparadas



Snowflake

- Camada de armazenamento separada da computação
- Sem gestão de infraestrutura
- Escala automática instantânea




databricks

Databricks

- Baseado no Spark
- Processamento paralelo em clusters
- Suporte a múltiplas linguagens

Cases Arquiteturais (Snowflake)



Facilidades Snowflake

1. **Separação total de Storage e Compute**
2. Auto-scale e Auto-suspend
3. Zero-Copy Cloning – QA/ Testing
4. Time Travel + Fail-Safe (Recuperação de dados apagados)
5. Querys em SQL



Quando Usar Snowflake?

Ideal Para Projetos Corporativos

- Business Intelligence padronizado
- Equipes não técnicas (analistas, BI)
- Necessidade de governança forte


Melhor Quando:

- Prioriza simplicidade
- Deseja operação hands-off
- Usa muito SQL e dashboards



Custos 24x7 – Kinesis vs Snowflake vs Databricks

Serviço	Configuração 24x7	Custo Mensal Aproximado	Modelo de Cobrança	Observações
AWS Kinesis Data Streams	1 shard ativo 24x7	US\$ 100–120/mês	Por shard/hora + PUTs	Baixo custo, ótimo para ingestão contínua
Snowflake	Warehouse Small (S) ligado 24x7	US\$ 2.200–2.800/mês	Créditos por hora	Ideal não usar 24x7 (usar autosuspend)
Databricks	Cluster mínimo (1 driver + 2 workers) rodando 24x7	US\$ 3.000–4.800/mês	DBUs + VMs	Mais caro, especialmente para clusters maiores



Características (Parte 1)

- Uma das características principais do Data Analytics é o uso de SQL para a realização das queries.
- O uso de SQL torna interessante o uso por parte de Analistas de Dados e/ou Negócios.
- OBS: Com o uso do Apache Flink, esse suporte se estende para Python e Scala.



Características (Parte 2)


- Outras aplicações interessantes do Data Analytics são a criação de uma camada de métricas (KPIs) e de indicadores de negócio.
- Serve como camada de suporte a dashboards e self-service BIs.
- Atua como um PaaS, não necessitando de gerenciar a infraestrutura e com escalabilidade automática, com um modelo similar ao AWS Lambda (Serverless).



- O uso do Apache Zeppelin (ferramenta “similar” ao Jupyter Notebook) permite a criação de processos de geração e consolidação de métricas.
- Com a parte de métricas, é possível a geração de dashboards e o seu monitoramento.
- O Zeppelin possui um foco maior em Data Analytics, enquanto que o Jupyter Notebook possui um suporte maior em termos de linguagens de programação.




Cases Arquiteturais (Parte 1)




Fonte: Amazon

Cases Arquiteturais (Parte 2)




Fonte: Amazon

Cases Arquiteturais (Parte 3)




Fonte: Amazon

Cases Arquiteturais (Parte 4)



Fonte: Cloudway

Cases Arquiteturais (Parte 5)



Fonte: Medium



- Vou mostrar aonde ficam as demos do AWS Kinesis Data Analytics. 😊
- E alguns Labs interessantes de Kafka Streams.
- Disclaimer: Infelizmente não está coberto no Free Tier e nem no AWS Academy o uso do Data Analytics. ☹️

Data Pipelines – Características (Parte 1)



- Um Data Pipeline nada mais é do que uma esteira que possui os processos (ou etapas) de transformação e sanitização dos dados.
- Existem os formatos Batch e de Streaming.
- Possuem semelhanças com os processos de CI/CD da área de desenvolvimento de software.
- De forma similar ao CI/CD, temos as seguintes etapas que são importantes para se ter uma esteira robusta:


Data Pipelines – Características (Parte 2)



1. Controle de Versionamento / Rollbacks.
2. Testes Automatizados.
3. Continuous Integration.
4. Repositório de Artefatos.
5. Continuous Deployment.
6. Security & Compliance.


Fonte: Medium

Data Pipelines - Exemplo



Fonte: Medium

Data Pipelines - Processo



Fonte: Splunk

Data Pipelines – Considerações



- Ainda é necessário fazer inúmeras adaptações em ferramentas de CI/CD para um suporte adequado para construção de Data Pipelines.
- Existem benefícios interessantes na sua implementação:
Para Discussão em Sala.



MBA⁺

Copyright © **2023-2025** - Prof. Rafael Tsuji Matsuyama

Todos direitos reservados. Reprodução ou divulgação total ou parcial deste documento é expressamente proibido sem o consentimento formal, por escrito, do Professor (autor).