


FIAP

NBA



ENTERPRISE ANALYTICS ARCHITEC

Modern Data Stack



Modern Data Stack (MDS) é um termo que descreve um conjunto de ferramentas e tecnologias utilizadas para processamento, armazenamento e análise de dados, incluindo softwares de código aberto e proprietários.

Não existe um consenso dentro do universo de dados sendo que sua interpretação varia entre pessoas e empresas.

MODERN DATA STACK VS TRADITIONAL DATA STACK

- Soluções de dados tradicionais são tipicamente on-primises, o que significa que elas são hospedadas e gerenciadas pela própria organização.
- Elas são baseadas em infraestrutura de hardware e software que a organização possui e mantém.
- Isso pode torná-las complexas e caras para instalar e manter.

MODERN DATA STACK VS TRADITIONAL DATA STACK


- Além disso, soluções de dados tradicionais nem sempre são facilmente integradas com sistemas baseados em nuvem, o que pode limitar sua flexibilidade e escalabilidade.
- Soluções de dados modernas são projetadas para abordar as limitações de soluções de dados tradicionais.
- Elas são tipicamente baseadas em nuvem, o que as torna mais escaláveis e flexíveis.
- Elas também são modulares, o que as torna mais fáceis de integrar com diferentes sistemas.

E quanto às soluções modernas?

- 1 **Cloud-First:** As ferramentas MDS são baseadas na nuvem, o que permite maior escalabilidade, elasticidade e facilidade de integração com a infraestrutura de nuvem existente.
- 2 **Construído em torno de um data warehouse de nuvem, data lake ou data lakehouse:** As ferramentas de data stack moderno são projetadas para se integrar perfeitamente com data warehouses de nuvem como Redshift, BigQuery e Snowflake, bem como data lakes ou até mesmo o filho dos dois primeiros — um data lakehouse.
- 3 **Projetado para ser modular:** Uma das principais vantagens dos data stacks modernos é sua modularidade. Em data stacks tradicionais, a mudança de um único componente pode levar um tempo e esforço consideráveis, sem falar no risco de quebrar toda a estrutura. Por outro lado, os data stacks modernos permitem que os componentes sejam trocados conforme necessário sem perturbar todo o sistema. Isso significa que as organizações podem escolher as melhores ferramentas para suas necessidades específicas e fazer alterações conforme suas necessidades evoluem sem reformular toda sua infraestrutura de dados. Além disso, essa modularidade pode ajudar a evitar o bloqueio de fornecedores, dando às organizações mais flexibilidade e controle sobre seu data stack.

- 1 **Oferecido como código-fonte aberto com suporte ativo das comunidades:** Muitos componentes de um data stack moderno (como Apache Airflow, Kafka, Spark e outros) são de código aberto e gratuitos. Isso promove um ecossistema de apoio de usuários e engenheiros que contribuem para o desenvolvimento de ferramentas, criam grupos no Slack, Reddit e outras plataformas, além de organizar meetups e conferências.
- 2 **Possibilidade de distribuição SaaS ou de serviços gerenciados:** Embora a parte de código aberto seja definitivamente uma coisa boa, ela requer um alto nível de expertise, pois geralmente não há GUI. É por isso que algumas ferramentas MDS são distribuições comerciais projetadas para serem de código baixo ou até mesmo sem código, tornando-as acessíveis a profissionais de dados com expertise técnica mínima. Isso significa que as empresas não precisam necessariamente de uma grande equipe de engenharia de dados.
- 3 **Democratização dos dados:** Em vez de ter dados limitados a um grupo selecionado de indivíduos, com as ferramentas de data stack moderno, todos dentro de uma organização podem consultar e acessar os dados de que precisam. Isso promove a alfabetização de dados e permite que mais indivíduos tomem decisões baseadas em dados. Ele também elimina o gargalo de ter apenas alguns indivíduos com expertise em análise de dados e incentiva uma cultura mais colaborativa e inclusiva em torno dos dados na organização.

IMPLEMENTAÇÃO




Coleta de dados

Processo de obtenção de dados para análise e tomada de decisão.




Data warehouse, BI e analytics

Processo de analisar e apresentar dados para ajudar os tomadores de decisão a tomar decisões informadas.



Integração de dados

processo de combinar dados de várias fontes para criar uma visão única e unificada.



Ciência de Dados e aprendizado de máquina

Processo de extrair insights significativos de dados usando modelos estatísticos, algoritmos e técnicas de aprendizado de máquina.

Definir Objetivos

Escolher as fontes certas

Escolher as ferramentas corretas para o problema correto

Armazenar dados em locais seguros

COLETA DE DADOS

- Pesquisas online;
- Aplicativos moveis;
- Sistemas corporativos;
- Webscrapping;
- Planilhas e relatorios;

INTEGRAÇÃO DE DADOS

- Ferramentas low code como talend, informatica, pentaho;
- Frameworks como apache bean, spark, duckdb e kafka;
- Ferramentas SaaS como dataflow, glue;

DATA WAREHOUSE, BUSSINES INTELLIGENCE E ANALYTICS

- Ferramentas de visualização de dados como power BI, Looker, Qlik e tableau;
- Bigquery, azure synapse, redshift e athena;
- SQL, python, scala e java

CIÊNCIA DE DADOS E MACHINE LEARNING

- Python, Java e R;
- Knime, SAS; jupyter
- TensorFlow, Scikit-learn, Torch, Keras;

O QUE SEPARA O MODERN DATA STACK DE UM DATA STACK LEGADO?

- Uma modern data stack (MDS) é tipicamente mais escalável, flexível e eficiente do que uma data stack (DS) legada. Uma MDS depende da computação em nuvem, enquanto uma DS legada armazena dados em servidores em vez da nuvem. As MDS fornecem acesso para mais profissionais de dados do que as DS legadas..
- Uma DS legada geralmente se refere ao sistema de gerenciamento de banco de dados relacional tradicional (RDBMS), que usa uma linguagem de consulta estruturada (SQL) para armazenar e processar dados.

O QUE SEPARA O MODERN DATA STACK DE UM DATA STACK LEGADO?

- Embora um RDBMS ainda possa ser usado em uma MDS, não é tão comum porque não é tão adequado para gerenciar big data. O SQL, no entanto, continua sendo uma linguagem de consulta popular para a data stack legada e modernas.

Quais os beneficios de uma modern data stack?

AUMENTAR A ESCALABILIDADE

- Com uma estrutura de dados moderna, é mais fácil dimensionar para cima ou para baixo conforme necessário.
- Várias ferramentas na estrutura podem ser usadas juntas ou separadamente, dependendo das necessidades da empresa.
- As capacidades elásticas da nuvem ajudam as organizações a usar os recursos computacionais necessários sob demanda para tarefas de dados importantes. Quando os trabalhos são concluídos, os recursos podem retornar ao estado normal, minimizando os custos de computação.

FLEXIBILIDADE

- Uma estrutura de dados moderna também é mais flexível do que uma estrutura de dados herdada.
- Várias ferramentas podem ser usadas de maneiras diferentes para atender às necessidades específicas da empresa. Os serviços dentro de uma estrutura de dados podem ser adicionados ou removidos conforme necessário. Muitos dos serviços têm preços baseados no consumo, o que permite que as empresas não tenham grandes custos de aquisição de software no início, quando começam a migrar para a nuvem.
- Os ativos de dados não são fixados a um fornecedor específico.

EFICIÊNCIA APRIMORADA


- Uma estrutura de dados moderna também pode ser mais eficiente do que uma estrutura de dados herdada.
- As ferramentas na stack são projetadas para trabalharem juntas em uma plataforma de nuvem, o que pode ajudar a economizar tempo e recursos.
- Alimentada pela computação em nuvem, mais profissionais de dados também têm acesso aos dados.
- Os analistas de dados têm acesso ao data warehouse usando ferramentas de BI como o Tableau; os cientistas de dados têm acesso a ferramentas de ciência de dados, como o Dataiku.

MELHOR CULTURA DE DADOS


- Uma estrutura de dados moderna pode ajudar a criar uma melhor cultura de dados dentro de uma organização.
- As várias ferramentas são projetadas com a usabilidade em mente. Isso torna mais fácil para os funcionários acessarem e usarem dados, independentemente de sua expertise técnica.
- Além disso, a flexibilidade de uma estrutura de dados moderna significa que os funcionários não estão restritos ao uso de uma ferramenta particular. Eles podem escolher a ferramenta que melhor atende às suas necessidades.

MELHOR CULTURA DE DADOS


- Os funcionários podem se beneficiar de uma boa cultura de dados da seguinte forma:
 - Pesquisa e descoberta de dados: Os funcionários podem encontrar dados relevantes para tomada de decisão pontual.
 - Literacia de dados: Os funcionários podem interpretar e analisar dados para tirar conclusões lógicas; eles também podem identificar especialistas em domínios mais bem equipados para educar sobre ativos de dados específicos.
 - Governança de dados: Os dados são gerenciados de forma apropriada, as informações de identificação pessoal (PII) são mascaradas e as regulamentações que regem certos tipos de dados são visíveis nos fluxos de trabalho, para que os funcionários usem os dados corretos das maneiras corretas.



Case 01: Airbnb



AIRBNB DATA INFRA



Para começar, o Airbnb tem um data warehouse centralizado que é construído sobre o Apache Hadoop e hospedado na plataforma de nuvem Amazon S3. Eles usam o Redshift da Amazon para tempos de consulta mais rápidos e para gerenciar seus grandes volumes de dados, o Apache Hive para processamento de dados e o Apache Airflow para orquestração de dados.

O Airbnb também depende de ferramentas de transformação de dados, como dbt, para converter seus dados brutos em formatos utilizáveis para inteligência de negócios e análise de dados. Eles optam pelo Tableau, uma popular ferramenta de BI, para permitir a análise auto-serviço em toda a organização.


Em termos de governança de dados, o Airbnb usa uma combinação de processos automatizados e manuais para garantir a qualidade e segurança dos dados. Eles têm uma equipe de governança de dados dedicada que trabalha para estabelecer políticas, padrões e melhores práticas para gerenciamento de dados. Isso inclui definir a propriedade dos dados, controles de acesso e procedimentos de auditoria.



Case 02: Uber



Generation 3 (2017-present) - Let's rebuild for long term





- A Uber é uma empresa de tecnologia que depende fortemente de dados para fornecer seus serviços e, como tal, construiu uma stack de dados moderna para suportar suas operações. A Uber usa uma arquitetura baseada em nuvem com foco principal em um sistema de processamento de dados escalável e confiável. Para construir sua stack de dados, a Uber escolheu uma combinação de tecnologias de código aberto e proprietárias que foram adaptadas às suas necessidades específicas.

No núcleo da stack de dados da Uber está o Apache Hadoop, que é usado para armazenar e processar grandes quantidades de dados. Ao mesmo tempo, a Uber desenvolveu o Apache Hudi (Hadoop Upserts and Incremental) - uma biblioteca de armazenamento e gerenciamento de dados para lidar com grandes conjuntos de dados que precisam de atualizações frequentes. Isso foi feito para lidar com as limitações que a Uber tinha ao usar o HDFS (Apache Hadoop Distributed File System). O Hudi fornece recursos como processamento de dados incremental, inserção e atualização de registro e particionamento de dados.


Uber



- Para gerenciar a ingestão de dados, a Uber usa o Apache Kafka, um sistema de mensagens distribuído que coleta e armazena dados de várias fontes. Os dados são então processados com o Apache Spark, um motor de análise de código aberto para processamento de dados em grande escala. A Uber também aproveita outras ferramentas de código aberto como Presto e Hive para consultar dados em seu data warehouse.

A equipe de ciência de dados da Uber aproveita uma variedade de técnicas de machine learning e inteligência artificial para analisar dados e obter insights. Para isso, a Uber construiu uma plataforma chamada Michelangelo para criar, implantar e gerenciar modelos de machine learning.

Para garantir a governança e segurança dos dados, a Uber implementou controles de acesso a dados rigorosos e mecanismos de auditoria. Também possui uma equipe de privacidade de dados dedicada que garante o cumprimento de leis e regulamentos.



REFERÊNCIAS

- <https://kondado.com.br/blog/blog/2023/05/09/o-que-e-modern-data-stack>
- <https://www.altexsoft.com/blog/modern-data-stack/-mds/>

OBRIGADO



Copyright © 2019 | Professor (a) Nome do Professor
Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente
proibido sem consentimento formal, por escrito, do professor/autor.

FIAP