



FIAP

NBA



DATA ARCHITECTURE, DATA FABRIC E DATA MESH

Cloud Datawarehouse



• Data warehouse é um sistema empresarial usado para a análise e geração de relatórios de dados estruturados e semiestruturados de várias fontes.

Data warehouse é adequado para análise ad hoc e geração de relatórios personalizados.

Data warehouse pode armazenar dados atuais e históricos em um único local e é projetado para fornecer uma visão de longo prazo dos dados ao longo do tempo, tornando-o um componente principal da Business Intelligence.

CLOUD DATA WAREHOUSE

- Cloud data warehouse uma solução é gerenciada e hospedada por um provedor de serviços de nuvem. Isso oferece a flexibilidade inerente de um ambiente de nuvem, bem como custos mais previsíveis, que podem ser baseados no uso ou em um valor fixo.
- O investimento inicial é tipicamente muito menor e os prazos de entrega são mais curtos do que as soluções on-premises porque você não precisa comprar hardware, o que reduz o CapEx. Você também pode obter eficiências operacionais da natureza serverless/NoOps dos data warehouses na nuvem.

CLOUD DATA WAREHOUSE VS TRADITIONAL ON-PREMISE DATA WAREHOUSE

- **Localização:** Um data warehouse na nuvem é armazenado na nuvem, enquanto um data warehouse tradicional on-premises é armazenado no local. Isso significa que um data warehouse na nuvem é mais acessível e pode ser escalado mais facilmente do que um data warehouse tradicional on-premises.
- **Custo:** Um data warehouse na nuvem pode ser mais econômico do que um data warehouse tradicional on-premises. Isso ocorre porque você só paga pelo que usa com um data warehouse na nuvem, enquanto com um data warehouse tradicional on-premises você precisa comprar e manter hardware caro.

CLOUD DATA WAREHOUSE VS TRADITIONAL ON-PREMISE DATA WAREHOUSE

- **Flexibilidade:** Um data warehouse na nuvem oferece mais flexibilidade do que um data warehouse tradicional on-premises. Isso ocorre porque você pode facilmente dimensionar um data warehouse na nuvem para cima ou para baixo para atender às suas necessidades, enquanto um data warehouse tradicional on-premises é mais difícil de escalar.
- **Segurança:** A segurança em um data warehouse na nuvem é muito mais rigorosa do que em um data warehouse tradicional on-premises. Isso ocorre porque os dados são armazenados na nuvem e, portanto, não são tão vulneráveis a violações de segurança.

CLOUD DATA WAREHOUSE VS TRADITIONAL ON-PREMISE DATA WAREHOUSE

- **Manutenção:** A manutenção na nuvem é muito mais fácil do que em um data warehouse tradicional on-premises. Isso ocorre porque você não precisa se preocupar com a manutenção de hardware ou software, pois isso é feito todo pelo provedor.
- **Integração:** A integração é muito mais fácil em um data warehouse na nuvem do que em um data warehouse tradicional on-premises. Isso ocorre porque os dados são armazenados na nuvem e podem ser facilmente integrados com outros aplicativos.

Pontos Chaves



- ● ● + ● □

- ● ● + ● □

VANTAGENS DO CLOUD DATA WAREHOUSE

- **Gerenciamento total para economia operacional:** Um cloud data warehouse permite que você terceirize o incômodo da administração para provedores de nuvem que devem cumprir os acordos de nível de serviço. Isso proporciona economia operacional e pode manter sua equipe interna focada em iniciativas de crescimento.
- **Maior tempo de disponibilidade:** Os provedores de nuvem são obrigados a cumprir os SLAs e fornecer melhor tempo de atividade com uma infraestrutura de nuvem confiável que escala sem problemas. Os data warehouses on-premises têm limitações de escala e recursos que podem afetar o desempenho.

VANTAGENS DO CLOUD DATA WAREHOUSE

- **Escala:** Os cloud data warehouses são elásticos, portanto, podem ser dimensionados sem problemas para cima ou para baixo conforme as necessidades do seu negócio mudam.
- **Preço Flexível:** Com a nuvem, você obtém preços flexíveis pagando pelo que usa ou escolhendo uma opção de taxa fixa mais previsível. Alguns provedores cobram por throughput ou por hora por nó. Outros cobram um preço fixo por um determinado volume de recursos. Em todos os casos, você evita os custos exorbitantes incorridos por um data warehouse on-premises que funciona 24 horas por dia, 7 dias por semana, independentemente de os recursos estarem em uso ou não.


Porque usar?



•




CLOUD DATA WAREHOUSE



Múltiplas fontes de
dados



Análise e
visualização de big
data



Machine Learning/
IA



Análise de streaming


CLOUD DATA WAREHOUSE



Geração de
relatórios



Mineração de dados




Ciência de dados

CLOUD DATA WAREHOUSE AUTOMATION

- O processo de automação de data warehouse na nuvem é projetado para facilitar a gestão de data warehouses pelas empresas. O processo automatiza a criação e manutenção de data warehouses, bem como a provisão de recursos e acesso aos dados. Isso permite que as empresas se concentrem em suas operações principais, em vez de gerenciar seus data warehouses.

O processo de automação de data warehouse na nuvem tem as seguintes etapas:

- 1 Coletar dados de várias fontes: A primeira etapa do processo é coletar dados de várias fontes. Esses dados podem ser coletados manualmente ou por meio de meios automatizados.
- 2 Carregar dados no warehouse: A terceira etapa é carregar os dados no warehouse. Isso pode ser feito manualmente ou por meio de meios automatizados.
- 3 Limpar e transformar dados: A próxima etapa é limpar e transformar os dados. Isso envolve remover erros e inconsistências dos dados.
- 4 Consultar e analisar dados: A quarta etapa é consultar e analisar os dados. Isso pode ser feito usando SQL ou outras ferramentas. Idealmente, isso inclui análises de autoatendimento, para que os usuários de negócios possam interagir diretamente com os dados, em vez de depender exclusivamente de profissionais de dados.




CASES

Amazon Redshift

Em novembro de 2012, a Amazon Web Services (AWS) lançou o Redshift, um serviço de data warehouse totalmente gerenciado e de escala petabyte na nuvem. Embora não tenha sido o primeiro data warehouse baseado na nuvem, foi o primeiro a ganhar participação no mercado por meio da adoção. O dialeto SQL do Redshift é baseado no PostgreSQL, que é bem compreendido por analistas em todo o mundo, e usa uma arquitetura familiar para muitos usuários de data warehouses locais.


Você pode começar com apenas alguns gigabytes de dados e escalar para petabytes. Isso capacita você a adquirir novos insights a partir de seus dados de negócios e clientes.



Microsoft Azure Synapse

Azure Synapse Analytics é um serviço de análise mais recente que combina o data warehouse empresarial e a análise de big data. O Azure Synapse oferece uma experiência unificada para ingerir, preparar, gerenciar e servir dados para suas necessidades de inteligência de negócios (BI) e aprendizado de máquina (ML).


No coração do Azure Synapse está um mecanismo de processamento de SQL distribuído nativo da nuvem. Ele é construído sobre a base do SQL Server para impulsionar seus workloads de data warehouse empresarial mais exigentes. Similar a outras soluções MPP de nuvem, o Azure SQL Data Warehouse (SQL DW) separa armazenamento e computação, cobrando cada um separadamente. O Azure Synapse salva dados de tabelas relacionais com armazenamento colunar e abstrai máquinas físicas representando o poder de computação na forma de unidades de data warehouse (DWUs). Isso permite que seus usuários escalem recursos de computação facilmente e sem problemas.



Google Bigquery

BigQuery é um data warehouse totalmente gerenciado e sem servidor que se escala automaticamente para atender às necessidades de armazenamento e poder computacional. O Google não espera que você gerencie sua infraestrutura de data warehouse, e é por isso que o BigQuery oculta muitos dos detalhes de hardware, banco de dados, nós e configuração subjacentes. Sua elasticidade funciona automaticamente, sem qualquer configuração. E para começar, basta criar uma conta na Google Cloud Platform (GCP), carregar uma tabela e executar uma consulta. O Google cuida do resto.


Com o BigQuery, você obtém um banco de dados colunar e ANSI SQL que pode analisar terabytes a petabytes de dados em velocidades incríveis. O BigQuery também permite fazer análise espacial usando SQL familiar com o BigQuery GIS. Além disso, você pode criar e operacionalizar rapidamente modelos de ML em grandes volumes de dados estruturados ou semiestruturados usando SQL simples com o BigQuery ML. E você pode suportar painéis interativos em tempo real com o BigQuery BI Engine.



Snowflake cloud data warehouse

Snowflake é um data warehouse totalmente gerenciado baseado em nuvem MPP que é executado no AWS, GCP e Azure. O Snowflake, diferente dos outros data warehouses aqui apresentados, é a única solução que não é executada em sua própria nuvem. Com um código-base comum e intercambiável, o Snowflake oferece replicação de dados global, o que significa que você pode mover seus dados para qualquer nuvem, em qualquer região - sem ter que recodificar seus aplicativos ou aprender novas habilidades.

Quando você é um usuário do Snowflake, pode criar quantas warehouses virtuais precisar para paralelizar e isolar o desempenho de consultas individuais. O Snowflake permite uma alta simultaneidade separando armazenamento e computação para garantir que muitas warehouses possam acessar simultaneamente a mesma fonte de dados.



É HORA DE MIGRAR PARA UM CLOUD DATA WAREHOUSE?

- O data warehousing não é mais o que era. Com os modernos data warehouses colunares que são frequentemente inseridos e somente leitura, os esquemas tradicionais e os ETLs/ELTs precisam ser atualizados.
- O tradeoff são data warehouses que são frequentemente mais baratos, mais rápidos e podem lidar com mais usuários do que em anos anteriores. Graças a melhorias no design, software e um impulso para mais decisões baseadas em dados, os data warehouses melhoraram em grande escala.

Data Lakehouse




DATA LAKEHOUSE

- Data lakehouse é uma arquitetura relativamente nova e combina o melhor dos dois mundos: data warehouses e data lakes. Serve como uma única plataforma para data warehousing e data lakes. Possui recursos de gerenciamento de dados, como transações ACID de uma perspectiva de data warehouse e armazenamento de baixo custo como um data lake. Fornece acesso direto aos dados de origem, permite operações de leitura e gravação simultâneas nos dados e suporte a esquema para governança de dados.

DATA LAKEHOUSE

- Todos os dados - estruturados, semiestruturados e não estruturados - são armazenados no data lake sem nenhum processamento e serão usados por outros processos para casos de uso específicos. Posteriormente, diferentes ferramentas de processamento são usadas para criar o caso de uso específico nos dados. Além disso, otimizações de desempenho, como indexação e compactação de dados, ajudam a obter resultados de consulta mais rápidos, semelhantes a um data warehouse. Ele também suporta dados em streaming para que possa atualizar os painéis de relatórios em tempo real.

DATA LAKEHOUSE ARCHITECTURE



Um data lakehouse oferece maior confiabilidade de dados ao reduzir as transferências de dados ETL, mas oferecendo armazenamento de dados brutos. Os dados não serão duplicados em vários sistemas. Devido à redução dos processos de ETL e da deduplicação, o custo também é reduzido. Além disso, também oferece uma melhor gestão de dados e abre os dados para múltiplos casos de uso.

Algumas das principais características do data lakehouse são as seguintes:

- **Suporte a transações ACID - (atomicidade, concorrência, isolamento e durabilidade)** garante a consistência e integridade dos dados. Ajuda a manter a integridade dos dados quando diferentes componentes estão realizando operações simultâneas ou em caso de falhas. É uma propriedade fundamental de um data warehouse e é herdada para um data lakehouse.
- **Formato de dados brutos ou não estruturados** - Um data warehouse só suportava dados estruturados, mas agora temos suporte para tipos de dados brutos, incluindo áudio, vídeo, etc.
- **Suporte a streaming** - Agora, os dados são gerados como um fluxo ilimitado, por isso o data lake tem suporte para streaming de dados e geração de insights em tempo real.
- **Armazenamento e computação desanexados** - Armazenamento e computação são desanexados, tornando-os escaláveis independentemente de acordo com as necessidades do caso de uso. Além disso, permite que você execute consultas usando diferentes nós de computação e enquanto outros acessam o armazenamento diretamente.

REFERÊNCIAS

- <https://cloud.google.com/learn/what-is-a-data-warehouse>
- <https://www.qlik.com/us/cloud-data-migration/cloud-data-warehouse>
- <https://www.thoughtspot.com/data-trends/data-storage/what-is-a-cloud-data-warehouse>
- <https://medium.com/big-data-processing/data-warehouse-vs-data-lake-vs-data-lakehouse-bde5676282e4>
- <https://medium.com/p/a7322947a479>



OBRIGADO



Copyright © 2019 | Professor (a) Nome do Professor
Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente
proibido sem consentimento formal, por escrito, do professor/autor.

FIAP