


FIAP

NBA



DATA ARCHITECTURE, DATA FABRIC E DATA MESH

Plataforma de dados



Uma plataforma de dados é uma solução abrangente de ponta a ponta projetada para ingerir, processar, analisar e apresentar dados gerados pelos sistemas e infraestruturas da empresa ou organização digital moderna. Embora existam inúmeras soluções pontuais e aplicativos de uso específico que governem efetivamente uma ou mais facetas do ciclo de vida dos dados, uma verdadeira plataforma de dados fornece gerenciamento de dados sobre a totalidade do seu ambiente, incluindo funções de negócios críticas, como segurança e observabilidade.

CASOS DE USO

- Desenvolver aplicações contextualmente conscientes baseadas em dados;
- Armazenar e gerenciar dados em todas as suas variedades;
- Analisar dados em todo o espectro de tipos de dados, usando uma única interface de consulta;
- Mostrar dados por meio de aplicações baseadas em busca informada;
- Visualizar dados como um todo;
- Relatar em silos de dados e fronteiras organizacionais;
- Monitorar e gerenciar dados, incluindo sua governança, segurança, linhagem, proveniência e valor;

CASOS DE USO

- Alimentar, aumentar e ingerir dados de outros repositórios de dados, como data warehouses, data lakes, data lakehouses, a fim de cumprir a missão de qualidade e segurança dos dados;
- Limpar e enriquecer dados para uso em análises com IA;
- Realizar inteligência baseada em objetos e atividades usando o que se sabe sobre os dados, em vez dos próprios dados;

PILARES

- Uma plataforma de dados moderna geralmente ingere muitos tipos de dados e incorpora uma ampla variedade de ferramentas e recursos de dados, como ingestão de dados, armazenamento em camadas, data warehouse, data lakes, business intelligence e análise, governança de dados, gerenciamento de dados e segurança e privacidade de dados. Algumas plataformas são otimizadas para determinados tipos de workloads, incluindo conjuntos de recursos voltados para casos de uso específicos. Além disso, as verdadeiras plataformas de dados modernas são frequentemente flexíveis e independentes de fornecedores, integrando uma variedade de ferramentas de código aberto e proprietárias personalizadas de acordo com as necessidades de negócios e de dados únicas de uma organização.

PILARES

- Existem também alguns pilares essenciais que servem de base para qualquer organização na construção de sua própria plataforma de dados. Estes incluem:
 - **Versatilidade:** A capacidade de gerenciar o fluxo de dados para que todas as áreas da organização possam acessar dados relevantes com facilidade.
 - **Inteligência:** A ingestão e distribuição de dados deve ser automatizada e categorizar e entregar os dados com confiabilidade ao seu nível correto, com a capacidade de responder a mudanças, identificar e mitigar erros e prever as necessidades dos usuários.

PILARES

- **Segurança:** A capacidade de proteger adequadamente os dados armazenados é fundamental, possibilitada por uma forte criptografia e uma robusta gestão do ciclo de vida dos dados, e deve atender a todas as necessidades de conformidade regulatória.
- **Escalabilidade:** Não só deve ser capaz de funcionar nos níveis de dados atuais, mas também deve ser adaptável ao crescimento projetado à medida que os volumes de dados aumentam.

Arquitetura de Dados vs Plataforma de dados

Uma arquitetura de dados é essencialmente um framework para o ambiente de dados de uma organização.


Uma arquitetura de dados não é uma plataforma de dados.

Uma arquitetura de dados é o plano para ingerir, armazenar e entregar os dados, enquanto a plataforma de dados é a máquina que acessa, move, analisa, correlaciona e valida os dados para os usuários finais.

Arquitetura de dados vs Plataforma de dados

Principais diferenças entre uma arquitetura de dados e uma plataforma de dados:

- **Arquitetura de dados:** Uma arquitetura de dados é um modelo de alto nível que descreve como os dados são coletados, armazenados e utilizados dentro de uma organização. Ele normalmente inclui um diagrama do fluxo de dados, bem como uma descrição das diferentes fontes de dados, repositórios de dados e data marts.
- **Plataforma de dados:** Uma plataforma de dados é uma coleção de hardware, software e serviços que são usados para gerenciar e analisar dados. Ele normalmente inclui um data warehouse, um data lake e uma variedade de dados.



Data warehouse vs Plataforma de dados


Embora possam ser usados de forma intercambiável, uma plataforma de dados, integra as funcionalidades de um data warehouse, juntamente com data lake e capacidades de business intelligence. Essencialmente, as plataformas de dados governam e gerenciam todos os aspectos do ciclo de vida dos dados - incluindo o armazenamento de dados - juntamente com a análise, processamento e apresentação de dados para que as organizações possam gerar insights acionáveis e tomar melhores decisões de negócios.


Como uma função crítica de uma plataforma de dados, os data warehouses são essencialmente sistemas de armazenamento que integram dados corporativos em repositórios centralizados onde podem ser processados e analisados. Os data warehouses incorporam servidores on-premises e baseados em nuvem, permitindo que as organizações armazenem grandes volumes de dados. Os dados, por sua vez, passam por um processo de extração, transformação e carga (ETL) que dá às organizações a capacidade de acessar, analisar e obter insights.

Plataforma de dados como dataops?

Por definição, uma plataforma de dados pode ser usada para todos os aspectos do ciclo de vida dos dados, o que, pelo menos em teoria, pode ser aplicado ao conceito de DataOps. Similar ao DevOps, que integra o desenvolvimento contínuo no ciclo de vida do desenvolvimento de software (SDLC), o DataOps, ou operações de dados, é um método de manter a análise de dados contínua nas operações e processos de negócios diários de uma organização. Ele depende da comunicação entre todos os stakeholders, com a automação sendo um elemento-chave na otimização dos fluxos de trabalho de dados de forma eficiente.

Uma plataforma de dados seria necessária, pois o processo do DataOps depende do controle de processo estatístico (SPC) para monitorar, controlar e verificar continuamente os fluxos de dados que passam pelo pipeline de análise de dados. Em caso de anomalia, a equipe de análise de dados é notificada por meio de um alerta automatizado.





6 components de uma Plataforma de dados



- 1 **Armazenamento e processamento de dados:** A primeira camada é a camada de armazenamento e processamento de dados, pois você precisa de um lugar para armazenar seus dados e processá-los antes de transformá-los e enviá-los para análise. Torna-se especialmente importante ter uma camada de armazenamento e processamento de dados quando você começa a lidar com grandes quantidades de dados e está mantendo esses dados por um longo período de tempo e precisa que eles estejam prontamente disponíveis para análise. (*snowflake, bigquery, redshift, firebolt, s3, databricks*)
- 2 **Ingestão de dados:** À medida que as infraestruturas de dados se tornam cada vez mais complexas, as equipes de dados ficam com a tarefa desafiadora de ingerir dados estruturados e não estruturados de uma ampla variedade de fontes. Isso é frequentemente referido como a fase de extração e carregamento do Extract Transform Load (ETL) e Extract Load Transform (ELT). (*apache kafka, kinesis, pub/sub, spark, fivetran, singer, airbyte*)

The 6 Must-Have Layers of Your Data Platform

Data Ingestion

Data Storage & Processing

Data Transformation & Modeling


Business Intelligence & Analytics

Data Observability

Data Discovery

- 3 **Transformação de dados e modelagem:** A transformação e modelagem de dados são frequentemente usadas de forma intercambiável, mas são dois processos muito diferentes. Quando você transforma seus dados, está pegando dados brutos e limpando-os com lógica de negócios para preparar os dados para análise e relatórios. Quando você modela dados, está criando uma representação visual dos dados para armazenamento em um data warehouse. (*dbt, dataform, ssis, airflow*)
 - 4 **Business Intelligence e Analytics:** Os dados que você coletou, transformou e armazenou em sua plataforma de dados não servem para nada para o seu negócio se seus funcionários não puderem usá-los. Se a plataforma de dados fosse um livro, a camada de BI e análise seria a capa, repleta de um título envolvente, visuais e um resumo do que os dados estão realmente tentando lhe dizer. Na verdade, essa camada é frequentemente o que os usuários finais pensam quando imaginam uma plataforma de dados, e com razão: ela torna os dados acionáveis e inteligentes, e sem ela, seus dados não têm significado. (*looker, tableau, powerbi, qlik, mode*)


The 6 Must-Have Layers of Your Data Platform



5 Observabilidade de dados: A observabilidade de dados é a capacidade de uma organização de entender completamente a saúde dos dados em seu ecossistema de dados. Ele elimina o tempo de inatividade dos dados aplicando as melhores práticas aprendidas com o DevOps aos pipelines de dados, garantindo que os dados sejam utilizáveis e acionáveis. Sua camada de observabilidade de dados deve ser capaz de monitorar e alertar para os seguintes pilares de observabilidade:

- **Frescor:** Os dados são recentes? Quando foi a última vez que foram gerados? Que dados upstream estão incluídos/omitidos?
- **Distribuição:** Os dados estão dentro dos intervalos aceitáveis? Estão formatados corretamente? Está completo?
- **Volume:** Todos os dados chegaram?
- **Esquema:** Qual é o esquema e como ele mudou? Quem fez essas alterações e por quê?
- **Linhagem:** Para um determinado ativo de dados, quais são as fontes upstream e os ativos downstream que são impactados por ele? Quem são as pessoas que geram esses dados e quem depende deles para tomada de decisão?


The 6 Must-Have Layers of Your Data Platform



6 Data Discovery: À medida que os dados se tornam cada vez mais complexos e a necessidade de acesso em tempo real a dados confiáveis se torna uma prioridade, os processos e tecnologias subjacentes a esta camada da plataforma de dados também precisam evoluir. Se os catálogos de dados são um mapa, a descoberta de dados é o sistema de navegação do seu smartphone, constantemente sendo atualizado e refinado com as últimas insights e informações.

- **Automação e descoberta self-service:** As equipes de dados devem ser capazes de aproveitar facilmente seu catálogo de dados sem uma equipe de suporte dedicada. A autoatendimento, automação e orquestração de fluxos de trabalho para suas ferramentas de dados removem os silos entre as etapas do pipeline de dados, e no processo, tornando mais fácil entender e acessar os dados. Maior acessibilidade naturalmente leva a um aumento da adoção de dados, reduzindo a carga para sua equipe de engenharia de dados.
- **Escalabilidade à medida que os dados evoluem:** À medida que as empresas ingerem mais e mais dados e os dados não estruturados se tornam a norma, a capacidade de escalar para atender a essas demandas será fundamental para o sucesso de suas iniciativas de dados.

The 6 Must-Have Layers of Your Data Platform



- **Visibilidade em tempo real da saúde dos dados:** Ao contrário de um catálogo de dados tradicional, a descoberta de dados fornece visibilidade em tempo real do estado atual dos dados, em oposição ao seu estado "catalogado" ou ideal. Uma vez que a descoberta abrange como seus dados estão sendo ingeridos, armazenados, agregados e utilizados pelos consumidores, você pode obter insights como quais conjuntos de dados estão desatualizados e podem ser descontinuados, se um determinado conjunto de dados é de qualidade de produção ou quando uma tabela foi atualizada pela última vez.
- **Suporte à governança e otimização de warehouse/lake:** Do ponto de vista da governança, a consulta e o processamento de dados no lago muitas vezes ocorrem usando uma variedade de ferramentas e tecnologias (Spark no Databricks para isso, Presto no EMR para aquilo, etc.), e como resultado, não há um único, fonte confiável de verdade para leituras e gravações (como um warehouse fornece). Uma ferramenta de descoberta de dados adequada pode servir como essa fonte central de verdade.

The 6 Must-Have Layers of Your Data Platform

Data Ingestion

Data Storage & Processing

Data Transformation & Modeling

Business Intelligence & Analytics

Data Observability

Data Discovery

Componentes adicionais



- 7 **Catálogo de dados:** Armazenamento e processamento de dados: Algumas organizações optam por implementar soluções de catálogo de dados para casos de uso de governança de dados e conformidade. Os catálogos de dados aproveitam os metadados gerados por meio de uma plataforma de dados moderna para fornecer informações descritivas sobre ativos de dados críticos, como tabelas, métricas principais e muito mais. Pense em uma enciclopédia que se atualiza automaticamente para sua plataforma de dados.
- 8 **Gerenciamento de acesso:** Ingestão de dados: Você deseja que os dados em sua plataforma de dados moderna estejam altamente disponíveis apenas para aqueles que precisam acessá-los. As soluções de gerenciamento de acesso se tornaram mais críticas como forma de proteger informações sensíveis e PII, bem como para evitar multas de regulamentos de dados como GDPR ou CCPA.
- 9 **Machine learning e IA:** Esta é uma categoria abrangente que podemos dividir ainda mais no futuro, que inclui soluções para ajudar a implantar e manter aplicativos de machine learning. Isso inclui categorias de soluções como notebooks, repositórios de recursos, ML Ops e ML Observability.

The 6 Must-Have Layers of Your Data Platform

Data Ingestion

Data Storage & Processing

Data Transformation & Modeling

Business Intelligence & Analytics

Data Observability

Data Discovery

CDP – Customer Data Platform

- Customer Data Platform, chamada também de CDP, é uma tecnologia inovadora que reúne dados estratégicos, de diferentes fontes, do consumidor de uma determinada empresa. Além das informações primárias (first party data) é comum que as CDPs se utilizem de dados de terceiros (3rd party data) para complementar o perfil do usuário. Abastecido com estes dados, ele consegue traçar um perfil levando em consideração dados de busca, dados demográficos, comportamento dentro do site, compras anteriores, relacionamento com a empresa, interação por diferentes canais, entre outros. O perfil é desenhado usando a tecnologia de machine learning para entender a interação das informações.

Assim, é possível ter uma visão ampla do relacionamento do consumidor com a marca. A Customer Data Platform consegue analisar informações de diferentes canais, portanto, ela aglutina as interações no site, aplicativo e redes sociais da empresa. Com isso, os gestores podem ter acesso a como o consumidor está usando os serviços e produtos e no que está interessado



Plataforma de dados vs CDP

As plataformas de dados às vezes podem ser confundidas com uma plataforma de dados de clientes. É importante notar que uma plataforma de dados de clientes lida exclusivamente com dados relacionados ao cliente.


O Customer Data Platform Institute define uma plataforma de dados de clientes como um "software empacotado que cria um banco de dados de clientes persistente e unificado acessível a outros sistemas". As plataformas de dados de clientes consistem em dados de várias fontes de primeira, segunda ou terceira parte, incluindo formulários da web, atividades de páginas da web, atividades de mídia social e dados de comportamento.

As plataformas de dados de clientes e as plataformas de dados não devem ser usadas de forma intercambiável. Eles são duas ferramentas completamente diferentes, com propósitos muito diferentes. As plataformas de dados de clientes existem para criar uma fonte única de verdade para um perfil de cliente, ajudando as empresas a juntar comportamentos e informações díspares sobre um determinado cliente para melhorar as experiências ou enviar comunicações e anúncios mais direcionados.

Por outro lado, as plataformas de dados agregam todos os dados analíticos de uma empresa - dados de clientes e dados operacionais - para ajudar a empresa a tomar melhores decisões e impulsionar serviços digitais.

FUNCIONALIDADES

- **Data Lake Management:** A plataforma pode ser integrada a um Data Lake, ou seja, um repositório enorme de dados organizados, de diferentes formatos e fontes. Ela será a interface organizada que ajudará a coletar e ativar os dados do Data Lake.
- **Data Lineage e Consent Management:** Essas funcionalidades ajudam o negócio a estar em compliance com as leis de proteção de dados, como a LGPD no Brasil. A CMP (Consent Management Platform) ajuda a criar interfaces de fácil entendimento que explicam para o usuário como seus dados serão usados, pedem seu consentimento e fazem a gestão dessa informação. Já o Data Lineage facilita o armazenamento de todo ciclo de vida dos dados.




FUNCIONALIDADES

- **Built-in Function:** Essa funcionalidade oferece uma biblioteca com modelos de customização das buscas por dados, a fim de criar uma base para facilitar futuras análises.
- **ID Resolution:** Com essa funcionalidade, uma Customer Data Platform é capaz de criar usuários únicos e entender o caminho dos clientes a partir de dados anonimizados.
- **Data Enrichment:** Além dos dados proprietários, quem acessa uma Customer Data Platform pode ainda contar com o enriquecimento de dados feito a partir de informações de terceiros, como o IBGE, Bureaus de Crédito, Dados de Web-Behavior, Geo-Behavior, entre outros.


FUNCIONALIDADES

- **Ativações Inteligentes:** A criação de clusters faz com que os dados de uma CDP possam ser ativados em campanhas de marketing, para compra de mídia, por exemplo.
- **Trendspotting:** Faz com que uma CDP tenha uma interface amigável e possibilite a criação de diversos dashboards personalizados.

Data Platform Engineer



Data Fabric




O que é?


O Data Fabric foi identificado como uma das 10 principais tendências de tecnologia de dados e análises para 2021, pela empresa de consultoria Gartner. Data Fabric pode ser traduzido como malha de dados e oferece novas maneiras de gerenciar os limites que separam aplicativos, dados, nuvens e as pessoas que os projetam. Mas o que é Data Fabric? Uma camada integrada de dados e processos de conexão que utiliza análises contínuas de ativos de metadados existentes, detectáveis e inferidos para apoiar o design, implantação e utilização de diversos dados para reduzir o tempo de integração, implementação e manutenção.

Em outras palavras analisa continuamente os metadados disponíveis para as principais métricas e estatísticas e cria um modelo de gráfico, descreve graficamente os metadados de uma maneira fácil de entender, aproveita as principais métricas de metadados para habilitar algoritmos que aprendem com o tempo e produzem previsões com relação ao gerenciamento e integração de dados e otimiza o gerenciamento de dados ao automatizar tarefas repetitivas, como criar perfis de conjuntos de dados, descobrir e alinhar o esquema a novas fontes de dados e até corrigir integração de dados com falha.


Componentes



Arquitetura



Microsoft Fabric





O QUE É?

O Microsoft Fabric é uma solução de análise completa para empresas que abrange tudo, desde movimentação de dados até ciência de dados, análise em tempo real e inteligência de negócios. Ele oferece um conjunto abrangente de serviços, incluindo data lake, engenharia de dados e integração de dados, tudo em um só lugar.

Com o Fabric, você não precisa reunir diferentes serviços de vários fornecedores. Em vez disso, você pode aproveitar um produto altamente integrado, completo e fácil de usar, projetado para simplificar suas necessidades de análise.

A plataforma é construída sobre uma base de Software como Serviço (SaaS), que leva a simplicidade e a integração a um nível totalmente novo.

SaaS Foundation

O Fabric reúne experiências como Data Engineering, Data Factory, Data Science, Data Warehouse, Real-Time Analytics e Power BI em uma base SaaS compartilhada. Essa integração oferece as seguintes vantagens:

- Uma ampla gama de análises profundamente integradas no setor.
- Experiências compartilhadas através de experiências que são familiares e fáceis de aprender.
- Os desenvolvedores podem acessar e reutilizar facilmente todos os ativos.
- Um data lake unificado que permite reter os dados onde estão enquanto usa suas ferramentas de análise preferidas.
- Administração centralizada e governança em todas as experiências.




Componentes do Microsoft Fabric

Engenharia de dados - a experiência em engenharia de dados fornece uma plataforma Spark de classe mundial com ótimas experiências de criação, permitindo que os engenheiros de dados realizem transformações de dados em grande escala e democratizem os dados por meio do lakehouse. A integração do Microsoft Fabric Spark com o Data Factory permite que notebooks e tarefas do Spark sejam agendadas e orquestradas.

Data Factory - o Azure Data Factory combina a simplicidade do Power Query com a escala e o poder do Azure Data Factory. Você pode usar mais de 200 conectores nativos para se conectar a fontes de dados locais e na nuvem.

Data Science - A experiência em Data Science permite que você crie, implante e operacionalize modelos de aprendizado de máquina perfeitamente em sua experiência com o Fabric. Ele se integra ao Azure Machine Learning para fornecer rastreamento de experimento interno e registro de modelo. Os cientistas de dados têm o poder de enriquecer os dados organizacionais com previsões e permitir que os analistas de negócios integrem essas previsões em seus relatórios de BI. Dessa forma, ele muda de insights descritivos para preditivos.





Componentes do Microsoft Fabric

Data Warehouse - A experiência em Data Warehouse fornece desempenho e escala SQL líderes do setor. Ele separa totalmente a computação do armazenamento, permitindo o dimensionamento independente de ambos os componentes. Além disso, ele armazena dados nativamente no formato Delta Lake aberto.

Real-Time Analytics - Dados observacionais, que são coletados de várias fontes, como aplicativos, dispositivos IoT, interações humanas e muito mais. Atualmente, é a categoria de dados que mais cresce. Esses dados geralmente são semiestruturados em formatos como JSON ou Texto. Ele vem em alto volume, com esquemas mutáveis. Essas características dificultam o trabalho das plataformas de armazenamento de dados tradicionais. Real-Time Analytics é o melhor mecanismo da categoria para análise de dados observacionais.

Power BI - O Power BI é a principal plataforma de Business Intelligence do mundo. Ele garante que os proprietários de negócios possam acessar todos os dados no Fabric de forma rápida e intuitiva para tomar melhores decisões com os dados.





REFERÊNCIAS

- <https://pt.community.intersystems.com/post/dataops-com-intersystems-iris>
- <https://www.element61.be/en/competence/customer-data-platform-cdp>
- <https://www.gartner.com/en/newsroom/press-releases/2021-03-16-gartner-identifies-top-10-data-and-analytics-technologies-trends-for-2021>
- <https://learn.microsoft.com/en-us/fabric/get-started/microsoft-fabric-overview>
- https://www.splunk.com/en_us/data-insider/what-is-a-data-platform.html
- <https://blog.tail.digital/o-que-e-customer-data-platform-e-porque-voce-precisa-de-um/>
- <https://www.montecarlodata.com/blog-what-is-a-data-platform-and-how-to-build-one/>
- <https://www.marklogic.com/blog/what-is-a-data-platform/>
- <https://medium.com/institutohub/o-que-%C3%A9-data-fabric-b718a622d718>

OBRIGADO



Copyright © 2019 | Professor (a) Nome do Professor
Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente
proibido sem consentimento formal, por escrito, do professor/autor.

FIAP