

Pipeline de Dados



Introdução

Prof. Thiago Nascimento Nogueira

Jun/2023


Agenda

Batch vs
Streaming

Tipos de
Pipeline

Arquitetura

Replicação
de Dados



01

Batch vs Streaming



Batch vs Streaming

- Batch:
 - Dataset fixo
 - Depois que o evento ocorre (at rest)
 - Estatísticas de um grupo numa sala fechada
- Streaming:
 - Dados de entrada contínua
 - Enquanto o evento ocorre (in motion)
 - Estatísticas de um grupo numa maratona

Processamento Batch

- Características:
 - Acesso aos dados completos
 - Devolve a resposta **ao final do processo**
 - Permite fazer análises complexas (ex: treinamento de modelos)
 - Otimizado para throughput (dados processados por segundo)
- Exemplos:
 - Sumário de vendas do ultimo mês
 - Treinamento de modelos para detecção e spam
 - Frameworks: ETL tradicional, Map Reduce, Spark

Processamento Streaming


- Características:
 - Acesso ao fluxo de dados
 - Devolve a resposta **nesse momento**
 - Processa dados de 1 registro ou pequenas janelas
 - Computações relativamente simples
 - Otimizado para latência (tempo médio para um registro)
- Exemplos:
 - Detecção de fraudes
 - Utilização de um modelo pré-treinado para rotular uma reclamação
 - Frameworks: Apex, Storm, Spark Streaming

02

Arquitetura



Data Platform




03

Tipos de Pipeline



Tipos de Pipeline



Tipos de Captura

- **Batch:** Operação de processo de carga agendada para ocorrer automaticamente em um horário definido ou em intervalos de tempos regulares
- **Tempo real:** As fontes são monitoradas constantemente e as operações são capturadas no momento em que ocorrem
 - Exigências de negócio tem aumentado a demanda por este tipo de captura
 - **CDC (Change Data Capture)** – Conjunto de design patterns para determinar e rastrear os dados que mudaram para que a ação possa ser tomada a partir da alteração

Tipos de Captura

Table 1. Classification of Loading Processes (cf. Farooq and Sarwar 2010 and Kotopoulos 2012)

ETL-Types	Traditional ETL	Near Real-Time ETL		ETL-DDF	ETL-RDC
Mode	Batch	Incremental / Mini-Batch	Incremental / Micro-Batch	Incremental / Real-Time	Incremental / Real-Time
Description	Data is loaded in full or incrementally using a off-peak window	Data is loaded incrementally using intra-day loads	Source changes are captured and accumulated to be loaded in intervals	Source changes are captured and immediately applied to the DW	Source changes are captured and immediately applied to the DW
frequency	monthly, weekly, daily	daily, twice a day, hourly, minutes	15 minutes or higher	minutes, seconds	minutes, seconds
data volumes	high	low	low	low	low
Latency	hours	minutes	minutes	minutes, seconds	minutes, seconds
Capture	filter query	filter query	CDC	CDC	CDC
Initialization	Pull	Pull	Push, then Pull	Push	Push
Target Load	High impact	Low Impact, load frequency is tuneable			
Source Load	High impact	Queries at peak times necessary	Some to none depending on CDC technique		

O Caso da Limonada

Livia abre uma venda de limonada em frente à sua casa. **Tânia**, sua irmã, possui a tarefa de informar à sua mãe sobre o progresso de vendas e assegurar que tenham insumos suficientes para garantir a venda de limonada a qualquer tempo

O Caso da Limonada

Batch:

Tânia consulta (QUERY) **Livia** como foram as vendas ao final de cada dia. **Livia** possui uma série de atividades para contabilizar o resultado final do dia. Com este resultado, elas podem estimar o faturamento do próximo dia e a quantidade de limonada que deve ser feita para o dia seguinte

O Caso da Limonada

Mini-Batch:

Percebendo que precisa de melhor visibilidade das operações ao longo do dia, Tânia nota que seria melhor ter esse resultado a cada 15 minutos, mas um limite prático torna-se aparente:

- Quando **Livia** mal terminou de consolidar os dados, já precisa iniciar uma nova consolidação
- O método de coleta torna o processo ineficiente, pois o trabalho adicional durante a jornada atrapalha no atendimento aos consumidores

O Caso da Limonada

Tempo-Real:

Tânia passa a trabalhar ao lado de sua irmã e coleta cada nota fiscal. Imediatamente entrega à sua mãe.

- Neste caso, a transição do formato Batch para CDC, não só tornou mais eficiente o trabalho de **Lívia**, que pode se dedicar ao atendimento aos clientes, como deu à sua mãe uma visão instantânea sobre o progresso de vendas

04

Replicação
de Dados



Ingestão de dados

- **Definição:** É o processo de obtenção, importação e processamento para uso posterior em um **repositório de dados**.
- Desafios da ingestão de dados:
 - Quantidade de dados produzida cresce exponencialmente
 - Dados gerados a partir de diversas fontes com padrões próprios
 - Crescimento da geração de dados não-estruturados
 - Valor dos dados está no alto volume para reconhecimento de padrões

Tipos de ingestão

- **Carga Full**

- Todos os dados são apagados e ingeridos em sua totalidade no processo.

- **Merge**

- Criação de uma “fotografia” inicial
- Captura das operações (insert, update e **delete**)
- Aplicação das operações para atualização da entidade

Tipos de ingestão

- **Carga Full**


- Todos os dados são apagados e ingeridos em sua totalidade no processo.

- **Merge**


- Criação de uma “fotografia” inicial
- Captura das operações (insert, update e **delete**)
- Aplicação das operações para atualização da entidade

Carga Merge


Updates to merge




Target Table / Directory in Data Lake




Merging records in data lake **without** Databricks Delta



Merging records in data lake **with** Databricks Delta



ETL vs ELT



ETL	ELT
Data transformation is performed in a staging area.	Data transformation is performed in the back-end data warehouse.
It requires a specialized and independent transformation engine.	The back-end data warehouse must have the computational and processing capabilities to perform transformations.
Ideal for small to medium data volumes.	Ideal for large data volumes.
Strengths: Facilitates data quality, data security and data compliance.	Strengths: Greater flexibility and speed when transforming large volumes of unstructured data.

Muchas gracias

A photograph of a man and a woman smiling and looking at each other in a library. The man is on the left, wearing a checkered shirt, and the woman is on the right, wearing a dark top. Bookshelves filled with books are visible in the background. The image has a purple tint.