

MBA⁺

Data Pipelines
SQOOP

Prof. Thiago Nogueira
tnnogueira@gmail.com

Linked-in: <https://www.linkedin.com/in/thnogueira>



Sqoop

O que é Sqoop?



- **Definição:** “SQL-to-Hadoop” é uma ferramenta de linha de comando desenvolvida para transferir dados entre cluster Hadoop e banco de dados de armazenamento estruturado – bancos de dados relacionais (Oracle, DB2, Teradata, MySQL). Projeto foi iniciado em 2009 pela Cloudera e virou Top-level na ASF em 2012.
- **Objetivo:** Tornar o Hadoop um componente central da infraestrutura de dados, facilitando o processo de *import* e *export* de/para banco de dados SQL.
- **Motivações:**
 - Tornar o processo de transferência de dados de RDBMS SQL e Hadoop o mais transparente possível para o usuário.
 - Automatizar o processo de ingestão de tabelas de banco de dados relacionais.
 - Resolver os problemas de transferências de dados de sistemas externos para o Hadoop.
 - Facilitar a conexão com banco de dados por meio de conectores.

Características do Sqoop

- Realiza a leitura linha por linha da tabela para escrever o arquivo no HDFS. O resultado do import é um conjunto de arquivos contendo a cópia dos dados da tabela importada.
- Pode importar dados e metadados de bancos de dados SQL direto para o Hive.
- Utiliza MapReduce para realizar *import* / *export* dos dados, provendo um processamento paralelo e tolerante a falha.
- Permite especificar o intervalo e quais colunas serão importadas.
- Possibilita a especificação de delimitadores e formatos de arquivos.
- Realiza conexões em bancos de dados em paralelo, executando comandos de Select (import) e Insert/Update (export).
- Aceita conexão com diversos plug-ins: MySQL, PostgreSQL, Oracle, Teradata, Netezza, Vertica, DB2 e SQL Server.
- O formato padrão do arquivo importado no HDFS é CSV.
- Converte tipo dos campos.

Fluxo de Import de tabelas de Bancos de Dados para o HDFS

Origem: Tabela Cities no MySQL


id	country	city
1	USA	Palo Alto
2	Czech Republic	Brno
3	USA	Sunnyvale

Linha de comando do Sqoop


```
sqoop import \  
--connect jdbc:mysql://mysql.example.com/sqoop \  
--username sqoop \  
--password sqoop \  
--table cities
```

Destino: Arquivo CSV no HDFS
(home do usuário)


```
1,USA,Palo Alto  
2,Czech Republic,Brno  
3,USA,Sunnyvale
```



Fluxo de Import de tabelas de Bancos de Dados para o HDFS e metadados para o Hive



Fluxo de Import dos dados – Sqoop2



Sqoop - Opções para importar dados de uma tabela

```
sqoop import \
```

```
--connect jdbc:mysql://mysql.example.com/sqoop \
```

```
--username sqoop \
```

```
--password sqoop \
```

```
--table cities
```

```
--warehouse-dir /etl/input/ Permite especificar um diretório no HDFS como destino.
```

```
--where "country = 'Brazil'" Para importar apenas um subconjunto de registros de uma tabela.
```

```
-P ou --password-file my-sqoop-password
```

```
--as-sequencefile ou --as-avrodatafile Para escrever o arquivo no HDFS em formato binário (Sequence ou Avro).
```

```
--compress Comprime os blocos antes de gravar no HDFS em formato gzip por padrão.
```

```
--compression-codec Utilizar outros codecs de compressão, exemplo: org.apache.hadoop.io.compress.BZip2Codec.
```

```
--direct Realiza import direto por meio das funcionalidades nativas do banco de dados para melhorar a performance, exemplo: mysqldump ou pg_dump.
```

Splittable	Not Splittable
BZip2, LZ4	GZip, Snappy

```
--map-column-java c1=String Especificar o tipo do campo.
```

```
--num-mappers 10 Especificar a quantidade de paralelismo para controlar o workload.
```

```
--null-string '\N' \
```

```
--null-non-string '\N'
```

```
--incremental append ou lastmodified Funcionalidade para incrementar os dados.
```

```
--check-column id ou last_update_date Identifica a coluna que será verificada para incrementar novos dados.
```

```
--last-value 1 ou "2013-05-22 01:01:01" Para especificar o último valor importado no Hadoop.
```


Sqoop - Opções para importar todas as tabelas

```
sqoop import-all-tables \ Importar todas as tabelas do banco de dados.  
--connect jdbc:mysql://mysql.example.com/sqoop \  
--username sqoop \  
--password sqoop  
--exclude-tables cities,countries Excluir algumas tabelas do processo.
```


Sqoop – Opções avançadas para importar dados

```
sqoop import \  
--connect  
jdbc:mysql://mysql.example.com/sqoop \  
--username sqoop \  
--password sqoop \  
--query 'SELECT normcities.id, \  
countries.country, \  
normcities.city \  
FROM normcities \  
JOIN countries USING(country_id) \  
WHERE $CONDITIONS' \  
--split-by id \  
--target-dir cities
```


O parâmetro \$CONDITIONS será substituído pela divisão determinada pela coluna do split-by.

Coluna utilizada para dividir o processamento das múltiplas tarefas independentes. Por padrão é a chave-primária. É um dos principais fatores para determinar o bom desempenho da transferência.
 $split_size = (max - min) / qtd. \text{ de mappers}$.


Sqoop – Divisão da tarefa em mappers



Sqoop – Divisão da tarefa em mappers



Sqoop – Divisão da tarefa em mappers (exemplo)



Sqoop – Opções para exportar dados

```
sqoop export \  
--connect  
jdbc:mysql://mysql.example.com/sqoop \  
--username sqoop \  
--password sqoop \  
--table cities \ Tabela de destino.  
--export-dir cities Diretório que contém os dados a serem exportados.  
--batch sqoop.export.statements.per.transaction (números de linhas inseridas por transação) e sqoop.export.records.per.statement  
(número de registros por insert). O padrão é 100 para ambos.  
  
--staging-table staging_cities Cria uma tabela temporária antes de exportar os dados para o banco de dados.  
--clear-staging-table  
--update-key id Atualizar uma tabela.  
--update-mode allowinsert Inserir conteúdo em uma tabela.  
--columns country,city Exportar apenas algumas colunas. O banco de dados de destino precisa permitir insert apenas nessas  
colunas.  
  
--input-null-string '\\N' \  
--input-null-non-string '\\N'
```

Sqoop – Integração com Hive (import)

```
sqoop import \  
--connect  
jdbc:mysql://mysql.example.com/sqoop \  
--username sqoop \  
--password sqoop \  
--table cities \  
--hive-import Vai criar automaticamente os metadados no hive. Conversão de tipos padrão: VARCHAR e CHAR viram STRING.  
--map-column-hive Especificar um tipo específico.  
id=STRING,price=DECIMAL \  
--hive-partition-key day \Para importar dados em uma tabela particionada.  
--hive-partition-value "2013-05-22" Especificar uma partição de destino.  
--hive-drop-import-delims ou Remover os delimitadores padrões utilizados pelo hive (\n, \t).  
--hive-delims-replacement "SPECIAL" Caso não for possível remover, utilize esse parâmetro para especificar uma string.
```

- Gibilisco, Stan. **Data Ingestion**, 2013.
<http://whatis.techtarget.com/definition/data-ingestion>
- Kimball, A. **Introducing Sqoop**, 2009.
<http://blog.cloudera.com/blog/2009/06/introducing-sqoop/>
- Apache. **Sqoop User Guide (v1.4.0-incubating)**, 2014.
<https://sqoop.apache.org/docs/1.4.0-incubating/SqoopUserGuide.html>
- Arvind. **Apache Sqoop**. 2012.
https://blogs.apache.org/sqoop/entry/apache_sqoop_graduates_from_incubator
- Janssen, C. **Apache Sqoop**, 2014.
<http://www.techopedia.com/definition/30170/apache-sqoop>
- https://blogs.apache.org/sqoop/entry/apache_sqoop_overview
- Ting, K.; Cecho, J. J. *Apache Sqoop Cookbook*. " O'Reilly Media, Inc.", 2013.
- Cecho, J. **UNDERSTANDING CONNECTORS AND DRIVERS IN THE WORLD OF SQOOP**, 2014. <http://ingest.tips/2014/11/05/understanding-connectors-and-drivers-in-the-world-of-sqoop/>
- <http://ingest.tips/2014/10/21/sqoop-1-or-sqoop-2/>
- [Hauenstein](http://br.hortonworks.com/blog/get-a-jumpstart-on-your-competition-with-hadoop/) Hauenstein, D. **Get a Jumpstart on your competition with Hadoop**, 2015. <http://br.hortonworks.com/blog/get-a-jumpstart-on-your-competition-with-hadoop/>