


FIAP

NBA



.

ENGENHARIA DE DADOS



DATA SCIENCE



Dra. Regina Tomie Ivata Bernal

Cientista de Dados na área da Saúde

Formação Acadêmica:

Estatístico - UFSCar

Mestre em Saúde Pública - FSP/USP

Doutor em Ciências - Epidemiologia - FSP/USP

Atividades Profissionais:

Professora de pós-graduação na FIAP

Consultora externa da SVS/MS

Cientista de Dados em Saúde

profregina.bernal@fiap.com.br
reginabernal@terra.com.br

CALENDÁRIO

Presencial

02/02/2026

Aplicação de Data
Science
Introdução a
Estatística
Exercício prático

09/03/2026

Introdução a
probabilidade
Inferência Estatística
Exercício prático

16/03/2026

TÓPICO 3


23/03/2026

30/03/2026


TÓPICO 4

Extração de Conhecimento


Extração de conhecimento em bases de dados
- A metodologia de data mining -



PROCESSO KDD



Fonte: Berry & Linoff, 2004.



NOÇÕES DE **PROBABILIDADE**



Probabilidade

Fenômenos aleatórios: situação ou acontecimentos cujos resultados não podem ser previstos com certeza.

Exemplos:

- Condições climáticas no próximo domingo.
- Faturamento da empresa no próximo mês.
- Quantidade de clientes cancelados nos próximos seis meses.
- Taxa de inflação no próximo mês.



Modelos podem ser estabelecidos
para quantificar as INCERTEZAS.






**MODELOS
PROBABILÍSTICOS**

PROBABILIDADE

Inferência clássica

Frequência é uma estimativa da probabilidade de ocorrência de certos eventos de interesse.

- Exemplo:** Qual a probabilidade de um cliente ser atendido entre 4 e 5 minutos na agência Z? E na agência Y? E na agência K?



PROBABILIDADE

Propriedades:

1. Para cada experiência define-se um espaço amostral
2. Probabilidade de um evento E: $0 \leq P(E) \leq 1$
3. $P(S) = \text{Soma das probabilidades dos eventos simples} = 1$

PROBABILIDADE

Definição 1:

“A probabilidade simplesmente determina qual é a chance de algo acontecer.”

“Toda vez que não temos certeza sobre o resultado de algum evento, estamos tratando da probabilidade de certos resultados acontecerem—ou quais as chances de eles acontecerem.”

Fonte: <https://pt.khanacademy.org/math/probability/probability-geometry/probability-basics/a/probability-the-basics>

PROBABILIDADE

Definição 2:

“As frequências relativas são estimativas de probabilidade de ocorrência de certos eventos de interesse. Com suposições adequadas, e sem observarmos diretamente o fenômeno aleatório de interesse, podemos criar um modelo teórico que reproduza de maneira razoável a distribuição das frequências, quando o fenômeno é observado diretamente. Tais modelos são chamados de modelos probabilísticos.”

(Bussab, WO e Morettin, PA, Estatística Básica. 5 ed. São Paulo: Saraiva, 2002, página 103).

Noções de Probabilidade

Exemplo 1:

De um grupo de duas mulheres (M) e três homens (H), uma pessoa será sorteada para presidir uma reunião. Queremos saber as probabilidades de o presidente ser do sexo masculino ou feminino.

1) Espaço amostral: $\{ M, H \}$


2) Modelo teórico:

Sexo	M	H	Total
Frequência teórica	2/5	3/5	1

Fonte: Exemplo extraído do livro Estatística Básica página 108

Noções de Probabilidade

Qual a probabilidade de ganhar o prêmio máximo da Mega Sena com um único jogo de seis dezenas?



O jogo da Mega-sena consiste em escolher seis dezenas dentre as 60 dezenas.

Noções de Probabilidade

- Qual a probabilidade de ganhar o prêmio máximo da Mega Sena com um único jogo de seis dezenas?

Lembrando que o jogo da Mega-sena consiste em escolher seis dezenas dentre as 60 dezenas.

Espaço amostral consiste da enumeração de todos os resultados possíveis do jogo.

$$\Omega = \{ \underset{1}{(1,2,3,4,5,6)}, \underset{2}{(1,2,3,4,5,7)}, \underset{3}{(1,2,3,4,5,8)}, \underset{?}{\dots} \}$$

Noções de Probabilidade

- Evento A = ganhar o prêmio máximo da Mega Sena com um único jogo de seis dezenas

Análise Combinatória Simples : $C_{(n,p)} = \binom{n}{p} = \frac{n!}{(n-p)!p!}$

n=60 e p= 6

$$\Omega = \binom{60}{6} = \frac{60!}{(60-6)!6!} = \frac{60!}{54!6!} = \frac{60.59.58....3.2.1}{(54.533...3.2.1).6.5.4.3.2.1} = 50.063.860$$

$$\text{Probabilidade}(A) = \frac{A}{(\Omega)} = \frac{1}{\binom{60}{6}} = \frac{1}{50.063.860}$$

Noções de Probabilidade

Análise Combinatória e Probabilidade

Fatorial : $n! = n \cdot (n - 1) \cdot (n - 2) \dots 3 \cdot 2 \cdot 1$

Permutação: $P = n!$

Arranjo: $C_{(n,p)} = \frac{n!}{(n - p)!}$

Análise Combinatória Simples : $C_{(n,p)} = \binom{n}{p} = \frac{n!}{(n - p)! p!}$

PROBABILIDADE

Exemplo 2:

O jogo da Mega-sena consiste em escolher seis dezenas dentre as 60 dezenas (01, 02, 03, ..., 60). O jogador pode marcar num cartão de 6 a 15 dezenas. Os custos em reais (R\$) de cada jogo estão relacionados abaixo.

Dezenas	Custo (R\$)
6	4,50
7	31,50
8	126,00
9	378,00
10	945,00
11	2.079,00
12	4.158,00
13	7.722,00
14	13.513,50
15	22.522,50

$$\binom{60}{6} = \frac{60!}{(60-6)! \cdot 6!} = 50.063.860 \text{ possibilidades}$$

Com um único jogo a probabilidade de ganhar o

prêmio máximo é $\frac{1}{\binom{60}{6}}$, isto é, aproximadamente

uma chance em 50 milhões.

Fonte: Exemplo extraído do livro Estatística Básica página 109. O custo e a probabilidade foram atualizadas.

PROBABILIDADE

Exemplo 2:

O jogo da Mega-sena consiste em escolher seis dezenas dentre as 60 dezenas (01, 02, 03, ..., 60). O jogador pode marcar num cartão de 6 a 15 dezenas. Os custos em reais (R\$) de cada jogo estão relacionados abaixo.

Dezenas	Custo (R\$)	Probabilidade de acerto (1 em) Sena
6	4,50	50.063.860
7	31,50	7.151.980
8	126,00	1.787.995
9	378,00	595.998
10	945,00	238.399
11	2.079,00	108.363
12	4.158,00	54.182
13	7.722,00	29.175
14	13.513,50	16.671
15	22.522,50	10.003

Fonte: Exemplo extraído do livro Estatística Básica página 109. O custo e a probabilidade foram atualizadas.

Noções de Probabilidade

Artigos:

<https://mundoeducacao.uol.com.br/matematica/anagrama.htm>

<https://mundoeducacao.uol.com.br/matematica/combinacao-simples.htm>

<https://mundoeducacao.uol.com.br/matematica/permutacao-envolvendo-elementos-repetidos.htm>

<https://mundoeducacao.uol.com.br/matematica/principio-fundamental-contagem-fatorial.htm>

<https://mundoeducacao.uol.com.br/matematica/arranjos-simples.htm>

DISTRIBUIÇÃO DE PROBABILIDADE

Distribuição de Probabilidade

Exemplo:

- Construir o modelo preditivo a fim de prever o resultado de partidas do campeonato brasileiro.
- Considerando que a quantidade de gols marcados (K) em uma partida de futebol do Campeonato Brasileiro de Futebol (Brasileirão) em 2018 seja uma variável aleatória que segue a distribuição de Poisson com média de gols igual a λ .
- Calcule a probabilidade de ocorrer $k = 0, 1, 2, 3, 4, 5, 6$ e 7

Distribuição de Probabilidade

Distribuição de Poisson

A probabilidade de existam exatamente k ocorrências é:

$$P(K = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

$k = 0, 1, 2, 3 \dots$ (número inteiro positivo)

$e = 2.71828$

$k! = k \cdot (k-1) \cdot (k-2) \dots 3 \cdot 2 \cdot 1$

λ = média do valor esperado de k

Distribuição de Probabilidade

- Dados históricos

<https://github.com/henriquegomide/caRtola/tree/master/data>

game	round	date	home_team	score	away_team	gol_m	gol_v	gols	arena	Lcal
1	1	14/04/2018 - 16:00	Cruzeiro - MG	0 x 1	0	1	1	1	Grêmio - RS	Mineirão - Belo Horizonte - MG
2	1	15/04/2018 - 19:00	Atlético - PR	5 x 1	5	1	6	6	Chapecoense - SC	Arena da Baixada - Curitiba - PR
3	1	15/04/2018 - 11:00	América - MG	3 x 0	3	0	3	3	Sport - PE	Independência - Belo Horizonte - MG
4	1	14/04/2018 - 19:00	Vitória - BA	2 x 2	2	2	4	4	Flamengo - RJ	Manoel Barradas - Salvador - BA
5	1	15/04/2018 - 16:00	Vasco da Gama - RJ	2 x 1	2	1	3	3	Atlético - MG	São Januário - Rio de Janeiro - RJ
6	1	16/04/2018 - 20:00	Botafogo - RJ	1 x 1	1	1	2	2	Palmeiras - SP	Nilton Santos - Rio de Janeiro - RJ
7	1	16/04/2018 - 20:00	São Paulo - SP	1 x 0	1	0	1	1	Paraná - PR	Morumbi - Sao Paulo - SP

λ = média do número de gols em uma partida de futebol do Brasileirão.

Distribuição de Probabilidade

- Dados históricos


<https://github.com/henriquegomide/caRtola/tree/master/data>

game	round	date	home_team	score	away_team	gol_m	gol_v	gols	arena	Lcal
1	1	14/04/2018 - 16:00	Cruzeiro - MG	0 x 1	0	1	1	1	Grêmio - RS	Mineirão - Belo Horizonte - MG
2	1	15/04/2018 - 19:00	Atlético - PR	5 x 1	5	1	6	6	Chapecoense - SC	Arena da Baixada - Curitiba - PR
3	1	15/04/2018 - 11:00	América - MG	3 x 0	3	0	3	3	Sport - PE	Independência - Belo Horizonte - MG
4	1	14/04/2018 - 19:00	Vitória - BA	2 x 2	2	2	4	4	Flamengo - RJ	Manoel Barradas - Salvador - BA
5	1	15/04/2018 - 16:00	Vasco da Gama - RJ	2 x 1	2	1	3	3	Atlético - MG	São Januário - Rio de Janeiro - RJ
6	1	16/04/2018 - 20:00	Botafogo - RJ	1 x 1	1	1	2	2	Palmeiras - SP	Nilton Santos - Rio de Janeiro - RJ
7	1	16/04/2018 - 20:00	São Paulo - SP	1 x 0	1	0	1	1	Paraná - PR	Morumbi - Sao Paulo - SP

λ = média do número de gols em uma partida de futebol do Brasileirão.

Distribuição de Probabilidade

- Dados históricos



```
> mean(cartola2018$gols)
```

```
> [1] 2.18
```

Distribuição de Probabilidade

Distribuição de Poisson

A probabilidade de existam exatamente k ocorrências é:

$$P(K = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

λ = média de 2.18 gols

Qual a probabilidade de ocorrer 0 gol?

$$P(K = 0) = \frac{e^{-\lambda} \lambda^k}{k!} = \frac{e^{-2.18} 2.18^0}{0!} = 0.135$$

Qual a probabilidade de ocorrer 1 gol?

$$P(K = 1) = \frac{e^{-\lambda} \lambda^k}{k!} = \frac{e^{-2.18} 2.18^1}{1!} = 0.271$$

Distribuição de Probabilidade


- Distribuição de Poisson


A probabilidade de existam exatamente k ocorrências é:

$$P(K = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

λ = média de 2.18 gols

k (gols)	Probabilidade
0	0.14
1	0.27
2	0.27
3	0.18
4	0.09
5	0.04
6	0.01
7	0.00
Soma	1.00






DISTRIBUIÇÃO **NORMAL**



DISTRIBUIÇÃO NORMAL



CARACTERÍSTICAS:

- A) A variável pode assumir qualquer valor no conjunto real.
- B) O gráfico da distribuição é uma curva em forma de sino, simétrica em torno da média μ , que é igual à mediana e à moda.
- C) A área sob a curva é igual a 1, e corresponde à probabilidade de a variável assumir valores entre $[-\infty \dots \dots +\infty]$.
- D) $\mu; \sigma$ (Mi e Sigma) representam os parâmetros de posição e dispersão da distribuição.
- E) Os pontos de inflexão da curva ocorrem nos valores definidos por $(\mu - \sigma$ e $\mu + \sigma)$.
- F) A expressão da função densidade de probabilidade é:


$$f(X) = \frac{1}{\sigma\sqrt{2\pi}} e^{-1/2[(X-\mu)/\sigma]^2}$$

Qual a probabilidade de ocorrer valores entre 0 e 1?

$$P(0 < Z < 1.00) = ?$$

DISTRIBUIÇÃO NORMAL


Tabela III — Distribuição Normal Padrão
 $Z \sim N(0, 1)$
 Corpo da tabela dá a probabilidade p , tal que $p = P(0 < Z < Z_c)$




parte inteira e primeira decimal de Z_c	Segunda decimal de Z_c										parte inteira e primeira decimal de Z_c
	0	1	2	3	4	5	6	7	8	9	
0,0	00000	00399	00798	01197	01595	01994	02392	02790	03188	03586	0,0
0,1	03983	04380	04776	05172	05567	05962	06356	06749	07142	07535	0,1
0,2	07926	08317	08706	09095	09483	09871	10257	10642	11026	11409	0,2
0,3	11791	12172	12552	12930	13307	13683	14058	14431	14803	15173	0,3
0,4	15542	15910	16276	16640	17003	17364	17724	18082	18439	18793	0,4
0,5	19146	19497	19847	20194	20540	20884	21226	21566	21904	22240	0,5
0,6	22575	22907	23237	23565	23891	24215	24537	24857	25175	25490	0,6
0,7	25804	26115	26424	26730	27035	27337	27637	27935	28230	28524	0,7
0,8	28814	29103	29389	29673	29955	30234	30511	30785	31057	31327	0,8
0,9	31594	31859	32121	32381	32639	32894	33147	33398	33646	33891	0,9
1,0	34134	34375	34614	34850	35083	35314	35543	35769	35993	36214	1,0
1,1	36433	36650	36864	37076	37286	37493	37698	37900	38100	38298	1,1
1,2	38493	38686	38877	39065	39251	39435	39617	39797	39973	40147	1,2
1,3	40320	40490	40658	40824	40988	41149	41309	41466	41621	41774	1,3
1,4	41924	42073	42220	42364	42507	42647	42786	42922	43056	43189	1,4
1,5	43319	43448	43574	43699	43822	43943	44062	44179	44295	44408	1,5
1,6	44520	44630	44738	44845	44950	45053	45154	45254	45352	45449	1,6
1,7	45543	45637	45728	45818	45907	45994	46080	46164	46246	46327	1,7
1,8	46407	46485	46562	46638	46712	46784	46856	46926	46995	47062	1,8
1,9	47128	47193	47257	47320	47381	47441	47500	47558	47615	47670	1,9
2,0	47725	47778	47831	47882	47932	47982	48030	48077	48124	48169	2,0
2,1	48214	48257	48300	48341	48382	48422	48461	48500	48537	48574	2,1
2,2	48610	48645	48679	48713	48745	48778	48809	48840	48870	48899	2,2
2,3	48928	48956	48983	49010	49036	49061	49086	49111	49134	49158	2,3
2,4	49180	49202	49224	49245	49266	49286	49305	49324	49343	49361	2,4
2,5	49379	49396	49413	49430	49446	49461	49477	49492	49506	49520	2,5
2,6	49534	49547	49560	49573	49585	49598	49609	49621	49632	49643	2,6
2,7	49653	49664	49674	49683	49693	49702	49711	49720	49728	49736	2,7
2,8	49744	49752	49760	49767	49774	49781	49788	49795	49801	49807	2,8
2,9	49813	49819	49825	49831	49836	49841	49846	49851	49856	49861	2,9
3,0	49865	49869	49874	49878	49882	49886	49889	49893	49897	49900	3,0
3,1	49903	49906	49910	49913	49916	49918	49921	49924	49926	49929	3,1
3,2	49931	49934	49936	49938	49940	49942	49944	49946	49948	49950	3,2
3,3	49952	49953	49955	49957	49958	49960	49961	49962	49964	49965	3,3
3,4	49966	49968	49969	49970	49971	49972	49973	49974	49975	49976	3,4

Distribuição Normal Padronizada


$$Z \sim N(0,1)$$



$$P[(\mu - \sigma) < X < (\mu + \sigma)] = 68,25\%$$




$$P[(\mu - 2\sigma) < X < (\mu + 2\sigma)] = 95,44\%$$



$$P[(\mu - 3\sigma) < X < (\mu + 3\sigma)] = 99,74\%$$

• DISTRIBUIÇÃO NORMAL



Exercícios

NORMALIZAÇÃO DOS DADOS

- Distribuição Normal Padronizada


$$X \sim N(\mu, \sigma^2) \Rightarrow Z = \frac{X - \mu}{\sigma} \Rightarrow Z \sim N(0,1)$$

Exemplos de aplicações da normalização dos dados:

Convolutional Neural Networks (CNNs) e Algoritmos de Machine Learning (Regressão, SVM, Cluster e outros)

NORMALIZAÇÃO DOS DADOS

Distribuição Normal





Fonte: Pesquisa Nacional de Saúde 2013 – População adulta

NORMALIZAÇÃO DOS DADOS

$$X \sim N(\mu, \sigma^2) \Rightarrow Z = \frac{X - \mu}{\sigma} \Rightarrow Z \sim N(0,1)$$

Exemplo: Ingestão de sal estimada na população adulta. PNS, 2013



DISTRIBUIÇÃO **NORMAL PADRONIZADA**

EXEMPLO

$$X \sim N(\mu, \sigma^2) \Rightarrow Z = \frac{X - \mu}{\sigma} \Rightarrow Z \sim N(0,1)$$

Exemplo: Ingestão de sal estimada na população adulta. PNS, 2013

Ingestão de sal (X)

8.56

$$Z = \frac{8.56 - 9.14}{2.31} = -0.25$$

4.54



$$Z = (4.54 - 9.14) / 2.31 = -1.99 \sim -2 \text{ dp}$$

13.7



$$Z = (13.7 - 9.14) / 2.31 = +1.97 \sim +2 \text{ dp}$$

NORMALIZAÇÃO DOS DADOS

- Distribuição Normal Padronizada


$$X \sim N(\mu, \sigma^2) \Rightarrow Z = \frac{X - \mu}{\sigma} \Rightarrow Z \sim N(0,1)$$

- Máximo e Mínimo

$$X_p = \frac{X - X_{\text{mínimo}}}{X_{\text{máximo}} - X_{\text{mínimo}}}$$

Variáveis normalizadas pelo critério de máximo e mínimo

Variável	Descrição	Tipo de Variável	Regra de data mining
instant	record index	ID	
dteday	date	ID	
season	season (1:winter, 2:spring, 3:summer, 4:fall)	Qualitativa ordinal	Preditora
yr	year (0: 2011, 1:2012)	Qualitativa nominal	Preditora
mnth	month (1 to 12)		Preditora
holiday	weather day is holiday or not	Qualitativa nominal	Preditora
weekday	day of the week	Qualitativa ordinal	Preditora
workingday	if day is neither weekend nor holiday is 1, otherwise is 0.	Qualitativa nominal	Preditora
weathersit	1: Clear, Few clouds, Partly cloudy; Partly cloudy; 2: Mist + Cloudy, Mist + Broken clouds, Mist + Few clouds, Mist; 3: Light Snow, Light Rain + Thunderstorm + Scattered clouds, Light Rain + Scattered clouds; 4: Heavy Rain + Ice Pellets + Thunderstorm + Mist, Snow + Fog	Qualitativa nominal	Preditora
temp	Normalized temperature in Celsius. The values are derived via $(t-t_{min})/(t_{max}-t_{min})$, $t_{min}=-8$, $t_{max}=+39$ (only in hourly scale)	Quantitativa contínua	Preditora
atemp	Normalized feeling temperature in Celsius. The values are derived via $(t-t_{min})/(t_{max}-t_{min})$, $t_{min}=-16$, $t_{max}=+50$ (only in hourly scale)	Quantitativa contínua	Preditora
hum	Normalized humidity. The values are divided to 100 (max)	Quantitativa contínua	Preditora
windspeed	Normalized wind speed. The values are divided to 67 (max)	Quantitativa contínua	Preditora
casual	count of casual users	Quantitativa discreta	Target
registered	count of registered users	Quantitativa discreta	Target
cnt	count of total rental bikes including both casual and registered	Quantitativa discreta	Target



PROBABILIDADE **CONDICIONAL**



PROBABILIDADE **CONDICIONAL**



Exemplo 3:

Considere o evento A = chover em SP no dia 12 de janeiro do próximo ano.

Suponha que uma pessoa morando em Fortaleza tenha que calcular essa probabilidade. Se ela não tiver informação sobre o tempo em São Paulo, poderá atribuir a probabilidade de $\frac{1}{4}$. Já o morador de São Paulo tem informações adicionais, como por exemplo, ele saberá que janeiro, fevereiro e março são os meses mais chuvosos e poderá arriscar uma probabilidade de $\frac{2}{3}$ de ocorrer o evento A .

Fonte: Exemplo extraído do livro Estatística Básica página 121.

PROBABILIDADE **CONDICIONAL**



O fenômeno aleatório pode ser separado em etapas. A informação que ocorreu em uma determinada etapa pode influenciar nas probabilidades de ocorrências das etapas sucessivas.

Definição:

Dados dois eventos A e B, a probabilidade condicional de A dado que ocorreu B é representado por $P(A/B)$ e dada por:


$$P(A/B) = \frac{P(A \cap B)}{P(B)}, P(B) > 0$$

Fonte: Exemplo extraído do livro Noções de Probabilidade e Estatística página 41.

PROBABILIDADE **CONDICIONAL**

Exemplo 4:

O São Paulo Futebol Clube ganha com probabilidade 0,7 se chove e com 0,8 se não chove. Em Setembro a probabilidade de chuva é de 0,3. O São Paulo ganhou uma partida em Setembro, qual a probabilidade de ter chovido nesse dia?



$$P(A/B) = \frac{P(A \cap B)}{P(B)}, P(B) > 0$$

Eventos:

C: Chover

G: São Paulo ganhar um jogo

$$P(C/G) = \frac{P(C) * P(G/C)}{P(C) * P(G/C) + P(NC) * P(G/NC)}$$

$$P(C/G) = \frac{0,30 * 0,70}{0,30 * 0,70 + 0,70 * 0,80} = \frac{0,21}{0,21 + 0,56} = 0,273$$

Fonte: Exemplo extraído e adaptado do livro Noções de Probabilidade e Estatística página 41.

PROBABILIDADE CONDICIONAL

A técnica de Basket Analysis utiliza a probabilidade condicional para encontrar cestas de produtos.

Um Exemplo de Sucesso!



- ✓ Descobriu-se que homens entre trinta e quarenta e cinco anos, que compram cervejas, nas sextas-feiras, após as dezesseis horas, também compram fraldas!
- ✓ Resultado: apenas mudando os produtos de lugar, colocando as fraldas ao lado de cervejas nos pontos de venda, obteve-se um aumento de mais de quarenta por cento nas vendas de fraldas.
- ✓ O que acha de possuir uma informação como essa?

A Wall-Mart soube tirar bom proveito dela!

Medidas estatísticas

- Support (frequência)

$$(A \cap B \Rightarrow C) = \%$$

- Confidence (probabilidade condicional)

$$(A \cap B \Rightarrow C) = \frac{P(A \cap B \cap C)}{P(A \cap B)}$$

- Lift(associação)


$$(A \& B \Rightarrow C) = \frac{P(A \cap B \cap C)}{P(A \cap B)P(C)}$$

MARKET BASKET ANALYSIS

É uma técnica estatística para identificar cestas de produtos, por meio de regras de associação, a qual relaciona todos os produtos adquiridos em uma mesma transação/ticket disponível na base de dados.

Essa técnica é muito utilizada na área de Marketing para identificar hábitos de compra de clientes. O exemplo clássico, citado na literatura, é a associação encontrada entre fralda e cerveja pela rede de supermercados americana WalMart.

Graph-based visualization of the top ten rules in terms of lift.




Exemplo

Técnica Descoberta de Sequências

Quais associações são significativas ?

Item comprado anteriormente




Itens a serem sugeridos de acordo com a força


1.o produto



2.o produto



3.o produto




EXEMPLO

Item comprado anteriormente



Itens a serem sugeridos de acordo com a força


1.o produto



2.o produto



3.o produto



+

+

•

□

•

•

•



Exemplo

Market Basket Analysis

- A pizzaria XPTO vendeu 2000 pizzas:
 - 100 de cogumelos, 150 de pepperoni , 200 com extra queijo
 - 400 de cogumelos e pepperoni, 300 de cogumelos e extra queijo, 200 de pepperoni e extra queijo
 - 100 de cogumelos, pepperoni e extra queijo
 - 500 outros
- Cálculo da probabilidade das combinações dos itens:

Pepperoni



$$150 + 400 + 200 + 100 = 850 \text{ pizzas}$$

$$frequência = \frac{850}{2000} * 100 = 42.5\%$$

Market Basket Analysis

- Cálculo da probabilidade das combinações dos itens:

Cogumelo



$$100 + 400 + 300 + 100 = 900 \text{ pizzas}$$

$$frequência = \frac{900}{2000} * 100 = 45\%$$

Pepperoni



$$150 + 400 + 200 + 100 = 850 \text{ pizzas}$$

$$frequência = \frac{850}{2000} * 100 = 42.5\%$$

Queijo



$$200 + 300 + 200 + 100 = 800 \text{ pizzas}$$


$$frequência = \frac{800}{2000} * 100 = 40\%$$

Exemplo

Market Basket Analysis

- Cálculo da probabilidade das combinações dos itens:


Cogumelo e Pepperoni



$$400 + 100 = 500 \text{ pizzas}$$

$$frequência = \frac{500}{2000} * 100 = 25\%$$


Cogumelo e Queijo



$$300 + 100 = 400 \text{ pizzas}$$

$$frequência = \frac{400}{2000} * 100 = 20\%$$

Pepperoni e Queijo



$$200 + 100 = 300 \text{ pizzas}$$

$$frequência = \frac{300}{2000} * 100 = 15\%$$

Exemplo

Market Basket Analysis

- Cálculo da probabilidade das combinações dos itens:

Cogumelo, Pepperoni e Queijo



100 pizzas

$$frequência = \frac{100}{2000} * 100 = 5\%$$


Exemplo

Market Basket Analysis

- Regra 1 com os três itens:

Exemplo

Se pizza de Cogumelo e Pepperoni então Queijo



Estatísticas	Valor
Support = $(A \cap B \Rightarrow C)$	 +  +  = 5% ou 0.05
Confidence = $(A \cap B \Rightarrow C) = \frac{P(A \cap B \cap C)}{P(A \cap B)}$	$\frac{\text{mushrooms} + \text{pepperoni} + \text{cheese}}{\text{mushrooms} + \text{pepperoni}} = \frac{5\%}{25\%} = 0.20$
Improvement/lift $(A \& B \Rightarrow C) = \frac{P(A \cap B \cap C)}{P(A \cap B)P(C)}$	$\frac{\text{mushrooms} + \text{pepperoni} + \text{cheese}}{\text{mushrooms} + \text{pepperoni} \quad \text{cheese}} = \frac{5\%}{25\% \times 40\%} = 0.5$

Market Basket Analysis

- Três regras com os três itens:

Se pizza de Cogumelo e Pepperoni então Queijo



Support = 0.05
Confidence = 0.20
Improvement/lift = 0.5

Se pizza de Cogumelo e Queijo então Pepperoni



Support = 0.05
Confidence = 0.25
Improvement/lift = 0.588

Se pizza de Queijo e Pepperoni então Cogumelo



Support = 0.05
Confidence = 0.33
Improvement/lift = 0.74

Exemplo

Data Mining

Market Basket Analysis

Aplicação na área da saúde

Exemplo na área da saúde

Análise considerando o tempo (sequência)

ID	INTERVAL	1
SEQUENCE	INTERVAL	1
TARGET	NOMINAL	1

Sequence Report

Chain Length	Transaction Count	Support (%)	Confidence (%)	Rule
2	1979	55.95	63.21	ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG
2	1396	39.47	44.59	ELETROCARDIOGRAMA - ECG ==> ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
3	1272	35.96	64.27	ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG
2	1255	35.48	58.43	ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
3	859	24.29	61.53	ELETROCARDIOGRAMA - ECG ==> ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
4	837	23.66	65.80	ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG
3	791	22.36	39.97	ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG ==> ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
2	754	21.32	61.55	TESTE ERGOMETRICO (TE) - EM BICICLETA OU EM ESTEIRA ==> ELETROCARDIOGRAMA - ECG
3	745	21.06	59.36	ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG
2	744	21.03	23.76	ELETROCARDIOGRAMA - ECG ==> TESTE ERGOMETRICO (TE) - EM BICICLETA OU EM ESTEIRA
2	729	20.61	23.28	ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG & ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
2	717	20.27	33.38	ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
2	711	20.10	57.02	ELETROCARDIOGRAMA - ECG & ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
4	530	14.98	61.70	ELETROCARDIOGRAMA - ECG ==> ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
4	524	14.81	66.25	ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG ==> ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
2	498	14.08	15.91	ELETROCARDIOGRAMA - ECG ==> SISTEMA HOLTER - 24 HORAS - 2 CANAIS
4	498	14.08	39.15	ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG ==> ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
3	497	14.05	66.80	ELETROCARDIOGRAMA - ECG ==> TESTE ERGOMETRICO (TE) - EM BICICLETA OU EM ESTEIRA ==> ELETROCARDIOGRAMA - ECG
2	463	13.09	62.99	SISTEMA HOLTER - 24 HORAS - 2 CANAIS ==> ELETROCARDIOGRAMA - ECG
3	454	12.84	32.52	ELETROCARDIOGRAMA - ECG ==> ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
4	452	12.78	60.67	ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG
3	451	12.75	35.94	ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG ==> ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
3	439	12.41	22.18	ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG & ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG
3	437	12.36	57.96	TESTE ERGOMETRICO (TE) - EM BICICLETA OU EM ESTEIRA ==> ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG
3	435	12.30	59.67	ELETROCARDIOGRAMA - ECG ==> ELETROCARDIOGRAMA - ECG & ECOCARDIOGRAMA BIDIMENSIONAL COM MAPEAMENTO DE FLUXO A CORES ==> ELETROCARDIOGRAMA - ECG


Análise de Coluna

Association Report

Relations	Expected			Transaction			Análise considerando a frequência
	Confidence (%)	Confidence (%)	Support (%)	Lift	Count	Rule	
3	6.99	80.00	2.15	11.45	4.00	COLUMNA LOMBO-SACRA & ARTICULACAO TIBIO-TARSICA ==> PE OU PODODACTILO	
3	2.69	30.77	2.15	11.45	4.00	PE OU PODODACTILO ==> COLUMNA LOMBO-SACRA & ARTICULACAO TIBIO-TARSICA	
2	6.99	77.78	3.76	11.13	7.00	ARTICULACAO TIBIO-TARSICA ==> PE OU PODODACTILO	
2	4.84	53.85	3.76	11.13	7.00	PE OU PODODACTILO ==> ARTICULACAO TIBIO-TARSICA	
3	4.84	50.00	2.15	10.33	4.00	PE OU PODODACTILO & COLUMNA LOMBO-SACRA ==> ARTICULACAO TIBIO-TARSICA	
3	4.30	44.44	2.15	10.33	4.00	ARTICULACAO TIBIO-TARSICA ==> PE OU PODODACTILO & COLUMNA LOMBO-SACRA	
3	5.91	46.15	3.23	7.80	6.00	COLUMNA TOTAL OU ESCOLIOSE PANORAMICA & COLUMNA LOMBO-SACRA ==> COLUMNA PARA ESCOLIOSE: TA-LATERAL	
3	6.99	54.55	3.23	7.80	6.00	COLUMNA PARA ESCOLIOSE: TA-LATERAL ==> COLUMNA TOTAL OU ESCOLIOSE PANORAMICA & COLUMNA LOMBO-SACRA	
3	5.38	36.36	2.15	6.76	4.00	TORAX: PA & COLUMNA CERVICAL: AP-LAT-TO OU FLEXAO ==> ARTICULACAO ESCAPULO-UMERAL	
3	5.91	40.00	2.15	6.76	4.00	ARTICULACAO ESCAPULO-UMERAL ==> TORAX: PA & COLUMNA CERVICAL: AP-LAT-TO OU FLEXAO	
3	3.76	23.53	2.15	6.25	4.00	COLUMNA LOMBO-SACRA & BACIA ==> ARTICULACAO COXO-FEMORAL (CADA LADO)	
3	9.14	57.14	2.15	6.25	4.00	ARTICULACAO COXO-FEMORAL (CADA LADO) ==> COLUMNA LOMBO-SACRA & BACIA	
3	5.91	36.36	2.15	6.15	4.00	COLUMNA TOTAL OU ESCOLIOSE PANORAMICA & COLUMNA DORSAL: AP-LATERAL ==> COLUMNA PARA ESCOLIOSE: TA-LATERAL	
3	5.91	36.36	2.15	6.15	4.00	COLUMNA PARA ESCOLIOSE: TA-LATERAL ==> COLUMNA TOTAL OU ESCOLIOSE PANORAMICA & COLUMNA DORSAL: AP-LATERAL	
3	3.23	17.39	2.15	5.39	4.00	RADIOSCOPIA PARA ACOMPANHAMENTO DE PROCEDIMENTO CIRURGICO & COLUMNA LOMBO-SACRA ==> JOELHO OU ROTULA: AP.-LAT	
3	12.37	66.67	2.15	5.39	4.00	JOELHO OU ROTULA: AP.-LAT - AXIAL ==> RADIOSCOPIA PARA ACOMPANHAMENTO DE PROCEDIMENTO CIRURGICO & COLUMNA LOMBO-SACRA	
2	15.05	80.00	2.15	5.31	4.00	ESCANOMETRIA ==> COLUMNA TOTAL OU ESCOLIOSE PANORAMICA	
2	2.69	14.29	2.15	5.31	4.00	COLUMNA TOTAL OU ESCOLIOSE PANORAMICA ==> ESCANOMETRIA	
3	15.05	75.00	3.23	4.98	6.00	COLUMNA PARA ESCOLIOSE: TA-LATERAL & COLUMNA LOMBO-SACRA ==> COLUMNA TOTAL OU ESCOLIOSE PANORAMICA	
3	4.30	21.43	3.23	4.98	6.00	COLUMNA TOTAL OU ESCOLIOSE PANORAMICA ==> COLUMNA PARA ESCOLIOSE: TA-LATERAL & COLUMNA LOMBO-SACRA	
4	12.37	60.00	3.23	4.85	6.00	TORAX :PA - LAT & BACIA ==> RADIOSCOPIA PARA ACOMPANHAMENTO DE PROCEDIMENTO CIRURGICO & COLUMNA LOMBO-SACRA	
4	5.38	26.09	3.23	4.85	6.00	RADIOSCOPIA PARA ACOMPANHAMENTO DE PROCEDIMENTO CIRURGICO & COLUMNA LOMBO-SACRA ==> TORAX :PA - LAT & BACIA	
2	15.05	72.73	4.30	4.83	8.00	COLUMNA PARA ESCOLIOSE: TA-LATERAL ==> COLUMNA TOTAL OU ESCOLIOSE PANORAMICA	
2	5.91	28.57	4.30	4.83	8.00	COLUMNA TOTAL OU ESCOLIOSE PANORAMICA ==> COLUMNA PARA ESCOLIOSE: TA-LATERAL	
4	4.30	20.69	3.23	4.81	6.00	TORAX :PA - LAT & COLUMNA LOMBO-SACRA ==> RADIOSCOPIA PARA ACOMPANHAMENTO DE PROCEDIMENTO CIRURGICO & BACIA	

Exemplo de arquivo de entrada na área da saúde

	△ COD_SERVICO	△ DIAGNOSTICO	13	DT_ATENDIMENTO
1	20010028	HAS	50440926	12DEC2008:00:00:00
2	20010010	HAS	50440926	16APR2009:00:00:00
3	20010141	HAS	50440926	05JUN2009:00:00:00
4	20010010	HAS	50440926	30NOV2009:00:00:00
5	20010010	HAS	50440926	15APR2010:00:00:00
6	20010010	HAS	50440926	14JUL2010:00:00:00
7	20010010	HAS	50440926	03NOV2010:00:00:00
8	20010010	HAS	50440926	14FEB2011:00:00:00
9	20010010	HAS	50440926	01JUL2011:00:00:00
10	20010010	HAS	50440926	14OCT2011:00:00:00
11	20010141	HAS	50440926	19OCT2011:00:00:00
12	20010010	HAS	50440926	08FEB2012:00:00:00
13	20010010	HAS	50440926	02JUL2012:00:00:00
14	20010141	HAS	50440926	07JUL2012:00:00:00
15	20010010	HAS	50440926	11DEC2012:00:00:00
16	20010141	HAS	50440926	23JAN2013:00:00:00
17	20010010	HAS	50440926	16MAY2013:00:00:00
18	20010010	HAS	50440926	15AUG2013:00:00:00
19	20010028		50440945	05FEB2009:00:00:00
20	20010010		50440945	12MAR2009:00:00:00
21	20010010		50440945	09JUN2009:00:00:00
22	20020058		50440945	16JUL2009:00:00:00
23	20010010		50440945	10DEC2009:00:00:00
24	20010010		50440945	05MAY2010:00:00:00
25	20010028		50440945	24MAY2010:00:00:00
26	20010028		50440945	04APR2011:00:00:00
27	20010010		50440945	13JUN2012:00:00:00
28	20010028		50440945	25JUN2012:00:00:00
29	20020058		50440945	20SEP2013:00:00:00
30	20010010		50440959	08MAR2010:00:00:00
31	20010133		50440959	29MAR2010:00:00:00
32	20020058		50440959	27SEP2010:00:00:00



PROBABILIDADE EM **MODELOS DE LINGUAGEM**



Large Language Models

Large Language Models (LLMs) são modelos de inteligência artificial baseados em redes neurais profundas, utilizados para processar, entender e gerar linguagem natural. Esses modelos são treinados com grandes volumes de dados textuais não estruturados, como livros, artigos, teses, conversas e sites, para aprender padrões, contextos e relações linguísticas.

Probabilidade em Modelos de Linguagem

- Probabilidade condicional sequencial

$$P(w_n | w_1, w_2, \dots, w_{n-1})$$

Sendo: w_n = próxima palavra

$w_1, w_2, \dots, w_{n-1}$ = palavras anteriores

Probabilidade em Modelos de Linguagem

- Probabilidade condicional de duas sequências

$$P(B|A) = \frac{\text{frequência do bigrama}(A,B)}{\text{frequência de todos os bigramas começando com } A}$$

- Probabilidade condicional de três sequências

$$P(C|A, B) = \frac{\text{frequência do trigrama}(A,B,C)}{\text{frequência de todos os trigramas começando com } (A,B)}$$

Probabilidade em Modelos de Linguagem

Corpus = {"Eu amo gatos",

"Eu amo cachorros",

"Você ama cachorros",

"Eu odeio gatos",

"Eles amam gatos",

"Eu amo gatos"}

Frase	Bigramas	Trigramas
Eu amo gatos	(Eu, amo), (amo gatos)	(Eu, amo, gatos)
Eu amo cachorros	(Eu, amo), (amo cachorros)	(Eu, amo, cachorros)
Você ama cachorros	(Você ama), (ama, cachorros)	(Você, ama, cachorros)
Eu odeio gatos	(Eu odeio), (odeio gatos)	(Eu, odeio, gatos)
Eles amam gatos	(Eles amam), (amam, gatos)	(Eles, amam, gatos)
Eu amo gatos	(Eu amo), (amo gatos)	(Eu, amo, gatos)

Probabilidade em Modelos de Linguagem

Corpus = {"Eu amo gatos",

"Eu amo cachorros",

"Você ama cachorros",

"Eu odeio gatos",

"Eles amam gatos",

"Eu amo gatos"}

Probabilidade da primeira palavra da sentença
 $P(\text{palavra})$:

$$P(\text{"Eu"}) = \frac{4}{6} = 0,67$$

$$P(\text{"Você"}) = \frac{1}{6} = 0,17$$

$$P(\text{"Eles"}) = \frac{1}{6} = 0,17$$


Probabilidade condicional: $P(\text{palavra}_t | \text{palavra}_{t-1})$

$$P(\text{"amo"} | \text{"Eu"}) = \frac{\text{frequência}(\text{"Eu amo"})}{\text{frequência}(\text{"Eu"})} = \frac{3}{4} = 0,75$$

$$P(\text{"gatos"} | \text{"Eu amo"}) = \frac{\text{frequência}(\text{"Eu amo gatos"})}{\text{frequência}(\text{"Eu amo"})} = \frac{2}{3} = 0,67$$

Probabilidade Condicional

Aspecto	Market Basket Analysis (MBA)	Large Language Models (LLMs)
Objetivo	Descobrir padrões de associação entre itens em transações.	Modelar e gerar linguagem natural.
Entradas	Conjunto de itens (dados transacionais)	Sequência de texto (palavras, sentenças, tokens).
Saída	Regras de associação	Probabilidade de próximas palavras ou geração de textos.
Área da Estatística	Probabilidade condicional entre itens. Associação. Independência entre itens na transação.	Probabilidade condicional sequencial. Modelos de linguagem. Dependência sequencial. A ordem das palavras importa.
Tipo de dados	Estruturado (transações, itens).	Dados não estruturados (texto).
Algoritmo	Apriori	Redes neurais (Transformers), n-gramas, embeddings.
Aplicação	Varejo, e-commerce, recomendação de produtos.	Chatbots, tradução, resumo, IA generativa



AMOSTRAGEM



Exemplo: Quarterly Earnings per Johnson & Johnson Share


Forecasts from Holt-Winters' additive method

$$Y_{t+m} = (L_t + b_t m) S_{t-s+m}$$

```
modelo5 = hw(johnsonjohnson, seasonal=c("additive"),h=16)
modelo5$model
autoplot(modelo5)
```

Smoothing parameters:


- alpha = 0.0701 **Nível**
- beta = 0.0699 **Tendência**
- gamma = 0.8563 **Sazonalidade**



APLICAÇÃO DA AMOSTRAGEM

Validação Cruzada

- Dividir os dados em partes iguais e utilizar:
 - uma fração delas para treinar o algoritmo com um hiperparâmetro;
 - outra parte testar a sua predição



Seleção do hiperparâmetro com melhor performance → definição do algoritmo com esse hiperparâmetro nos dados de treino.

Fazer o mesmo para todos os algoritmos.

A única forma de saber qual o algoritmo de melhor performance é testando todos.

APLICAÇÃO DE IA

RETAIL OCTOBER 10, 2018 / 8:04 PM / UPDATED 3 YEARS AGO

Amazon scraps secret AI recruiting tool that showed bias against women

By Jeffrey Dastin

8 MIN READ



SAN FRANCISCO (Reuters) - Amazon.com Inc's [AMZN.O](#) machine-learning specialists uncovered a big problem: their new recruiting engine did not like women.

...

That is because Amazon's computer models were trained to vet applicants by observing patterns in resumes submitted to the company over a 10-year period. Most came from men, a reflection of male dominance across the tech industry.

Fonte: <https://www.reuters.com/article/us-amazon-com-jobs-automation-insight-idUSKCN1MK08G>

EXEMPLO

APLICAÇÃO DE MACHINE LEARNING

Ethical Implications Of Bias In Machine Learning

Adrienne Yapo
Bentley University
175 Forest St.
Waltham, MA 02452
adrienne.yapo@gmail.com

Joseph Weiss
Bentley University
175 Forest St.
Waltham, MA 02452
jweiss@bentley.edu

1.2. Machine learning algorithm bias

Although machine learning algorithms can produce numerous benefits to individuals, consumers, businesses, investors, the government, and society at large, recent research has uncovered many instances of bias in machine learning algorithms that have troubling implications and deleterious consequences.

1.3. Machine learning in the criminal justice system

Yet perhaps the most troubling incidents of bias in machine learning to date are unfolding in the criminal justice system. Consider the following statement from then U.S. Attorney General Eric Holder on the Sentencing Reform and Corrections Act of 2015:

Table 1: Disproportionate incarceration rates


Source: *Propublica* analysis from Broward County, Florida

Prediction Fails Differently for Black Defendants

	White	African American
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

"Overall, Northpointe's assessment tool correctly predicts recidivism 61 percent of the time. But blacks are almost twice as likely as whites to be labeled a higher risk but not actually re-offend. It makes the opposite mistake among whites: They are much more likely than blacks to be labeled lower risk but go on to commit other crimes."


Fonte: <https://scholarspace.manoa.hawaii.edu/bitstream/10125/50557/paper0670.pdf>



INFERÊNCIA ESTATÍSTICA



INFERÊNCIA ESTATÍSTICA






INFERÊNCIA **ESTATÍSTICA**

• Amostragem

O que é necessário garantir?

- Que a amostra seja representativa da população

A amostra deve possuir as mesmas características básicas da população, no que diz respeito às variáveis que desejamos pesquisar.



INFERÊNCIA ESTATÍSTICA

• Amostragem: Conceitos

População

É um conjunto de indivíduos, objetos, ou elementos que possuem pelo menos uma característica em comum.

Característica em comum é o atributo usado como critério de reconhecimento ou de inclusão.

Parâmetros: μ (média), σ (desvio padrão), P (proporção)

Amostra

É um subconjunto da população.

Estimativas $\bar{x}$ (média), s (desvio padrão), p (proporção)

Unidade amostral é um objeto (pessoa ou coisas) sobre o qual coletaremos as medidas.

INFERÊNCIA ESTATÍSTICA

Tipos de amostragem

✓ PROBABILÍSTICA

- ✓ ALEATÓRIA SIMPLES
- ✓ SISTEMÁTICA
- ✓ ESTRATIFICADA
- ✓ CONGLOMERADO

✓ NÃO PROBABILÍSTICA
(INTENCIONAL)

- ✓ COTAS
- ✓ PROCURA
- ✓ INTERNET PANELS (RIVER SAMPLING,
RESPONDENT-DRIVEN SAMPLING)

Procedimento de Sorteio de Amostra

✓ Aleatória Simples

Cadastro de clientes da Empresa XPTO

ID	tel_mov	tel_fixo	sexo	idade	anos_estudo
1	1	1	2	63	1
2	1	1	2	28	12
3	1	1	2	75	12
4	1	1	2	34	12
5	1	1	4	26	9
6	1	1	2	25	11
7	0	1	2	30	16
8	0	0	4	75	5
9	0	0	2	40	12
10	1	1	2	58	16
11	1	1	4	39	1
12	1	1	2	46	12
13	1	1	4	46	16
14	1	1	2	22	14
15	1	1	2	20	13
16	1	1	4	18	12
17	0	0	4	76	5
18	0	0	2	34	1
19	1	1	2	50	16
20	1	1	4	44	16
21	1	1	2	19	13
22	1	1	4	18	12
23	0	1	2	89	12
24	0	1	4	87	12
25	0	1	2	76	12
26	0	1	4	74	6

Sorteio de uma amostra aleatória simples composta de cinco clientes

- $n = 5$
- gerar cinco números aleatórios entre 1 a N

Usando o Excel:

Função geradora de número aleatório:

$= \text{aleatórioentre}(1;N)$

Resultado →

Contador	Sorteio
1	15
2	25
3	4
4	9
5	8

Procedimento de Sorteio de Amostra

✓ Sistemática

Cadastro de clientes da Empresa XPTO

ID	tel_mov	tel_fixo	sexo	idade	anos_estudo	Contador
1	1	1	2	63	1	1
2	1	1	2	28	12	2
3	1	1	2	75	12	3
4	1	1	2	34	12	4
6	1	1	2	25	11	5
7	0	1	2	30	16	6
9	0	0	2	40	12	7
10	1	1	2	58	16	8
12	1	1	2	46	12	9
14	1	1	2	22	14	10
15	1	1	2	20	13	11
18	0	0	2	34	1	12
19	1	1	2	50	16	13
21	1	1	2	19	13	14
23	0	1	2	89	12	15
25	0	1	2	76	12	16
5	1	1	4	26	9	17
8	0	0	4	75	5	18
11	1	1	4	39	1	19
13	1	1	4	46	16	20
16	1	1	4	18	12	21
17	0	0	4	76	5	22
20	1	1	4	44	16	23
22	1	1	4	18	12	24
24	0	1	4	87	12	25
26	0	1	4	74	6	26

Sorteio de uma amostra sistemática composta de cinco clientes (n=5)

Usando o Excel:

- 1) Arquivo ordenado por Sexo
- 2) Intervalo = $N/n = 26/5 = 5,2$
- 3) Sorteio do início casual : gerar um número aleatório entre 1 e 5,2 (intervalo)
 $=\text{aleatório}() * (5.2 - 1) + 1$

obs: copie e cole especial (valor)

Contador	Fórmula	Sorteio
1	A1 = IC	3.815336
2	A2 = A1+INT	8.515336
3	A3 = A2+INT	13.71534
4	A4 = A3+INT	18.91534
5	A5 = A4+INT	24.11534

Procedimento de Sorteio de Amostra

✓ Exemplo de Amostra Estratificada

Uma empresa emprega 2000 engenheiros do sexo masculino e 500 do sexo feminino. O departamento de RH deseja pesquisar opiniões desses profissionais sobre o sistema de avaliação de desempenho da empresa. Para dar uma atenção adequada à opinião feminina, a amostra será composta por 200 engenheiros e 200 engenheiras.

ID	Sexo	
1	F	Estrato 1
2	F	
.	.	
.	.	
500	F	Estrato 2
501	M	
502	M	
.	.	
2500	M	

Amostra aleatória simples de tamanho 200

Amostra aleatória simples de tamanho 200

+

+

.

□



.

.

.

• •

-



Procedimento de Sorteio de Amostra

✓ Usos

Procedimento de Sorteio da Amostra	Pesos amostrais(*)
Aleatória Simples	Não
Sistemática	Não
Estratificada	Sim
Conglomerado	Sim

(*) análise estatística

✓ Amostra por Cotas

▪ pesos amostrais

INFERÊNCIA **ESTATÍSTICA**


Usos de amostragem

- ✓ Pesquisa eleitoral
- ✓ Pesquisa com clientes
- ✓ Desenvolvimento de modelos estatísticos
 - ✓ Amostra de desenvolvimento
 - ✓ Amostra de validação

Intervalo de Confiança

Intervalos de confiança

$$P[(\bar{x} - 1.96.dp(\bar{x})) \leq \bar{X} \leq \bar{x} + 1.96.dp(\bar{x})] = 0.95$$



Distribuição da média amostral segundo o modelo normal com parâmetros ($\bar{x}; dp(\bar{x})$)

O uso da distribuição normal como modelo para a distribuição da média amostral possibilita esperar que 95% das estimativas sejam diferentes do valor populacional por no máximo 1.96 desvios padrão.

Intervalo de Confiança

A figura 8.5 mostra 100 intervalos de confiança (95%) para a média de glicose no sangue de uma população. Os intervalos com estimativas menores que 34(g/l) ou maiores que 36(g/l) também não contém o valor 35.





Figure 8.5 Confidence intervals from Figure 8.4 ordered by the magnitude of the mean of the random sample.

Teorema do Limite Central



Para amostras aleatórias simples ($X_1, \dots, X_n$) retiradas de uma população com média μ e variância σ^2 finita, a distribuição da média amostral $\bar{X}$ aproxima-se, para n grande, de distribuição normal com média μ e variância $\frac{\sigma^2}{n}$.

Fonte: BUSSAB, W.O.; MORETTIN, P. A., Estatística Básica, 5a. ed., São Paulo: Saraiva, 2006. Página 273.

Medidas de Dispersão

Desvio Padrão X Erro Padrão (Std Error)

- Desvio Padrão: variabilidade das observações em relação à média de uma amostra.
- Erro Padrão (Std Error) : variabilidade entre as amostras

$$Erropadrao = \frac{desviopadrão}{\sqrt{n}}$$

A grande finalidade do
conhecimento não é conhecer,
mas agir.

T. Huxley

OBRIGADO

 / Regina T. I. Bernal

FIAP

Copyright © 2025 | Professora Dra. Regina Tomie Ivata Bernal
Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente proibido sem consentimento formal, por escrito, do professor/autor.

FIAP