


FIAP

NBA



.

ENGENHARIA DE DADOS



DATA SCIENCE



Dra. Regina Tomie Ivata Bernal

Cientista de Dados na área da Saúde

Formação Acadêmica:

Estatístico - UFSCar

Mestre em Saúde Pública - FSP/USP

Doutor em Ciências - Epidemiologia - FSP/USP

Atividades Profissionais:

Professora de pós-graduação na FIAP

Consultora externa da SVS/MS

Cientista de Dados em Saúde

profregina.bernal@fiap.com.br
reginabernal@terra.com.br

CALENDÁRIO

Presencial

02/02/2026

Aplicação de Data Science
Introdução a Estatística
Exercício prático

09/03/2026

Introdução a probabilidade
Inferência Estatística
Exercício prático

16/03/2026

Técnicas supervisionadas
Modelos de predição
Exercício prático

23/03/2026

Técnicas supervisionadas
Modelos de predição
Exercício prático


30/03/2026

TÓPICO 3


TÓPICO 4

Extração de Conhecimento

Extração de conhecimento em bases de dados
- A metodologia de data mining -




PROCESSO KDD




Fonte: Berry & Linoff, 2004.

Extração de Conhecimento


Extração de conhecimento em bases de dados
- A metodologia de data mining -



PROCESSO KDD



Fonte: Berry & Linoff, 2004.




TÉCNICAS SUPERVISIONADAS



Data Mining



aplicações práticas de Data Mining se podem ser categorizadas de acordo com a tarefa que se pretende resolver




Técnicas Estatísticas

Construir modelos
(MINERAÇÃO)

Extração de conhecimento em bases de dados

- A metodologia de data mining -

Técnicas Supervisionadas



Técnicas Não Supervisionadas

Data Mining: Mineração - Construção de Modelos



Funções matemáticas

Uma função matemática é uma relação entre dois conjuntos, na qual cada elemento do primeiro conjunto (domínio) está associado a um único elemento do segundo conjunto (contradomínio).

Estrutura de uma função:

$$f: A \rightarrow B$$

Onde: f é uma função de A em B

A = domínio (os valores de entrada)

B = contradomínio (valores possíveis de saída)

$f(x)$ = a regra que transforma cada entrada x em uma saída $f(x)$

Exemplo

Tipo

Exemplo

Descrição


Linear

$f(x)=2x+1$

Crescimento constante

Solução

x	$f(x)$
1	3
2	5
3	7
4	9



Data Mining: Mineração - Construção de Modelos




Funções matemáticas

Exemplos

Tipo de funções	Exemplo	Descrição
Linear	$f(x)=2x+1$	Crescimento constante
Quadrática	$f(x)=x^2$	Curva parabólica
Exponencial	$f(x)=2^x$	Crescimento acelerado
Logarítmica	$f(x)=\log x$	Crescimento desacelerado
Constante	$f(x)=5$	Sempre igual

Regressão Linear

✓ Case 2: Quando o Brasil vai ter 100 celulares para cada 100 habitantes?



Fonte: <http://www.teleco.com.br/comentario/com237.asp>



MODELOS PREDITIVOS





• Estatística + Tradicional

➤ Inferência estatística



Conjunto de técnicas
estatísticas baseadas
em I.C. e erro padrão
Modelos
interpretáveis

Machine Learning




- Baseado em algoritmos
- O objetivo é identificar o que funciona
- Interessa em prever os resultados de amostras futuras
- Foco na praticidade ➔ Desenvolve em uma amostra e aplica em outra
- Algoritmos para tomada de decisão
- Limitações/grandes desafios:
 - Tendência ao sobre ajuste
 - Dados influenciados por erros de medição e fatores aleatórios
 - Ajuste perfeito para um grupo de dados e pode não funcionar bem para outro
 - Algoritmo preconceituoso

Modelos Preditivos

Machine learning

Problemas **práticos** de predição (para tomada de decisão)

- Pouco interesse em interpretar os modelos
- Liberdade para modelar a complexidade do mundo real



Se machine learning não se importa muito com interpretação, então se importa de fato com o quê?

➔ **Performance preditiva** (ou seja, acurácia das decisões)




Fig. 2 — Visualização do Overfitting e Underfitting.

Fone: <https://medium.com/comunidades/o-que-é-overfitting-0b91850d0512>



REGRESSÃO LINEAR




Data Mining: Mineração - Construção de Modelos



aplicações práticas de Data Mining se podem ser categorizadas de acordo com a tarefa que se pretende resolver

- **Regressão:** Compreende a busca por uma função que mapeie os registros de um banco de dados em um intervalo de valores numéricos reais. Esta tarefa é similar à tarefa de Classificação, com a diferença de que o atributo alvo assume valores numéricos.



Data Mining: Mineração - Construção de Modelos




Pipeline da Regressão Linear Simples e Múltipla

Diagrama do Modelo de Regressão Linear

Suposições da Regressão Linear Múltipla
 Normalidade
 Linearidade
 Homocedasticidade
 Distribuição Normal dos resíduos

Passo 1



Regressão Linear

OBJETIVO

Unir de forma paramétrica os dados históricos, buscando sua relação de dependência entre períodos de tempo e na relação de causa e efeito entre variáveis

Modelos de Regressão

REGRESSÃO

Técnica estatística que relaciona, funcionalmente, uma variável dependente às suas possíveis variáveis explicativas


Não-Linear

LINEAR

✓ SIMPLES: uma variável explicativa

✓ MÚLTIPLA: duas ou mais variáveis explicativas

Regressão Linear Simples






Inclinação populacional
Intercepto populacional

$$Y_i = \beta_0 + \beta_1 X_i + \xi_i$$

Transformação da Variável

Quando o modelo não é conhecido, pode-se escolher a transformação examinando o gráfico x e y.

Exemplos:




Análise de Resíduos

Forma de avaliar se as suposições colocadas no desenvolvimento do modelo não foram violadas

$$\hat{e}_i = y_i - \hat{y}_i$$


Pelo gráfico de dispersão, visualizamos o comportamento dos resíduos



Análise de Resíduos

RESÍDUOS PADRONIZADOS:

$$\frac{e_i}{se}$$



$$P[(\mu - 2\sigma) < X < (\mu + 2\sigma)] = 95.44\%$$

RESÍDUOS STUDENTIZADOS:


$$\frac{e_i}{se\sqrt{1 - v_{ii}}}$$

onde $v_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum (x_i - \bar{x})^2}$


Análise de Resíduos

LINEARIDADE


Gráfico de dispersão dos valores preditos ($\hat{y}$) e o resíduo $\Rightarrow$ os resíduos devem estar distribuídos aleatoriamente.




Análise de Resíduos



Modelo adequado



Modelo não adequado



Modelo não adequado




o comportamento não aleatório dos resíduos podem ser eliminados ajustando no modelo um termo quadrático.

Análise de Resíduos

IGUALDADE DE VARIÂNCIA

Quando o gráfico de dispersão dos Resíduos Studentizados, contra o valor predito, indica que a extensão dos resíduos aumentam com a magnitude dos valores preditos:


Então a suposição de igualdade da variância está violada



Análise de Resíduos

NORMALIDADE


Pelo histograma dos resíduos padronizados pode-se analisar a suposição de normalidade.



Análise de Resíduos

LOCALIZANDO OS OUTLIERS:

Em geral, resíduos padronizados com valores maiores que 2 são considerados outliers



Medidas de Erros

Erro Médio (Mean error-ME): $ME = \frac{\sum_{i=1}^n y_i - \hat{y}_i}{n}$

Erro Médio Absoluto (Mean Absolut Error-MAE): $MAE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n}$

Raiz do Erro Quadrático Médio (Root Mean Squared Error-RMSE):


$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}$$

Erro Percentual Médio (Mean Percent Error-MPE):

$$MPE = \frac{\sum_{i=1}^n \frac{y_i - \hat{y}_i}{y_i * 100}}{n}$$

Erro Percentual Absoluto Médio (Mean Absolut Percent Error-MAPE):

$$MAPE = \frac{\sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i * 100}}{n}$$



CORRELAÇÃO DE PEARSON



CORRELAÇÃO DE PEARSON





Correlação indica a força e a direção do relacionamento linear entre duas **variáveis aleatórias**. No uso estatístico geral, correlação se refere à medida da relação entre duas variáveis, embora correlação não implique **causalidade**. Nesse sentido geral, existem vários coeficientes medindo o grau de correlação, adaptados à natureza dos dados.

Vários coeficientes são utilizados para situações diferentes. O mais conhecido é o **coeficiente de correlação de Pearson**, o qual é obtido dividindo a **covariância** de duas variáveis pelo produto de seus **desvios padrão**. Apesar do nome, ela foi apresentada inicialmente por **Francis Galton**, em meados do século XVII.

Coeficiente de correlação de Pearson, em geral é expresso por R ou ρ .





CORRELAÇÃO DE PEARSON

Análise de correlação



coeficiente de correlação (r) representa a relação linear entre duas variáveis

Valores de r e suas implicações



Correlação Linear Simples
(r de Pearson)


$$\frac{\sum_{i=1} (X_i - \bar{X}) * (Y_i - \bar{Y})}{\sqrt{\sum_{i=1} (X_i - \bar{X})^2 * \sum_{i=1} (Y_i - \bar{Y})^2}}$$

Para avaliar-se a correlação entre variáveis, é importante conhecer a magnitude ou força tanto quanto a significância da correlação.


Cuidado

É importante lembrar que o conceito de correlação refere-se a uma associação numérica entre duas variáveis, não implicando necessariamente numa relação de *causa-efeito*. Portanto, mesmo que duas variáveis apresentem-se matematicamente relacionadas, não significa que deva existir uma relação lógica entre elas.

Volume de vendas X Número de vendedores



Volume de vendas X Número de vendedores



Interpretação dos resultados

Vemos na tabela abaixo que apenas os 3 primeiros resultados não incluem dúvidas. Entretanto, nas demais situações o quadrado do valor de R informa a quantidade de variação conjunta para as duas variáveis.

R		R ²	Variação conjunta %
- 1	Correlação negativa perfeita	1	100
0	Independência	0	nenhuma
1	Correlação perfeita positiva	1	100
0,9	????	0,81	81
0,8		0,64	64
0,7		0,49	49
0,5	????	0,25	25
0,6		0,36	36
0,3	????	0,09	9

Análise de Variância

Podemos resumir todas essas informações numa única tabela anova:

Fonte	gl	SQ	QM	F
Regressão	$p - 1$	SQReg	$QMReg = \frac{SQReg}{p - 1}$	$\frac{QMReg}{Se^2}$
Resíduo	$n - p$	SQRes	$Se^2 = \frac{SQRes}{n - p}$	
Total	$n - 1$	SQTOT	$S^2 = \frac{SQTot}{n - 1}$	

Análise de Variância

Coeficiente de determinação (R^2): Multiple R-squared

$$R^2 = \frac{SQReg}{SQTot}$$

Coeficiente de determinação ajustado (R^2): Adjusted R-squared


$$R_a^2 = 1 - \frac{n - 1}{n - (p + 1)} (1 - R^2)$$

Onde: n = número de observações


p = número de variáveis preditoras



REGRESSÃO LINEAR MÚLTIPLA



Campanhas



Variáveis:

Segmento:

Pequeno
Médio
Grande
Muito Grande

Dia da semana:

Domingo
Segunda-feira
Terça-feira
Quarta-feira
Quinta-feira
Sexta-feira
Sábado

Ordem da oferta:


1ª
2ª
3ª
4ª
5ª

Marca:

A
B
C

Celebridade:

Sim
Não




Quantidade
de vendas

Campanhas



+



Variáveis:

Segmento: (X1) **Preditora**

- Pequeno (1)
- Médio (2)
- Grande (3)
- Muito Grande (4)

Dia da semana: (X2) Ordem da oferta: (X3)

- | | |
|-------------------|--------|
| Domingo (1) | 1ª (1) |
| Segunda-feira (2) | 2ª (2) |
| Terça-feira (3) | 3ª (3) |
| Quarta-feira (4) | 4ª (4) |
| Quinta-feira (5) | 5ª (5) |
| Sexta-feira (6) | |
| Sábado (7) | |


Marca: X4

- A (1)
- B (2)
- C (3)

Celebridade: X5

- Sim (1)
- Não (2)

Modelo Preditivo



Quantidade
de vendas

Y

Resposta

+

+

.



.

.

.

.

Campanhas



Variáveis:

Segmento: (X1)

- Pequeno (1)
- Médio (2)
- Grande (3)
- Muito Grande (4)

Dia da semana: (X2) Ordem da oferta: (X3)

- | | |
|-------------------|--------|
| Domingo (1) | 1ª (1) |
| Segunda-feira (2) | 2ª (2) |
| Terça-feira (3) | 3ª (3) |
| Quarta-feira (4) | 4ª (4) |
| Quinta-feira (5) | 5ª (5) |
| Sexta-feira (6) | |
| Sábado (7) | |


Marca: X

- A (1)
- B (2)
- C (3)

Celebridade: X

- Sim (1)
- Não (2)

Analytics



Quantidade de vendas

Y

Modelo de regressão linear múltipla

$$Y = a + b1 \cdot X1 + b2 \cdot X2 + b3 \cdot X3 + b4 \cdot X4 + b5 \cdot X5$$

Variáveis qualitativas → Criar variáveis dicotômicas (booleanas/dummies) para cada categoria

Segmento: **(X1)** Preditora

Pequeno (1)
Médio (2)
Grande (3)
Muito Grande (4)



SegPequeno (X11)	SegMedio(X12)	SegGrande(X13)	SegMuitoGde (X14)
0	0	0	0
1	1	1	1

```
case2$segmentacao1=case2$Segmentacao_valor
case2$segmentacao1=ifelse(case2$Segmentacao_valor==1,1,0)
case2$segmentacao2=case2$Segmentacao_valor
case2$segmentacao2=ifelse(case2$Segmentacao_valor==2,1,0)
case2$segmentacao3=case2$Segmentacao_valor
case2$segmentacao3=ifelse(case2$Segmentacao_valor==3,1,0)
case2$segmentacao4=case2$Segmentacao_valor
case2$segmentacao4=ifelse(case2$Segmentacao_valor==4,1,0)
case2$segmentacao5=case2$Segmentacao_valor
case2$segmentacao5=ifelse(case2$Segmentacao_valor==5,1,0)
```

Variáveis qualitativas → Criar variáveis dicotômicas (booleanas/dummies) para cada categoria


```
case2$ordem_oferta_valor1 = case2$ordem_oferta_valor
case2$ordem_oferta_valor1 = ifelse(case2$ordem_oferta_valor == 1, 1, 0)
case2$ordem_oferta_valor2 = case2$ordem_oferta_valor
case2$ordem_oferta_valor2 = ifelse(case2$ordem_oferta_valor == 2, 1, 0)
case2$ordem_oferta_valor3 = case2$ordem_oferta_valor
case2$ordem_oferta_valor3 = ifelse(case2$ordem_oferta_valor == 3, 1, 0)
case2$ordem_oferta_valor4 = case2$ordem_oferta_valor
case2$ordem_oferta_valor4 = ifelse(case2$ordem_oferta_valor == 4, 1, 0)
```

```
case2$celebridade_valor1 = case2$celebridade_valor
case2$celebridade_valor1 = ifelse(case2$celebridade_valorr == 1, 1, 0)
case2$celebridade_valor2 = case2$celebridade_valor
case2$celebridade_valor2 = ifelse(case2$celebridade_valor == 2, 1, 0)
```


Variáveis qualitativas → Criar variáveis dicotômicas (booleanas/dummies) para cada categoria

```
case2$Dia_Semana_valor1 = case2$Dia_Semana_valor
case2$ordem_oferta_valor1 = ifelse(case2$Dia_Semana_valor == 1, 1, 0)
case2$Dia_Semana_valor2 = case2$Dia_Semana_valor
case2$ordem_oferta_valor2 = ifelse(case2$Dia_Semana_valor == 2, 1, 0)
case2$Dia_Semana_valor3 = case2$Dia_Semana_valor
case2$ordem_oferta_valor3 = ifelse(case2$Dia_Semana_valor == 3, 1, 0)
case2$Dia_Semana_valor4 = case2$Dia_Semana_valor
case2$ordem_oferta_valor4 = ifelse(case2$Dia_Semana_valor == 4, 1, 0)
case2$Dia_Semana_valor5 = case2$Dia_Semana_valor
case2$ordem_oferta_valor5 = ifelse(case2$Dia_Semana_valor == 5, 1, 0)
case2$Dia_Semana_valor6 = case2$Dia_Semana_valor
case2$ordem_oferta_valor6 = ifelse(case2$Dia_Semana_valor == 6, 1, 0)
case2$Dia_Semana_valor7 = case2$Dia_Semana_valor
case2$ordem_oferta_valor7 = ifelse(case2$Dia_Semana_valor == 7, 1, 0)
```

Análise bivariada



Modelo de regressão linear múltipla

$$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3 \quad \Rightarrow \quad \text{Quantidade} = 738 + 0.87 \cdot \text{Seg2} - 291 \cdot \text{Seg3} - 475 \cdot \text{Seg4}$$


(teórico) (ajustado)

```
Call:
lm(formula = Quantidade ~ Segmentacao_valor, data = case2)

Residuals:
    Min       1Q   Median       3Q      Max
-703.9  -316.8  -123.9   111.2  3220.1

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   738.8710    56.7257   13.025 < 2e-16 ***
Segmentacao_valor2    0.8706    81.1186    0.011 0.991444
Segmentacao_valor3 -291.0539    82.8690   -3.512 0.000511 ***
Segmentacao_valor4 -475.0199    97.9028   -4.852 1.95e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 547 on 307 degrees of freedom
Multiple R-squared:  0.1044,    Adjusted R-squared:  0.09569
F-statistic: 11.93 on 3 and 307 DF,  p-value: 2.062e-07
```



Acerto do modelo:
O segmento do produto explica 9,5% da variação da quantidade de vendas.

Modelo de regressão linear múltipla

$$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3$$

(teórico)

$$\text{Quantidade} = 738 + 0.87 \cdot \text{Seg2} - 291 \cdot \text{Seg3} - 475 \cdot \text{Seg4}$$

(ajustado)

Call:

```
lm(formula = Quantidade ~ Segmentacao_valor, data = case2)
```

Residuals:

Min	1Q	Median	3Q	Max
-703.9	-316.8	-123.9	111.2	3220.1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	738.8710	56.7257	13.025	< 2e-16 ***
Segmentacao_valor2	0.8706	81.1186	0.011	0.991444
Segmentacao_valor3	-291.0539	82.8690	-3.512	0.000511 ***
Segmentacao_valor4	-475.0199	97.9028	-4.852	1.95e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 547 on 307 degrees of freedom

Multiple R-squared: 0.1044, Adjusted R-squared: 0.09569

F-statistic: 11.93 on 3 and 307 DF, p-value: 2.062e-07

X	Quantidade
Seg2=0 Seg3=0 Seg4=0	?
	Previsão de vendas

$$\text{Quantidade} = 738 + 0.87 \cdot 0 - 291 \cdot 0 - 475 \cdot 0$$

$$\text{Quantidade} = 738$$

Modelo de regressão linear múltipla

$$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3$$

(teórico)



$$\text{Quantidade} = 738 + 0.87 \cdot \text{Seg2} - 291 \cdot \text{Seg3} - 475 \cdot \text{Seg4}$$

(ajustado)

Call:

```
lm(formula = Quantidade ~ Segmentacao_valor, data = case2)
```

Residuals:

Min	1Q	Median	3Q	Max
-703.9	-316.8	-123.9	111.2	3220.1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	738.8710	56.7257	13.025	< 2e-16 ***
Segmentacao_valor2	0.8706	81.1186	0.011	0.991444
Segmentacao_valor3	-291.0539	82.8690	-3.512	0.000511 ***
Segmentacao_valor4	-475.0199	97.9028	-4.852	1.95e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 547 on 307 degrees of freedom

Multiple R-squared: 0.1044, Adjusted R-squared: 0.09569

F-statistic: 11.93 on 3 and 307 DF, p-value: 2.062e-07

X

Quantidade

Seg2=0

Seg3=0

Seg4=0

738

Previsão de vendas

Modelo de regressão linear múltipla

$$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3 \quad \Rightarrow \quad \text{Quantidade} = 738 + 0.87 \cdot \text{Seg2} - 291 \cdot \text{Seg3} - 475 \cdot \text{Seg4}$$

(teórico) (ajustado)

```
Call:
lm(formula = Quantidade ~ Segmentacao_valor, data = case2)

Residuals:
    Min       1Q   Median       3Q      Max
-703.9 -316.8 -123.9  111.2 3220.1

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    738.8710    56.7257  13.025  < 2e-16 ***
Segmentacao_valor2    0.8706    81.1186   0.011  0.991444
Segmentacao_valor3 -291.0539    82.8690  -3.512  0.000511 ***
Segmentacao_valor4 -475.0199    97.9028  -4.852  1.95e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 547 on 307 degrees of freedom
Multiple R-squared:  0.1044,    Adjusted R-squared:  0.09569
F-statistic: 11.93 on 3 and 307 DF,  p-value: 2.062e-07
```

X	Quantidade
Seg2=1 Seg3=0 Seg4=0	?
	Previsão de vendas

$$\text{Quantidade} = 738 + 0.87 \cdot 1$$

Modelo de regressão linear múltipla

$$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3$$

(teórico)



$$\text{Quantidade} = 738 + 0.87 \cdot \text{Seg2} - 291 \cdot \text{Seg3} - 475 \cdot \text{Seg4}$$

(ajustado)

```
Call:
lm(formula = Quantidade ~ Segmentacao_valor, data = case2)

Residuals:
    Min       1Q   Median       3Q      Max
-703.9  -316.8  -123.9   111.2  3220.1

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    738.8710    56.7257  13.025  < 2e-16 ***
Segmentacao_valor2  0.8706    81.1186   0.011  0.991444
Segmentacao_valor3 -291.0539    82.8690  -3.512  0.000511 ***
Segmentacao_valor4 -475.0199    97.9028  -4.852  1.95e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 547 on 307 degrees of freedom
Multiple R-squared:  0.1044,    Adjusted R-squared:  0.09569
F-statistic: 11.93 on 3 and 307 DF,  p-value: 2.062e-07
```

X	Quantidade
Seg2=1 Seg3=0 Seg4=0	738,87 Previsão de vendas

Modelo de regressão linear múltipla

$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3$
(teórico)



Quantidade = 738 + 0.87 * Seg2 -291 * Seg3 -475 * Seg4
(ajustado)

```
Call:
lm(formula = Quantidade ~ Segmentacao_valor, data = case2)
```

Residuals:

Min	1Q	Median	3Q	Max
-703.9	-316.8	-123.9	111.2	3220.1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	738.8710	56.7257	13.025	< 2e-16
Segmentacao_valor2	0.8706	81.1186	0.011	0.991444
Segmentacao_valor3	-291.0539	82.8690	-3.512	0.000511 ***
Segmentacao_valor4	-475.0199	97.9028	-4.852	1.95e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 547 on 307 degrees of freedom
Multiple R-squared: 0.1044, Adjusted R-squared: 0.09569
F-statistic: 11.93 on 3 and 307 DF, p-value: 2.062e-07

X	Quantidade
Seg2=0 Seg3=1 Seg4=0	?
	Previsão de vendas

Quantidade = 738 + 0.87 * 0 -291 * 1 -475 * 0

Quantidade = 738 -291 * 1

Modelo de regressão linear múltipla

$$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3 \quad \Rightarrow \quad \text{Quantidade} = 738 + 0.87 \cdot \text{Seg2} - 291 \cdot \text{Seg3} - 475 \cdot \text{Seg4}$$

(teórico) (ajustado)

```
Call:
lm(formula = Quantidade ~ Segmentacao_valor, data = case2)

Residuals:
    Min       1Q   Median       3Q      Max
-703.9 -316.8 -123.9  111.2 3220.1

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   738.8710    56.7257  13.025  < 2e-16 ***
Segmentacao_valor2    0.8706    81.1186   0.011  0.991444
Segmentacao_valor3 -291.0539    82.8690  -3.512  0.000511 ***
Segmentacao_valor4 -475.0199    97.9028  -4.852  1.95e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 547 on 307 degrees of freedom
Multiple R-squared:  0.1044,    Adjusted R-squared:  0.09569
F-statistic: 11.93 on 3 and 307 DF,  p-value: 2.062e-07
```

X	Quantidade
Seg2=0 Seg3=1 Seg4=0	447 Previsão de vendas

Modelo de regressão linear múltipla

$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3$
(teórico)



Quantidade = 738 + 0 * Seg1 + 0.87 * Seg2 - 291 * Seg3 - 475 * Seg4
(ajustado)

```
Call:
lm(formula = Quantidade ~ Segmentacao_valor, data = case2)

Residuals:
    Min       1Q   Median       3Q      Max
-703.9  -316.8  -123.9   111.2  3220.1

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    738.8710    56.7257  13.025  < 2e-16 ***
Segmentacao_valor2  0.8706    81.1186   0.011  0.991444
Segmentacao_valor3 -291.0539    82.8690  -3.512  0.000511 ***
Segmentacao_valor4 -475.0199    97.9028  -4.852  1.95e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 547 on 307 degrees of freedom
Multiple R-squared:  0.1044,    Adjusted R-squared:  0.09569
F-statistic: 11.93 on 3 and 307 DF,  p-value: 2.062e-07
```

X	Quantidade
Seg2=0 Seg3=0 Seg4=1	263 Previsão de vendas

Modelo de regressão linear múltipla

$$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3$$

(teórico)

$$\text{Quantidade} = 738 + 0.87 \cdot \text{Seg2} - 291 \cdot \text{Seg3} - 475 \cdot \text{Seg4}$$

(ajustado)

```
Call:
lm(formula = Quantidade ~ Segmentacao_valor, data = case2)

Residuals:
    Min       1Q   Median       3Q      Max
-703.9  -316.8  -123.9   111.2  3220.1

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  738.8710    56.7257   13.025 < 2e-16 ***
Segmentacao_valor2    0.8706    81.1186    0.011 0.991444
Segmentacao_valor3 -291.0539    82.8600   -3.512 0.000511 ***
Segmentacao_valor4 -475.0199    97.9028   -4.852 1.95e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 547 on 307 degrees of freedom
Multiple R-squared:  0.1044,    Adjusted R-squared:  0.09569
F-statistic: 11.93 on 3 and 307 DF,  p-value: 2.062e-07
```

	Data	Quantidade	Segmentacao_valor	predito	residuo	residuop
300	7/12/2018	2112	2	740	1372.26	2.52271
301	8/11/2018	1844	3	448	1396.18	2.56794
302	7/13/2018	2248	2	740	1508.26	2.77273
303	4/7/2018	2249	2	740	1509.26	2.77457
304	7/30/2018	2305	2	740	1565.26	2.87752
305	3/16/2018	2308	1	739	1569.13	2.88393
306	2/10/2018	2363	1	739	1624.13	2.98502
307	3/17/2018	2506	2	740	1766.26	3.24703
308	7/28/2018	2999	2	740	2259.26	4.15335
309	6/8/2018	3177	1	739	2438.13	4.48108
310	3/10/2018	3816	1	739	3077.13	5.65551
311	5/5/2018	3959	1	739	3220.13	5.91833

Modelo de regressão linear múltipla

$$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3 + \dots + b_p \cdot X_p$$

(teórico)

```
lm(formula = Quantidade ~ Segmentacao_valor + marca_valor + ordem_oferta_valor +
  dia_semana_valor + celebridade_valor, data = case2)
```

Residuals:

Min	1Q	Median	3Q	Max
-851.84	-203.79	-36.35	131.22	2428.28

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	790.97	91.02	8.690	2.58e-16	***
Segmentacao_valor2	-50.56	62.38	-0.810	0.418341	
Segmentacao_valor3	-298.83	69.51	-4.299	2.34e-05	***
Segmentacao_valor4	-387.65	80.12	-4.838	2.12e-06	***
marca_valor2	-36.97	69.36	-0.533	0.594392	
marca_valor3	114.08	56.47	2.020	0.044274	*
ordem_oferta_valor2	-510.69	74.64	-6.842	4.53e-11	***
ordem_oferta_valor3	-498.71	64.83	-7.693	2.19e-13	***
ordem_oferta_valor4	-627.77	83.92	-7.481	8.61e-13	***
ordem_oferta_valor5	-692.40	64.49	-10.737	< 2e-16	***
dia_semana_valor2	172.14	75.64	2.276	0.023570	*
dia_semana_valor3	309.67	113.32	2.733	0.006664	**
dia_semana_valor4	247.79	104.07	2.381	0.017902	*
dia_semana_valor5	270.77	74.38	3.640	0.000322	***
dia_semana_valor6	415.35	82.08	5.060	7.40e-07	***
dia_semana_valor7	716.83	79.67	8.997	< 2e-16	***
celebridade_valor2	59.89	47.81	1.253	0.211351	

Residual standard error: 399.7 on 294 degrees of freedom
 Multiple R-squared: 0.542, Adjusted R-squared: 0.5171
 F-statistic: 21.75 on 16 and 294 DF, p-value: < 2.2e-16



Modelo de regressão linear múltipla

$$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3 + \dots + b_p \cdot X_p$$

(teórico)

```
lm(formula = Quantidade ~ Segmentacao_valor + marca_valor + ordem_oferta_valor +
  Dia_Semana_desc + celebridade_valor, data = case2_sout)
```

Residuals:

Min	1Q	Median	3Q	Max
-614.46	-164.55	-24.35	128.61	1068.70

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	648.154	60.646	10.688	< 2e-16 ***
Segmentacao_valor2	-19.711	41.910	-0.470	0.638488
Segmentacao_valor3	-246.302	46.370	-5.312	2.20e-07 ***
Segmentacao_valor4	-336.864	52.917	-6.366	7.81e-10 ***
marca_valor2	-43.420	46.165	-0.941	0.347737
marca_valor3	93.464	37.573	2.488	0.013440 *
ordem_oferta_valor2	-335.299	50.080	-6.695	1.16e-10 ***
ordem_oferta_valor3	-330.744	43.651	-7.577	5.06e-13 ***
ordem_oferta_valor4	-436.846	56.191	-7.774	1.42e-13 ***
ordem_oferta_valor5	-508.046	43.635	-11.643	< 2e-16 ***
Dia_Semana_desc2-seg	189.014	49.939	3.785	0.000188 ***
Dia_Semana_desc3-ter	350.749	74.615	4.701	4.05e-06 ***
Dia_Semana_desc4-qua	311.068	68.529	4.539	8.36e-06 ***
Dia_Semana_desc5-qui	251.245	49.317	5.094	6.40e-07 ***
Dia_Semana_desc6-sex	310.554	55.403	5.605	4.93e-08 ***
Dia_Semana_desc7-sab	591.194	53.425	11.066	< 2e-16 ***
celebridade_valor2	4.085	31.972	0.128	0.898433

```
Residual standard error: 262.9 on 283 degrees of freedom
Multiple R-squared: 0.6042, Adjusted R-squared: 0.5818
F-statistic: 27 on 16 and 283 DF, p-value: < 2.2e-16
```

> |

Modelo final
sem resíduos outliers

Seg4
Marca C
Dia da semana 7
Ordem 2
Não tem
celebridade

?

previsão



Modelo de regressão linear múltipla

$$Y = a + b_1 \cdot X_1 + b_2 \cdot X_2 + b_3 \cdot X_3 + \dots + b_p \cdot X_p$$

(teórico)

```
lm(formula = Quantidade ~ Segmentacao_valor + marca_valor + ordem_oferta_valor +
  Dia_Semana_desc + celebridade_valor, data = case2_sout)
```

Residuals:

Min	1Q	Median	3Q	Max
-614.46	-164.55	-24.35	128.61	1068.70

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	648.154	60.646	10.688	< 2e-16 ***
Segmentacao_valor2	-19.711	41.910	-0.470	0.638488
Segmentacao_valor3	-246.302	46.370	-5.312	2.20e-07 ***
Segmentacao_valor4	-336.864	52.917	-6.366	7.81e-10 ***
marca_valor2	-43.420	46.165	-0.941	0.347737
marca_valor3	93.464	37.573	2.488	0.013440 *
ordem_oferta_valor2	-335.299	50.080	-6.695	1.16e-10 ***
ordem_oferta_valor3	-330.744	43.651	-7.577	5.06e-13 ***
ordem_oferta_valor4	-436.846	56.191	-7.774	1.42e-13 ***
ordem_oferta_valor5	-508.046	43.635	-11.643	< 2e-16 ***
Dia_Semana_desc2-seg	189.014	49.939	3.785	0.000188 ***
Dia_Semana_desc3-ter	350.749	74.615	4.701	4.05e-06 ***
Dia_Semana_desc4-qua	311.068	68.529	4.539	8.36e-06 ***
Dia_Semana_desc5-qui	251.245	49.317	5.094	6.40e-07 ***
Dia_Semana_desc6-sex	310.554	55.403	5.605	4.93e-08 ***
Dia_Semana_desc7-sab	591.194	53.425	11.066	< 2e-16 ***
celebridade_valor2	4.085	31.972	0.128	0.898433

```
Residual standard error: 262.9 on 283 degrees of freedom
Multiple R-squared: 0.6042, Adjusted R-squared: 0.5818
F-statistic: 27 on 16 and 283 DF, p-value: < 2.2e-16
```

> |

Modelo final
sem resíduos outliers

Seg4 → -337

Marca C → +93

Dia da semana 7 → +591

Ordem 1 → 0


Não tem celebridade → +4

Intercepto → 648

Previsão = 999 produtos


Enterprise Miner - SAS

Processo de modelagem e escoragem



Enterprise Miner - SAS

Processo de modelagem e escoragem



EXERCÍCIO 2

FAÇA A PREVISÃO DAS VENDAS (R\$) MENSAL NO PERÍODO DE 12 MESES DA EMPRESA XYZ A PARTIR DOS DADOS DISPONÍVEIS DE VENDAS (R\$) E BUDGET ADVERTISING (R\$) DA EMPRESA.

Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.

	Data	ano	Vendas	Budget_Advertising
1	jan/16	2016	1160081	72800
2	fev/16	2016	1622540	123392
3	mar/16	2016	1597260	135761
4	abr/16	2016	1640675	148064
5	mai/16	2016	1511270	159746
6	jun/16	2016	1634073	183353
7	jul/16	2016	1856971	190722
8	ago/16	2016	1585566	197802
9	set/16	2016	2041672	248891
10	out/16	2016	1933557	256353
11	nov/16	2016	2076910	298805
12	dez/16	2016	1740202	268925


Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.

	Data	ano	Vendas	Budget_Advertising
1	jan/16	2016	1160081	72800
2	fev/16	2016	1622540	123392
3	mar/16	2016	1597260	135761
4	abr/16	2016	1640675	148064
5	mai/16	2016	1511270	159746
6	jun/16	2016	1634073	183353
7	jul/16	2016	1856971	190722
8	ago/16	2016	1585566	197802
9	set/16	2016	2041672	248891
10	out/16	2016	1933557	256353
11	nov/16	2016	2076910	298805
12	dez/16	2016	1740202	268925

	Média	Desvio padrão	Média	Desvio padrão
ano	`mean(vendas)` <fct>	`sd(vendas)` <dbl>	`mean(Budget_Advertis~` <dbl>	`sd(Budget_Advertis~` <dbl>
1 2016	1700065.	253028.	190384.	67306.
2 2017	2428664.	361468.	271978	96151.
3 2018	3035830.	451835.	339973	120189.

Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.

	Data	ano	Vendas	Budget_Advertising
1	jan/16	2016	1160081	72800
2	fev/16	2016	1622540	123392
3	mar/16	2016	1597260	135761
4	abr/16	2016	1640675	148064
5	mai/16	2016	1511270	159746
6	jun/16	2016	1634073	183353
7	jul/16	2016	1856971	190722
8	ago/16	2016	1585566	197802
9	set/16	2016	2041672	248891
10	out/16	2016	1933557	256353
11	nov/16	2016	2076910	298805
12	dez/16	2016	1740202	268925




```
> mc = cor(dadosquant);mc
               vendas Budget_Advertising
vendas          1.000             0.852
Budget_Advertising 0.852             1.000
```

Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.


	Data	ano	Vendas	Budget_Advertising
1	jan/16	2016	1160081	72800
2	fev/16	2016	1622540	123392
3	mar/16	2016	1597260	135761
4	abr/16	2016	1640675	148064
5	mai/16	2016	1511270	159746
6	jun/16	2016	1634073	183353
7	jul/16	2016	1856971	190722
8	ago/16	2016	1585566	197802
9	set/16	2016	2041672	248891
10	out/16	2016	1933557	256353
11	nov/16	2016	2076910	298805
12	dez/16	2016	1740202	268925

Modelo de regressão linear simples

$$Y = b_0 + b_1 * X_1 \quad (\text{teórico})$$


$$\text{Vendas} = b_0 + b_1 * \text{Budget}$$

Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.



H0: regressão = média
H1 : regressão $\neq$ média

```
import statsmodels.api as sm
from scipy import stats
from statsmodels.compat import lzip
from scipy.stats.stats import pearsonr
```

```
# Ordinary Least Square (OLS)
X_ = sm.add_constant(X)
est = sm.OLS(y, X_)
est2 = est.fit()
print(est2.summary())
```



OLS Regression Results						
=====						
Dep. Variable:	Vendas	R-squared:	0.725			
Model:	OLS	Adj. R-squared:	0.717			
Method:	Least Squares	F-statistic:	89.75			
Date:	Mon, 21 Jun 2021	Prob (F-statistic):	4.58e-11			
Time:	23:18:47	Log-Likelihood:	-509.57			
No. Observations:	36	AIC:	1023.			
Df Residuals:	34	BIC:	1026.			
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	1.061e+06	1.52e+05	6.988	0.000	7.52e+05	1.37e+06
Budget_Advertising	4.9641	0.524	9.473	0.000	3.899	6.029
=====						
Omnibus:	1.236	Durbin-Watson:	0.781			
Prob(Omnibus):	0.539	Jarque-Bera (JB):	1.112			
Skew:	0.256	Prob(JB):	0.574			
Kurtosis:	2.309	Cond. No.	7.54e+05			

Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.

Adequação
do modelo
ajustado

```

=====
                        OLS Regression Results
=====
Dep. Variable:          Vendas    R-squared:                0.725
Model:                  OLS      Adj. R-squared:             0.717
Method:                 Least Squares  F-statistic:              89.75
Date:                   Mon, 21 Jun 2021  Prob (F-statistic):      4.58e-11
Time:                   23:18:47   Log-Likelihood:           -509.57
No. Observations:       36        AIC:                      1023.
Df Residuals:           34        BIC:                      1026.
Df Model:                1
Covariance Type:        nonrobust

```

Coefficientes
do modelo

```

=====
                        coef    std err          t      P>|t|      [0.025    0.975]
-----
const                1.061e+06  1.52e+05    6.988    0.000    7.52e+05  1.37e+06
Budget_Advertising    4.9641      0.524      9.473    0.000      3.899      6.029

```

Análise de
resíduos

```

=====
Omnibus:                1.236   Durbin-Watson:           0.781
Prob(Omnibus):          0.539   Jarque-Bera (JB):         1.112
Skew:                   0.256   Prob(JB):                 0.574
Kurtosis:               2.309   Cond. No.                  7.54e+05
=====

```


Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.

```

=====
OLS Regression Results
=====
Dep. Variable:          Vendas  R-squared:          0.725
Model:                  OLS    Adj. R-squared:      0.717
Method:                 Least Squares  F-statistic:       89.75
Date:                   Mon, 21 Jun 2021  Prob (F-statistic): 4.58e-11
Time:                   23:18:47  Log-Likelihood:    -509.57
No. Observations:      36      AIC:               1023.
Df Residuals:          34      BIC:               1026.
Df Model:               1
Covariance Type:       nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
const	1.061e+06	1.52e+05	6.988	0.000	7.52e+05	1.37e+06
Budget_Advertising	4.9641	0.524	9.473	0.000	3.899	6.029

```

=====
Omnibus:                1.236  Durbin-Watson:      0.781
Prob(Omnibus):          0.539  Jarque-Bera (JB):    1.112
Skew:                   0.256  Prob(JB):            0.574
Kurtosis:               2.309  Cond. No.            7.54e+05
=====

```

Acurácia do modelo:
A variável Budget explica
72,5% da variação das
Vendas.

Análise de variância (ANOVA)
H0: regressão = média
H1: regressão <> média

Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.725
Model:	OLS	Adj. R-squared:	0.717
Method:	Least Squares	F-statistic:	89.75
Date:	Mon, 21 Jun 2021	Prob (F-statistic):	4.58e-11
Time:	23:18:47	Log-Likelihood:	-509.57
No. Observations:	36	AIC:	1023.
Df Residuals:	34	BIC:	1026.
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	p-value	Intervalo de confiança
				P> t	[0.025 0.975]
const	1.061e+06	1.52e+05	6.988	0.000	7.52e+05 1.37e+06
Budget_Advertising	-4.9641	0.524	-9.473	0.000	3.899 6.029

Omnibus:	1.236	Durbin-Watson:	0.781
Prob(Omnibus):	0.539	Jarque-Bera (JB):	1.112
Skew:	0.256	Prob(JB):	0.574
Kurtosis:	2.309	Cond. No.	7.54e+05

Acurácia do modelo:
A variável Budget explica 72,5% da variação das Vendas.

Análise de variância
H0: regressão = média
H1: regressão <> média

$$\text{Vendas} = b_0 + b_1 * \text{Budget}$$

(modelo ajustado)

$$\text{Vendas} = 1060550 + 4.964 * \text{Budget}$$

Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.725
Model:	OLS	Adj. R-squared:	0.717
Method:	Least Squares	F-statistic:	89.75
Date:	Mon, 21 Jun 2021	Prob (F-statistic):	4.58e-11
Time:	23:18:47	Log-Likelihood:	-509.57
No. Observations:	36	AIC:	1023.
Df Residuals:	34	BIC:	1026.
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	1.061e+06	1.52e+05	6.988	0.000	7.52e+05	1.37e+06
Budget_Advertising	-4.9641	0.524	9.473	0.000	3.899	6.029

Omnibus:	1.236	Durbin-Watson:	0.781
Prob(Omnibus):	0.539	Jarque-Bera (JB):	1.112
Skew:	0.256	Prob(JB):	0.574
Kurtosis:	2.309	Cond. No.	7.54e+05

Acurácia do modelo:
A variável Budget explica 72,5% da variação das Vendas.


Análise de variância
H0: regressão = média
H1: regressão <> média

$$\text{Vendas} = b_0 + b_1 * \text{Budget}$$

(modelo ajustado)

$$\text{Vendas} = 1060550 + 4.964 * \text{Budget}$$

- Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.



Condition Number: é uma medida usada para identificar a multicolinearidade.

Cond.No < 30: sem multicolinearidade

(30;100} multicolinearidade aceitável

> 100: multicolinearidade severa.

> 1000: modelo é instável e os resultados não confiáveis

Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.

Modelo de regressão linear simples

	Data	ano	Vendas	Budget_Advertising
1	jan/16	2016	1160061	72800
2	fev/16	2016	1622540	123392
3	mar/16	2016	1597260	135761
4	abr/16	2016	1640675	148064
5	mai/16	2016	1511270	159746
6	jun/16	2016	1634073	183353
7	jul/16	2016	1856971	190722
8	ago/16	2016	1585566	197802
9	set/16	2016	2041672	248891
10	out/16	2016	1933557	256353
11	nov/16	2016	2076910	298805
12	dez/16	2016	1740202	268925

```
> summary(modelo)
```

Call:

```
lm(formula = vendas ~ Budget_Advertising)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-655330 -256271 -30444   234875  743028
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 1060550.396 151771.308   6.99 0.000000046312 ***
Budget_Advertising 4.964    0.524    9.47 0.000000000046 ***
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 350000 on 34 degrees of freedom
Multiple R-squared:  0.725,    Adjusted R-squared:  0.717
F-statistic: 89.7 on 1 and 34 DF,  p-value: 0.0000000000458
```

Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.

Projeção para 2019

Vendas Budget

jan/19	2019	91000
fev/19	2019	154240
mar/19	2019	169702
abr/19	2019	185081
mai/19	2019	199683
jun/19	2019	229192
jul/19	2019	238403
ago/19	2019	247253
set/19	2019	311114
out/19	2019	320442
nov/19	2019	373507
dez/19	2019	336157

?

Modelo de regressão linear simples

```
> summary(modelo)
```

Call:

```
lm(formula = vendas ~ Budget_Advertising)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-655330 -256271 -30444  234875  743028
```

Coefficients:

```
              Estimate Std. Error t value    Pr(>|t|)
(Intercept)  1060550.396   151771.308     6.99 0.000000046312 ***
Budget_Advertising    4.964      0.524     9.47 0.000000000046 ***
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 350000 on 34 degrees of freedom

Multiple R-squared: 0.725, Adjusted R-squared: 0.717

F-statistic: 89.7 on 1 and 34 DF, p-value: 0.0000000000458

Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.

Projeção para 2019

Vendas Budget

jan/19	2019	91000
fev/19	2019	154240
mar/19	2019	169702
abr/19	2019	185081
mai/19	2019	199683
jun/19	2019	229192
jul/19	2019	238403
ago/19	2019	247253
set/19	2019	311114
out/19	2019	320442
nov/19	2019	373507
dez/19	2019	336157

Modelo de regressão linear simples

```
> summary(modelo)
```

Call:

```
lm(formula = vendas ~ Budget_Advertising)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-655330 -256271 -30444  234875  743028
```

Coefficients:

```
              Estimate Std. Error t value    Pr(>|t|)
(Intercept)  1060550.396   151771.308     6.99 0.000000046312 ***
Budget_Advertising    4.964      0.524     9.47 0.000000000046 ***
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 350000 on 34 degrees of freedom
Multiple R-squared:  0.725,    Adjusted R-squared:  0.717
F-statistic: 89.7 on 1 and 34 DF,  p-value: 0.0000000000458
```

$$\text{Vendas janeiro/19} = 1060550 + 4.964 * 91000 = 1.512.274$$

Faça a previsão das vendas (R\$) mensal no período de 12 meses da empresa XYZ a partir dos dados disponíveis de Vendas (R\$) e Budget Advertising (R\$) da empresa.

Projeção para 2019

Vendas Budget

jan/19	2019	1.512.274	91000
fev/19	2019		154240
mar/19	2019		169702
abr/19	2019		185081
mai/19	2019		199683
jun/19	2019		229192
jul/19	2019		238403
ago/19	2019		247253
set/19	2019		311114
out/19	2019		320442
nov/19	2019		373507
dez/19	2019		336157

Modelo de regressão linear simples

```
> summary(modelo)
```

Call:

```
lm(formula = vendas ~ Budget_Advertising)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-655330 -256271 -30444  234875  743028
```

Coefficients:

```
              Estimate Std. Error t value    Pr(>|t|)
(Intercept)  1060550.396   151771.308     6.99 0.000000046312 ***
Budget_Advertising    4.964      0.524     9.47 0.000000000046 ***
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 350000 on 34 degrees of freedom

Multiple R-squared: 0.725, Adjusted R-squared: 0.717

F-statistic: 89.7 on 1 and 34 DF, p-value: 0.0000000000458

$$\text{Vendas janeiro/19} = 1060550 + 4.964 * 91000 = 1.512.274$$

OLS Regression Results						
=====						
Dep. Variable:	total	R-squared:	0.474			
Model:	OLS	Adj. R-squared:	0.470			
Method:	Least Squares	F-statistic:	112.0			
Date:	Thu, 30 Sep 2021	Prob (F-statistic):	3.58e-69			
Time:	20:36:44	Log-Likelihood:	-4438.6			
No. Observations:	511	AIC:	8883.			
Df Residuals:	506	BIC:	8904.			
Df Model:	4					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	p-value	[0.025	0.975]

b const	3055.1200	475.857	6.420	0.000	2120.221	3990.019
Q temperatura	-1.194e+04	4542.337	-2.629	0.009	-2.09e+04	-3019.369
b sensacao_termica	2.108e+04	5139.806	4.100	0.000	1.1e+04	3.12e+04
h umidade	-3158.1830	469.556	-6.726	0.000	-4080.702	-2235.664
h vel_vento	-3587.8412	896.790	-4.001	0.000	-5349.731	-1825.951
=====						
Omnibus:	3.248	Durbin-Watson:	2.046			
Prob(Omnibus):	0.197	Jarque-Bera (JB):	2.749			
Skew:	0.080	Prob(JB):	0.253			
Kurtosis:	2.678	Cond. No.	150.			
=====						

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Acurácia do modelo:
As variáveis explicam 47%
da variação das
quantidades alugadas

Análise de variância
H0: regressão = média
H1: regressão <> média

Verificar se há correlação entre os
resíduos: Se Durbin $\approx$ 4 não há
correlação

Teste de normalidade dos resíduos:
Se p-valor < 0,05 $\rightarrow$ Distribuição <> Normal
Se p-valor $\geq$ 0,05 $\rightarrow$ Distribuição = Normal

Modelo Regressão

O Modelo que relaciona Y com várias variáveis independentes


- Modelo Linear Simples: $Y = B_0 + B_1X + e$

X = variáveis independentes

Y = variável dependente

B_0 = constante

B_1 = coeficientes de regressão




- Modelo Linear Múltiplo: $Y = B_0 + B_1X_1 + B_2X_2 + B_3X_3 + \dots + B_nX_n + e$

$X_1, X_2, X_3, \dots, X_n$ = variáveis independentes

Y = variável dependente

B_0 = constante

$B_1, B_2, B_3, \dots, B_n$ = coeficientes de regressão
associados às n variáveis



Regressão Linear

Métodos de seleção de variáveis preditoras

Instrumento para selecionar variáveis(atributos) significativos

BACKWARD
FORWARD
STEPWISE

- Backward Selection : Procedimento constrói **adicionando todas as variáveis** e vai eliminando iterativamente uma a uma até que não haja mais variáveis .
- Forward Selection: Procedimento constrói iterativamente **adicionando variáveis uma a uma** até que não haja mais variáveis preditoras
- Stepwise: Combinação de Forward Selection e Backward elimination. Procedimento constrói iterativamente uma seqüência de modelos pela **adição ou remoção** de variáveis em cada etapa.

Teste de Hipóteses

TESTANDO OS PARÂMETROS B'S

$$H_0: B_i = 0$$

$$H_1: B_i \neq 0$$

$$t = \frac{B_i}{\text{erro_padrao}(B_i)} \quad \text{com gl} = n - p$$

Quando $t > t_{\alpha/2} \Rightarrow$ região de rejeição

$$\text{IC: } \bar{b}_i \pm t_{\alpha/2} S b_i$$

Regressão Linear

Pontos de atenção	Análise	O que fazer
Colinearidade: Correlação entre duas variáveis preditoras do modelo	Correlação de Pearson	- Escolher uma das variáveis ou - Criar a variável de interação
Multicolinearidade: Qualquer variável preditora é correlacionada com um conjunto de outras variáveis preditoras	Fator de inflação da variância (VIF)	- Escolher uma das variáveis ou - Criar fatores usando a análise de componentes principais
Relação não linear entre a variável resposta e a preditora	Gráfico de dispersão	- Transformar a variável
Outliers	Resíduos padronizados	- Excluir os outliers da base de dados a cada nova rodada

Análise de Variância

A variabilidade total observada na variável dependente está dividido em componentes:

$$\sum (y_i - \bar{y})^2 = \sum (y_i - \hat{y}_i)^2 + \sum (\hat{y}_i - \bar{y})^2$$

Soma de
quadrados
total

SQTot


Soma de
quadrados
residual

SQRes

Soma de
quadrados
regressão

SQReg

Análise de Variância (ANOVA)



$$E(Y) = \beta_0 + \beta_1 X$$

Teste de hipóteses:

H_0 : regressão = $\bar{y}$

H_1 : regressão $\neq \bar{y}$

Critério de decisão:

Se p-valor < 0.05 então rejeito H_0

Se p-valor ≥ 0.05 então não rejeito H_0

```
(Intercept) 1214.6 161.2 7.537 0.000000000000143 *** temp 6640.7 305.2 21.759 <
0.0000000000000002 ***
```

Análise de Variância

Podemos resumir todas essas informações numa única tabela anova:

Fonte	gl	SQ	QM	F
Regressão	$p - 1$	SQReg	$QMReg = \frac{SQReg}{p - 1}$	$\frac{QMReg}{Se^2}$
Resíduo	$n - p$	SQRes	$Se^2 = \frac{SQRes}{n - p}$	
Total	$n - 1$	SQTOT	$S^2 = \frac{SQTot}{n - 1}$	

Análise de Variância

Coeficiente de determinação (R^2): Multiple R-squared

$$R^2 = \frac{SQReg}{SQTot}$$

Coeficiente de determinação ajustado (R^2): Adjusted R-squared

$$R_a^2 = 1 - \frac{n - 1}{n - (p + 1)} (1 - R^2)$$

Onde: n = número de observações

p = número de variáveis preditoras

```
> modelo <- lm(df$Vendas ~ df$Budget_Advertising)
> summary(modelo)
```

```
Call:
lm(formula = df$Vendas ~ df$Budget_Advertising)
```

```
Residuals:
```

```
      Min       1Q   Median       3Q      Max
-655330 -256271 -30444  234875  743028
```

```
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	1060550.396	151771.308	6.988	0.0000000463123	***
df\$Budget_Advertising	4.964	0.524	9.473	0.0000000000458	***

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 349600 on 34 degrees of freedom
```

```
Multiple R-squared:  0.7252,    Adjusted R-squared:  0.7172
```

```
F-statistic: 89.75 on 1 and 34 DF,  p-value: 0.00000000004575
```

Resultado da
ANOVA

.

□

+

+

.

.

.

.

.

□

.

.

●

●

$$\sum (y_i - \bar{y})^2 = \sum (y_i - \hat{y}_i)^2 + \sum (\hat{y}_i - \bar{y})^2$$

Soma de
quadrados total

SQTot

Soma de
quadrados residual

SQRes

Soma de
quadrados
regressão

SQReg

Exemplo: y =Vendas e x =budget

Análise de variância (ANOVA)

df\$predito = 1060550.396 + 4.964*df\$Budget_Advertising

df\$residuo = df\$Vendas - df\$predito

df\$residuo2 = df\$residuo*df\$residuo

df\$reg = (df\$predito - ybarra)*(df\$predito - ybarra)

Soma dos quadrados

sqreg = sum(df\$reg) ; sqreg

sqres = sum(df\$residuo2) ; sqres

sqttotal = sqreg+sqres

rquadrado = sqreg/sqttotal ; rquadrado

```
<
> # Soma dos quadrados
> sqreg = sum(df$reg) ; sqreg
[1] 10966753022839
> sqres = sum(df$residuo2) ; sqres
[1] 4154940166057
> sqttotal = sqreg+sqres
>
> rquadrado = sqreg/sqttotal ; rquadrado
[1] 0.7252331
>
```

```
> modelo <- lm(df$Vendas ~ df$Budget_Advertising)
> summary(modelo)
```

```
Call:
lm(formula = df$Vendas ~ df$Budget_Advertising)
```

```
Residuals:
```

```
      Min       1Q   Median       3Q      Max
-655330 -256271 -30444  234875  743028
```

```
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	1060550.396	151771.308	6.988	0.0000000463123	***
df\$Budget_Advertising	4.964	0.524	9.473	0.0000000000458	***

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 349600 on 34 degrees of freedom
```

```
Multiple R-squared:  0.7252,    Adjusted R-squared:  0.7172
```

```
F-statistic: 89.75 on 1 and 34 DF,  p-value: 0.00000000004575
```

Resultado da
ANOVA

.

□

+

+

.

.

.

.

.

□

.

.

●


●

Análise de Resíduos

Forma de avaliar se as suposições colocadas no desenvolvimento do modelo não foram violadas

$$\hat{e}_i = y_i - \hat{y}_i$$

Pelo gráfico de dispersão, visualizamos o comportamento dos resíduos



Análise de Resíduos

RESÍDUOS PADRONIZADOS:

$$\frac{e_i}{se}$$

RESÍDUOS STUDENTIZADOS:


$$\frac{e_i}{se\sqrt{1-v_{ii}}}$$

$$\text{onde } v_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum (x_i - \bar{x})^2}$$


Análise de Resíduos

LINEARIDADE


Gráfico de dispersão dos valores preditos ($\hat{y}$) e o resíduo $\Rightarrow$ os resíduos devem estar distribuídos aleatoriamente.




Análise de Resíduos



Modelo adequado



Modelo não adequado



Modelo não adequado




o comportamento não aleatório dos resíduos podem ser eliminados ajustando no modelo um termo quadrático.

Análise de Resíduos

IGUALDADE DE VARIÂNCIA

Quando o gráfico de dispersão dos Resíduos Studentizados, contra o valor predito, indica que a extensão dos resíduos aumentam com a magnitude dos valores preditos:


Então a suposição de igualdade da variância está violada



Análise de Resíduos

NORMALIDADE


Pelo histograma dos resíduos padronizados pode-se analisar a suposição de normalidade.



Análise de Resíduos

LOCALIZANDO OS OUTLIERS:

Em geral, resíduos padronizados com valores maiores que 2 são considerados outliers



Medidas de Erros

Erro Médio (Mean error-ME): $ME = \frac{\sum_{i=1}^n y_i - \hat{y}_i}{n}$

Erro Médio Absoluto (Mean Absolut Error-MAE): $MAE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n}$

Raiz do Erro Quadrático Médio (Root Mean Squared Error-RMSE):


$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}$$

Erro Percentual Médio (Mean Percent Error-MPE):

$$MPE = \frac{\sum_{i=1}^n \frac{y_i - \hat{y}_i}{y_i * 100}}{n}$$

Erro Percentual Absoluto Médio (Mean Absolut Percent Error-MAPE):


$$MAPE = \frac{\sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i * 100}}{n}$$



ÁRVORE DE REGRESSÃO

CLASSIFICATION AND REGRESSION TREE

(CART)



ÁRVORE DE REGRESSÃO

• Pontos positivos

- Facilmente interpretável
- Fácil de implementar
- Técnica não paramétrica
- Realiza seleção de variáveis

• Pontos negativos

- Alta variância / instabilidade
- Baixa performance preditiva


ÁRVORE DE REGRESSÃO

ID	X1	X2	X3	Target
1	0	1	18	125
20	1	1	50	100
32	1	2	70	70
4	0	3	30	220
54	0	1	23	10
63	1	2	44	1000
74	0	1	54	5000

Training Set

ID	X1	X2	X3	Target
2	1	2	55	100
22	1	3	40	2000
30	0	1	20	330
3	0	2	33	440

Test Set




EXEMPLO DE ÁRVORE DE REGRESSÃO

Algoritmo CART

		categórico	categórico	contínuo	classe
Id	Casa própria	EstCivil	Rendim.	Mau Pagador	
1	S	Solteiro	125K	NÃO	
2	N	Casado	100K	NÃO	
3	N	Solteiro	70K	NÃO	
4	S	Casado	120K	NÃO	
5	N	Divorc.	95K	SIM	
6	N	Casado	60K	NÃO	
7	S	Divorc.	220K	NÃO	
8	N	Solteiro	85K	SIM	
9	N	Casado	75K	NÃO	
10	N	Solteiro	90K	SIM	

10

Dados de treinamento



Modelo: árvore de regressão

Árvore de Regressão

Critérios de parada (hiperparâmetros):

- ☐ Número de observações na divisão dos nós filhos
- ☐ 100% de classificação de uma categoria de resposta
- ☐ Número de níveis



CURSOS ALURA



3291 resultados para "Regressão Linear: fundamentos e avaliação de modelos"

 CURSO

🕒 6h

Regressão Linear: fundamentos e avaliação de modelos

Aprenda a aplicar técnicas de regressão linear em machine learning, preparando dados,...

Alura

 ARTIGO

🕒 30min

Métricas de avaliação para modelos de regressão

Conheça algumas métricas importantes para avaliar o desempenho do seu modelo de...

 TRILHA • ALURA

7 CURSOS 🕒 62h

Machine Learning com Python: Regressão

Como seres humanos, somos capazes de detectar diversos tipos de padrões. Contudo, com o avanço na...

Alura

 CARREIRA

25 CURSOS 🕒 218h

Engenharia de IA

Aprenda a desenvolver e gerenciar soluções de Inteligência Artificial, com foco em aplicações práticas de...

 CURSO

🕒 12h

Regressão linear: testando relações e prevendo resultados

Utilizando data science, aprenda a criar modelos preditivos poderosos

 CARREIRA

70 CURSOS 🕒 590h

Ciência de Dados

Aprenda ciência de dados desde os primeiros passos até aplicações avançadas. Nesta carreira, você vai...



TRILHA • ALURA

7 CURSOS ⌚ 62h

Machine Learning com Python: Regressão

Como seres humanos, somos capazes de detectar diversos tipos de padrões. Contudo, com o avanço na...

[Alura](#)

CURSO

⌚ 8h

Regressão: construindo Árvores de Regressão

Aprenda sobre regressão com modelos baseados em Árvores Explore validação cruzada, ajuste d...

[Alura](#)

Orange Canvas

O que é o Orange?

É um programa *open source* desenvolvido para *data mining*.

Por que usar o Orange?


- Open source
- Não precisa escrever o código
- Fácil de usar as técnicas de visualização dos dados, modelos estatísticos e os algoritmos de *machine learning*
- Adicionar pacotes de análise
- Programming support
- Python scripting




Orange Canvas

Instalação


Disponível no link: <https://orange.biolab.si/download/>



Recomendação: utilizar o Anaconda para administrar os programas



Orange Canvas



Orange Canvas

Exemplo


Example Workflows

Example Workflows

Hierarchical Clustering

The workflow clusters the data items in Iris dataset by first estimating the distances between data instances. Distance matrix is passed to hierarchical clustering, which renders the dendrogram. Select different parts of the dendrogram to further analyze the corresponding data.

Notice that hierarchical clustering can only handle small datasets, that is, those that contain only a small number of data instances. For larger datasets the distance matrix may get too big and may not fit in the memory. An alternative method that can consider such datasets is k-means.



Exemplo

modelo_Regressao_Linear_Multipla_Vinhos.ows - Orange


File Edit View Widget Options Help

Orange Data Mining interface showing the widget palette and a selected widget description.

Data
Visualize
Model

Constant
CN2 Rule Induction
Calibrated Learner
kNN
Tree
Random Forest
Gradient Boosting
SVM
Linear Regression
Logistic Regression
Naive Bayes
AdaBoost
Curve Fit
Neural Network
Stochastic Gradient Descent
Stacking


Scatter Plot
Interactive scatter plot visualization with intelligent data visualization enhancements.
[more...](#)




O que você achou da aula de hoje?

Pelo aplicativo da FIAP

(Entrar no FIAPP, e no menu clicar em Experience Survey)



Experience Survey



A grande finalidade do
conhecimento não é conhecer,
mas agir.

T. Huxley

OBRIGADO

 / Regina T. I. Bernal

FIAP

Copyright © 2026 | Professora Dra. Regina Tomie Ivata Bernal
Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente proibido sem consentimento formal, por escrito, do professor/autor.

FIAP