

FIAP

NBA

· ENGENHARIA DE DADOS

· DATA SCIENCE





Dra. Regina Tomie Ivata Bernal

Cientista de Dados na área da Saúde

Formação Acadêmica:

Estatístico - UFSCar

Mestre em Saúde Pública - FSP/USP

Doutor em Ciências - Epidemiologia - FSP/USP

Atividades Profissionais:

Professora de pós-graduação na FIAP

Consultora externa da SVS/MS

Cientista de Dados em Saúde

profregina.bernal@fiap.com.br
reginabernal@terra.com.br

CALENDÁRIO

Presencial

02/02/2026Aplicação de Data
ScienceIntrodução a
Estatística

Exercício prático

09/03/2026Introdução a
probabilidade

Inferência Estatística

Exercício prático

16/03/2026Técnicas
supervisionadas

Modelos de predição

Exercício prático

TÓPICO 3

23/03/2026Técnicas
supervisionadasModelos de
classificação

Exercício prático


30/03/2026Técnicas não
supervisionadas

Clusters

Exercício prático

TÓPICO 4

Machine Learning Algorithms Mindmap




Técnicas Estatísticas

Extração de conhecimento em bases de dados

- A metodologia de data mining -

Técnicas Supervisionadas



Técnicas Não Supervisionadas

CURSOS ALURA

 ARTIGO 30min

Árvores de decisão: modelos de classificação e regressão

Esse artigo explica o que são as árvores de decisão no Machine Learning, tanto para classificação...

 CURSO 8h

Árvores de Decisão: aprofundando em modelos de Machine Learning

Crie vários modelos de Machine Learning baseados em árvore de decisão. Neste curso, você vai...

 7 PRÉ-REQUISITOS[Alura](#)

CURSOS ALURA

 CURSO

🕒 10h

Machine Learning: Credit Scoring

Você vai aprender como o Machine Learning está no mercado financeiro. Vamos desenvolver uma aplicação ...



7 PRÉ-REQUISITOS

Alura

 TRILHA • ALURA

7 CURSOS 🕒 58h

Machine Learning com Python: Regressão

Como seres humanos, somos capazes de detectar diversos tipos de padrões. Contudo, com o avanço na...

Alura

CURSOS ALURA

 CURSO 10h

Clustering aplicado: recomendando músicas com K-Means


Construir um recomendador de músicas utilizando técnicas de Machine Learning não...

 8 PRÉ-REQUISITOS[Alura](#) CURSO 8h

Clusterização: lidando com dados sem rótulo

Aprenda a construir o modelo de aprendizado não supervisionado K-means para agrupar dados por...

 7 PRÉ-REQUISITOS[Alura](#)



ÁRVORE DE DECISÃO




Modelos Preditivos

Data Mining: Mineração - Construção de Modelos

➔ aplicações práticas de Data Mining se podem ser categorizadas de acordo com a tarefa que se pretende resolver

- **Classificação.** A tarefa de Classificação consiste em descobrir uma função que mapeie um conjunto de registros em um conjunto de classes. Uma vez descoberta, tal função pode ser aplicada a novos registros de forma a prever a classe em que tais registros se enquadram.



Fonte: Ronaldo Goldschmidt e Eduardo Bezerra - DataMining: conceitos, técnicas, algoritmos, orientações e aplicações. Editora Elsevier.

ÁRVORE DE CLASSIFICAÇÃO

- **Pontos positivos**


- Facilmente interpretável
- Fácil de implementar
- Técnica não paramétrica
- Realiza seleção de variáveis

- **Pontos negativos**

- Alta variância / instabilidade
- Baixa performance preditiva

EXEMPLO

Id	categórico		categórico		classe
	Casa própria	EstCivil	Rendim.	Mau Pagador	
1	S	Solteiro	125K	NÃO	
2	N	Casado	100K	NÃO	
3	N	Solteiro	70K	NÃO	
4	S	Casado	120K	NÃO	
5	N	Divorc.	95K	SIM	
6	N	Casado	60K	NÃO	
7	S	Divorc.	220K	NÃO	
8	N	Solteiro	85K	SIM	
9	N	Casado	75K	NÃO	
10	N	Solteiro	90K	SIM	



Classificação de Mau pagador (Previsão)

Árvore de Decisão

Segmento: Área Financeira

A área de crédito deseja avaliar a propensão de um cliente tornar-se inadimplente.

Variável Resposta: 0 = Adimplente
1 = Inadimplente

Critério de seleção de variável:

$$\text{Entropia}(S) = \sum_{i=1}^c -p_i \log_2 p_i$$

$$\text{Ganho}(S,A) = \text{Entropia}(S) - \sum_{v \in \text{valores}(A)} \frac{|S_v|}{|S|} \text{Entropia}(S_v)$$

Exemplo

Variáveis predictoras	Categorias
Tempo de relacionamento	1-ate 1 ano
	2-1 a 3 anos
	3-3 a 8 anos
	4-mais 8 anos
Valor da fatura	1-Ate R\$250
	2-R\$250 a R\$800
	3-R\$800 a R\$1499
	4-R\$1500 e mais
% gastos com alimentação	1-Ate 10%
	2-10% a 20%
	3-20% a 30%
	4-30% e mais

+

+

Árvore de Decisão

Segmento: Área Financeira

Exemplo


A área de crédito deseja avaliar a propensão de um cliente tornar-se inadimplente.

cliente	Resposta	TempoRel	valorFatura	GastosAlim
2642	0	4-mais 8 anos	3-R\$800 a R\$1499	2-10% a 20%
5620	0	2-1 a 3 anos	3-R\$800 a R\$1499	4-30% e mais
8238	0	4-mais 8 anos	2-R\$250 a R\$800	1-Ate 10%
8272	1	1-ate 1 ano	3-R\$800 a R\$1499	2-10% a 20%
9724	0	2-1 a 3 anos	2-R\$250 a R\$800	4-30% e mais
13021	0	3-3 a 8 anos	1-Ate R\$250	2-10% a 20%
15361	0	4-mais 8 anos	1-Ate R\$250	4-30% e mais
15606	1	2-1 a 3 anos	2-R\$250 a R\$800	1-Ate 10%
18010	0	4-mais 8 anos	4-R\$1500 e mais	4-30% e mais
20060	1	2-1 a 3 anos	1-Ate R\$250	3-20% a 30%
20342	1	1-ate 1 ano	1-Ate R\$250	2-10% a 20%
20569	0	1-ate 1 ano	2-R\$250 a R\$800	3-20% a 30%
21191	1	4-mais 8 anos	2-R\$250 a R\$800	1-Ate 10%
24385	1	4-mais 8 anos	1-Ate R\$250	4-30% e mais

Árvore de Decisão

Exemplo

A área de crédito deseja avaliar a propensão de um cliente tornar-se inadimplente.




Adimplente (0)

Inadimplente (1)

Entropia

$$E(S) = -\frac{8}{14} \log_2 \left(\frac{8}{14} \right) - \frac{6}{14} \log_2 \left(\frac{6}{14} \right) = 0.98$$

Árvore de Decisão



Entropia

$$E(1) = -\frac{1}{3} \log_2 \left(\frac{1}{3} \right) - \frac{2}{3} \log_2 \left(\frac{2}{3} \right) = 0.92$$

$$E(2) = -\frac{2}{4} \log_2 \left(\frac{2}{4} \right) - \frac{2}{4} \log_2 \left(\frac{2}{4} \right) = 1$$

$$E(3) = -\frac{1}{1} \log_2 \left(\frac{1}{1} \right) - 0 = 0$$

$$E(4) = -\frac{4}{6} \log_2 \left(\frac{4}{6} \right) - \frac{2}{6} \log_2 \left(\frac{2}{6} \right) = 0.92$$

Árvore de Decisão

Exemplo

$$\text{Ganho}(\text{tempo de relacionamento}) = 0.98 - \frac{3}{14} * 0.92 - \frac{4}{14} * 1.5 - \frac{1}{14} * 0 - \frac{6}{14} * 0.92 = -0.039$$

Variável	Ganho da variável
Tempo de relacionamento	-0.039
Valor da fatura	0.095
% gasto com alimentação	0.10




Árvore de Decisão

Segmento: Área Financeira

A área de crédito deseja avaliar a propensão de um cliente tornar-se inadimplente.

Exemplo



Árvore de Decisão

Critérios de parada (hiperparâmetros):

- ☐ Número de observações na divisão dos nós filhos
- ☐ 100% de classificação de uma categoria de resposta
- ☐ Número de níveis



ANÁLISE DA ÁRVORE DE DECISÃO


Qualificação do Ajuste do Modelo

		Previsão do modelo		Total
		y=1	y=0	
Obs.	y=1	n1	n2	n1+n2
	y=0	n3	n4	n3+n4

Sensibilidade = $n1 / (n1+n2)$

Especificidade = $n4 / (n3+n4)$





REGRESSÃO LOGÍSTICA




Modelos Preditivos

Data Mining: Mineração - Construção de Modelos

- ➔ aplicações práticas de Data Mining se podem ser categorizadas de acordo com a tarefa que se pretende resolver

- **Classificação.** A tarefa de Classificação consiste em descobrir uma função que mapeie um conjunto de registros em um conjunto de classes. Uma vez descoberta, tal função pode ser aplicada a novos registros de forma a prever a classe em que tais registros se enquadram.



Análise de Discriminação de Estrutura

• • • + • □

• • +

REGRESSÃO LOGÍSTICA

Encontrar uma **função logística**, formada através de ponderações das variáveis (atributos), cuja resposta permita estabelecer a **probabilidade de ocorrência** de determinado evento e a **importância das variáveis** (peso) para esta ocorrência.

□

+ + •

• • • •

□ • • • •

Análise de Discriminação de Estrutura

• REGRESSÃO LOGÍSTICA

Cientes



Cientes sem o evento

Cientes com o evento(*)

(*) Evento (exemplos)

- Aquisição
- Cancelamento
- Pagamento


Pontuação dos Clientes com Probabilidade



Modelo

Regra de Decisão

Corte



0%

Probabilidade do evento ocorrer

100%

ANÁLISE DE REGRESSÃO LOGÍSTICA

Probabilidade

Sendo Y: a resposta à preferência por um evento (sim ou não),

→ a probabilidade de:

- Preferência (*ou sucesso*) será **p**
- Não-preferência (*de fracasso*) será **(1-p)**

“Chance de Ocorrência de um Evento”

➤ **Chance** = (probabilidade de sucesso) / (probabilidade de fracasso)

Exemplo, se a probabilidade de sucesso é 0,65:

a chance é igual a: $p / (1-p) = p / q = 0,65 / 0,35 = 1,86$

ANÁLISE DE REGRESSÃO LOGÍSTICA

Exemplo: Preferência por canal de futebol

Sexo	Prefere	Não Prefere	Total
Masculino	146	120	266
Feminino	110	124	234
Total	256	244	500

➤ **Chance** de preferir o canal de futebol entre homens:

$$➤ p1 / (1-p1) = (146/266) / (120/266) = 0,55 / 0,45 = 1,22$$

➤ **Chance** de preferir o canal de futebol entre mulheres:

$$➤ p2 / (1-p2) = (110/234) / (124/234) = 0,47 / 0,53 = 0,89$$

➤ **Razão de chances** de preferir canal de futebol entre homens, em relação às mulheres:

$$➤ [p1/(1-p1)] / [p2/(1-p2)] = 1,22 / 0,89 = 1,37$$

ANÁLISE DE REGRESSÃO LOGÍSTICA


Modelo de Regressão Logística

$$Y = a + B_1 X_1 + B_2 X_2 + \dots + B_n X_n$$

Y: logit da resposta de preferência (sim)

a : intersecção

B1, B2, ..., Bn : coeficientes logísticos



- A função logística é dada pelo logito-inverso (anti-logit) que nos permite transformar o logito em probabilidade:

$$Probabilidade = \frac{\exp(Y)}{1 + \exp(Y)}$$

Método de Estimação dos Coeficientes

➤ Regressão Linear: Método dos Mínimos Quadrados

⇒ É o método que determina a linha reta mais apropriada, minimizando a soma dos quadrados das diferenças entre os valores estimados de Y por meio da reta de regressão e os valores observados de Y.

➤ Logística: Método da Máxima Verossimilhança

(algoritmo iterativo)

⇒ Consiste em determinar uma função, denominada função de verossimilhança $[L(y, \vartheta)]$, que é a função de probabilidade de ocorrência de um específico conjunto de dados e estimar os parâmetros que maximizam a mesma.

ANÁLISE DE REGRESSÃO LOGÍSTICA

Seleção Conjuntos de Atributos (Variáveis)

- Variáveis Discriminantes
- Variáveis Não-Discriminantes

Instrumento para selecionar variáveis(atributos) significativos

BACKWARD
FORWARD
STEPWISE

- Backward Selection : Procedimento constrói **adicionando todas as variáveis** e vai eliminando iterativamente uma a uma até que não haja mais variáveis .
- Forward Selection: Procedimento constrói iterativamente **adicionando variáveis uma a uma** até que não haja mais variáveis preditoras .
- Stepwise: Combinação de Forward Selection e Backward elimination. Procedimento constrói iterativamente uma seqüência de modelos pela adição ou remoção de variáveis em cada etapa. + + .

ANÁLISE DE REGRESSÃO LOGÍSTICA

Qualificação do Ajuste do Modelo

Matriz de Classificação

Estatística de Ajuste

Verossimilhança : $-2 \log$ Verossimilhança

Significância do Modelo : Qui-quadrado (similar ao F regressão)

Ganho no Modelo (significância)



ANÁLISE DE REGRESSÃO LOGÍSTICA

Qualificação do Ajuste do Modelo

		Previsão do modelo		Total
		y=1	y=0	
Obs.	y=1	n1	n2	n1+n2
	y=0	n3	n4	n3+n4

$$\text{Sensibilidade} = n1 / (n1+n2)$$

$$\text{Especificidade} = n4 / (n3+n4)$$




Exemplo – Modelo de Inadimplência

Segmento: Cartões de Crédito


A área de crédito deseja avaliar a propensão ao risco de seus clientes e implementar políticas de redução da inadimplência

Exemplo – Modelo de Inadimplência

Média de dias com pagamentos em atraso nos últimos 6 meses




Exemplo – Modelo de Inadimplência




Exemplo – Modelo de Inadimplência


Valor Médio da Fatura Mensal




Exemplo – Modelo de Inadimplência



Exemplo – Modelo de Inadimplência



Exemplo – Modelo de Inadimplência



Exemplo – Modelo de Inadimplência

Tabela de Coeficientes do Modelo

variável	categoria	Coeficientes
fatura em atraso	até 3 dias	-1,276
	3 a 15 dias	-0,611
	de 15 a 30 dias	0,580
	mais de 30 dias	1,308
Tempo de cliente	até 1 ano	0,580
	de 1 a 3 anos	0,401
	de 3 a 8 anos	-0,264
	mais de 8 anos	-0,718
valor da fatura	Até R\$250	0,262
	R\$ 250 a R\$ 800	0,103
	R\$ 800 a R\$ 1.499	-0,105
	Mais de R\$1.500	-0,261
% de gasto com alimentação	até 10%	0,581
	de 10% a 20%	0,401
	de 20% a 30%	-0,264
	mais de 30%	-0,718
Região de Risco	Região 4	1,067
	Região 3	0,371
	Região 2	-0,368
	Região 1	-1,069
renda mensal	Até R\$ 1.518	0,455
	R\$ 1.519 a R\$ 3.000	0,080
	R\$ 3.000 a R\$ 4.500	-0,122
	Mais de R\$ 4.500	-0,413
Constante		0,099

Exemplo – Modelo de Inadimplência

Modelo Logístico

Pesos definidos na modelagem

-1,276	Até 3 dias	Fatura em atraso	Mais de 30 dias	1,308
-0,718	Mais de 8 anos	Tempo de Relacionamento	Até 1 ano	0,580
-0,261	Mais de R\$1.500	Valor da Fatura	Até R\$250	0,262
-0,718	Mais de 30%	% de gasto com alimentação	Até 10%	0,580
-1,069	Região 1	Região de Risco	Região 4	1,067
-0,413	Mais de R\$4.500	Renda Mensal	Até R\$1.518	0,455
0,099		Constante		0,099
4%	Propensão			98%

$$y = 0.099 + 1.308 + 0.580 + 0.262 + 0.580 + 1.067 + 0.455 = 4.351$$

$$\text{Propensão} = \text{probabilidade} = \frac{\exp(4.351)}{1 + \exp(4.351)} = 0.98 \text{ ou } 98\%$$


ANÁLISE DE REGRESSÃO LOGÍSTICA



Exemplo: Modelo Cross-Selling Propensão à Compra de um Produto

Objetivo

Estabelecer público-alvo para a venda qualificada de um determinado Produto X, com uso dos mailing's internos do cliente, através do desenvolvimento de modelos preditivos.



Modelos Cross Selling

• • • + • □

➔ Propensão de compra do Produto X



Sem Produto X

Com Produto X


+ + •

• • • •

□ • • • •

Modelos Cross Selling


→ Propensão de compra do Produto X



Modelos Cross Selling

→ Propensão de compra do Produto X

Regra de Decisão



Modelos Cross Selling - Implementação

• • • + • □

➔ Propensão de compra do Produto X

Algoritmo Matemático

Para associar uma probabilidade de compra de um produto X à cada cliente, os seguintes passos devem ser tomados:

1. Identificar as variáveis, associando os respectivos coeficientes;
2. Somar os coeficientes encontrados no item 1, juntamente com a constante do modelo determinando o valor de Y;
3. Efetuar a operação matemática que se segue, para determinação final do score.

□

$$Probabilidade = \frac{\exp(Y)}{1 + \exp(Y)}$$

+ + •

• • •

□ • • • •

Modelos Cross Selling

→ Propensão de compra do Produto X

Regra de Decisão Estatística

Após associar à cada indivíduo sua probabilidade de compra do produto, deve-se submetê-la à Regra de Decisão, ou seja, se a probabilidade obtida for menor ou igual ao valor de corte* o assinante pertencerá ao grupo que não irá adquirir o produto, caso contrário, se esta probabilidade for maior que o valor de corte, ele pertencerá ao grupo que irá adquirir.

* valor de corte é o valor de probabilidade que define os grupos, segundo análise de acertos do modelo.

Data Mining



aplicações práticas de Data Mining se podem ser categorizadas de acordo com a tarefa que se pretende resolver

Exercitando!!!!



Base Inadimplência



SAÍDAS DO PYTHON

REGRESSÃO LOGÍSTICA

Segmento: Cartões de Crédito

A área de crédito deseja avaliar a propensão ao risco de seus clientes e implementar políticas de redução da inadimplência

Variável	Descrição	Valor	Tipo de variável	Regra de data mining
atrasos	Atrasos	1-Ate 3 dias	Qualitativa ordinal	Preditora
		2-3 a 15 dias		
		3-15 a 30 dias		
		4-Mais de 30 dias		
temporel	Tempo de relacionamento	1-ate 1 ano	Qualitativa ordinal	Preditora
		2-1 a 3 anos		
		3-3 a 8 anos		
		4-mais 8 anos		
valorfatura	Valor da fatura	1-Ate R\$250	Qualitativa ordinal	Preditora
		2-R\$250 a R\$800		
		3-R\$800 a R\$1499		
		4-R\$1500 e mais		
p_gastoalim	% de gastos com alimentação	1-Ate 10%	Qualitativa ordinal	Preditora
		2-10% a 20%		
		3-20% a 30%		
		4-30% e mais		
regiao_risco	Região de Risco	I	Qualitativa nominal	Preditora
		II		
		III		
		IV		
rendamensal	Renda mensal	1-Ate R\$18	Qualitativa ordinal	Preditora
		2-R\$18 a R\$3000		
		3-R\$3000 a R\$4500		
		4-mais de R\$4500		
Resposta	Resposta	0=Não	Qualitativa nominal	Target
		1=Sim		

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 25984 entries, 0 to 25983
Data columns (total 19 columns):
#   Column              Non-Null Count  Dtype
---  -
0   Resposta             25984 non-null  int64
1   atrasos_2            25984 non-null  uint8
2   atrasos_3            25984 non-null  uint8
3   atrasos_4            25984 non-null  uint8
4   temporel_2           25984 non-null  uint8
5   temporel_3           25984 non-null  uint8
6   temporel_4           25984 non-null  uint8
7   valorfatura_2        25984 non-null  uint8
8   valorfatura_3        25984 non-null  uint8
9   valorfatura_4        25984 non-null  uint8
10  p_gastoalim_2        25984 non-null  uint8
11  p_gastoalim_3        25984 non-null  uint8
12  p_gastoalim_4        25984 non-null  uint8
13  regiaorisco_2        25984 non-null  uint8
14  regiaorisco_3        25984 non-null  uint8
15  regiaorisco_4        25984 non-null  uint8
16  rendamensal_2        25984 non-null  uint8
17  rendamensal_3        25984 non-null  uint8
18  rendamensal_4        25984 non-null  uint8
dtypes: int64(1), uint8(18)
memory usage: 659.9 KB
```

Segmento: Cartões de Crédito

A área de crédito deseja avaliar a propensão ao risco de seus clientes e implementar políticas de redução da inadimplência

Amostra proporcional de categorias 0 e 1

	cliente	%
Resposta		
0	13056	50.25
1	12928	49.75

Segmento: Cartões de Crédito

A área de crédito deseja avaliar a propensão ao risco de seus clientes e implementar políticas de redução da inadimplência



```
import statsmodels.api as sm
```

```
X_ = sm.add_constant(X_train)
logit_model=sm.Logit(y_train,X_)
result=logit_model.fit()
print(result.summary2())
```

Optimization terminated successfully.
Current function value: 0.483152
Iterations 6

Results: Logit

Model:	Logit	Pseudo R-squared:	0.303
Dependent Variable:	Resposta	AIC:	17607.1474
Date:	2023-03-23 15:16	BIC:	17732.0836
No. Observations:	18188	Log-Likelihood:	-8787.6
Df Model:	15	LL-Null:	-12607.
Df Residuals:	18172	LLR p-value:	0.0000
Converged:	1.0000	Scale:	1.0000
No. Iterations:	6.0000		

	Coef.	Std. Err.	z	P> z	[0.025	0.975]
const	0.5846	0.0708	8.2602	0.0000	0.4459	0.7233
atrasos_2	0.5013	5691891.6909	0.0000	1.0000	-11155902.2168	11155903.2193
atrasos_3	1.2169	nan	nan	nan	nan	nan
atrasos_4	1.4690	3695323.3497	0.0000	1.0000	-7242699.2076	7242702.1457
temporel_2	-0.1041	0.0523	-1.9910	0.0465	-0.2065	-0.0016
temporel_3	-1.0233	0.0561	-18.2560	0.0000	-1.1332	-0.9135
temporel_4	-1.0490	0.0501	-20.9280	0.0000	-1.1472	-0.9507
valorfatura_2	-0.0217	0.0344	-0.6312	0.5279	-0.0891	0.0457
valorfatura_3	-0.3817	0.0438	-8.7191	0.0000	-0.4675	-0.2959
valorfatura_4	-0.5699	0.0345	-16.5249	0.0000	-0.6375	-0.5023
p_gastoalim_2	-0.2694	0.0523	-5.1494	0.0000	-0.3720	-0.1669
p_gastoalim_3	-1.1579	0.0459	-25.2020	0.0000	-1.2480	-1.0679
p_gastoalim_4	-2.3206	0.0483	-48.0367	0.0000	-2.4153	-2.2259

(1) Valor do ponto de corte

(2) Coeficientes do modelo.


(3) Resultado do p-value do teste de hipótese para seleção da variável.

Segmento: Cartões de Crédito

A área de crédito deseja avaliar a propensão ao risco de seus clientes e implementar políticas de redução da inadimplência



Matriz de confusão



```
predictions = logmodel.predict(X_train)
print(classification_report(y_train['Resposta'], predictions))
```

	precision	recall	f1-score	support
0	0.74	0.74	0.74	9115
1	0.74	0.73	0.74	9073
accuracy			0.74	18188
macro avg	0.74	0.74	0.74	18188
weighted avg	0.74	0.74	0.74	18188

VN: Verdadeiro Negativo

FP: Falso Positivo


FN: Falso Negativo

VP: Verdadeiro Positivo

Segmento: Cartões de Crédito

A área de crédito deseja avaliar a propensão ao risco de seus clientes e implementar políticas de redução da inadimplência

Matriz de confusão



```
predictions = logmodel.predict(X_train)
print(classification_report(y_train['Resposta'], predictions))
```

	precision	recall	f1-score	support
0	0.74	0.74	0.74	9115
1	0.74	0.73	0.74	9073
accuracy			0.74	18188
macro avg	0.74	0.74	0.74	18188
weighted avg	0.74	0.74	0.74	18188

VN: Verdadeiro Negativo

FP: Falso Positivo

FN: Falso Negativo

VP: Verdadeiro Positivo


$$\text{Precision}(0) = \frac{6738}{6738 + 2405} = 0.74$$

$$\text{Precision}(1) = \frac{6668}{6668 + 2377} = 0.74$$

Segmento: Cartões de Crédito

A área de crédito deseja avaliar a propensão ao risco de seus clientes e implementar políticas de redução da inadimplência

Matriz de confusão



```
predictions = logmodel.predict(X_train)
print(classification_report(y_train['Resposta'], predictions))
```

	precision	recall	f1-score	support
0	0.74	0.74	0.74	9115
1	0.74	0.73	0.74	9073
accuracy			0.74	18188
macro avg	0.74	0.74	0.74	18188
weighted avg	0.74	0.74	0.74	18188

VN: Verdadeiro Negativo

FP: Falso Positivo

FN: Falso Negativo

VP: Verdadeiro Positivo


$$\text{Recall (0)} = \frac{6738}{6738 + 2377} = 0.74$$

$$\text{Recall (1)} = \frac{6668}{6668 + 2405} = 0.73$$

Segmento: Cartões de Crédito

A área de crédito deseja avaliar a propensão ao risco de seus clientes e implementar políticas de redução da inadimplência

Matriz de confusão



```
predictions = logmodel.predict(X_train)
print(classification_report(y_train['Resposta'], predictions))
```

	precision	recall	f1-score	support	
0	0.74	0.74	0.74	9115	50%
1	0.74	0.73	0.74	9073	50%
accuracy			0.74	18188	
macro avg	0.74	0.74	0.74	18188	
weighted avg	0.74	0.74	0.74	18188	

VN: Verdadeiro Negativo

FP: Falso Positivo

FN: Falso Negativo

VP: Verdadeiro Positivo


$$\begin{aligned} \text{F1-score}(0) &= 2 * (\text{precision}(0) + \text{recall}(0)) / (\text{precision}(0) + \text{recall}(0)) \\ &= (2 * (0.74 + 0.74)) / ((0.74 + 0.74)) = 0.74 \end{aligned}$$

$$\begin{aligned} \text{F1-score}(1) &= 2 * (\text{precision}(1) + \text{recall}(1)) / (\text{precision}(1) + \text{recall}(1)) \\ &= (2 * (0.74 + 0.74)) / ((0.74 + 0.74)) = 0.74 \end{aligned}$$

Segmento: Cartões de Crédito

A área de crédito deseja avaliar a propensão ao risco de seus clientes e implementar políticas de redução da inadimplência

Matriz de confusão



```
predictions = logmodel.predict(X_train)
print(classification_report(y_train['Resposta'], predictions))
```

	precision	recall	f1-score	support
0	0.74	0.74	0.74	9115
1	0.74	0.73	0.74	9073
accuracy			0.74	18188
macro avg	0.74	0.74	0.74	18188
weighted avg	0.74	0.74	0.74	18188

VN: Verdadeiro Negativo

FP: Falso Positivo

FN: Falso Negativo

VP: Verdadeiro Positivo

$$\text{Accuracy} = \frac{6016738 + 6668}{18188} = 0.66$$

$$\begin{aligned} \text{macro average} &= (\text{precision of class 0} + \text{precision of class 1}) / 2 \\ &= (0.74 + 0.74) / 2 = 0.74 \end{aligned}$$

Compute the F1 score, also known as balanced F-score or F-measure.

The F1 score can be interpreted as a harmonic mean of the precision and recall, where an F1 score reaches its best value at 1 and worst score at 0. The relative contribution of precision and recall to the F1 score are equal. The formula for the F1 score is:

$$F1 = 2 * (precision * recall) / (precision + recall)$$

In the multi-class and multi-label case, this is the average of the F1 score of each class with weighting depending on the average parameter.

Média Harmônica

$$M_h = \frac{n}{\frac{1}{x_1} + \frac{1}{x_2} + \frac{1}{x_3} + \dots + \frac{1}{x_n}}$$

M_h: média harmônica

n: quantidade de elementos

$$M_h = \frac{2}{\frac{1}{80} + \frac{1}{120}} = \frac{2}{\frac{3+2}{240}} = \frac{2}{\frac{5}{240}} = 2 \cdot \frac{240}{5}$$

$$M_h = 2 \cdot \frac{240}{5} = \frac{480}{5} = 96 \text{ km/h}$$

Um carro realiza um percurso duas vezes. Na ida, ele faz o percurso com uma velocidade $v_1 = 80$ km/h. Na volta, ele realiza o mesmo percurso com velocidade de $v_2 = 120$ km/h. Qual foi a velocidade média ao juntar-se ida e volta?

Note que a distância é a mesma, para a ida e para a volta, o que muda é a velocidade e, consequentemente, o tempo.

Se eu aumento a velocidade, o tempo que eu levo para percorrer uma mesma distância diminuirá, logo, essas grandezas são inversamente proporcionais.

Interpretação da estatística weighted average :

O modelo está adequado?

Classification Report :				
	precision	recall	f1-score	support
0	1.00	1.00	1.00	28432
1	0.02	0.02	0.02	49
accuracy			1.00	28481
macro avg	0.51	0.51	0.51	28481
weighted avg	1.00	1.00	1.00	28481

In the case of weighted average the performance metrics are weighted accordingly:

$$score_{weighted-avg} = 0.998 \cdot score_{class\ 0} + 0.002 \cdot score_{class\ 1}$$

However, macro avg is not weighted and therefore

$$score_{macro-avg} = 0.5 \cdot score_{class\ 0} + 0.5 \cdot score_{class\ 1}$$

Métrica	O que mede	Interpretação prática	Quando é mais importante
Recall	A proporção de positivos reais que o modelo conseguiu identificar corretamente.	Entre todos os positivos reais , quantos o modelo encontrou.	Quando não pode perder positivos (ex.: diagnóstico de doenças, fraudes).
Precision	A proporção de positivos previstos que realmente são positivos.	Entre todos os casos que o modelo previu como positivos , quantos estavam corretos.	Falso positivo : cliente adimplente (bom pagador) que foi classificado como inadimplente.
F1-score	Média harmônica entre Precision e Recall.	Equilíbrio entre recall e precision ; penaliza modelos que têm uma métrica alta e a outra muito baixa.	Quando é necessário equilibrar recall e precision (ex.: Ex.: prever se uma chamada é spam ou não.).


ANÁLISE DE REGRESSÃO LOGÍSTICA

Qualificação do Ajuste do Modelo

		Previsão do modelo		Total
		y=1	y=0	
Obs.	y=1	n1	n2	n1+n2
	y=0	n3	n4	n3+n4

Sensibilidade = $n1 / (n1+n2)$

Especificidade = $n4 / (n3+n4)$



Medidas de Avaliações dos Modelos

Resposta do modelo: Quantitativa
(Exemplo: Faturamento, Demanda ...)

ission Results

```
=====
R-squared:      0.725
Adj. R-squared: 0.717
F-statistic:    99.77
Prob (F-statistic): 4.58e-11
Log-Likelihood: -509.57
AIC:           1009.
```

Uma Variável preditora:

Acurácia do modelo:

A variável Budget explica 72,5%
da variação das Vendas.

Duas ou mais variáveis
preditoras

Erro Médio (Mean error-ME): $ME = \frac{\sum_{i=1}^n y_i - \hat{y}_i}{n}$

Erro Médio Absoluto (Mean Absolut Error-MAE): $MAE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n}$

Raiz do Erro Quadrático Médio (Root Mean Squared Error-RMSE):

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}$$


Erro Percentual Médio (Mean Percent Error-MPE): $MPE = \frac{\sum_{i=1}^n \frac{y_i - \hat{y}_i}{y_i * 100}}{n}$

Erro Percentual Absoluto Médio (Mean Absolut Percent Error-MAPE):

$$MAPE = \frac{\sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i * 100}}{n}$$

Resposta do modelo: Qualitativa
(Exemplo: Inadimplência PF, Cancelamento de produto ...)

Matriz de confusão




VN: Verdadeiro Negativo


FP: Falso Positivo

FN: Falso Negativo

VP: Verdadeiro Positivo

	precision	recall	f1-score	support
0	0.74	0.74	0.74	9115
1	0.74	0.73	0.74	9073
accuracy			0.74	18188
macro avg	0.74	0.74	0.74	18188
weighted avg	0.74	0.74	0.74	18188






TÉCNICAS NÃO SUPERVISIONADAS



ANÁLISE ESTRUTURAL

Análise de Conglomerados - Cluster

Descobertas Não Supervisionadas de Relações




Segmentação

A segmentação é um processo de agrupar clientes em grupos tais que apresentem características semelhantes entre os elementos do grupo e distintas entre os grupos.



Instrumentação da Estratégia de Fidelização



Tipos de Segmentações

Comportamental

Comportamento
quanto ao uso do produto

Descritiva

Geo-Demográficos

Atitudinal

Valores, Hábitos e
Atitudes do Cliente

Percepção


Considerações sobre o
Produto

**Conforme o
objetivo
selecionar a
entidade de
análise e as
variáveis
segmentadoras**




Tipos de Segmentações

Segmentação Comportamental de Clientes



Tipos de Segmentações

Modelos Geográficos



Processo Interpretativo


RENDA

- Acima de 3
- 1,1 a 3,0
- 0,5 a 1,1
- 0,3 a 0,5
- Abaixo de 0,3
- Inadimplentes
- Clientes


Segmentação Geo-demográfica

•Município de São Paulo

➤ geo-marketing




Análise de Agrupamentos – Cluster Analysis



Análise de Agrupamentos – Cluster Analysis

Objetivo: Separar um conjunto de objetos em grupos (clusters) de forma que os membros de qualquer grupo formado sejam os mais homogêneos possíveis com relação a algum critério → **uso de medidas de distância**

Distância Intra-Cluster Distância entre elementos de um mesmo grupo.



Distância Inter-Cluster Distância entre elementos de grupos distintos

A maioria dos algoritmos de análise de agrupamento tem como base medidas de dissimilaridade:

Quanto **MAIOR** for a medida de dissimilaridade menor será a semelhança entre os indivíduos.

Os grupos são “naturais”, isto é, surgem a partir da análise dos dados. Não existe suposição prévia sobre sua estrutura ou o número de grupos.

A decisão sobre o número de grupos depende de bom senso, embora existam critérios que dão suporte à tomada de decisão.


Análise de Agrupamentos – Cluster Analysis

Elementos da Análise

Entidades

Atributos

Seleção Conjuntos de Atributos - Variáveis Discriminantes



Análise de Agrupamentos – Cluster Analysis

As etapas do processo de análise de clusters são:

1. Seleção da base de modelagem → em função do objetivo (qual entidade, qual histórico..)
2. Seleção de atributos → variáveis segmentadoras
3. Medida de proximidade
4. Critério de agrupamento
5. Algoritmo de agrupamento
6. Verificação dos resultados
7. Interpretação dos resultados

Análise de Agrupamentos – Cluster Analysis

Medidas de distância

Por exemplo a distância Euclidiana é calculada por:

$$d_{ij} = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2}$$

Onde x_{ik} é o valor da variável X_k para o indivíduo (registro) i e x_{jk} é o valor da mesma variável para o indivíduo j .

➔ Usualmente as variáveis são padronizadas antes de se calcular as distâncias, assim, as p variáveis serão igualmente importantes. Geralmente, a padronização feita é para que todas as variáveis (quantitativas) tenham média zero e variância 1.

Análise de Agrupamentos – Cluster Analysis

• • • + • □

• • +

Padronização das variáveis :

Os métodos baseados em distância são afetados pela diferença de escala entre os valores das variáveis/atributos, sendo necessário normalizar os atributos.

Padronização - Transforma os valores em números de desvios padrões a partir da média. É dada por: :


$$Z = \frac{X - \bar{X}}{S}$$

Onde : $\bar{X}$ = Média da variável
 S = desvio padrão

•
 □
 + + •
 • • • •
 □ • • • •

Metodologia: Classificação das Técnicas

Método Hierárquico



Hierárquicas (envolvem a construção de uma hierarquia)


Aglomerativas

• *todas as observações iniciam como sendo um grupo(unitário); grupos próximos são, então gradualmente juntados até, finalmente, todas as observações constituírem um único grupo.*


• Divisivas

• *todas as observações iniciam num único grupo. Após são separados em dois grupos e assim por diante, até que cada observação seja o próprio grupo.*

Método Não-Hierárquico



Não Hierárquicas (trabalha com interações)



Análise de Agrupamentos

Métodos Hierárquicos de Agrupamentos:

Método do Vizinho Mais Próximo

Método calcula-se a matriz de distâncias entre os “n” indivíduos da população, em seguida os indivíduos mais próximos são agrupados(método do encadeamento simples “single linkage method”




Análise de Agrupamentos

Métodos Hierárquicos de Agrupamentos:

Exemplo de Agrupamento

- Método: vizinho mais próximo
- Dissimilaridade: distância euclidiana
- Dendrograma

Um *dendrograma* é um meio prático de sumarizar um padrão de agrupamento. Este começa com todos os indivíduos separados (“folhas”) fundindo-se progressivamente em pares (folhas, ramos, galhos, tronco) até chegar a uma única raiz. A ordem dos indivíduos mostrada no dendrograma e a ordem na qual os grupos entram no agrupamento.



Análise de Agrupamentos

Métodos Hierárquicos de Agrupamentos:

➔ Matriz de distância D1

Matriz de distância euclidiana entre os “n” indivíduos da população;

Como d (1 e 5) é a menor distância em D1, os indivíduos 1 e 5 são agrupados.

Ind. (n)	1	2	3	4	5
1	0	5	10	7	1
2		0	5	2	6
3			0	3	11
4				0	8
5					0

Distância Euclidiana

$$d_{ij} = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2}$$

Análise de Agrupamentos

Métodos Hierárquicos de Agrupamentos:

➔ Matriz de distância D2

Matriz de distância euclidiana entre d(1 e 5) e os demais indivíduos da população;
O menor valor em D2 é $d(2 \text{ e } 4)=2$, então os indivíduos 2 e 4 são agrupados.

	(15)	2	3	4
(15)	0	5	10	7
2		0	5	2
3			0	3
4				0

Análise de Agrupamentos

Métodos Hierárquicos de Agrupamentos:

➔ Matriz de distância D3

Matriz de distância euclidiana entre d_2 e d_4 e os demais indivíduos da população;

O menor valor em D3 é $d(2, 4)=3$, então o indivíduo 3 é incluído no grupo 2 e 4.

Ind.	(15)	(24)	3
(15)	0	5	10
(24)		0	3
3			0

➔ Matriz de distância D4

Matriz de distância euclidiana entre (234) e (15);

	(15)	(234)
(15)	0	5
(234)		0

O grupo (234) é incluído no grupo (15), formando assim um único grupo.


Análise de Agrupamentos

Métodos Hierárquicos de Agrupamentos:

Resumo do método do vizinho mais próximo

➔ Tabela resumindo passos, grupos e distâncias entre grupos.

PASSO	GRUPOS	DISTÂNCIA
1	1,5	1
2	2,4	2
3	24,3	3
4	15,234	5



Observação	Valor
a	2
b	8
c	1
d	15
e	3
f	11
g	13
h	7
i	10


$$\text{Distância} = |x_i - y_i|$$

	a	b	c	d	e	f	g	h	i
a	0	6	1	13	1	9	11	5	8
b		0	7	7	5	3	5	1	2
c			0	14	2	10	12	6	9
d				0	12	4	2	8	5
e					0	8	10	4	7
f						0	2	4	1
g							0	6	3
h								0	3
i									0

Análise de Agrupamentos – Cluster Analysis

Técnicas Hierárquicas

Dendograma - Representação Gráfica de Agrupamento Aglomerativo



Análise de Agrupamentos – Cluster Analysis

Técnica Não-Hierárquica

K-Means - Uso intenso para grande volume de dados

- Parte de k sementes ou k clusters iniciais sobre os quais calcula as médias;
- Associa um item à semente/ média mais próxima (usando, por exemplo, a Distância Euclideana). Recalcula a média deste novo cluster e repete iterativamente esta etapa até que não haja mais realocação de elementos.

Análise de Agrupamentos – Cluster Analysis


• • • + • □

• • +


Técnica Não-Hierárquica

K-Means - Uso intenso para grande volume de dados

- Parte de k sementes ou k clusters iniciais sobre os quais calcula as médias;
- Associa um item à semente/ média mais próxima (usando, por exemplo, a Distância Euclideana). Recalcula a média deste novo cluster e repete iterativamente esta etapa até que não haja mais realocação de elementos.



ANÁLISE DE CONGLOMERADOS: Cluster Analysis - KMeans)



Análise de Agrupamentos – Cluster Analysis

Estatísticas a serem Avaliadas

- Número de Grupos
- Quantidade de Elementos no Grupo
- Média e Desvio-Padrão das Variáveis do Grupo
- Valor Máximo e Mínimo das Variáveis do Grupo
- Soma de Quadrados Médios dentro dos Grupos
- Soma de Quadrados Médios entre os Grupos

Segmentação Comportamental

Modelo RFV - Exemplo

Exemplo

Dados Internos

- Período da base de dados
 - Janeiro de 2.018 a Dezembro de 2.018 (1,7 MM clientes)
- Variáveis
 - Recência: Quantos dias atrás última visita no site
 - Frequência: Quantos vezes por mês visita o site
 - Valor: Valor médio de compras em reais
- Técnica estatística: Análise de Cluster
 - Procedimento de aglomeração “K-Means”
 - Quantidade de Clusters: 4

Exercitando!!!!



Segmentação RFV



Segmentação Comportamental

Modelo RFV - Resultados

Exemplo

Perfil dos Segmentos

Variáveis	Segmento 1	Segmento 2	Segmento 3	Segmento 4	Total
Média de visitas por mês	7,8	1,9	3,2	1,5	2,6
Recência em dias *	3,4	9,3	6,7	15,0	10,4
Valor médio por compra	R\$ 490,47	R\$ 260,94	R\$ 155,21	R\$ 110,79	R\$ 188,81


* Em média quantos dias atrás fez visita no site

Segmentação Comportamental


Modelo RFV - Resultados

Distribuição da quantidade de Clientes, quantidade visitas e faturamento

Exemplo




DATA ANALYTICS




O que você achou da aula de hoje?

Pelo aplicativo da FIAP

(Entrar no FIAPP, e no menu clicar em Experience Survey)



Experience Survey



A grande finalidade do
conhecimento não é conhecer,
mas agir.

T. Huxley

OBRIGADO

 / Regina T. I. Bernal

FIAP

Copyright © 2025 | Professora Dra. Regina Tomie Ivata Bernal
Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente proibido sem consentimento formal, por escrito, do professor/autor.

FIAP