

FIAP

NABA

Distributed Data Processing & Storage



FÁBIO JARDIM

Bacharel em Ciência da Computação.

Pós graduação em Big Data.

Experiência em Infraestrutura, desenvolvimento e banco de dados.

Mais de 15 anos em plataforma de dados (Sql, NoSql e Big Data).

Vivência em indústria, e-commerce, varejo, banco e startups.

Atualmente Head de Dados na Contabilizei



<https://www.linkedin.com/in/fjardim/>



• Programação Paralela

- Uso simultâneo de várias unidades de processamento (CPUs) para realizar trabalhos computacionais

Objetivos:


- Resolver problemas maiores
Resolver mais rápido
Resolver problemas mais complexos

• Computação Serial e Paralela




• Computação Distribuída

- Coleção de computadores autônomos interligados através de uma rede de computadores e equipados com software que permita o compartilhamento dos recursos do sistema: hardware, software e dados



Cluster


- Sistema que relaciona dois ou mais computadores para que estes trabalhem de maneira conjunta no intuito de processar uma tarefa



• Scale Up x Scale Out



Vertical Scaling

(Increase size of instance (RAM , CPU etc.))




Horizontal Scaling

(Add more instances)



Performance


Scale-Out



Scale-Up




Evolução






Exemplo

- Apache Hadoop é um framework, open source, para o processamento paralelo e distribuído de grandes quantidades de dados em clusters com escalabilidade horizontal, assim como muitos outros frameworks do ecossistema de dados.



Evolução das plataformas




Data Warehouse (DW)

- Suporte ao BI
- Banco de dados
- Retirar carga do transacional
- Cargas pesadas de dados
- Modelagem fixa (Dados Estruturados)
- ETL (pré processamento)
- Cloud ou On Premise
- SQL Server, Oracle, PostgreSQL, Teradata, etc...




Data Lake

- Vasto repositório de dados
- Sistema de arquivos
- Variedade de dados
- Dados brutos
- Camadas de dados
- Dados coerentes
- Hadoop, S3, Blob Storage, etc...





Data Lakehouse

- Sistema de armazenamento de dados de baixo custo no data lake, utilizando um formato aberto de arquivos
- Camada de metadados transacional
- Resolver desafios enfrentados no DW e DL
- Reduz os custos operacionais
- Simplificar o processo de transformação
- Melhorar a governança
- Delta Lake, Apache Iceberg e Apache Hudi




DW, Data Lake e Data Lakehouse






Data Mesh

- Arquitetura de dados descentralizada orientada ao domínio
- Dados disponibilizados como produto
- Infraestrutura para disponibilizar os dados como self-service
- Governança federada para permitir a interoperabilidade dos domínios




. Dados em evidências





2020 This Is What Happens In An Internet Minute



2021 This Is What Happens In An Internet Minute





Onde armazenar
tudo isso?

Como processar
tudo isso?


Como obter valor
desses dados?

Como capturar
fontes diversas
de dados?



Por que Big Data?

- Constante evolução
- Flexível
- Uso genérico
- Alto poder de processamento e armazenamento
- Potencializa análise de grandes volumes de dados
- Tipos diversos de dados
- Open Source



<https://www.kendoo.com.br/wp-content/uploads/2018/12/Data-Lake-1024x541.png>


O que é Big Data?

Grande conjunto de dados que excedem a capacidade de processamento de dados convencional.

Principais características:

- Volume muito grande de dados
- Movem-se muito rápido
- Estruturados, semi-estruturados e não estruturados

O Vs




Uso democrático

- Tamanhos diferentes, desafios diferentes
- Pode começar pequeno
- Cloud ou On Premise
- Nem todo mundo tem um Big Data
- Mas todo mundo pode usar Big Data
- Use sem moderação
- Para pequenas, médias e grandes empresas




O engenheiro de dados no mundo Big Data

- Coletar dados internos e externos
- Armazenamento de dados
- Criação e manutenção de pipelines
- Batch e Real Time
- Distribuição de dados
- Qualidade de dados



Evolução do Profissional de Dados

- Plataformas mais complexas
- Dados como estrutura central das organizações
- Profissional multi função
- Conhecimentos profundos em outras áreas
- Tudo em tempo real
- Soluções escaláveis e baixo custo




•




VS.




GCP




Azure



AWS




Open Source



Big Data Landscape 2012





FRAMEWORKS



FORMAT



QUERY / DATA FLOW



DATA ACCESS



DATABASES




OLAP




ORCHESTRATION



INFRA-STRUCTURE



DATA OPS



STREAMING & MESSAGING



STAT TOOLS & LANGUAGES



MLOPS & AI INFRA



AI FRAMEWORKS & LIBRARIES



AI MODELS & ARCHITECTURES



SEARCH



LOGGING & MONITORING




VISUALIZATION




COLLABORATION




Big Data Ecosystem (2017)



Modern Data Stack (2022)




0 Data Lake



Ingestão

- Prefira Real time/Orientado a eventos
- Batch sempre vai existir
- Dados diversos
- Escalável
- Controle e rastreabilidade
- Flexível
- Pipelines bem definidos




Ferramentas de ingestão



Flink



Apache
Airflow



kafka




beam



nifi

Processamento


- Real time e Batch
- Armazenamento alta e baixa latência
- Rastreabilidade
- Defina padrões de desenvolvimento
- Distribuir dados
- Análise simples e modelos complexos
- Cruzamentos de bases




Armazenamento




redis



APACHE
HBASE



PostgreSQL



neo4j

MINIO



mongoDB

Manipulação e processamento



Acesso e visualização


- Controle de acesso
- Integração com ferramentas
- API
- Data Driven
- Democratização
- Empoderamento do usuário
- Self Service



Visualização e colaboração



Apache Zeppelin



kibana



Metabase



Grafana

O que armazenar?

- Dados internos / Corporativos
- Dados de parceiros
- Dados externos / Crawlers
- Redes Sociais
- Dados públicos
- IoT
- O que o negócio precisar/pedir




Tipos e formatos de dados

- Novos modelos de dados
- Text (XML, JSON, TXT, CSV, etc...)
- Vídeo e imagens
- Dados geoespaciais
- Compactados
- Serializados
- Streaming


Dados Estruturados

- Muito utilizado
- Dados organizados
- Segue uma padronização
- Abordagem linha e coluna
- Vários formatos
- Banco de dados e CSV



Dados não estruturados

- Maior parte dos dados atuais
- Não são em linhas e colunas
- Não possuem modelo de dados
- Mais difícil de analisar
- IA possibilita processamento mais fácil
- Vídeos, fotos, textos, etc...



Dados Semi Estruturado

- Fica entre estruturado e não estruturado
- Estrutura flexível
- Existência de “metadados”
- Organizado
- Fácil entendimento
- Muito utilizado na web
- ex: JSON


```
{
  "orders": [
    {
      "orderno": "748745375",
      "date": "June 30, 2088 1:54:23 AM",
      "trackingno": "TN0039291",
      "custid": "11045",
      "customer": [
        {
          "custid": "11045",
          "fname": "Sue",
          "lname": "Hatfield",
          "address": "1409 Silver Street",
          "city": "Ashland",
          "state": "NE",
          "zip": "68003"
        }
      ]
    }
  ]
}
```

Desafios do cenário atual de dados

- Precisamos melhorar a eficiência na utilização dos dados
- Reduzir custo de dados redundantes
- Maioria das empresas não conhecem seus dados
- Melhorar governança sobre os dados
- Open Source cada vez mais utilizado, principalmente em ambientes multi cloud ou sem lockin
- Muita demanda atual e futura para profissionais de dados

Agora sim... o que veremos

- Conceitos, arquitetura, configuração e funcionamento dos frameworks
- Armazenamento de dados
- Análise de dados
- Processamento de dados
- Orquestração
- Gerenciamento de recursos
- Monitoria do ambiente



OBRIGADO



proffabio.jardim@fiap.com.br



Copyright © 2018 | Professor (a) Fábio Jardim
Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente proibido
sem consentimento formal, por escrito, do professor/autor.

FIAP