


FIAP

NABA



Apache Hive



O que é Hive

- Projeto Apache
- Criado para facilitar consulta e análise de dados
- Fornece interface SQL para dados armazenados em vários bancos de dados e sistemas de armazenamento
- Compatível com ingestão e análise de dados tradicionais
- Escalável e extensível
- Data Warehousing no ambiente Hadoop

O que é Hive

- Interpreta instruções SQL para Job MapReducer.
- Lê dados de arquivos estruturados e semi-estruturados no HDFS, e se baseia em metadados para simular uma tabela de um banco de dados relacional
- Não possui um SGBD
- Criado para análise em grandes volumes de dados


O que não é Hive

- Banco de dados relacional
- Feito para transação OnLine
- Para trabalhar em real time
- Baixa latência

História

- Iniciou o desenvolvimento em Agosto de 2007
- Criado pelo Facebook
- Petabytes de dados
- Projeto Apache
- Largamente utilizado

Arquitetura



Componentes

- Driver: Compila, otimiza, executa o HiveQL, e decide se executa a query local ou submete um MapReduce job.
- Metastore: Armazena os metadados, interpretando dos arquivos no HDFS como conteúdos de uma tabela. Armazena as informações de como as linhas e colunas são delimitadas dentro do arquivo. Pode ser armazenado no MySQL, Oracle, Derby ou Postgresql.


Componentes

- Hiveserver2: Permite que conexões (Thrift, ODBC e JDBC) de outros componentes tenham comunicação com o hive. Suporta autenticação e múltiplos usuários concorrentes.
- Beeline: É a Command Line Interface para acessar o hiveserver2, utilizando conexão JDBC.
- HiveQL: Utiliza Data Definition Language (DDL) para criar os bancos de dados e tabelas.

Hive-on-MR vs. Hive-on-Tez

```
SELECT g1.x, g1.avg, g2.cnt
FROM (SELECT a.x, AVERAGE(a.y) AS avg FROM a GROUP BY a.x) g1
JOIN (SELECT b.x, COUNT(b.y) AS avg FROM b GROUP BY b.x) g2
ON (g1.x = g2.x)
ORDER BY avg;
```

Tez avoids
unnecessary writes
to HDFS



	HIVE	RDBMS
Uso	Foco em analytics	Foco em on line ou analytics
Acesso	Batch	Batch e Interativo
Integridade	Baixa	Alta
Escalabilidade	Horizontal	Vertical
Armazenamento	Baixo custo por PB	PB?
Interface	HiveQL	SQL
Lantência	Minutos ou mais	ms ou segundos
Estrutura de dados	Semi Estruturado	Estruturado

HiveQL

- HiveQL é a linguagem de consulta de Hive
- Não está totalmente de acordo com o padrão ANSI SQL
- Muito próximo do padrão utilizado pelo MySql
- O Hive não suporta transações*
- Ainda assim, o HiveQL será familiar
- É utilizado para criar, alterar e excluir bancos de dados, tabelas, queries, funções e índices

Database

- Banco de dados no Hive é essencialmente apenas um catálogo ou espaço para tabelas
- Se não especificar o banco de dados, o banco de dados default é usado
- Podemos criar vários bancos de dados
- Podemos alterar o diretório na hora da criação

Database - Comandos

- Criar banco de dados
create database if not exists [nome] location 'path on hdfs'
- Visualizar banco de dados
show databases
- Definição do banco de dados
describe database [nome]
- Excluir banco de dados
drop database [nome]
- Alterar banco de dados
alter database [nome] [parametros]

Criando um database

- Crie um banco de dados no Hive

create database aula location '/app/aula';

- Verifique o database

show databases;

- Definição do banco de dados

describe database aula

Tabelas

- Hive possui dois tipos de tabelas:
- Tabelas Gerenciadas
- Tabelas Externas

Tabela Gerenciada

- Também chamadas de tabelas internas
- Hive controla o ciclo de vida de seus dados (mais ou menos).
- Armazena os dados dessas tabelas em um subdiretório sob o diretório definido por `hive.metastore.warehouse.dir` (por exemplo, `/user/hive/warehouse`)
- Podemos informar o local de armazenamento dos dados
- Quando excluimos a tabela os dados também são excluídos

Criando uma tabela gerenciada

- Crie uma tabela
use aula;
create table tabelagerenciada
(id int, nome string)
row format delimited fields terminated by ','
stored as Textfile
location '/hive/aula/tabelagerenciada';
- Verifique a tabela
show tables;
*select * from tabelagerenciada;*

Criando uma tabela gerenciada

- Crie um arquivo local e inserir no HDFS

No terminal digite `vi teste.csv`

Crie linhas com o modelo `id,nome`

- Insira o arquivo no HDFS

`hadoop fs -put teste.csv /app/aula/tabelagerenciada`

- Consulte os registros

`select * from tabelagerenciada;`

Tabela Externa

- Hive não é dono dos dados
- Deve ser informado a localização dos dados
- Quando excluimos a tabela os dados não são excluídos
- Apenas os metadados são excluídos
- A palavra-chave EXTERNAL diz ao Hive que esta tabela é externa
- Cláusula LOCATION é necessária para informar ao Hive onde os dados estão localizados

Criando uma tabela externa

*create external table [name] (column type...)
row format delimited fields terminated by ','
location 'path on hdfs'*

*create external table tabelaexterna
(id int,nome string)
row format delimited fields terminated by ','
stored as TextFile
location '/app/aula/tabelaexterna'*

Informações

- Exibir o banco de dados atual e header (HiveCli)
`set hive.cli.print.current.db=true`
`set hive.cli.print.header=true;`
- Informações básicas da tabela
`DESCRIBE [nome da tabela]`
- Informações da estrutura da tabela:
`DESCRIBE FORMATTED [nome da tabela]`
`DESCRIBE EXTENDED [nome da tabela]`
- Retorna DDL da tabela
`SHOW CREATE TABLE [nome da tabela]`

Documentação

- <https://cwiki.apache.org/confluence/display/Hive/LanguageManual+DDL>

Formatos de armazenamento


- Text File: Arquivo texto (csv, txt, json, etc)
- Avro: é um sistema de serialização de dados, baseado em schema. Muito utilizado para compactar os dados que trafegam em um cluster ou rede.
- ORC: Optimized Row Columnar, maneira altamente eficiente de armazenar dados em Hive. Melhora o desempenho de leitura, escrita e processamento de dados
- Parquet: Formato colunar em larga escala do ecossistema para Hadoop. Compatível com várias ferramentas como Impala, Spark e Pig.

SerDe

- Abreviação de Serializer / Deserializer
- O Hive usa a interface SerDe para IO
- Um SerDe permite que o Hive leia os dados de uma tabela e os grave no HDFS em qualquer formato personalizado
- Qualquer um pode escrever seu próprio SerDe para seus próprios formatos de dados
- Avro, ORC, RegEx, Parquet, CSV, JsonSerDe, customizados...

SerDe

How Hive Reads and Writes Records



SerDe TextFile

```
CREATE EXTERNAL TABLE tabelatextfile  
(  
  column1 string,  
  column2 string  
)  
row format delimited fields terminated by ','  
STORED AS TEXTFILE  
LOCATION '/aula/hive/tabelatextfile'
```

SerDe Parquet

```
CREATE EXTERNAL TABLE tabelaparquet  
(  
  column1 string,  
  column2 string  
)  
STORED AS PARQUET  
LOCATION '/aula/hive/tabelaparquet'
```

Particionamento

- Particiona a tabela em diretórios no HDFS
- Ganho de performance e eficiência
- Evita a leitura da base toda
- Muito utilizado em grandes volumes de dados
- partitioned by

Tabelas Particionadas

```
create external table tabelaparticionada  
(nome string)  
partitioned by (ano int)  
row format delimited fields terminated by ';'   
lines terminated by '\n'  
stored as textfile  
location '/aula/hive/tabelaparticionada';
```

Manipulando Partição

Criando partição

```
alter table tabelaparticionada
```

```
add partition (ano = 2017)
```

```
location '/aula/hive/tabelaparticionada/particao/ano=2017'
```

Excluindo partição

```
alter table tabelaparticionada drop partition (ano = 2017)
```


Inserindo dados

Insert tabela

```
insert into tabelagerenciada  
values (1,'teste')
```

```
select * from tabelagerenciada
```

Insert tabela particionada

```
insert into tabelaparticionada partition (ano=2018)  
values ('teste')
```

Load

Load do SO para o Hive

```
load data local inpath '/tmp/load.txt'  
overwrite into table tabelagerenciada  
select * from tabelagerenciada
```

Load do HDFS para o Hive

```
load data inpath '/aula/load.txt'  
overwrite into table tabelagerenciada  
select * from tabelagerenciada
```

Extraíndo dados

Para o HDFS

```
insert overwrite directory '/output'  
select * from tabelaparticionada
```

Para o SO

```
insert overwrite local directory '/tmp/export'  
select * from tabelaparticionada
```


Apache Impala

- Open Source
- Analytic Database for Apache Hadoop
- Cloudera, MapR, Oracle e Amazon
- Fornece baixa latência
- Suporte SQL
- Integração com metastore do Hive
- Compartilha bancos de dados e tabelas com Hive




Apache Impala - Arquitetura

Common Hive SQL and interface




Unified metadata



LLAP

- Live Long and Process
- Presente no Hive2
- Armazenamento em cache na memória
- Fornecer consultas SQL extremamente rápidas
- Não sacrifica a escalabilidade pela qual o Hive e o Hadoop são conhecidos


LLAP - Arquitetura




Presto/Trino

- Engine SQL distribuida de alta performance
- Desenvolvido pelo Facebook em 2012
- Open Source desde 2013
- Cerca de 1000 funcionários do Facebook executam 30.000 queries em petabytes de dados diariamente
- PrestoDB mantido pelo Facebook (atualmente pela Linux Foundation) e PrestoSQL mantido pela Presto Software Foundation

Presto - Arquitetura



```
select * from sqlserver.banco.tabela s  
inner join mysql.banco.tabela m on m.id = s.id
```



Acessando o Hive

- HiveCli
- Beeline
- Hue
- Ambari Views
- Clients JDBC
- Spark
- DBeaver
- Apache Zeppelin
- PyHive

Acessando o Hive

```
docker exec -it hive-server bash
```

Beeline

- `beeline -u "jdbc:hive2://localhost:10000/default"`
- `beeline -help`

```
root@hive server:/opt# beeline -u "jdbc:hive2://localhost:10000/default"
Connecting to jdbc:hive2://localhost:10000/default
Connected to: Apache Hive (version 2.3.2)
Driver: Hive JDBC (version 2.3.2)
Transaction isolation: TRANSACTION_REPEATABLE_READ
Beeline version 2.3.2 by Apache Hive
0: jdbc:hive2://localhost:10000/default> █
```

HiveCLI

```
root@hive_server:/opt# hive
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/opt/hive/lib/log4j-slf4j-impl-2.6.2.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/opt/hadoop-2.7.4/share/hadoop/common/lib/slf4j-log4j12-1.7.10.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.apache.logging.slf4j.Log4jLoggerFactory]

Logging initialized using configuration in file:/opt/hive/conf/hive-log4j2.properties Async: true
Hive-on-MR is deprecated in Hive 2 and may not be available in the future versions. Consider using a
different execution engine (i.e. spark, tez) or using Hive 1.X releases.
hive> █
```

HUE

The screenshot displays the Apache Hue web interface. At the top, there's a blue header with the 'Hue' logo and a 'Query' button. A search bar is located to the right of the header. The left sidebar is dark blue and contains navigation links: Editor (selected), Dashboard, Scheduler, Documents, Files, Tables, Jobs, and Importer. The main workspace is light gray. On the left side of the workspace, there's a pane showing the 'Hive' database and a 'default' table. The right side of the workspace is the SQL editor, which has a toolbar with icons for running queries, saving, and settings. Below the editor is a 'Query Builder' tab, which is currently empty, displaying a message: 'There are currently no rules defined. To get started, right click on any table column in the SQL Assist panel.'




Referências

Site Projeto Apache Hive:

<https://cwiki.apache.org/>

<https://hive.apache.org/>

Livros:



OBRIGADO



proffabio.jardim@fiap.com.br



Copyright © 2018 | Professor (a) Fábio Jardim
Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente proibido
sem consentimento formal, por escrito, do professor/autor.

FIAP