



**FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO
PAULISTA: ENGENHARIA DE DADOS**

Data Pipelines

SÃO PAULO

2025

Bruno Gomes Nogueira – 364457

Evaldo Loiola Mota Junior – 364056

Gabriel Pinheiro Ximenes - 365776

Herivelto Raimundo Lemos de Macedo Junior – 364212

João Paulo Martins Rodrigues – 364668

Exercícios

1. Ingestão de arquivos para um diretório no HDFS


Nesta atividade você deverá importar arquivos de vendas da sua empresa para o HDFS. Os arquivos estão em formato delimitado na origem e deverão ser salvos no mesmo formato no destino. Seguem parâmetros para criação do fluxo:

- **Diretório de origem (Linux):** /data/marketplace/sales/
- **Diretório de destino (HDFS):** /data/bronze/sales/
- **Formato dos arquivos no destino:** preservar mesmo formato da origem
- **Compressão dos arquivos no destino:** Nenhuma

Grupos :



Detalhes do processo de diretório local para HDFS:



Detalhes do ListFile:

Processor Details

▶ Running STOP & CONFIGURE

SETTINGS SCHEDULING **PROPERTIES** COMMENTS

Required field

Property	Value
Input Directory	/data/marketplace/sales/
Listing Strategy	Tracking Timestamps
Recurse Subdirectories	false
Record Writer	No value set
Input Directory Location	Local
File Filter	[^\\.]*
Path Filter	No value set
Include File Attributes	true
Minimum File Age	0 sec
Maximum File Age	No value set
Minimum File Size	0 B
Maximum File Size	No value set

OK

Detalhes do Fetch File:

Processor Details

▶ Running

STOP & CONFIGURE

SETTINGS

SCHEDULING

PROPERTIES

COMMENTS

Required field

Property	Value
File to Fetch	\${absolute.path}/\${filename}
Completion Strategy	Move File
Move Destination Directory	\${absolute.path}/processed
Move Conflict Strategy	Rename
Log level when file not found	ERROR
Log level when permission denied	ERROR

OK

Detalhes do PutHDFS:

Processor Details

▶ Running

STOP & CONFIGURE

SETTINGS

SCHEDULING

PROPERTIES

COMMENTS

Required field

Property	Value
Hadoop Configuration Resources	/etc/hadoop/conf/core-site.xml,/etc/hadoop/conf/hdfs-sit...
Kerberos Credentials Service	No value set
Kerberos Principal	No value set
Kerberos Keytab	No value set
Kerberos Password	No value set
Kerberos Relogin Period	4 hours
Additional Classpath Resources	No value set
Directory	/data/bronze/sales
Conflict Resolution Strategy	fail
Block Size	No value set
IO Buffer Size	No value set
Replication	No value set

OK



Evidências dos arquivos no HDFS:

Ambari - hadoop_demo — Mozilla Firefox

Ambari - hadoop_demo X NIFI Flow X NIFI Flow X Ambari - hadoop_demo X +

hdpdemo.local:8080/#/main/view/FILES/auto_files_instance

Ambari NIFI

/ > data > bronze > sales

Total: 10 files or folders

+ Select All New Folder Upload

Search in current directory ...

Name >	Size >	Last Modified >	Owner >	Group >	Permission
20200301.csv	30.6 MB	2025-11-26 22:23	hdpadmin	hdfs	-rw-r--r--
20200302.csv	30.2 MB	2025-11-26 22:23	hdpadmin	hdfs	-rw-r--r--
20200303.csv	25.4 MB	2025-11-26 22:23	hdpadmin	hdfs	-rw-r--r--
20200304.csv	26.7 MB	2025-11-26 22:23	hdpadmin	hdfs	-rw-r--r--
20200305.csv	32.2 MB	2025-11-26 22:23	hdpadmin	hdfs	-rw-r--r--
20200306.csv	29.4 MB	2025-11-26 22:23	hdpadmin	hdfs	-rw-r--r--
20200307.csv	25.7 MB	2025-11-26 22:23	hdpadmin	hdfs	-rw-r--r--
20200308.csv	33.2 MB	2025-11-26 22:23	hdpadmin	hdfs	-rw-r--r--
20200309.csv	27.4 MB	2025-11-26 22:23	hdpadmin	hdfs	-rw-r--r--
20200310.csv	29.5 MB	2025-11-26 22:23	hdpadmin	hdfs	-rw-r--r--

2. Ingestão de uma tabela para um diretório no HDFS

Nesta atividade você deverá utilizar o NiFi para fazer a importação de uma tabela do banco de Dados para o HDFS. Para isso, você deverá utilizar o processor **ExecuteSQL**.

Para a correta utilização deste *processor* é necessária a criação de um **Database Connection Pooling Service**. Utilize a imagem abaixo como exemplo, e não se esqueça de adicionar usuário e senha do DB:


Para configuração do processo, utilize os seguintes dados de origem e destino:

- **Tabela de origem:** LOC_AGENCIA
- **Tipo de Carga:** Carga Full
- **Diretório de destino (HDFS):** /data/bronze/carloca/loc_agencia/

Importante: Para evitar que a query rode continuamente, ajuste o parâmetro Run Schedule na aba SCHEDULING para **60s**. Isso permitirá que você faça uma validação da recorrência do processo sem gerar uma quantidade descontrolada de conexões simultâneas ao banco de dados.

#adicione neste espaço suas evidências e comentários

Arquitetura do flow:



Detalhes do execute SQL:

Processor Details

Running

STOP & CONFIGURE

SETTINGS

SCHEDULING

PROPERTIES

COMMENTS

Required field

Property	Value
Database Connection Pooling Service	DBCPConnectionPool →
SQL Pre-Query	No value set
SQL select query	SELECT * FROM LOC_AGENCIA
SQL Post-Query	No value set
Max Wait Time	0 seconds
Normalize Table/Column Names	false
Use Avro Logical Types	false
Compression Format	NONE
Default Decimal Precision	10
Default Decimal Scale	0
Max Rows Per Flow File	0
Output Batch Size	0
Batch Size	0

OK

Agenda a cada 60 segundos:

The screenshot shows the 'Processor Details' dialog box with the 'SCHEDULING' tab selected. The 'Running' status is indicated at the top right. The 'STOP & CONFIGURE' button is visible. The 'SCHEDULING' tab contains the following settings:

- Scheduling Strategy:** Timer driven
- Run Duration:** 00:00:00.000
- Concurrent Tasks:** 1
- Run Schedule:** 60 sec
- Execution:** All nodes

An 'OK' button is located at the bottom right of the dialog.

Detalhe do DBCPConnectionPool:

The screenshot shows the 'Controller Service Details' dialog box with the 'PROPERTIES' tab selected. The 'Required field' section is highlighted. The table below lists the properties and their values:

Property	Value
Database Connection URL	jdbc:oracle:thin:@localhost:1521:XE
Database Driver Class Name	oracle.jdbc.driver.OracleDriver
Database Driver Location(s)	/home/hdpadmin/Downloads/ojdbc6.jar
Database User	hdpadmin
Password	Sensitive value set
Max Wait Time	500 millis
Max Total Connections	8
Validation query	No value set

Tabela to HDFS Configuration

GENERAL	CONTROLLER SERVICES
---------	---------------------

Name	Type	Bundle	State	Scope
DBCConnectionPool	DBCConnectionPool 1.13.2	org.apache.nifi - nifi-dbc-service-nar	Enabled	Tabela to HDFS

Detalhe do PutHDFS:

Processor Details

Running STOP & CONFIGURE

SETTINGS SCHEDULING PROPERTIES COMMENTS

Required field

Property	Value
Hadoop Configuration Resources	/etc/hadoop/conf/core-site.xml,/etc/hadoop/conf/hdfs-sit...
Kerberos Credentials Service	No value set
Kerberos Principal	No value set
Kerberos Keytab	No value set
Kerberos Password	No value set
Kerberos Relogin Period	4 hours
Additional Classpath Resources	No value set
Directory	/data/bronze/carloca/loc_agencia/
Conflict Resolution Strategy	fail
Block Size	No value set
IO Buffer Size	No value set
Replication	No value set

OK

Arquivos no HDFS:

hdpdemo.local:8080/#/main/view/FILES/auto_files_instance

carloca > loc_agencia 1 Files, 0 Folders selected

Select All New Folder Upload

Open Rename Permissions Delete Copy Move Download concatenate Search in current directory...

Name	Size	Last Modified	Owner	Group	Permission
55d34369-3d55-469d-896c-75cc843bac35	1.5 kB	2025-11-26 22:48	hdpadmin	hdfs	-rw-r--r--
592d61b5-65f0-405f-bdb6-01fc124ac5b1	1.5 kB	2025-11-26 22:49	hdpadmin	hdfs	-rw-r--r--
962e212a-f855-40be-a277-b8c10d1b8c5b	1.5 kB	2025-11-26 22:48	hdpadmin	hdfs	-rw-r--r--

FIAP