

# Data Science – Turma 29ABD

## Atividade prática aula 04

**Habilidades desenvolvidas:** Modelos preditivos usando modelos de regressão logística. Técnicas de data mining.

### Parte 1: Regressão Logística

Utilize os resultados do modelo de inadimplência do cartão de crédito para completar os exercícios a seguir.

- 2) Use o resultado da Regressão Logística Múltipla para calcular a probabilidade de inadimplência do cartão de crédito:

| Variável     | Descrição                   | Valor               |
|--------------|-----------------------------|---------------------|
| atrasos      | Atrasos                     | 1-Ate 3 dias        |
|              |                             | 2-3 a 15 dias       |
|              |                             | 3-15 a 30 dias      |
|              |                             | 4-Mais de 30 dias   |
| temporel     | Tempo de relacionamento     | 1-ate 1 ano         |
|              |                             | 2-1 a 3 anos        |
|              |                             | 3-3 a 8 anos        |
|              |                             | 4-mais 8 anos       |
| valorfatura  | Valor da fatura             | 1-Ate R\$250        |
|              |                             | 2-R\$250 a R\$800   |
|              |                             | 3-R\$800 a R\$1499  |
|              |                             | 4-R\$1500 e mais    |
| p_gastoalim  | % de gastos com alimentação | 1-Ate 10%           |
|              |                             | 2-10% a 20%         |
|              |                             | 3-20% a 30%         |
|              |                             | 4-30% e mais        |
| regiao_risco | Região de Risco             | I                   |
|              |                             | II                  |
|              |                             | III                 |
|              |                             | IV                  |
| rendamensal  | Renda mensal                | 1-Ate R\$1518       |
|              |                             | 2-R\$1519 a R\$3000 |
|              |                             | 3-R\$3000 a R\$4500 |
|              |                             | 4-mais de R\$4500   |

```
Optimization terminated successfully.
Current function value: 0.457274
Iterations: 6

Results: Logit
=====
Model:          Logit          Method:          MLE
Dependent Variable: Resposta    Pseudo R-squared: 0.348
Date:           2025-02-10 14:45 AIC:           16671.7997
No. Observations: 18188         BIC:           16820.1615
Df Model:        18             Log-Likelihood: -8316.9
Df Residuals:    18169          LL-Null:       -12607.
Converged:       1.0000         LLR p-value:   0.0000
No. Iterations:  6.0000         Scale:        1.0000
=====
              Coef.   Std. Err.      z    P>|z|    [0.025   0.975]
-----+-----
const              1.5857    0.0862   18.3944  0.0000    1.4167   1.7547
atrasos_2           0.7132    0.0574   12.4348  0.0000    0.6008    0.8257
atrasos_3           2.2605    0.0602   37.5804  0.0000    2.1426    2.3784
atrasos_4           2.9364    0.0637   46.1324  0.0000    2.8117    3.0612
temporel_2          -0.2324    0.0573   -4.0554  0.0001   -0.3447   -0.1201
temporel_3          -0.9481    0.0539  -17.5886  0.0000   -1.0538   -0.8425
temporel_4          -1.0730    0.0533  -20.1218  0.0000   -1.1775   -0.9685
valorfatura_2        0.0669    0.0512    1.3075  0.1910   -0.0334    0.1672
valorfatura_3       -0.2870    0.0559   -5.1302  0.0000   -0.3967   -0.1774
valorfatura_4       -0.6676    0.0592  -11.2768  0.0000   -0.7826   -0.5516
p_gastoalim_2       -0.1942    0.0578   -3.3623  0.0008   -0.3074   -0.0810
p_gastoalim_3       -1.0228    0.0532  -19.2139  0.0000   -1.1272   -0.9185
p_gastoalim_4       -2.2470    0.0601  -37.4054  0.0000   -2.3648   -2.1293
regiao_risco_2      -0.7995    0.0549  -14.5510  0.0000   -0.9072   -0.6918
regiao_risco_3      -1.0748    0.0600  -17.9013  0.0000   -1.1925   -0.9571
regiao_risco_4      -1.6490    0.0563  -29.2759  0.0000   -1.7594   -1.5386
rendamensal_2       -0.4814    0.0594   -8.1004  0.0000   -0.5978   -0.3649
rendamensal_3       -1.1061    0.0582  -19.0068  0.0000   -1.2202   -0.9921
rendamensal_4       -0.8090    0.0591  -13.6914  0.0000   -0.9248   -0.6932
=====
```

| ID | Características                                                                                                                                                                                                                     | Probabilidade de Inadimplência                                                                                                                                                                                                                                                                                                               |
|----|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | Cliente com 2 anos de relacionamento com a Instituição Financeira, renda mensal de R\$4000, reside na região I, com 20 dias de atraso no pagamento, valor da fatura R\$2000 e percentual de gastos com alimentação no cartão de 35% | $z = 1,5857 (\text{const}) - 0,2324 (\text{temporel\_2}) - 1,1061 (\text{rendamensal\_3}) + 0 (\text{regiaorisco\_1}) + 2,2605 (\text{atrasos\_3}) - 0,6676 (\text{valorfatura\_4}) - 2,2470 (\text{p\_gastoalim\_4})$ $z = 1,5857 - 0,2324 - 1,1061 + 2,2605 - 0,6676 - 2,2470 = -0,4069$ $P = 1 / (1 + e^{0,4069}) = 1 / 2,5022 = 39,96\%$ |
| 2  | Cliente com 1 ano de relacionamento com a Instituição Financeira, renda mensal de R\$1000, reside na região IV, com 20 dias de atraso no pagamento, valor da fatura R\$500 e percentual de gastos com alimentação no cartão de 5%   | $z = 1,5857 (\text{const}) + 0 (\text{temporel\_1}) + 0 (\text{rendamensal\_1}) - 1,6490 (\text{regiaorisco\_4}) + 2,2605 (\text{atrasos\_3}) + 0,0669 (\text{valorfatura\_2}) + 0 (\text{p\_gastoalim\_1})$ $z = 1,5857 - 1,6490 + 2,2605 + 0,0669 = +2,2641$ $P = 1 / (1 + e^{-2,2641}) = 1 / 1,1040 = 90,58\%$                            |
| 3  | Cliente com 9 anos de relacionamento com a Instituição Financeira, renda mensal de R\$7000, reside na região II, com 2 dias de atraso no pagamento, valor da fatura R\$4000 e percentual de gastos com alimentação no cartão de 35% | $z = 1,5857 (\text{const}) - 1,0730 (\text{temporel\_4}) - 0,8090 (\text{rendamensal\_4}) - 0,7995 (\text{regiaorisco\_2}) + 0 (\text{atrasos\_1}) - 0,6676 (\text{valorfatura\_4}) - 2,2470 (\text{p\_gastoalim\_4})$ $z = 1,5857 - 1,0730 - 0,8090 - 0,7995 - 0,6676 - 2,2470 = -4,0104$ $P = 1 / (1 + e^{4,0104}) = 1 / 56,07 = 1,78\%$   |

- a) Utilize os resultados da matriz de confusão do modelo da Regressão Logística na amostra de treinamento. Preencha o quadro a seguir e responda:

| Resposta real | Resposta do modelo Predito |      | Total |
|---------------|----------------------------|------|-------|
|               | 0                          | 1    |       |
| 0             | 7460                       | 1655 | 9115  |
| 1             | 1961                       | 7112 | 9073  |
| Total         | 9421                       | 8767 | 18188 |

- Qual o percentual de acerto (recall) da resposta 0 (adimplente)? Apresente o cálculo.  

$$7460 / (7460 + 1655) = 81,84\%$$
- Qual o percentual de acerto (recall) da resposta 1 (inadimplente)? Apresente o cálculo.  

$$7112 / (1961 + 7112) = 78,39\%$$
- Qual o percentual de acerto médio (recall) do modelo? Apresente o cálculo.

$$(81,84\% + 78,39\%) / 2 = 80,11\%$$

- 4) Apresente o cálculo da capacidade do modelo em identificar corretamente (*precision*) a classe 0. Qual o valor?

$$7460 / (7460 + 1961) = 79,18\%$$

- 5) Apresente o cálculo da capacidade do modelo em identificar corretamente (*precision*) a classe 1. Qual o valor?

$$7112 / (1655 + 7112) = 81,12\%$$

- b) Utilize os resultados da matriz de confusão do modelo da Regressão Logística na amostra de validação. Preencha o quadro a seguir e responda:

| Resposta real | Resposta do modelo Predito |      | Total |
|---------------|----------------------------|------|-------|
|               | 0                          | 1    |       |
| 0             | 3164                       | 777  | 3941  |
| 1             | 855                        | 3000 | 3855  |
| Total         | 4019                       | 3777 | 7796  |

- 1) Qual o percentual de acerto (recall) da resposta 0 (adimplente)? Apresente o cálculo.

$$3164 / (3164 + 777) = 80,28\%$$

- 2) Qual o percentual de acerto (recall) da resposta 1 (inadimplente)? Apresente o cálculo.

$$3000 / (855 + 3000) = 77,82\%$$

- 3) Qual o percentual de acerto médio (recall) do modelo? Apresente o cálculo.

$$(80,28\% + 77,82\%) / 2 = 79,05\%$$

- 4) Apresente o cálculo da capacidade do modelo em identificar corretamente (*precision*) a classe 0. Qual o valor?

$$3164 / (3164 + 855) = 78,73\%$$

- 5) Apresente o cálculo da capacidade do modelo em identificar corretamente (*precision*) a classe 1. Qual o valor?

$$3000 / (777 + 3000) = 79,43\%$$

- c) O modelo de regressão logística ajustado tem poder de generalização? Por quê?

O modelo demonstra boa capacidade de generalização, com resultados consistentes entre as amostras de treino e teste. A acurácia foi de aproximadamente 0,80 no treino e 0,79 no teste, e os valores de recall e precision de ambas as classes permaneceram estáveis entre as duas amostras, sem quedas expressivas de desempenho. Esses resultados indicam ausência de overfitting, confirmando que o modelo mantém desempenho equivalente diante de dados inéditos.

Data de entrega: 10/04/2026

Arquivo formato Word.

Regina Bernal

30/03/2026