



**FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO
PAULISTA: ENGENHARIA DE DADOS**

Data Analytics Architecture

SÃO PAULO
2026

29ABD

Bruno Gomes Nogueira – 364457

Evaldo Loiola Mota Junior – 364056

Herivelto Raimundo Lemos de Macedo Junior – 364212

João Paulo Martins Rodrigues – 364668

Introdução

O Maria Bank possui um problema típico de empresas em crescimento: os dados estão espalhados entre diferentes fontes, existem processos em batch e streaming convivendo ao mesmo tempo, e não há uma estrutura formal de dados para organizar esse ambiente. Além disso, a ausência de liderança na área e a dependência dos engenheiros de software para sustentar as demandas de dados dificultam a evolução do banco para um modelo multiproduto.

Para responder a esse cenário, este trabalho propõe uma arquitetura de dados moderna em Azure, com processamento centralizado em Databricks, capaz de integrar dados do Oracle, fontes de terceiros e eventos transacionais em uma estrutura única e governada. A proposta considera uma visão de plataforma de dados com base em uma arquitetura lakehouse, permitindo suportar ingestão batch e streaming, processamento, armazenamento, consumo analítico e governança de forma integrada.

Além da arquitetura, o trabalho também propõe uma organização mínima para o time de dados, com liderança formal, papéis definidos e separação entre responsabilidades de plataforma, engenharia, governança e analytics. O objetivo é reduzir silos, melhorar a confiabilidade dos dados e criar uma base mais escalável para o crescimento do Maria Bank. Como foco principal da entrega, serão apresentados um fluxograma da arquitetura proposta e um organograma da estrutura recomendada para o time de dados.

Diagnóstico do Problema

O Maria Bank apresenta um cenário de crescimento em que a estrutura de dados ainda não acompanhou a complexidade do negócio. A partir do case, é possível identificar os seguintes pontos principais:

- O banco possui dados de clientes, transações, produtos e serviços distribuídos em diferentes fontes.
- Essas fontes incluem sistemas on-premises e fontes de terceiros, o que aumenta a complexidade de integração.
- Os dados estão armazenados em silos separados, dificultando a visão unificada e análise consistente.
- A empresa possui uma necessidade híbrida de processamento, com streaming para transações e batch para fechamento de fatura.
- O banco de dados atual é Oracle e o ambiente de nuvem adotado pela empresa é Azure.
- Não existe hoje uma liderança formal de dados dentro da organização.
- A área de dados é mantida pelos próprios engenheiros de software, sem uma estrutura dedicada.
- A empresa encontra dificuldade para evoluir para um modelo multiproduto, em grande parte por causa da desorganização dos dados.

Com base nesse cenário, os principais problemas de negócio e arquitetura podem ser resumidos da seguinte forma:

- Baixa integração entre dados, causada pela existência de múltiplas fontes e armazenamento em silos.
- Dificuldade de governança, já que não há uma estrutura clara de responsabilidade sobre os dados.
- Dependência operacional da engenharia de software, o que reduz foco, escala e especialização na frente de dados.
- Limitação para análises e tomada de decisão, pois os dados não estão organizados de forma centralizada e confiável.
- Baixa escalabilidade organizacional, dificultando a expansão do banco para novos produtos e serviços.



- Necessidade de suportar batch e streaming ao mesmo tempo, exigindo uma arquitetura moderna e flexível.

Dessa forma, o problema do Maria Bank não é apenas tecnológico, mas também organizacional. A empresa precisa de uma estrutura que permita integrar, governar, processar e disponibilizar dados de forma mais eficiente, com capacidade de crescimento, segurança e suporte ao negócio.

Stack de Dados Proposta

Considerando o cenário apresentado no case, a stack de dados escolhida para o Maria Bank foi baseada em uma arquitetura moderna em Azure, com Databricks como principal motor de processamento e uma arquitetura lakehouse como base central de armazenamento e consumo analítico. A escolha busca atender a necessidade de integrar diferentes fontes, suportar processamento batch e streaming e reduzir os silos de dados existentes na empresa.

A definição dessa stack foi guiada pelos seguintes pontos:

- A empresa já utiliza Azure como provedor de nuvem, o que torna mais natural evoluir a arquitetura no mesmo ecossistema.
- O case exige convivência entre processos streaming e processos batch, o que demanda uma stack flexível e capaz de lidar com diferentes padrões de processamento.
- A organização sofre com dados em silos, o que reforça a necessidade de uma camada central de dados para integração e governança.
- Os conceitos de Modern Data Stack discutidos em aula destacam o uso de soluções cloud-first, modulares e integradas com data warehouse, data lake ou lakehouse.
- A visão de plataforma de dados apresentada nas aulas mostra a importância de uma solução ponta a ponta, envolvendo ingestão, processamento, armazenamento, análise, segurança e observabilidade.

A stack proposta pode ser organizada nas seguintes camadas:

- **Fontes de dados**
 - Oracle on-premises, como base transacional atual do banco.
 - Fontes de terceiros.
 - Sistemas internos relacionados a clientes, produtos, serviços e transações.
 - Eventos transacionais gerados em tempo quase real.
- **Ingestão de dados**
 - Processos batch para cargas históricas, integrações periódicas e fechamento de fatura.

- Processos streaming para eventos transacionais e dados que exigem menor latência.
- Camada de integração responsável por trazer os dados das fontes legadas e externas para a plataforma analítica central.
- **Processamento e transformação**
 - Databricks como engine principal para processamento de dados.
 - Uso do Databricks para pipelines batch, processamento contínuo, transformação de dados e preparação das camadas analíticas.
 - Centralização do processamento em uma única plataforma, reduzindo fragmentação operacional e simplificando a arquitetura.
- **Armazenamento central**
 - Adoção de uma arquitetura lakehouse como base do ambiente de dados.
 - Essa escolha permite concentrar dados brutos, tratados e analíticos em uma mesma estrutura lógica, reduzindo redundância e melhorando governança.
 - O modelo lakehouse é aderente ao cenário do banco porque combina flexibilidade de armazenamento com capacidade analítica e suporte a diferentes workloads.
- **Consumo analítico**
 - Disponibilização dos dados para BI, relatórios, análises operacionais e futuras iniciativas de produtos de dados.
 - Criação de uma base mais confiável para tomada de decisão e expansão do banco para um cenário multiproduto.
- **Governança, segurança e observabilidade**
 - Inclusão de mecanismos de controle de acesso, qualidade, catálogo e monitoramento.
 - Esses elementos são importantes porque o problema do Maria Bank não está apenas no armazenamento dos dados, mas também na sua organização, confiabilidade e uso ao longo de todo o ciclo de vida.

A escolha por Databricks com arquitetura lakehouse faz sentido porque permite atender, em uma única estratégia, os principais desafios do case:

- integrar diferentes fontes de dados;
- suportar batch e streaming no mesmo ambiente;
- reduzir silos;
- melhorar governança;
- escalar a arquitetura para novas demandas do negócio;
- criar uma base mais moderna para analytics e expansão multiproduto.

Dessa forma, a stack proposta não é apenas uma escolha tecnológica, mas uma resposta direta às necessidades de modernização, integração e escalabilidade identificadas no Maria Bank.

Camada	Função	Tecnologia
Fontes	Origem dos dados	Oracle, sistemas internos, fontes de terceiros
Ingestão Streaming	Capturar e processar eventos transacionais em baixa latência	Databricks Structured Streaming
Ingestão/Orquestração Batch	Execução de cargas agendadas, integrações periódicas, fechamentos.	Databricks Lakeflow Jobs
Processamento e Transformação	Tratamento, padronização, enriquecimento e preparação dos dados	Databricks Apache Spark
Armazenamento	Camada central de dados	Azure Datalake Storage (ADLS)
Governança	Catálogo, controle de acesso, descoberta e governança centralizada	Unity Catalog
Consumo Analítico	Dashboards, análise self-service e interação com dados	Databricks AI/BI
Consumo em linguagem natural	Perguntas em linguagem natural para usuários de negócio	Genie spaces
Observabilidade	Monitoramento de pipelines e workloads	Observabilidade nativa de Lakeflow Jobs, Lakeflow Spark Declarative Pipelines e workloads Databricks

Arquitetura proposta

A proposta adota lakehouse como arquitetura central de armazenamento e processamento, por combinar flexibilidade de data lake com capacidade analítica e governança. Ao mesmo tempo, a solução é tratada como uma plataforma de dados, pois inclui ingestão, transformação, armazenamento, governança, consumo e observabilidade de forma integrada. O uso de um data lake isolado não seria suficiente para o cenário do Maria Bank, pois o problema da empresa não é apenas armazenar dados, mas organizá-los e disponibilizá-los com governança e capacidade analítica.

Na arquitetura, os dados provenientes do Oracle on-premises, de sistemas internos, de fontes de terceiros e dos eventos transacionais são ingeridos por dois fluxos principais: batch, para cargas periódicas e fechamento de fatura, e streaming, para eventos que exigem menor latência. Esses fluxos são processados no Databricks, com uso de Lakeflow Jobs para orquestração batch e Structured Streaming para o fluxo contínuo. Após o processamento, os dados são armazenados no ADLS, seguindo a lógica do lakehouse, e disponibilizados para consumo analítico com apoio de Unity Catalog na governança e AI/BI + Genie Spaces na camada de consumo.

Essa arquitetura foi escolhida porque responde diretamente aos principais desafios do case: integração entre fontes distintas, redução de silos, suporte simultâneo a batch e streaming, melhoria da governança e criação de uma base escalável para o crescimento do banco em direção a um modelo multiproduto.




Figura 1 – Arquitetura - Lakehouse



Na arquitetura proposta, o Oracle on-premises é integrado principalmente por meio de CDC, permitindo capturar alterações de forma incremental e reduzir a latência na disponibilização dos dados para a plataforma analítica.

Da mesma forma, outras fontes transacionais também podem ser integradas via CDC, sempre que esse padrão estiver disponível e fizer sentido para o tipo de sistema e dado analisado.

Embora o fluxo principal de integração transacional seja incremental, a arquitetura também mantém suporte a processos batch customizados. Esses fluxos podem ser utilizados em cenários específicos, como cargas históricas, reprocessamentos, backfills, reconciliações ou integrações que não se encaixem no padrão principal de CDC.

Essa abordagem traz mais flexibilidade para a solução e permite atender tanto necessidades operacionais de menor latência quanto demandas analíticas e técnicas que exigem processamento em lote.

Estrutura Proposta para o Time de Dados

O time de dados do Maria Bank adota o modelo centralizado, no qual um time central liderado pelo Head of Data define e governa os padrões aplicados em toda a organização.

O modelo descentralizado foi descartado pois pressupõe maturidade organizacional, cultura orientada à domínios e ownership distribuído de dados, pré-requisitos que o Maria Bank ainda não possui.

Dentro do modelo centralizado, adota-se a estratégia Alternativa em vez da Prescritiva. O Head of Data define os padrões globais da plataforma Azure, Databricks, Unity Catalog e Delta Lake mas cada área possui autonomia para escolher a abordagem técnica mais adequada à sua camada. A Engenharia de Dados decide entre Structured Streaming ou Lakeflow Jobs conforme o tipo de carga. Analytics escolhe a ferramenta de consumo conforme a necessidade do negócio.

A estratégia Prescritiva foi descartada por impor rigidez incompatível com uma arquitetura que, por natureza, exige ferramentas distintas em cada camada.

Centralizado para garantir governança e liderança formal. Alternativo para garantir flexibilidade técnica. Essa combinação é a mais adequada para o estágio atual de maturidade do Maria Bank.




Figura 2 – Estrutura do time de Dados - Centralizada

Conclusão

O cenário do Maria Bank mostra que os principais desafios da empresa não estão apenas no volume ou na origem dos dados, mas principalmente na falta de integração, governança e estrutura organizacional para sustentar o crescimento do negócio. A existência de múltiplas fontes, a convivência entre batch e streaming e a ausência de uma liderança formal de dados tornam necessária uma solução que vá além da simples centralização do armazenamento.

Diante disso, a proposta apresentada adota uma arquitetura lakehouse em Azure com Databricks, combinando ingestão incremental e batch, processamento centralizado, armazenamento em camadas Bronze, Silver e Gold, governança com Unity Catalog e consumo analítico por meio de AI/BI e Genie Spaces. Essa escolha permite reduzir silos, melhorar a confiabilidade dos dados e criar uma base mais escalável para suportar a evolução do banco para um cenário multiproduto.

Além da dimensão tecnológica, a proposta também considera a necessidade de estruturar minimamente o time de dados, com liderança formal e responsabilidades mais claras entre plataforma, engenharia, governança e analytics. Dessa forma, a solução não se limita à adoção de ferramentas, mas estabelece uma base arquitetural e organizacional mais consistente para que o Maria Bank consiga transformar dados em capacidade real de decisão, eficiência operacional e crescimento sustentável.